

به نام خداوند خورشید و ماه
که دل را به دانش خرد داد راه
(حکیم ابولقاسم فردوسی)

این پایان نامه به اساتید زندگی

پدر و مادرم

و به اساتید علم و اخلاق که در طول
تحصیل بیشترین نقش را در زندگی علمی
ام داشته اند

دکتر علیرضا فتوحی

و

دکتر سید محمد مهدی طباطبایی

تقدیم می شود.

امیدوارم این ناقابل را از حقیر پذیرا
باشند

پایان نامه جهت اخذ درجه ی کارشناسی
ارشد آمار ریاضی

عنوان :

تحلیل سیستمهای اندازه گیری کیفی به کمک

مدلهای اثرات تصادفی دوتایی¹

استاد راهنما

دکتر غلامحسین شاهکار

استاد مشاور

دکتر سید محمد مهدی طباطبایی

اساتید داور

دکتر ناصر رضا ارقامی

دکتر ابوالقاسم بزرگنیا

تهیه و تنظیم

وحید پرتوی نیا

قدردانی

من لم یشکر المخلوق، لم یشکر الخالق

خداوند را شاکرم که پس از 4 سال تحصیل در دوره
ی کارشناسی و 2 سال در دوره ی کارشناسی ارشد در
گروه آمار دانشگاه فردوسی در شهر یور 1383 موفق
به کسب افتخار دانش آموختگی در دوره کارشناسی
ارشد آمار ریاضی از دانشگاه فردوسی مشهد
گردیدم.

قبل از آغاز پایان نامه بر خود واجب می دانم از
زحمات دوستانی که به نوعی در این پایان نامه
نقش داشته اند تشکر و قدردانی کنم چرا که اگر
کمک دوستانه ی آنان وجود نداشت این پایان نامه

¹ باعث مباحثات و افتخار بنده است که این پایان نامه پس از دفاع
موفق به اخذ نمره ی کامل (20) شده است.

در سطحی که هم اکنون در دستان شماست بوجود نمی آمد. نقاط قوت این پایان نامه را در مساعدت این عزیزان می دانم و به همین جهت از آنها در ابتدای پایان نامه قدردانی می کنم. امیدوارم خوانندگان عزیز اشکالات احتمالی این پایان نامه را به بزرگواری خود بر حقیر ببخشایند و بنده را از نظرات سازنده ی خود بی نصیب نفرمایند¹.

از دوست عزیزم، همکلاسی دوره ی کارشناسی و کارشناسی ارشد آقای محمد مهدی غلامرضایی متشکرم که در دو فصل اول همکاری بنده در این تحقیق بوده اند و در برنامه نویسی مقایسه ی دو روش تعیینی و راهنمای MSA کمک شایانی داشته اند و در خلال فصول بعدی نیز بنده را از نظرات سازنده ی خود بی نصیب نگذاشته اند.

از استاد عزیز و دوست صمیمی دکتر علیرضا فتوحی (که در کانادا به سر می برند) متشکرم که به عنوان راهنما در گامهای اولیه ی تحقیق مخصوصاً در دو فصل اول حضور فعال داشته اند. تحقیقات دو فصل اول در اتاق شخصی ایشان در دانشکده انجام شده است، از صمیم قلب آرزو دارم در هر جای دنیا که باشند، همواره موفق و پیروز باشند.

از استاد ارجمند دکتر شاهکار متشکرم که در ادامه ی تحقیق انجام شده با دکتر فتوحی استاد راهنمای بنده بوده اند و مخصوصاً در فصول 3 تا 5 از نظرات ارزنده ی شان استفاده کرده ام.

از استاد عزیزم ((دکتر طباطبایی)) که سمت استاد مشاور این پایان نامه را داشته اند ((بسیار)) متشکرم زیرا هر چند استاد راهنمای بنده در این پایان نامه نبوده اند ولی به راستی زمان بیشتری برای این تحقیق با بنده صرف نموده اند. تصمیم گیری به کمک بازه های اطمینان بوت استرپ و اثبات سازگاری روش تعیینی مدیون راهنمایی های ایشان است. به علاوه شبیه سازی ها و برنامه های

¹ <http://vahidpartovinia.tripod.com>
vahidpartovinia@yahoo.com

فصول 3 تا 5 و تایپ تمامی این پایان نامه در اتاق ایشان در دانشکده انجام شده است و در طول قریب به 1 سال بهره های بسیاری از این فداکاری و اعتماد برده ام و حقیقتاً معتقدم بدون لطف بی شائبه ی ایشان، این پایان نامه در این سطح، آماده نمی شد.

از استاد عزیزم دکتر ارقامی متشکرم زیرا هرچند در طول انجام این تحقیق سمت رسمی و اداری در پایان نامه نداشتند ولی همواره از مشاوره ی مفید علمیشان بهره برده ام و مدل اثرات متقابل نتیجه ی این همکاری است. به علاوه بر بنده منت نهادند و زحمت داوری این پایان نامه را نیز متقبل شدند.

از استاد بزرگ آمار ایران، دکتر بزرگنیا متشکرم که پذیرفتند این پایان نامه را داوری کنند. این افتخار شگرف که توانستم تا لحظات پایانی نیز شاگرد کوچک ایشان باشم، هرگز از خاطر نخواهم برد.

از شرکت طلایه گستران کیفیت و مدیران لایق آن، آقایان مهندس صادقیان و مهندس شیخ رودی متشکرم که پس از گذراندن دوره کارشناسی آمار موقعیت کاری ای در صنعت برای بنده در نظر گرفتند. همین موقعیت، جرقه های این پایان نامه را بوجود آورد.

از همکلاسی دوره ی کارشناسی و دوست گرامی خانم محبوبه مبرا متخصص آمار شرکت طلایه گستران به خاطر بحثهای اولیه و مفیدشان در زمینه ی تحلیل سیستمهای اندازه گیری متشکرم.

از کارمندان دلسوز کتابخانه ی پروفیسور فاطمی، خانم ها حسینی، صادقی، آقای داودنژاد و مخصوصاً آقای رسول اتحاد متشکرم که زحمت تهیه ی قریب به 250 مقاله (قریب به 100 تای آنها در پایان نامه بطور مستقیم استفاده شده است) را متحمل شدند و با خشرویی پذیرای بنده بودند و همواره پذیرای دیگر پژوهشگران هستند.

از خواهر بزرگترم راحله دانشجوی کارشناسی ارشد

شیمی تجزیه متشکریم زیرا مقالاتی که در مشهد قابل تهیه نبود از دانشگاه شیراز تهیه می کردند و به سرعت ارسال می فرمودند.

از دوست گرامی آقای مجتبی شاکری دانشجوی کارشناسی ارشد صنایع متشکریم که مقالات کلیدی این تحقیق را از دانشگاه علم و صنعت تهیه کردند و در مدت کمی در اختیارم قرار دادند.

از دکتر داسکالاکیس¹ عضو هیئت علمی گروه آمار زیستی دانشگاه توماس جفرسون متشکریم که وقایع 11 سپتامبر مانع از این نشد علم دوستی ایشان تضعیف شود. ایشان تمامی تحقیقات خود را در زمینه ی آماره ی کاپا مخصوصاً یادداشتها و ماکروی نوشته شده در SAS که توسط خودشان تهیه شده بود بدون هیچگونه چشمداشتی در اختیارم قرار دادند.

از دانشجوی دکتری بیومتری در دانمارک آقای مهدی شریعتی متشکریم که جزوه ی درسی پروفسور سورنسن² را در اختیارم قرار دادند و مروری بر BIC نتیجه ی این سخاوت است، همینجا از پروفسور سورنسن نیز متشکریم که بسیار زیبا مطلب را باز کرده بودند.

از پروفسور دیویسن³ استاد برجسته ی دانشگاه EPFL و آمار جهان متشکریم زیرا ایده ی P-مقدار تجربی مدیون کمک ایشان است.

از استاد گروه ریاضی خانم دکتر توتونیان متشکریم که همواره با روی گشاده پذیرای سئوالات حقیر در موضوع تقریب عددی انتگرالها بودند. منابع مفیدی که ایشان در زمینه ی تربیع گاوس-هرمیتی به بنده معرفی کردند، فهم این مفهوم را بسیار ساده نمود.

از دکتر صابری عضو هیئت علمی گروه ریاضی که علاوه بر تبدیلات انتگرالی، در آمار نیز صاحب نظر هستند و واژه ی تربیع را به جای Quadrature به

¹ Constantine Daskalakis

² Daniel Sorensen

³ Anthony Davison

حقیر پیشنهاد دادند، متشکرم.

از دکتر تقی زاده عضو هیئت علمی گروه ریاضی که قفل نظریه ی بهینه سازی بدون مشتق مخصوصاً روش شبه نیوتن را که اساس ماکزیمم سازی عددی توابع درستنمایی بوده است با دیدی شهودی بر بنده گشودند متشکرم.

از خانم حیدری همکلاسی دوره ی کارشناسی و کارشناسی ارشد و دوست گرامی که زمانهایی را به بحثهای مفید در زمینه ی محك AIC با بنده اختصاص دادند متشکرم.

از خانم رقیه حاجی زاده کارشناس ارشد شهرسازی، خانم شهرزاد اسدی کارشناسی برنامه ریزی شهری و آقای شهاب بهشتی، همکاران بنده در واحد آمار اطلاعات شهرداری مشهد به خاطر همکاری و دوستی خالصانه شان متشکرم

از آقایان حسین باغیشنی و مهدی مودی دانشجویان کارشناسی ارشد آمار ریاضی که در ویرایش علمی و ادبی مقاله ی انگلیسی استخراج شده از پایان نامه کمک کرده اند متشکرم.

از خواهر کوچکترم الهه دانشجوی طراحی به خاطر لطیفه های با ذوقش که شوق ادامه ی تحقیق را در من بیشتر می کرد متشکرم.

از خانم فاطمه روحی دانشجوی کارشناسی آمار به خاطر همراهیشان، از خانم شروین عسگری دانشجوی کارشناسی ارشد آمار ریاضی به خاطر تهیه ی منابعی در اثبات سازگاری آزمونهای نسبت درستنمایی تعمیم یافته و مخصوصاً از خانم سمیه باصری دانشجوی کارشناسی آمار به خاطر تاثیرشان متشکرم.

از خانم سحر حسینیان دانشجوی دکتری آمار دانشگاه EPFL به خاطر تشویقشان به ادامه تحصیل در سوئیس متشکرم.

از دکتر فتوحی، دکتر طباطبایی، دکتر شاهکار، دکتر ارقامی و دکتر بزرگنیا که با توصیه نامه های مثبت خود، زمینه ی رشد آتی را در دانشگاه EPFL برایم فراهم کردند دوباره متشکرم.

از پروفیسور دیویسن که پذیرفتند افتخار شاگردی
ایشان در سوئیس در دوره ی دکتری نصیب حقیر شود
و با فراهم کردن پشتیبانی مالی گام بزرگی در
تسهیل این مهم برداشتند، دوباره متشکرم.
از تك تك اعضاي گروه آمار دانشگاه فردوسی مشهد
که افتخار شاگردیشان را در دوره ی کارشناسی و
کارشناسی ارشد داشته ام، نیز متشکرم.
بیشتر از همه از خانواده ام که در طول يك سال
تحقیق پذیرای مشکلات و متحمل نگرانی ها و تاخیر
های شبانه ام بوده اند متشکرم.

فهرست

فصل 1	مقدمه	11
1 - 1	تاریخچه و مقدمات	11
1 - 2	تعاریف بنیادین	14
1 - 3	تحلیل سیستمهای اندازه گیری	15
فصل 2	تحلیل سیستمهای اندازه گیری کیفی	17
2 - 1	مقدمه	17
2 - 1 - 1	ضرایب همبستگی گسسته و آماره ی کاپا	18
2 - 1 - 2	عدم کفایت آماره ی کاپا به عنوان محک	
	توافق	24
2 - 1 - 3	مراحل تصمیم گیری در روش راهنمای	
	MSA	26
2 - 1 - 4	انتقادهای وارد بر روش راهنمای MSA	29
2 - 2	روش تعیینی	32
2 - 2 - 1	آزمون همسانی بازرشها	32
2 - 2 - 2	آزمون اریبی	35
2 - 2 - 3	آزمون تاثیرپذیری سیستم اندازه گیری	38
2 - 2 - 4	ساختار تصمیم گیری	39
2 - 2 - 5	خاصیت سازگاری	40
2 - 3	مقایسه ی روش تعیینی با روش راهنمای	
	MSA	46
2 - 3 - 1	روش شبیه سازی	46
2 - 3 - 2	نتیجه گیری	55
2 - 3 - 3	پیاده سازی در مثال عملی	58
فصل 3	دیدگاه های مدلبندی	60
3 - 1	مقدمه	60
3 - 2	مدل های مزدوج دوتایی و انتخاب توزیع	
	پیشین	61
3 - 2 - 2	پیشین لاپلاس	62

- 3 - 2 - 3 پیشین مرجع و جفریز 62
- 3 - 2 - 4 بیز تجربی 63
- 3 - 2 - 5 برآورد و استنباط 66
- 3 - 2 - 6 آزمون R&R 69
- 3 - 2 - 7 آزمون تاثیر پذیری 70

3 - 3 روشهای برآورد و استنباط در مدل‌های

خطی تعمیم یافته ی آمیخته 71

- 3 - 3 - 1 مروری بر تاریخچه و پیشرفت‌ها در
مدل‌های خطی تعمیم یافته 71
- 3 - 3 - 2 مدل‌های خطی تعمیم یافته 73
- 3 - 3 - 3 مشکل فراپراشی در مدل‌های خطی تعمیم
یافته 74
- 3 - 3 - 4 مدل‌های خطی آمیخته 75
- 3 - 3 - 5 مدل‌های خطی تعمیم یافته ی آمیخته 77
- 3 - 3 - 6 برآورد در مدل‌های غیر خطی آمیخته 78
- 3 - 3 - 7 بحث‌ها : 84
- 3 - 3 - 8 درونیابی هرمیتی 85
- 3 - 3 - 9 تربیع هرمیتی 89
- 3 - 3 - 10 تربیع گاوسی 90
- 3 - 3 - 11 تربیع گاوس هرمیتی 91

3 - 4 مدل‌بندی با اثرات تصادفی و محاسبه ی

تابع درست‌نمایی حاشیه ای 96

- 3 - 4 - 1 مدل‌بندی اندازه گیری (مدل با اثرات
متقابل) 97
- 3 - 4 - 2 مدل‌بندی تاثیر پذیری (مدل آشیانه ای) 101
- 3 - 4 - 3 مدل آستانه ای دوتایی و تعبیر آن در
تحلیل سیستم‌های اندازه گیری کیفی 102

3 - 5 آزمون R&R در مدل‌های اثرات تصادفی . 104

- 3 - 5 - 2 روش P-مقدار تجربی 106
- 3 - 5 - 3 روش بازه های اطمینان بوت استرپ 107

فصل 4 محک‌های R&R 109

4 - 1 مقدمه 109

- 4 - 1 - 1 محک R&R برای مدل مزدوج 109

4 - 1 - 2 محک R&R برای مدل اثرات متقابل 110

4 - 1 - 3 محک R&R برای مدل آشیانه ای 110

4 - 2 استفاده از محک BIC در مدل‌های اثرات

تصادفی 112

4 - 2 - 1 مروری بر BIC 113

4 - 2 - 2 AIC2 یا BIC؟ 115

4 - 3 استفاده از عامل بیز و BIC در مدل‌های

آمیخته 118

فصل 5 پیاده سازی مدل‌های مختلف بر روی

داده ها 121

5 - 1 مقدمه 121

5 - 2 مدل مزدوج 121

5 - 3 مدل‌بندی با اثرات تصادفی 124

5 - 3 - 1 مدل‌بندی اندازه گیری 124

5 - 3 - 2 مدل‌بندی تاثیر پذیری 128

5 - 4 نتیجه گیری 132

5 - 4 - 1 خلاصه و پیشنهادات 133

فصل 1

مقدمه

1-1 تاریخچه و مقدمات

یکی از پایه های مهم علوم مخصوصاً علوم تجربی اندازه گیری است. در اولین نگاه، اندازه کمیتی پیوسته به نظر می رسد ولی در واقع همواره کمیتی پیوسته نیست و در بسیاری از اوقات یا جنبه ی کمی ندارد و یا جهت سهولت انجام اندازه گیری به کمیتی کیفی تبدیل می گردد. به هر حال اندازه هم جنبه ی کمی و هم جنبه ی کیفی دارد. مسلماً هر اندازه گیری نیاز به ابزار اندازه گیری دارد و هر ابزار اندازه گیری باید خواصی داشته باشد که بتوان آن اندازه گیری را قابل اعتماد و به بیان علمی تر دقیق دانست. وسیله اندازه گیری زمان، طول، جهت و... از قدیم الایام فکر انسانها را به خود مشغول داشته است و پس از گذشت زمانهای بسیار ابزارهای مناسبی برای اندازه گیری این اقلام کشف گردیده است: ساعت، خط کش، قطب نما و... نتایج سالها تفکر و تحقیق در این مقوله ها بوده است.

تحلیل سیستمهای اندازه گیری به فرآیندی اطلاق می شود که بررسی می کند آیا ابزار اندازه گیری دارای خواص مطلوب مورد نظر هست یا خیر. این

موضوع به خصوص در صنعت خودرو سازی مورد توجه قرار گرفته است تا جایی که راهنمای روش تحلیل سیستمهای اندازه گیری در سال 1995 ویرایش دوم و 2002 ویرایش سوم خود را به چاپ رساند. هم اکنون کارخانه های مهم قطعه سازی خودرو مانند Daimler-Chrysler، General Motors و Ford که تهیه کنندگان این راهنما هستند، تمامی زیر مجموعه های خود را ملزم به رعایت این استانداردها و پیاده سازی

تحلیل سیستمهای اندازه گیری برای تمامی مراحل اندازه گیری و تعیین کیفیت جهت دست یافتن به استاندارد QS¹ کردند. هم کنون ایران خودرو و تقریباً تمامی شرکتهای سازنده ی قطعات خودرو ملزم به داشتن استاندارد QS هستند و مطمئناً سیستمهای اندازه گیری آنها توسط راهنمای ذکر شده مورد تحلیل و بررسی قرار می گیرد. در آخرین ویرایش راهنمای تحلیل سیستمهای اندازه گیری (راهنمای MSA²) تغییرات اساسی در روش تحلیل بوجود آمد که این روش را در فصل 2 تشریح می کنیم و سپس نارساییهای آن را مورد بررسی قرار خواهیم داد و روش تعیینی را در 2 - 2 معرفی می کنیم و این دو را به کمک شبیه سازی با هم مقایسه خواهیم کرد. در فصل 3 مدل مزدوج بیزی و در 3 - 4 مدلهای آمیخته را بررسی می کنیم و فصل 5 به پیاده سازی این مدلها اختصاص خواهد یافت و در ضمائم داده ها و برنامه های مهم بکار برده شده در این تحقیق ارائه خواهند گردید. تحلیل سیستمهای اندازه گیری کمی بطور وسیع مورد بررسی قرار گرفته اند و در بسیاری از نرم افزارهای آماری مانند Minitab ، Statistica و SAS نیز پیاده سازی شده اند و خود این موضوع بیانگر اهمیت تحلیل سیستمهای اندازه گیری است ولی تحلیل سیستمهای اندازه گیری کیفی³ در نرم افزارهای همه منظوره ی آماری پیاده سازی نشده اند و تنها در برخی نرم افزارهای تجاری مانند PQ-Systems و JMP که نرم افزارهای مخصوص ابزار کیفیت هستند برنامه نویسی گردیده اند. این موضوع می تواند نشانگر کم بودن تقاضا برای وجود این گونه نرم افزارها یا نو بودن این زمینه ی تحقیقاتی باشد که مورد دوم با توجه به تعداد

¹ Quality System Requirements

² Measurement Systems Analysis Reference Manual

³ Attribute Measurement Systems Analysis

مقالات چاپ شده در این زمینه و با توجه به اینکه از 220 صفحه ي راهنمای MSA تنها 15 صفحه به تحلیل سیستمهای اندازه گیری کیفی اختصاص داده شده است، محتمل تر است.

		
<p>نمودار (1 3) کولیس، سیستم اندازه گیری پیوسته</p>	<p>نمودار (1 2) خط کش و متر، سیستمهای اندازه گیری پیوسته</p>	<p>نمودار (1 4) - ولت متر - آمپر متر اهم متر، سیستم اندازه گیری پیوسته</p>
		
<p>نمودار (1 6) : انواع گیجهای برو- نرو، سیستمهای اندازه گیری گسسته</p>	<p>نمودار (1 5) گیج برو-نرو²، سیستم اندازه گیری گسسته</p>	<p>نمودار (1 4) گیج برو¹، سیستم اندازه گیری گسسته</p>

¹ Go Gage

² Go-NoGo Gage

1- 2 تعاریف بنیادین

مفاهیم پایه ای در تحلیل سیستمهای اندازه گیری به شرح زیر است :

تکرار پذیری¹ : بدین معنا است که تکرار اندازه گیری توسط یک فرد تغییری در نتیجه ی اندازه گیری نداشته باشد یا به بیان دیگر سیستم اندازه گیری مستقل از تکرار توسط فرد باشد.

تکثیر پذیری² : بدین معنا است که تعویض اپراتور اندازه گیرنده تغییری در نتیجه ی اندازه گیری نداشته باشد ، به بیان دیگر سیستم اندازه گیری مستقل از افراد باشد.

اریبی : وقتی به طور متوسط ، مقدار اندازه گیری شده با مقدار واقعی برابر نباشد می گوییم سیستم اریب است . در حقیقت اگر μ_i اندازه ی واقعی قطعه و M_i متغیر تصادفی اندازه گیری آن توسط سیستم اندازه گیری باشد ، $E(M_i) \neq \mu_i$.

خطی بودن (خطیت)³ : زمانی که اندازه گیری ها با تغییر اندازه ی واقعی قطعه روند خطی داشته باشد می گوییم سیستم خطی است.

به سیستمهای اندازه گیری که دارای خاصیت 1 و 2 باشند ، سیستمهای اندازه گیری R&R گفته می شود و به سیستم اندازه گیری که تمامی خواص را دارا باشد ، سیستم اندازه گیری قابل⁴ اطلاق می گردد . در تحلیل سیستمهای اندازه گیری کمی ، تمامی تعاریف فوق به کمک معیار های کمی قابل بررسی اند، این در حالی است که برای حالت کیفی این فقدان محسوس است. محکهای برای R&R بودن سیستم اندازه گیری به خصوص مد نظر است که متاسفانه در راهنمای MSA تعریف نشده اند ولی خواهیم دید با

¹ Repeatability

² Reproducibility

³ Linearity

⁴ Capable

دیدگاه مدلبندی می توان این موضوع را مرتفع کرد و معیارهای مناسبی برای میزان R&R بودن سیستم اندازه گیری کیفی و قابلیت سیستم و همچنین روشی مناسب برای رد یا قبول سیستم اندازه گیری یافت.

1-3 تحلیل سیستمهای اندازه گیری

همانطور که اشاره شد در این پایان نامه تنها سیستمهای اندازه گیری کیفی دو حالت بررسی می شوند ولی تمام مسائل مطرح شده با کمی تأمل به وضعیتهای بیش از دو حالت نیز قابل تعمیم است. تمامی سیستمهای کنترل فرآیند آماری¹ یا سیستمهای کنترل کیفیت آماری² (چه کمی و چه کیفی) بر اساس اندازه گیری ها بنا شده اند که یکی از فرضیات پیاده سازی این قبیل سیستمها آن است که تغییرات مشاهده شده مربوط به فرآیند تولید قطعه باشد نه سیستم اندازه گیری آن. این موضوع روشن می کند که تحلیل سیستم اندازه گیری باید قبل از پیاده سازی سیستم کنترل فرآیند یا سیستم کنترل کیفیت باشد، به علاوه زمانی که قرار است روی سیستم اندازه گیری، یک سیستم کنترل فرآیند یا یک سیستم کنترل کیفیت آماری پیاده سازی شود، لازم است سیستم اندازه گیری از دقت بالایی برخوردار باشد. این دیدگاه نشان می دهد اهمیت تحلیل سیستمهای اندازه گیری به اندازه ی پیاده سازی یک سیستم کنترلی مهم است. در مورد اهمیت تحلیل سیستمهای اندازه گیری کیفی باید اذعان کرد که با توجه به سهولت و سرعت به کار بری این قبیل سیستمها حداقل به اندازه ی سیستمهای اندازه گیری کمی مهم است و شاید به این علت کمتر مورد توجه قرار گرفته است که تحلیل سیستمهای اندازه گیری خود نیازمند داشتن پیش

¹ Statistical Process Control

² Statistical Quality Control

زمینه ی کافی در علم آمار است که کمتر افرادی
که در این زمینه فعالیت می کنند دارای این پیش
زمینه ها هستند.

فصل 2

تحليل سیستمهای اندازه گیری کیفی

2- 1- مقدمه

کتاب فارسی نوشته شده در زمینه ی تحلیل سیستم های اندازه گیری محدود است و به جز رضا مهربان (1377) نشر پیکان ((تجزیه و تحلیل سیستمهای اندازه گیری ، کنترل و صلاحیت ابزار دقیق)) که در این زمینه تالیف شده است ، بقیه ی کتابها ترجمه های کتاب راهنمای MSA¹ هستند که اکثراً به صورت جزوه یا کتاب در دسترس هستند.

روش راهنمای MSA ویرایش دوم (سال 1995) که در کتاب دکتر مهربان نیز توضیح داده شده است در ویرایش سوم (سال 2002) به کلی تغییر یافته است. در این پایان نامه تنها روش آماری ارائه شده در ویرایش سوم مورد نقد و بررسی قرار می گیرد.

راهنمای MSA، مراحل زیر را جهت پذیرش یا رد سیستم اندازه گیری پیشنهاد می دهد :

بررسی توافق² بازرسان با همدیگر به کمک آماره ی کاپا³

بررسی توافق هر بازرس با وضعیت واقعی قطعه به کمک آماره ی کاپا

بررسی امتیاز⁴ بازرسان

بررسی تاثیرپذیری⁵ سیستم اندازه گیری

با توجه به اینکه تمامی توافقات به کمک آماره ی کاپا انجام می پذیرد در بخش بعد به بررسی تفصیلی آماره ی کاپا و ضرایب همبستگی گسسته می

¹ Measurement Systems Analysis

² Agreement

³ Kappa Statistic

⁴ Score

⁵ Effectiveness

پردازیم و مفاهیم پایه ای آن را مرور می کنیم.

2- 1- ضرایب همبستگی گسسته و آماره ی کاپا

فرض کنید علاقمند به بررسی هماهنگی در تصمیم گیری دو بازرس در مورد قطعات خراب و درست هستیم ، اولین چیزی که برای بررسی این توافق به ذهن می رسد ، تشکیل یک جدول توافقی است. به عنوان مثال برای بررسی نظریات دو بازرس 1 و 2 و قضاوت در مورد درست یا خراب بودن تعدادی اقلام خواهیم داشت :

		بازرس 1		
بازرس 2		درست	خراب	جمع
	درست	A	B	B ₁
	خراب	C	D	B ₂
	جمع	A ₁	A ₂	N

مسلماً به هر اندازه که B و C اعداد کمتر و به طور معادل فراوانی های روی قطر اصلی اعداد بزرگتری باشند، توافق بین دو بازرس بیشتر است که N تعداد کل قطعات هستند.

یک معیار توافق منطقی به صورت $ICC = \frac{A+D}{N}$ ¹ تعریف

می شود. بدیهی است که $ICC \leq 1$ و بزرگ بودن ICC نمایانگر بیشتر بودن توافق است و صفر بودن آن نشانگر عدم توافق خواهد بود.

مثال زیر روشن کننده ی این موضوع است که محک ICC محک مناسبی برای تشخیص توافق نیست :

		بازرس 1		
بازرس 2		درست	خراب	جمع
	درست	25	25	50
	خراب	25	25	50
	جمع	50	50	100

¹ Intuitive Correlation Coefficient

در نگاه اول به نظر می آید با توجه به اینکه $ICC=0.5$ است ، دو بازرس در 50 درصد از حالات با هم توافق دارند . این در حالی است که واقعاً توافقی بین این دو بازرس وجود ندارد و عدد 0.5 گمراه کننده می نماید . در حقیقت دو بازرس کاملاً روی قطعات به طور تصادفی تصمیم می گیرند . برای از بین بردن اینچنین اشکالات ، معیار توافق بر اساس تصادف بیان می شود . یکی از این محکها ، آماره ی پیرسن است .

$$\chi^2 = \sum_i \sum_j \frac{(O_{i,j} - E_{i,j})^2}{E_{i,j}}, \chi^2 \geq 0 \quad (4 \ 2)$$

که $O_{i,j}$ فراوانی مشاهده شده و $E_{i,j}$ فراوانی برآورد شده تحت فرض تصادفی بودن است در حقیقت اگر دو بازرس 1 و 2 مستقل از هم تصمیم گیری کنند ، سیستم اندازه گیری نا مناسب است . هر چه χ^2 عدد بزرگتری باشد بیانگر توافق یا عدم توافق بیشتر در مقایسه با تصمیم بر اساس تصادف است . بطور مشابه همبستگی اسمی کرامر بر اساس آماره ی پیرسن به صورت زیر تعریف می شود .

$$\phi = \sqrt{\frac{\chi^2}{N}} \quad 0 \leq \phi \leq 1 \quad (2 \ 2)$$

این محک شبیه ICC کران پایین صفر و کران بالای یک دارد ، زمانی صفر می شود که توافق کاملاً بر اساس تصادف باشد و زمانی 1 می گردد که توافق یا عدم توافق حداکثر ممکن با تصادف فاصله بگیرد . ضریب همبستگی مشابه دیگری توسط کندال و استوارت¹ در سال 1979 به نام ضریب توافق² به صورت زیر تعریف شده است :

$$P = \sqrt{\frac{\chi^2}{\chi^2 + N}} \quad 0 \leq P \leq 1 \quad (3 \ 2)$$

¹ Kendall and Stuart

² Contingency Coefficient

فلیس¹ در سال 1981 تحت عنوان اندازه ی فی²، معیار دیگری را به صورت زیر معرفی کرده است:

$$\varphi = \frac{A \times D - B \times C}{A_1 \times B_1 \times A_2 \times B_2} \quad -1 \leq \varphi \leq 1 \quad (4 \ 2)$$

اسکات³ در سال 1955 نیز معیار دیگری با نام اندازه ی پی⁴ تعریف کرده است:

$$\pi = \frac{P_O - P_E}{1 - p_E} \quad (5 \ 2)$$

$$p_O = \frac{A}{N} \quad p_E = \left(\frac{A_1 + B_1}{2N} \right)^2 + \left(\frac{A_2 + B_2}{2N} \right)^2$$

آنچه در راهنمای MSA مورد استفاده قرار گرفته است محک کاپا است که توسط کوهن⁵ در سال 1960 به صورت زیر تعریف شده است:

$$\kappa = \frac{p_O - p_E}{1 - p_E} \quad -1 \leq \kappa \leq 1 \quad (6 \ 2)$$

اندازه ی فی، پی و کاپا دارای خواصی هستند که آنها را از دیگر معیارها مجزا می کند: همانند χ^2 و ضریب همبستگی اسمی کرامر⁶، زمانی صفر می شوند که توافق بر اساس تصادف باشد به علاوه زمانی به کران بالای خود نزدیک می شوند که توافق از تصادف بیشترین فاصله را داشته باشد و زمانی به کران پایین خود نزدیک می شوند که عدم توافق از تصادف حداکثر فاصله را بگیرد. در حقیقت سه معیار اخیر برای عدم توافق (بر اساس تصادف) مقدار منفی و برای توافق (بر اساس تصادف) مقدار مثبت ارائه می کنند.

قضیه 1.2 : $\kappa \leq 1$

اثبات :

¹ Fleiss

² Phi Measure

³ Scott

⁴ Pi Measure

⁵ Cohen

⁶ Cramer V Nominal Correlation

$$A \leq N$$

$$\Rightarrow \frac{A}{N} \leq 1$$

$$\Rightarrow \frac{AN - (A+B)(A+C)}{N^2} \leq \frac{N^2 - (A+B)(A+C)}{N^2} \quad (7 \ 2)$$

$$\Rightarrow \frac{\frac{A}{N} - \frac{(A+B)(A+C)}{N^2}}{1 - \frac{(A+B)(A+C)}{N^2}} = \frac{p_o - p_E}{1 - p_E} \leq 1$$

قضیه 2.2 : $\kappa \geq -1$

اثبات :

$$A(B+C+D) + 2D(A+B+C) + (B^2 + C^2 + D^2) \geq 0$$

$$\Rightarrow A(A+B+C+D) + (B^2 + C^2 + D^2 + A^2) +$$

$$(2AB + 2AC + 2AD + 2BC + 2BD + 2CD) \geq 2(A^2 + AC + AB + BC)$$

$$\Rightarrow AN + N^2 - (A+B)(A+C) \geq (A+B)(A+C)$$

$$\Rightarrow AN - (A+B)(A+C) \geq (A+B)(A+C) - N^2$$

$$\Rightarrow \frac{A}{N} - \frac{(A+B)(A+C)}{N^2} \geq \frac{(A+B)(A+C)}{N^2} - 1$$

$$\Rightarrow \frac{\frac{A}{N} - \frac{(A+B)(A+C)}{N^2}}{\frac{(A+B)(A+C)}{N^2} - 1} \geq -1 \quad (8 \ 2)$$

$$\Rightarrow \frac{p_o - p_E}{1 - p_E} \leq -1$$

و اثبات تمام است.

اکنون جهت بررسی عمیق تر خواص معیار کاپا آن را

در چند مثال محاسبه می کنیم :

مثال 1.2 توافق :

		بازرس 1		
		درست	خراب	جمع
بازرس 2	درست	99	0	99
	خراب	0	1	1
	جمع	99	1	100

$$\kappa = 0.99 \quad (9 \ 2)$$

مثال 2.2: عدم توافق

		بازرس 1		
		درست	خراب	جمع
بازرس 2	درست	0	99	99
	خراب	1	0	1
	جمع	1	99	100

$$\kappa = -0.99 \quad (10 \ 2)$$

مثال 3.2: توافق بر اساس تصادف :

		بازرس 1		
		درست	خراب	جمع
بازرس 2	درست	25	25	50
	خراب	25	25	50
	جمع	50	50	100

$$\kappa = 0.00 \quad (14 \ 2)$$

جهت پذیرش توافق لازم است آماره ی کاپا عدد بزرگی باشد ، نظرات در مورد اینکه آماره ی کاپا چقدر بزرگ باشد تا توافق را بین بازرسان بپذیریم متفاوت است، لاندیس و کخ¹ در سال 1977 جدول زیر را پیشنهاد می دهند:

0>	توافق ضعیف
0.2-0	توافق کم
0.4-0.2	توافق متعادل
0.6-0.4	توافق متوسط
0.8-0.6	توافق قوی
1-0.8	توافق تقریباً کامل

راهنمای MSA مقادیر بزرگتر از 0.75 را برای پذیرش توافق قبول می کند. با توجه به اینکه اعتماد به آماره ی کاپا به حجم نمونه بستگی دارد ، شاید بهتر باشد به جای تصمیم با خود آماره ی کاپا آن را آزمون کنیم :

¹ Landis and Koch

$$\begin{cases} H_0: \kappa \geq 0.75 \\ H_1: \kappa < 0.75 \end{cases} \quad (12 \ 2)$$

یا به جای پذیرش توافق ، توافق معنی دار (بر اساس تصادف) را بپذیریم :

$$\begin{cases} H_0: \kappa \geq 0 \\ H_1: \kappa < 0 \end{cases} \quad (13 \ 2)$$

متاسفانه حتی تحت فرضیه H_0 نیز توزیع آماره Y کاپا ناشناخته است.

و جهت آزمون این فرضیه ها راه حل های جایگزین متفاوتی ارائه شده است : فلیس¹ در سال 1981 به عنوان مثال استنباط بر اساس تقریب نرمال را پیشنهاد می دهد، افرن و تیبشیرانی² روشهای بنا شده بر باز نمونه گیری را توصیه می کنند، لاندیس و کخ³ در سال 1977 روش حداقل مربعات تعمیم یافته ، لیانگ و زگر⁴ در سال 1986 روش معادلات برآورد تعمیم یافته، اگریستی⁵ در سال 1990 روشهای بنا شده بر مدلهای لگ خطی ، اگریستی و لنگ⁶ در سال 1993 روشهای مدل دسته های مخفی را پیشنهاد می دهند.

استنباط بر اساس تقریب نرمال تنها برای آزمون فرضیه Y :

$$\begin{cases} H_0: \kappa = 0 \\ H_1: \kappa \neq 0 \end{cases} \quad (14 \ 2)$$

بررسی شده است ، اوریت⁷ در سال 1968 گشتاورهای آماره Y کاپا را توسط خواص توزیع فوق هندسی محاسبه کرده است :

$$k \sim Normal(\kappa, Var(k)) \quad (15 \ 2)$$

¹ Fleiss

² Efron and Tibshirani

³ Landis and Koch

⁴ Liang and Zeger

⁵ Agresti

⁶ Agresti and Lang

⁷ Everitt

$$\text{Var}(k) = V(\kappa, \pi_{i+}, \pi_{+j}, \pi_{ij}) = \frac{-A(1-\kappa)^2 + 2A(1-\kappa)}{N \left(1 - \sum_i \sum_j \pi_{i+} \pi_{+j} \right)^2} \quad (16 \ 2)$$

$$A = \left(1 + \sum_i \sum_j \pi_{i+} \pi_{+j} \right)^2 \quad (17 \ 2)$$

$$\pi_{1+} = \frac{A+B}{N}, \pi_{2+} = \frac{C+D}{N} \quad (18 \ 2)$$

$$\pi_{+1} = \frac{A+C}{N}, \pi_{+2} = \frac{B+D}{N}$$

2- 1- 2 عدم کفایت آماره ی کاپا به عنوان محک توافق

با اینکه محک کاپا خواص مناسب ذکر شده را دارد در همه ی حالات محک مناسبی برای توافق نیست ، حساسیت این محک به فراوانی های حاشیه ای بیشترین مشکل این محک است که به همین جهت در اکثر استنباط ها که در بخش قبل به آن اشاره شد (مخصوصاً استنباط با تقریب نرمال) تعادل تقریبی در فراوانی های حاشیه ای را فرض کرده اند. این عدم کفایت در دو مثال زیر خود را بیشتر نشان می دهد :

مثال 4.2:

		بازرس 1		
		درست	خراب	جمع
باز رس 2	درست	40	9	49
	خراب	6	45	50
	جمع	46	54	100

$$\kappa = 0.32 \quad (19 \ 2)$$

		بازرس 1		
		درست	خراب	جمع
باز رس 2	درست	80	10	90
	خراب	5	5	10

	جمع	85	15	100
--	-----	----	----	-----

$$\kappa = 0.7 \quad (20 \ 2)$$

با توجه به اینکه بحثهاي لازم در مورد محکهاي توافق به اندازه ي کافي در بخش قبل صورت گرفته است ، و با توجه به مفهوم توافق و برابر بودن ICC در هر دو جدول ($ICC=0.85$) انتظار مي رود محک توافق براي اين دو جدول مقادير نزديک به هم باشند در صورتي که آماره ي کاپا براي جدول دوم که عدم تعادل در فراواني حاشيه اي وجود دارد بيش از دو برابر جدول اول است. جدول توافقي زير حساسيت آماره ي کاپا را به فراواني هاي حاشيه اي، روشن تر مي کند:

مثال 5.2 :

		بازرس 1		
		درست	خراب	جمع
بازرس 2	درست	90	1	91
	خراب	8	1	9
	جمع	98	2	100

$$\kappa = 0.154 \quad (24 \ 2)$$

اين در حالي است که $ICC=0.91$ (که معياري براي توافق شهودي است) عدد بزرگي را نشان مي دهد و اين در حالي است که $\kappa=0.154$ نشان دهنده ي توافق بسيار ضعيف است.

اکنون اين سؤال پيش مي آيد که : ((آيا مي توان محک توافقي (بر اساس تصادف) تعريف کرد که نسبت به عدم تعادل فراواني هاي حاشيه اي حساس نباشد و به علاوه همخواني بيشتري با محک توافق شهودي داشته باشد ؟)). گوت¹ در سال 2001 محک AC1 را اخيراً معرفي کرده است که جواب مثبت به اين سؤال است و دلایل برتري اين محک بر محک کاپا در گوت در سال 2002 به تفصيل بررسي شده است.

¹ Gwett

2- 1- 3 مراحل تصمیم گیری در روش راهنمای MSA

چند عامل مهم در تصمیم گیری درباره ی سیستم اندازه گیری کیفی به روش راهنمای MSA نقش اساسی را بازی می کنند

آماره های توافق

امتیاز بازرسان و بازه ی اطمینان آنها

قابلیت سیستم اندازه گیری

مفهوم اول در بخشهای قبل مورد بررسی واقع شده اند در مورد امتیاز و قابلیت در خلال توضیح مراحل تصمیم گیری ، بحث خواهد شد. جهت سادگی توضیحات فرض کنید سه بازرس در سه تکرار و روی 50 قطعه که تعدادی از آنها قطعه ی خراب و تعدادی قطعه ی صحیح است توسط سیستم اندازه گیری گسسته ای تصمیم می گیرند و آنها را به یکی از دو دسته ی درست و خراب نسبت می دهند ولی در هر بار تصمیم گیری نمی دانند روی کدام قطعات چه تصمیمی گرفته اند. داده های مورد استفاده داده هایی است که در راهنمای MSA گزارش شده است که 1 نشان دهنده ی پذیرش قطعه و 0 نشان دهنده ی رد قطعه در مجموع سه تکرار انجام گرفته توسط هر بازرس است، جدول توافق بازرسان و آماره های کاپا به صورت زیر محاسبه شده اند:

		بازرس 1		
باز رس 2		درست	خراب	جمع
	درست	44	3	47
	خراب	6	97	113
	جمع	50	100	150

$$\kappa = 0.863 \quad (22 \quad 2)$$

		بازرس 1		
باز رس 3		درست	خراب	جمع
	درست	43	8	51
	خراب	7	92	99
	جمع	50	100	150

$$\kappa = 0.776 \quad (23 \quad 2)$$

		بازرس 2		
		درست	خراب	جمع
بازرس 3	درست	42	9	51
	خراب	5	94	99
	جمع	47	103	150

$$\kappa = 0.788 \quad (24 \quad 2)$$

این سه جدول توافقی در حقیقت تکثیرپذیری سیستم اندازه گیری را بررسی می کنند . در راهنمای MSA بیان می شود آماره ی کاپا ی بزرگتر از 0.75 برای توافق بین بازرسان کافی است ولی به هر حال امکان دارد همه ی بازرسان در مورد درست بودن یا خراب بودن قطعات توافق داشته باشند و همه نادرست تصمیم بگیرند. بنابراین توافق تک تک بازرسان با وضعیت واقعی قطعه نیز باید مد نظر قرار گیرد و به این منظور سه جدول توافقی دیگر تشکیل می گردد :

		بازرس 1		
		درست	خراب	جمع
وضعیت واقعی	درست	45	3	48
	خراب	5	97	102
	جمع	50	100	150

$$\kappa = 0.879 \quad (25 \quad 2)$$

		بازرس 2		
		درست	خراب	جمع
وضعیت واقعی	درست	45	3	48
	خراب	2	100	102
	جمع	47	103	150

$$\kappa = 0.923 \quad (26 \quad 2)$$

		بازرس 2		
		درست	خراب	جمع
وضعیت واقعی	درست	42	6	48
	خراب	9	93	102

	جمع	51	99	150
--	-----	----	----	-----

$$\kappa = 0.774 \quad (27 \ 2)$$

همانطور که مشاهده می شود، تمامی آماره های کاپا بزرگتر از عدد 0.75 است و توافق تمامی بازرسان با همدیگر و وضعیت واقعی، تایید می شود.

مرحله ی بعد محاسبه ی امتیاز بازرسان و بازه ی اطمینان امتیازهای آنها است.

امتیاز هر بازرس روی هر قطعه عدد 1 یا 0 است: اگر هر بازرس در هر تکرار، قطعه ای را همانند تکرارهای دیگر و درست تشخیص داده بود عدد 1 و در غیر اینصورت عدد 0 می گیرد و امتیاز بازرس میانگین امتیازهای او روی قطعات مختلف است، در حقیقت میزان برابری امتیاز کاربران درجه ی تکرار پذیری سیستم اندازه گیری است. بازه ی اطمینان امتیاز بازرسان هم به کمک تقریب نرمال بدست می آید و انتظار می رود در یک سیستم R&R امتیاز بازرسان نیز با هم همخوانی داشته باشد بدین منظور راهنمای MSA پیشنهاد می دهد که امتیاز هر بازرس باید در بازه ی اطمینان امتیازات بازرسان دیگر قرار بگیرد. نتایج محاسبه ی امتیاز بازرسان به صورت زیر است :

	بازرس 1	بازرس 2	بازرس 3
حد بالا	0.94	0.98	0.91
امتیاز	0.84	0.90	0.80
حد پایین	0.74	0.82	0.69

البته بعضی از جوابهای بدست آمده در این جدول با جوابهای راهنمای MSA متفاوت است، غلط نامه ی راهنمای MSA که در آدرس اینترنتی :

<https://www.carwin.co.uk/qs/english/msaamend.htm>

موجود است محاسبات ما را تایید می کند. بنابراین مرحله ی پایانی بررسی کردن وضعیت امتیاز بازرسان است. همانطور که مشاهده می شود

، امتیاز بازرس 3 (0.80) در بازه اطمینان بازرس 2 قرار نمی گیرد، با توجه به نزدیک بودن امتیاز بازرس 3 به حد پایین بازه ی اطمینان بازرس 2 ، سیستم اندازه گیری مورد قبول واقع می شود ولی پیشنهاد می شود در اولین فرصت تعویض گردد .

در پایان اشاره می شود در راهنمای MSA به معیارهای دیگری مانند تاثیر سیستم اندازه گیری بر بازرسان که نسبت کل تمامی تصمیمهای صحیح بر تعداد کل تصمیم های گرفته شده است برای هر بازرس است نیز تعریف شده است و تاثیر کل سیستم اندازه گیری که تعداد کل تصمیم های گرفته شده است که در تصمیم گیری در قبول یا رد سیستم اندازه گیری ، نقش اساسی را بازی نمی کنند ولی پیشنهاد می شود مقادیر تاثیر پذیری با 0.8 برای قبول سیستم اندازه گیری و 0.9 برای تفکیک سیستمهای اندازه گیری تاثیر پذیر مناسب مورد بررسی واقع شود بدیهی است هر چه مقدار تاثیر پذیری به 1 نزدیک تر باشد ، سیستم اندازه گیری بهتر است. در مجموع قبول یا رد سیستم اندازه گیری نیاز به انجام مراحل متفاوتی دارد که به ترتیب آنها را ذکر می کنیم :

بررسی توافق بازرسان به کمک آماره ی کاپا
 بررسی توافق بازرسان با وضعیت واقعی قطعات به کمک آماره ی کاپا
 بررسی امتیاز بازرسان و محاسبه ی بازه ی اطمینان 95 درصدی آنها
 انتظار می رود تاثیر سیستم اندازه گیری برای سیستمهای اندازه گیری مطلوب بزرگتر از 0.8 باشد و این ادعا به کمک بازه ی اطمینان 95 درصد تاثیر سیستم اندازه گیری قابل بررسی است.

2- 1- 4- انتقادهای وارد بر روش راهنمای MSA

اولین مشکلی که در اجرای روش راهنما به نظر می رسد روشن نبودن پذیرش و یا رد قطعی سیستم

اندازه گيري است.

دومين مشكل استفاده از آماره ي كاپا (توافق با وضعيت واقعي) و بازه اطمینان امتياز بازرسان است ، اگر سيستم اندازه گيري صحيح عمل كند ، هر دو قاعدتاً به يك نتيجه منجر مي شوند حال آنكه راهنما اين موضوع را از دو روش مختلف و از دو دیدگاه مجزا (توافق و امتياز) بررسی کرده است ، اين اضافه كردن مراحل تصميم گيري همانطور كه خواهيم دید خطاي كل نوع اول آزمون سيستم اندازه گيري را افزايش خواهد داد .

سومين مشكل ، استفاده از آماره ي كاپا است. همانطور كه بحث شد آماره ي مناسبی برای توافق مخصوصاً زمانی كه فراواني هاي حاشیه اي نامتعادل هستند ، نیست.

چهارمین مشكل ، عدم كنترل روي خطا هاي تصميم گيري در هر مرحله است .

اگر حتي فرض كنيم در هر مرحله خطاي نوع اول (α) را تحت كنترل قرار دهيم و براي هر مرحله ي آزمون α خطاي نوع اول در نظر بگيريم ، حداكثر 3α خطاي نوع اول در مرحله توافق بازرسان با هم (به كمك آماره ي كاپا) ، حداكثر 3α خطا در مرحله ي توافق بازرسان با وضعيت واقعي ، حداكثر 3α خطا در مرحله ي آزمون به كمك بازه هاي اطمینان امتياز بازرسان خواهيم داشت كه در مجموع حداكثر 9α خطاي نوع اول براي كل آزمون پديد مي آورد.

اين در حالي است كه هيچكدام از خطا ها كنترل نمي شوند و به علاوه حتي اگر بتوان آنها را تحت كنترل قرار داد ، آيا مي توان ادعا كرد اين روش آزمون با زياد كردن حجم نمونه قادر است سيستم اندازه گيري مطلوب را از سيستم اندازه گيري نامطلوب با احتمال مناسبی تميز دهد ؟ شبیه سازی هاي ارائه شده در 2 - 3 نشان مي دهد اين موضوع درست نیست بدین معنا كه این روش آزمون سیستم اندازه گيري با زياد شدن حجم نمونه احتمال تشخيص صحيح سيستمهاي اندازه گيري مطلوب از

نامطلوب بیشتر نمی شود.

پنجمین مشکل ، نامناسب بودن تعریف امتیاز کاربران است: با زیاد کردن تکرارها بر روی قطعات ، سیستم اندازه گیری مطلوب امتیاز صفر برای کاربران نشان خواهند داد.

و ششمین مشکل این است که بر عکس تحلیل سیستمها اندازه گیری کمی ، محکی برای R&R بودن سیستم اندازه گیری تعریف نمی کند.

برای تصحیح این روش شاید به نظر برسد ، بهتر است به جای بررسی توافق بر اساس آماره ی کاپا ، از آماره ی AC1 یا AC2 استفاده کرد و برخی مراحل را تغییرات مختصری داد ، مانند اینکه آزمون فرضیه بر اساس بازه ی اطمینان امتیاز بازرسان را تصحیح کرد و یا تاثیر سیستم اندازه گیری را برای هر بازرس به جای امتیاز آن در نظر گرفت . به هر حال پس از بررسی های اولیه مشخص شد ، بهبود روش تصمیم گیری نیاز به تغییر اساسی در مراحل انجام این روش دارد و به این منظور روش ساده ی دیگری طراحی شد که هر چند تمام مشکلات اشاره شده را حل نکرده است ولی علاوه بر کوتاه بودن و روشن بودن مراحل انجام آن ، دارای خواص مناسب جانبی است.

2- 2 روش تعییني

در تعیین نحوه ی آزمون کردن در روش تعییني سعی شده است شفافیت نحوه پذیرش یا رد سیستم اندازه گیری کیفی کاملاً مشخص باشد و از طرف دیگر بتوان با خطای نوع اول به نسبت پایین در هر مرحله، آزمونی طراحی کرد که علاوه بر خطای نوع اول کم، خواص جانبی مطلوبی داشته باشد و یا به بیان دیگر آزمونی با خطای نوع اول کم و سازگار باشد. در پیشنهاد این روش، طرح آزمایشی ذکر شده در راهنما (3) بازرس با 3 تکرار بر روی 50 قطعه ی (مختلف) مد نظر قرار گرفته است. این روش اساساً بر سه مرحله استوار است:

آزمون همسانی بازرسها

آزمون اریبی سیستم اندازه گیری

آزمون ((ترکیبی)) یا ((جدا)) با توجه به آزمون اریبی

در تمام این مراحل سعی شده است از آزمونهای سازگار استفاده شود و ساختار تصمیم گیری طوری طراحی شده است که تصمیم گیری نهایی، سازگار باشد.

2- 2- 1 آزمون همسانی بازرسها

می توان جدول زیر را در مورد فراوانیهای مشاهده شده تنظیم کرد که در آن به طور مثال $O_{F,11}$ نشانگر تعداد قطعات خرابی است که در توسط بازرس اول بار در اولین بازرسی به درستی به دسته های درست و خراب نسبت داده شده اند. برای هر بار بازرسی انجام شده توسط هر بازرس یک ستون جداگانه در نظر گرفته شده است:

نتایج اجراهای مختلف برای هر بازرس					
بازرس سوم در اجرای سوم	...	بازرس اول در اجرای دوم	بازرس اول در اجرای اول	بازرسان در اجراهای مختلف تعداد قطعات	قطعات
$O_{F,33}$...	$O_{F,12}$	$O_{F,11}$	n_F	خراب
$O_{C,33}$...	$O_{C,12}$	$O_{C,11}$	n_C	سالم
$O_{E,33} = n - O_{F,33} - O_{C,33}$		$O_{E,12} = n - O_{F,12} - O_{C,12}$	$O_{E,11} = n - O_{F,11} - O_{C,11}$	0	خطا
n	...	n	n	n	جمع

بنابراین فراوانی های مشاهده شده $(O_{F,ij}, O_{C,ij}, O_{E,ij})$ آماره های بسنده ی متغیر های تصادفی $(X_{F,ij,1}, X_{C,ij,1}, X_{E,ij,1}), (X_{F,ij,2}, X_{C,ij,2}, X_{E,ij,2}), \dots, (X_{F,ij,n}, X_{C,ij,n}, X_{E,ij,n})$ (28 2)

هستند که هر کدام، مستقلاً دارای توزیع سه جمله ای با پارامترهای مستقل خطی $(\theta_{F,ij}, \theta_{C,ij})$ اند و آزمون همسانی بازرسها بدین معنا که ((آیا بازرسها در تکرارهای مختلف مانند یکدیگر و تکرارهای قبل خود قطعات درست را از قطعات خراب تشخیص می دهند)) معادل آزمون فرضیه ی :

$$\begin{cases} H_0 : (\theta_{F,ij}, \theta_{C,ij}) = (\theta_{F,i'j'}, \theta_{C,i'j'}) \\ H_1 : (\theta_{F,ij}, \theta_{C,ij}) \neq (\theta_{F,i'j'}, \theta_{C,i'j'}) \end{cases} \quad (29 \ 2)$$

با فرض اینکه زوجهای $(O_{F,ij}, O_{C,ij}, O_{E,ij})$ از هم مستقل اند یعنی بازرسان در تکرارهای مختلف خود مستقل از هم تصمیم می گیرند، می توان فرضیه ی فوق را توسط آزمون نسبت درستنمایی تعمیم یافته آزمون کرد:

قضیه : آماره ی درستنمایی آزمون فرضیه ی

$$\begin{cases} H_0 : (\theta_{F,ij}, \theta_{C,ij}) = (\theta_{F,i'j'}, \theta_{C,i'j'}) \\ H_1 : (\theta_{F,ij}, \theta_{C,ij}) \neq (\theta_{F,i'j'}, \theta_{C,i'j'}) \end{cases} \quad (30 \ 2)$$

به صورت :

$$G^2 = -2 \log \frac{\sup_{\Omega_0} L}{\sup_{\Omega_1} L}$$

$$= 2 \sum_{i=1}^3 \sum_{j=1}^3 \left(O_{F,ij} (\log(O_{F,ij}) - \log(n\hat{\theta}_{F,ij})) + O_{C,ij} (\log(O_{C,ij}) - \log(n\hat{\theta}_{C,ij})) + O_{E,ij} (\log(O_{E,ij}) - \log(n\hat{\theta}_{E,ij})) \right)$$

اثبات این موضوع به علت حجم بودن ارائه نشده است ولی در اکثر کتب چند متغیره ی گسسته موجود است اندرسن¹ در سال 1991 با فرض اینکه تحت فرضیه H_0 ، پارامترها در مرز نباشند یعنی $0 < \theta_C < 1$ ، $0 < \theta_F < 1$ و $0 < \theta_C + \theta_F < 1$ ، آماره ی $-2 \log(LR)$ به طور مجانبی دارای توزیع کی دو با 16 درجه ی آزادی است، اثبات این موضوع در ویلکس² در سال 1963 به تفصیل آمده است. آماره ی پیرسن این آزمون، فرم زیر است که مشابه آماره ی G^2 دارای توزیع تقریبی کی-دو با 16 درجه آزادی است.

$$\chi^2 = \sum_{i=1}^3 \sum_{j=1}^3 \left(\frac{(O_{F,ij} - n\hat{\theta}_{0F})^2}{n\hat{\theta}_{0F}} + \frac{(O_{C,ij} - n\hat{\theta}_{0C})^2}{n\hat{\theta}_{0C}} + \frac{(O_{E,ij} - n\hat{\theta}_{0E})^2}{n\hat{\theta}_{0E}} \right) \quad (2 \ 34)$$

اثبات اینکه آماره ی پیرسن دارای توزیع χ^2_{16} است با توجه به این حقیقت که $|\chi^2 - G^2| \xrightarrow{P} 0$ (مراجعه کنید به اندرسن)، کار ساده ای است :

لم 1: اگر $X_n \xrightarrow{D} X$ و $Y_n \xrightarrow{D} 0$ آنگاه $X_n + Y_n \xrightarrow{D} X$ Chung (1974)

لم 2: اگر $X_n \xrightarrow{P} X$ آنگاه $X_n \xrightarrow{D} X$ Chung (1974)
قضیه 1.3 نشان دهید $\chi^2 \sim \chi^2_{16}$:

اثبات: چون $|\chi_n^2 - G_n^2| \xrightarrow{P} 0$ پس $\chi_n^2 - G_n^2 \xrightarrow{P} 0$ ، از طرفی می دانیم $G_n^2 \xrightarrow{D} \chi_{16}^2$ ،

بنابراین $\chi_n^2 - G_n^2 + G_n^2 \xrightarrow{D} \chi_{16}^2$ و اثبات تمام است.

در واقع این دو آماره، برابری فراوانی قضاوت‌های درست را برای بازرسان در هر اجرا به طور

¹ Andersen

² Wilks

جداگانه در مورد قطعات سالم و خراب مورد آزمون قرار می دهند.

اگر آماره $\chi^2_{16,1-\alpha_1}$ بیشتر شود، فرضیه $1-\alpha$ توزیع کی دو ($\chi^2_{16,1-\alpha_1}$) بیشتر شود، فرضیه $1-\alpha$ توزیع کی دو عدم وجود تفاوت بین قضاوت های بازرسان در هر اجرا است، رد می کنیم. در این صورت سیستم اندازه گیری مورد بحث بی اعتبار خواهد بود.

همچنین P -مقدار آزمون نیز به صورت تقریبی با استفاده از توزیع کی-دو قابل محاسبه است.

دو آماره G^2 و χ^2 ، تفاوت اساسی با هم ندارند و در اکثر مواقع به نتایج یکسانی منجر می شوند. در شرایطی نیز که تفاوتی بین دو آزمون وجود دارد، ترجیحاً از آماره آزمون پیرسن استفاده می کنیم، چرا که نسبت به آماره درستنمایی همگرایی سریعتری به توزیع کی دو دارد کرسی و رید¹ در 1963. همگرایی توزیع آماره پیرسن به توزیع کی دو در شرایطی که تعداد مشاهدات کمتر از پنج برابر تعداد خانه ها باشد ضعیف است (مراجعه کنید به اگریستی² 1996). البته با توجه به حجم نمونه (50 قطعه)، این حالت در شرایط آزمایشی طراحی شده توسط راهنمای MSA پیش نخواهد آمد. بنابراین می توان از آماره درستنمایی نیز استفاده کرد.

2- 2- 2 آزمون اریبی

آزمون اریبی در حقیقت بیان می کند که آیا سیستم اندازه گیری برای قطعات خراب به همان خوبی قطعات صحیح تصمیم می گیرد یا خیر. در حقیقت اریبی سیستم اندازه گیری در بعضی مواقع خاصیت نامناسب به حساب نمی آید مخصوصاً زمانی که اندازه گیری تنها برای تشخیص قطعات خراب (یا درست) طراحی شده باشد. در این مرحله علاوه بر تعیین اریب بودن سیستم اندازه گیری، کارایی

¹ Cressie and Read

² Agresti

آزمون کلي نیز افزایش پیدا می کند.
در این مرحله نیز از آزمون نسبت درستنمایی
تعمیم یافته استفاده می کنیم.
اگر θ_C را احتمال تشخیص صحیح برای قطعات درست و
 θ_F را احتمال تشخیص صحیح برای قطعات خراب در

نظر بگیریم ، داریم
 $O_C \sim \text{Bin}(N_C, \theta_C)$ و مستقلاً $O_F \sim \text{Bin}(N_F, \theta_F)$ است که

تعداد تصمیم گیری های صحیح کاربران در
 $N_C = 9 \times n_C$ آزمایش روی قطعات درست و O_F تعداد تصمیم
گیری های صحیح کاربران بر روی $N_F = 9 \times n_F$ آزمایش
بر روی قطعات خراب است.
علاقتمندیم آزمون کنیم :

$$\begin{cases} H_0: \theta_C = \theta_F \\ H_1: \theta_C \neq \theta_F \end{cases} \quad (32 \ 2)$$

برای انجام این آزمون از آزمون تقریب نرمال به
صورت زیر استفاده می کنیم :

اگر $\hat{\theta}_{1C}$ نسبت تصمیم های صحیح کاربران برای قطعات
درست و $\hat{\theta}_{1F}$ نسبت تصمیم های صحیح کاربران برای
قطعات خراب باشد ، مشخص است که $\hat{\theta}_{1C}$ و $\hat{\theta}_{1F}$
برآوردهای درستنمایی ماکزیمم θ_C و θ_F تحت
فرضیه H_1 و $\hat{\theta}_G$ برآوردهای درستنمایی تحت فرضیه
 H_0 آنگاه به کمک آماره ی آزمون زیر

$$Z_1 = \frac{\hat{\theta}_{1C} - \hat{\theta}_{1F}}{\sqrt{\hat{\theta}_G \left(1 - \hat{\theta}_G\right) \left(\frac{1}{9 \times n_C} + \frac{1}{9 \times n_F}\right)}} \quad (33 \ 2)$$

$$\hat{\theta}_G = \frac{N_C \hat{\theta}_{1C} + N_F \hat{\theta}_{1F}}{N_C + N_F} = \frac{n_C \hat{\theta}_{1C} + n_F \hat{\theta}_{1F}}{n_C + n_F} \quad (34 \ 2)$$

فرضیه ی H_0 را رد می کنیم اگر $Z_1 > Z_{1-\alpha_2/2}$ یا
 $Z_1 < Z_{\alpha_2/2}$ یا بطور معادل $Z_1^2 > \chi_{1,1-\alpha}^2$ که $Z_{1-\alpha_2/2}$ و $\chi_{1,1-\alpha}^2$
به ترتیب چندهای توزیع نرمال و توزیع کی دو با
یک درجه ی آزادی اند.
قضیه 2.3: آماره ی آزمون Z_1^2 آماره ی پیرسن آزمون
نسبت درستنمایی تعمیم یافته برای آزمون فرضیه ی
مربوطه است.

اثبات : بنابر تعریف آماره ی پیرسن داریم :

$$\chi^2 = \frac{(O_C - N_C \hat{\theta}_G)^2}{N_C \hat{\theta}_G} + \frac{((N_C - O_C) - N_C(1 - \hat{\theta}_G))^2}{N_C(1 - \hat{\theta}_G)} + \frac{(O_F - N_F \hat{\theta}_G)^2}{N_F \hat{\theta}_G} + \frac{((N_F - O_F) - N_F(1 - \hat{\theta}_G))^2}{N_F(1 - \hat{\theta}_G)}$$

با ساده کردن جملات داریم :

$$= \frac{(O_C - N_C \hat{\theta}_G)^2}{N_C \hat{\theta}_G} + \frac{(N_C \hat{\theta}_G - O_C)^2}{N_C(1 - \hat{\theta}_G)} + \frac{(O_F - N_F \hat{\theta}_G)^2}{N_F \hat{\theta}_G} + \frac{(N_F \hat{\theta}_G - O_F)^2}{N_F(1 - \hat{\theta}_G)} \quad (35 \ 2)$$

با گرفتن مخرج مشترک داریم :

$$= \frac{N_F(1 - \hat{\theta}_G)(O_C - N_C \hat{\theta}_G)^2 + N_F \hat{\theta}_G(N_C \hat{\theta}_G - O_C)^2 + N_C(1 - \hat{\theta}_G)(O_F - N_F \hat{\theta}_G)^2 + N_C \hat{\theta}_G(N_F \hat{\theta}_G - O_F)^2}{N_C N_F \hat{\theta}_G(1 - \hat{\theta}_G)}$$

با بسط توان دوم های صورت داریم :

$$= \frac{\left\{ (N_F - N_F \hat{\theta}_G)(O_C^2 + N_C^2 \hat{\theta}_G^2 - 2N_C O_C \hat{\theta}_G) + N_F \hat{\theta}_G(N_C^2 \hat{\theta}_G^2 + O_C^2 - 2N_C O_C \hat{\theta}_G) \right\} + \left\{ (N_C - N_C \hat{\theta}_G)(O_F^2 + N_F^2 \hat{\theta}_G^2 - 2N_F O_F \hat{\theta}_G) + N_C \hat{\theta}_G(N_F^2 \hat{\theta}_G^2 + O_F^2 - 2N_F O_F \hat{\theta}_G) \right\}}{N_C N_F \hat{\theta}_G(1 - \hat{\theta}_G)}$$

پس از ساده کردن و حذف بسیاری از جملات داریم :

$$= \frac{\hat{\theta}_G^2(N_C^2 N_F + N_C N_F^2) + \hat{\theta}_G(-2N_C N_F O_C - 2N_C N_F O_F) + N_F O_C^2 + N_C O_F^2}{N_C N_F \hat{\theta}_G(1 - \hat{\theta}_G)} \quad (36 \ 2)$$

با توجه به اینکه :

$$\hat{\theta}_G = \frac{N_C \hat{\theta}_C + N_F \hat{\theta}_F}{N_C + N_F} = \frac{O_C + O_F}{N_C + N_F} \quad (37 \ 2)$$

$$\rightarrow \hat{\theta}_G^2 = \left(\frac{O_C + O_F}{N_C + N_F} \right)^2 = \frac{(O_C^2 + O_F^2 + 2O_C O_F)}{(N_C + N_F)^2}$$

بنابراین داریم :

$$= \frac{(O_C^2 + O_F^2 + 2O_C O_F - 2O_C^2 - 2O_F^2 - 4O_C O_F + O_C^2 + O_F^2 + \frac{N_C}{N_F} O_F^2 + \frac{N_F}{N_C} O_C^2)}{N_C N_F (N_C + N_F) \hat{\theta}_G(1 - \hat{\theta}_G)} \quad (38 \ 2)$$

$$= \frac{\frac{N_C}{N_F} O_F^2 + \frac{N_F}{N_C} O_C^2 - 2O_C O_F}{\hat{\theta}_G(1 - \hat{\theta}_G)(N_C + N_F)} = \frac{\frac{1}{N_F^2} O_F^2 + \frac{1}{N_C^2} O_C^2 - \frac{2O_C O_F}{N_C N_F}}{\hat{\theta}_G(1 - \hat{\theta}_G) \left(\frac{N_C + N_F}{N_C N_F} \right)} = \frac{\left(\frac{O_F}{N_F} - \frac{O_C}{N_C} \right)^2}{\hat{\theta}_G(1 - \hat{\theta}_G) \left(\frac{1}{N_C} + \frac{1}{N_F} \right)}$$

$$= \left(\frac{\hat{\theta}_{1C} - \hat{\theta}_{1F}}{\sqrt{\hat{\theta}_G(1-\hat{\theta}_G) \left(\frac{1}{9 \times n_C} + \frac{1}{9 \times n_F} \right)}} \right)^2 \quad (39 \ 2)$$

و اثبات تمام است.

2- 2- 3 آزمون تاثیرپذیری سیستم اندازه گیری

آزمون قابلیت در دو قسمت بررسی می شود : با فرض اریب بودن یا نااریب بودن سیستم اندازه گیری. در ابتدا فرض می کنیم سیستم اندازه گیری یک سیستم نااریب باشد ، در حقیقت در بخش قبل آزمون فرضیه ی

$$\begin{cases} H_0 : \theta_C = \theta_F \\ H_1 : \theta_C \neq \theta_F \end{cases} \quad (40 \ 2)$$

رد نشده باشد. در این صورت نمونه های قطعات خراب را با نمونه های قطعات درست با هم ادغام کرد و آزمون :

$$\begin{cases} H_0 : \theta_G \geq \theta_{G0} \\ H_1 : \theta_G < \theta_{G0} \end{cases} \quad (44 \ 2)$$

را انجام داد که θ_G تاثیرپذیری سیستم اندازه گیری بدون در نظر گرفتن وضعیت قطعات است و θ_{G0} حداقل تاثیرپذیری است که سیستم اندازه گیری باید دارا باشد . این حداقل برای سیستم های اندازه گیری قابل قبول 0.8 و برای سیستم های اندازه گیری خوب 0.9 در راهنمای MSA گزارش شده است.

آزمون این فرضیه به کمک آماره ی آزمون زیر انجام می شود :

$$Z_2 = \frac{\hat{\theta}_G - \theta_{G0}}{\sqrt{\hat{\theta}_G(1-\hat{\theta}_G) \frac{1}{9(n_C + n_F)}}} \quad (42 \ 2)$$

فرضیه ی H_0 رد می شود اگر $Z_2 < Z_{1-\alpha_3}$.
و اگر سیستم اندازه گیری یک سیستم اندازه گیری

اریب باشد ، تاثیر پذیری سیستم برای قطعات خراب و درست مانند هم نیست و بنابراین لازم است جداگانه آزمون شود .

برای آزمون فرضیه ی تاثیرپذیری سیستم اندازه گیری بر روی قطعات درست :

$$\begin{cases} H_0: \theta_C > \theta_{C0} \\ H_1: \theta_C \leq \theta_{C0} \end{cases} \quad (43 \ 2)$$

از آماره ی آزمون

$$Z_3 = \frac{\hat{\theta}_{1C} - \theta_{C0}}{\sqrt{\hat{\theta}_{1C}(1-\hat{\theta}_{1C})\frac{1}{9n_C}}} \quad (44 \ 2)$$

فرضیه ی H_0 را رد می کنیم اگر $Z_3 < Z_{1-\alpha_4}$.
برای آزمون فرضیه ی تاثیرپذیری سیستم اندازه گیری بر روی قطعات خراب :

$$\begin{cases} H_0: \theta_F > \theta_{F0} \\ H_1: \theta_F \leq \theta_{F0} \end{cases} \quad (45 \ 2)$$

توسط آماره ی آزمون

$$Z_3 = \frac{\hat{\theta}_{1F} - \theta_{F0}}{\sqrt{\hat{\theta}_{1F}(1-\hat{\theta}_{1F})\frac{1}{9n_F}}} \quad (46 \ 2)$$

استفاده می کنیم و فرضیه ی H_0 را رد می کنیم اگر $Z_4 < Z_{1-\alpha_5}$.

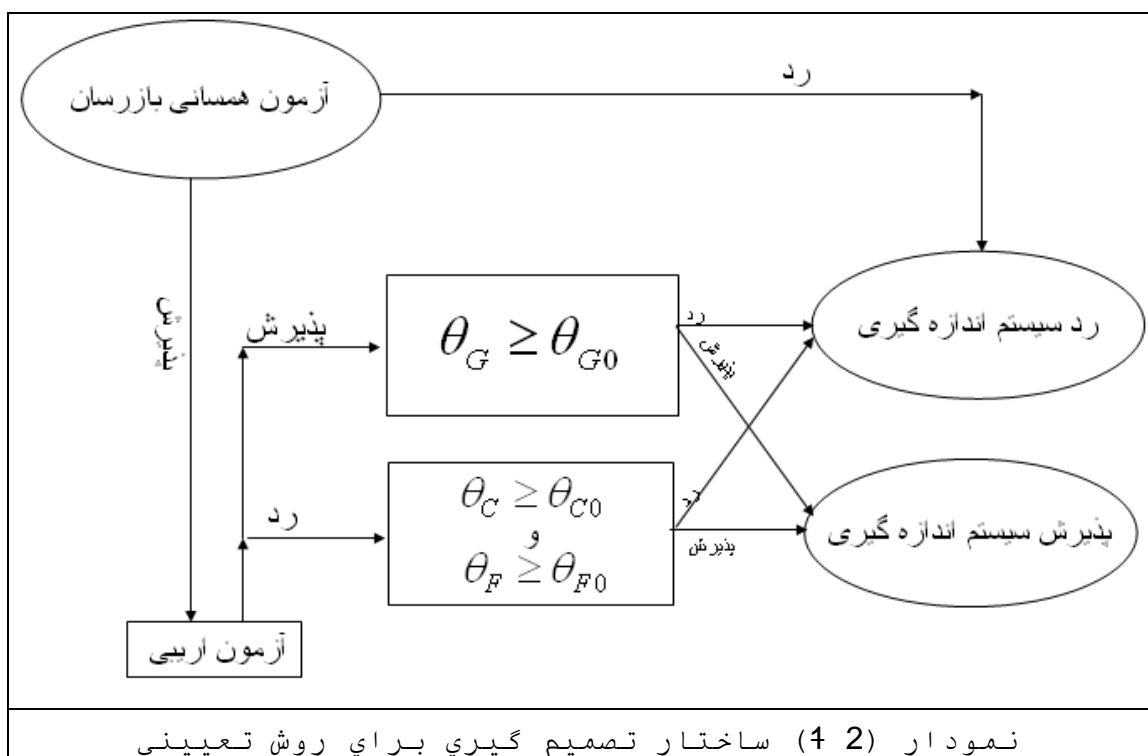
2- 2- 4 ساختار تصمیم گیری

در بخشهای قبل آزمونهای متفاوتی جهت بررسی خواص مناسب یک سیستم اندازه گیری بررسی شد و در این بخش ساختار ترتیب انجام آزمونها را سعی می کنیم طوری بنا کنیم تا این روش ، خواص جانبی مطلوبی داشته باشد .

ساختار تصمیم گیری به صورت زیر طراحی شده است:
آزمون همسانی بازرسها
آزمون اریبی
آزمون تاثیر پذیری

با توجه به مطالب گفته شده در فصل قبل ، نمودار زیر ساختار تصمیم گیری روش تعیینی را دقیقتر

روشن می کند :



2- 2- 5- خاصیت سازگاری

همانطور که در ابتدا اشاره شد طراحی روش تعیینی با دیدگاه ساختن روشی با خواص مجانبی مطلوب انجام شده است.

لذا در ابتدا لازم است تعریف سازگاری آزمون و مفهوم سازگار بودن روش تعیینی روشن گردد.

تعریف :

سازگاری آزمون¹ : اگر Ω_0 فضای پارامتر تحت فرضیه H_0 و Ω_1 فضای پارامتر تحت فرضیه H_1

¹ Test Consistency

باشد، آزمون را سازگار گوئیم اگر $\forall \theta \in \Omega_1$ داشته باشیم :

$$\lim_{n \rightarrow \infty} \pi_n(\theta) = 1 \quad (47 \ 2)$$

که در آن $\pi_n(\theta)$ توان آزمون در حجم نمونه n است.

به بیان ساده تر ، آزمونی سازگار است اگر $\forall \theta \in \Omega_1$ آن آزمون بتواند آن را بطور مجانبی با احتمال 1 رد کند (تصمیم درست را بگیرد).

مشابه همین مفهوم می تواند برای تعیین سیستم اندازه گیری مورد استفاده قرار گیرد:

روش تصمیم گیری در تعیین سیستم اندازه گیری ، سازگار است اگر هر سیستم اندازه گیری غیر قابل قبول ، بطور مجانبی با احتمال 1 آن را رد کند. این تعریف می تواند از جهت دیگری نیز بررسی شود با این مفهوم که هر سیستم اندازه گیری قابل قبول با احتمال 1 پذیرفته شود.

مفهوم اول از لحاظ عملی در حیطه ی تحلیل سیستم های اندازه گیری بیشتر مد نظر است.

برای اینکه نشان دهیم روش تعیینی یک روش سازگار (با مفهوم اول) است لازم است ذکر کنیم تمامی آزمون فرضیه هایی که در روش تعیینی مورد استفاده قرار گرفته اند ، آزمونهای سازگار هستند :

آزمون همسانی بازرسها و آزمون اریبی ، آزمونهای نسبت درستنمایی تصمیم یافته اند که در شرایط Lehman¹ 1986 صدق می کند به علاوه برفکوف² 1998 نشان داده است آزمونهای نسبت درستنمایی تحت شرایط Lehman 1986 بطور مجانبی آزمون بهینه است بدین معنا که بطور مجانبی توزیع پیشینی برای H_0 و H_1 وجود دارد بطوریکه تحت آن توزیع پیشین ، آزمون نسبت درستنمایی یک آزمون بیز باشد. سازگاری آزمونهای یکطرفه از جمله آزمونهای

¹ Lehman

² Brovko

تأثیر پذیری نیز نتیجه ای از لم نیمن پیرسن است (مراجعه کنید به روهاتگی و صالح¹ 2000).

اکنون در پی ثابت کردن سازگاری روش تعیینی با استفاده از سازگاری آزمونهای استفاده شده هستیم.

در حقیقت می خواهیم ثابت کنیم اگر یک سیستم اندازه گیری نادرست باشد (R&R نباشد یا تأثیر پذیری کمی داشته باشد)، آنگاه روش تعیینی با زیاد شدن حجم نمونه ($n_C \rightarrow \infty$ و $n_F \rightarrow \infty$) با احتمال 1 آن را رد می کند.

قضیه 3.3: روش تعیینی یک روش تصمیم گیری سازگار است.

اثبات: اثبات این موضوع به طور مستقیم به علت پیچیدگی مراحل، تقریباً غیر ممکن است، بنابراین در سه مرحله آن را ثابت می کنیم پیشامد نادرست بودن سیستم اندازه گیری را A در نظر بگیرید.

-- در ابتدا فرض کنید سیستم اندازه گیری R&R نباشد یعنی حداقل بتوان بازرسی را پیدا کرد که با احتمال نابرابر در مقایسه با تکرارهای خود (یا در مقایسه با تکرارهای دیگران) بر روی قطعات درست یا خراب تصمیم بگیرد این وضعیت را A_1 بنامید:

یعنی حداقل وجود دارد i, j بطوریکه $(\theta_{F,ij}, \theta_{C,ij}) \neq (\theta_{F,i'j'}, \theta_{C,i'j'})$ و این یعنی در مرحله ی آزمون بازرسیها در فضای Ω_1 واقع هستیم، اگر R را عمل رد کردن سیستم اندازه گیری نشان دهیم

$$\Pr(R | A_1) \geq \Pr(R \text{ in 1st Step} | A_1) = \Pr(\chi_n^2 > \chi_{16,1-\alpha_1}^2 | \theta \in \Omega_1) \quad (48 \ 2)$$

بنابراین با توجه به سازگار بودن آزمون همسانی بازرسان داریم:

$$\lim_{\substack{n_C \rightarrow \infty \\ n_F \rightarrow \infty}} \Pr(R | A_1) \geq \lim_{\substack{n_C \rightarrow \infty \\ n_F \rightarrow \infty}} \Pr(\chi_n^2 > \chi_{16,1-\alpha_1}^2 | \theta \in \Omega_1) = 1 \quad (49 \ 2)$$

-- فرض کنید سیستم اندازه گیری R&R و نااریب باشد، به علاوه فرض کنید چنین سیستم اندازه گیری دارای تأثیر پذیری لازم نیز نباشد، این وضعیت را

A_2 بنامید.

چون سیستم اندازه گیری R&R است ، بنابراین در مرحله ی آزمون همسانی بازرسیها و همچنین در مرحله ی آزمون اریبی در Ω_0 قرار دارد و در بقیه ی مراحل در Ω_1 ، بنابراین:

$$\begin{aligned} \Pr(R | A_2) &= \alpha_1 + (1 - \alpha_1) \Pr(Z_1^2 > \chi_{1,1-\alpha_2}^2 | A_2) \\ &= \alpha_1 + (1 - \alpha_1) [\alpha_2 \Pr(Z_3 < Z_{1-\alpha_4} \text{ or } Z_4 < Z_{1-\alpha_5} | A_2) + (1 - \alpha_2) \Pr(Z_2 < Z_{1-\alpha_3} | A_2)] \\ &\geq \alpha_1 + (1 - \alpha_1) [\alpha_2 \Pr(Z_3 < Z_{1-\alpha_4} | A_2) + (1 - \alpha_2) \Pr(Z_2 < Z_{1-\alpha_3} | A_2)] \end{aligned}$$

علاوه بر این

$$\begin{aligned} &\alpha_1 + (1 - \alpha_1) [\alpha_2 \Pr(Z_3 < Z_{1-\alpha_4} \text{ or } Z_4 < Z_{1-\alpha_5} | A_2) + (1 - \alpha_2) \Pr(Z_2 < Z_{1-\alpha_3} | A_2)] \\ &\geq \alpha_1 + (1 - \alpha_1) [\alpha_2 \Pr(Z_4 < Z_{1-\alpha_5} | A_2) + (1 - \alpha_2) \Pr(Z_2 < Z_{1-\alpha_3} | A_2)] \end{aligned}$$

از طرفی بنا بر فرض، سیستم اندازه گیری تاثیر پذیر نیست بنابراین چون سیستم اندازه گیری نااریب هم هست ، در مرحله ی آزمون به کمک آماره ی Z_3 و Z_4 در فضای Ω_1 قرار دارد و چون این آزمونها همگی سازگارند داریم :

$$\begin{aligned} \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(R | A_2) &\geq \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \left\{ \alpha_1 + (1 - \alpha_1) [\alpha_2 \Pr(Z_3 < Z_{1-\alpha_4} | A_2) + (1 - \alpha_2) \Pr(Z_2 < Z_{1-\alpha_3} | A_2)] \right\} \\ &= \alpha_1 + (1 - \alpha_1) \left[\alpha_2 \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_3 < Z_{1-\alpha_4} | \theta \in \Omega_1) + (1 - \alpha_2) \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_2 < Z_{1-\alpha_3} | \theta \in \Omega_1) \right] \\ &= 1 \end{aligned}$$

-- اکنون فرض کنید سیستم اندازه گیری R&R و اریب باشد. همانطور که اشاره شد اریب بودن سیستم اندازه گیری همواره یک خاصیت نامناسب برای سیستم های اندازه گیری نیست و بنابراین سیستم اندازه گیری اریبی را فرض کنید که تاثیر پذیری آن کمتر از حد استاندارد باشد، چنین وضعیتی را A_3 می نامیم.

بنابراین داریم :

$$\begin{aligned} \Pr(R | A_3) &= \alpha_1 + (1 - \alpha_1) \Pr(Z_1^2 > \chi_{1,1-\alpha_2}^2 | A_3) + \alpha_1 + (1 - \alpha_1) \Pr(Z_1^2 > \chi_{1,1-\alpha_2}^2 | \theta \in \Omega_1) \end{aligned}$$

با توجه به ساختار تصمیم گیری و این نکته که
آزمون اریبی ، آزمون سازگار است داریم :

$$\begin{aligned}
 & \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(R | A_3) \\
 &= \alpha_1 + (1 - \alpha_1) \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_1^2 > \chi_{1,1-\alpha_2}^2 | \theta \in \Omega_1) \\
 &= \alpha_1 + (1 - \alpha_1) \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_1^2 > \chi_{1,1-\alpha_2}^2 | \theta \in \Omega_1) \\
 &= \alpha_1 + (1 - \alpha_1) \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_1^2 > \chi_{1,1-\alpha_2}^2 | \theta \in \Omega_1) \quad (50 \ 2) \\
 &= \alpha_1 + (1 - \alpha_1) \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_1^2 > \chi_{1,1-\alpha_2}^2 | \theta \in \Omega_1) \\
 &= \alpha_1 + (1 - \alpha_1) \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_3 < Z_{\alpha_4} \text{ or } Z_3 < Z_{\alpha_4} | \theta \in \Omega_1) \\
 &\geq \alpha_1 + (1 - \alpha_1) \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_3 < Z_{\alpha_4} | \theta \in \Omega_1) \quad (54 \ 2)
 \end{aligned}$$

و همچنین

$$\begin{aligned}
 & \alpha_1 + (1 - \alpha_1) \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_3 < Z_{\alpha_4} \text{ or } Z_3 < Z_{\alpha_4} | \theta \in \Omega_1) \\
 & \geq \alpha_1 + (1 - \alpha_1) \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_3 < Z_{\alpha_4} | \theta \in \Omega_1) \quad (52 \ 2)
 \end{aligned}$$

و چون بنا بر فرض سیستم تاثیر پذیر استاندارد
نیست حداقل برای یکی از دو وضعیت فوق داریم
 $\lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_3 < Z_{\alpha_4} | \theta \in \Omega_1) = 1$ یا $\lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(Z_3 < Z_{\alpha_4} | \theta \in \Omega_1) = 1$ بنابراین

داریم :

$$\lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(R | A_3) = 1 \quad (53 \ 2)$$

و اکنون که بطور شرطی در تمام شرایط ثابت کردیم
روش تعیینی یک روش سازگار است ، لازم است
سازگاری را در حالت کلی نشان دهیم :
فرض کنید سیستم اندازه گیری ، یک سیستم اندازه
گیری نامناسب است (این وضعیت را با A نشان می
دهیم) ، بنابراین یکی از سه حالت فوق با
احتمالی (نه لزوماً معلوم) برقرار است.
فرض کنید یک سیستم نامناسب که به روش تعیینی
قرار است تحلیل شود با احتمال p_1 در وضعیت A_1 ،

با احتمال p_2 در وضعیت A_2 و با احتمال $p_3 = 1 - p_1 - p_2$ در وضعیت A_3 باشد.

بنابراین :

$$\Pr(R|A) \geq \Pr(R|A \cap A_1)\Pr(A_1|A) + \Pr(R|A \cap A_2)\Pr(A_2|A) + \Pr(R|A \cap A_3)\Pr(A_3|A)$$

از طرفی چون داریم :

$$\begin{cases} A_1 \subseteq A \\ A_2 \subseteq A \\ A_3 \subseteq A \end{cases} \quad (54 \quad 2)$$

می توان آن را به صورت زیر نوشت :

$$\Pr(R|A) \geq \Pr(R|A_1)\Pr(A_1|A) + \Pr(R|A_2)\Pr(A_2|A) + \Pr(R|A_3)\Pr(A_3|A)$$

بنابراین :

$$\lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(R|A) \geq \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(R|A_1)p_1 + \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(R|A_2)p_2 + \lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(R|A_3)p_3$$

و در تمام حالات نشان دادیم حد احتمالات فوق برابر 1 است، بنابراین:

$$\lim_{\substack{n_F \rightarrow \infty \\ n_C \rightarrow \infty}} \Pr(R|A) \geq 1 \quad (55 \quad 2)$$

و اثبات تمام است.

متاسفانه چنین بررسی هایی برای روش راهنمای MSA انجام نشده است و بررسی کردن آن از لحاظ نظری به علت عدم استفاده از روشهای بنا شده بر آزمون های فرضیه کاری دشوار است از طرفی شاید در حجم نمونه ی پایین هر دو روش مانند هم عمل کنند و این بحث که حجم نمونه ی قطعات چقدر باشد تا خواص مجانبی روش تعیینی در حد قابل قبولی برقرار باشد ، خود موضوع جالب و قابل بحثی است. لازم به ذکر است روش تعیینی (طبق ساختار طراحی شده) دارای حداکثر خطای نوع اول برابر با $\max(\alpha_1 + \alpha_2 + \alpha_3, \alpha_1 + \alpha_2 + \alpha_4 + \alpha_5)$ است.

2- 3- مقایسه ی روش تعیینی با روش راهنمای MSA

اگر با طرح آزمایشی پیشنهاد شده در راهنمای MSA تصمیم گیری کنیم ($n_C + n_F = 50$) ، این طرح منجر به انجام 450 آزمایش می گردد و زیاد کردن حجم نمونه به عدد 500 (به عنوان مثال) هر چند ممکن است از لحاظ آماری به نسبت روش راهنمای MSA بسیار دقیقتر باشد ولی نیاز به انجام 4500 آزمایش دارد که از لحاظ عملی به خصوص در صنعت، غیر ممکن است.

بنابراین لازم است تحقیقاتی نیز در مورد مقایسه ی کارایی های دو روش در شرایط مختلف در حجم های نمونه ی مختلف (مخصوصاً $n_C + n_F = 50$) انجام شود. با توجه به اینکه بررسی تفاوت های این دو روش در حجم نمونه های پایین از لحاظ نظری بسیار دشوار است جهت مقایسه از شبیه سازی مونت کارلو استفاده می کنیم.

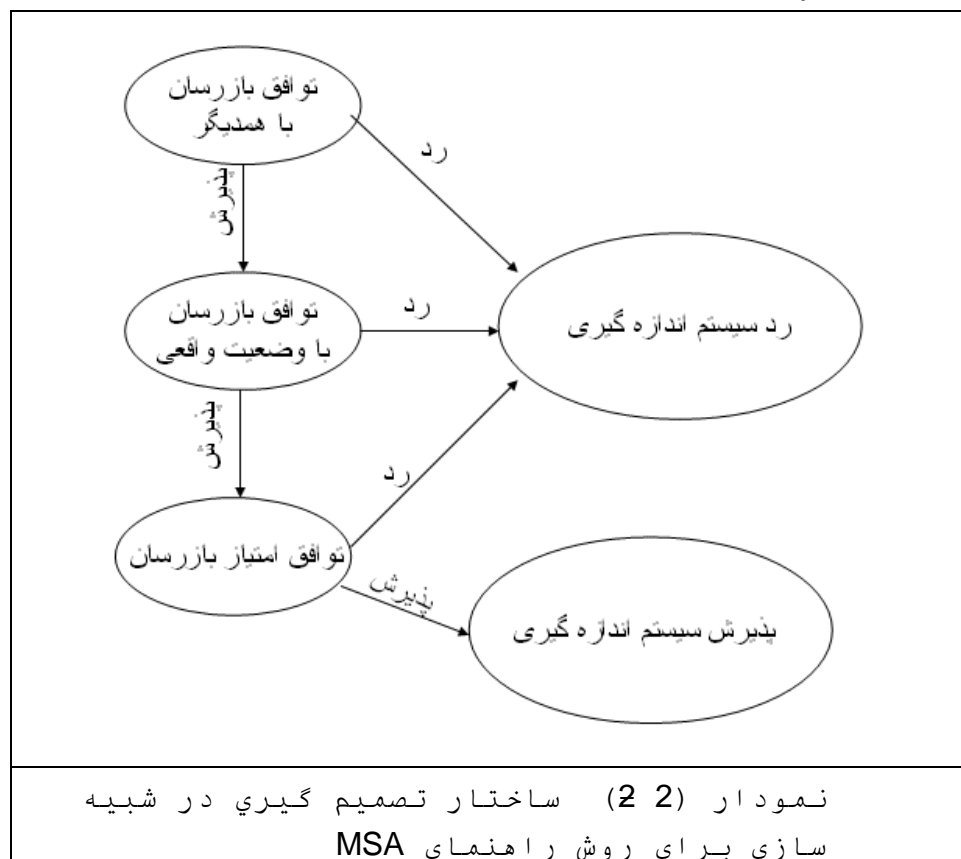
2- 3- 1- روش شبیه سازی

خلاصه ی روش شبیه سازی به این صورت است که سیستم اندازه گیری فرض می شود و تکرارهای مختلف کاربران مستقل از هم از توزیع دو جمله ای با تاثیر پذیری انتخاب شده از قبل تولید، می شود سپس هر دو روش تصمیم گیری راهنمای MSA و روش تعیینی بر روش آنها پیاده سازی می گردد. چون وضعیت واقعی سیستم اندازه گیری معلوم است، می توان دریافت در شرایط فرض شده ، کدام روش بهتر از دیگری عمل می کند.

با توجه به اینکه در روش راهنمای MSA ، به ترتیب خاصی برای تصمیم گیری ، اشاره نشده است ، به ترتیب اهمیت آزمونها ، تصمیم گیری صورت گرفته است.

این ترتیب برای تصمیم گیری به روش راهنمای MSA به قرار زیر است:

آزمون توافق بازرسیها به کمک آماره Y کاپا
 آزمون توافق بازرسیها با وضعیت واقعی قطعه
 آزمون همسانی تصمیم گیری بازرسیها به کمک بازه Y
 اطمینان امتیازهای آنها
 و ترتیب تصمیم گیری برای روش تعیینی نیز مشخص
 بوده است و دقیقاً همان ترتیبی است که در بخش
 ((ساختار تصمیم گیری)) ذکر گردید .
 لازم به ذکر است در روش تعیینی ، خطای نوع اول
 تمامی آزمونها به جز آزمون اریبی که 0.05 انتخاب
 شده است 0.01 در نظر گرفته شده است.
 ساختار تصمیم گیری برای روش راهنمای MSA به
 صورت زیر بوده است، معیار رد آماره های کاپا
 عدد 0.7 (بنا بر پیشنهاد راهنمای MSA) انتخاب
 شده است:



برای حجم نمونه های کم $(n_C + n_F = 50)$ ساختار های
 زیر با تکرار مونت کارلوی 1000 شبیه سازی شده

اند. دانه¹ ي شبیه سازی بطور تصادفی انتخاب گردیده است و برای هر ساختار نتیجه ي بدست آمده طی نمودار نمایش داده شده است. تمامی برنامه ي شبیه سازی از مرحله ي تولید داده تا تصمیم گیری و رسم نمودارها در نرم افزار **SPLUS** انجام شده است و برای هر ساختار شبیه سازی با رایانه ي **Pentium III 700 MHz** با **256** مگا بایت **RAM** و تحت سیستم عامل **Windows XP** ، **5** ساعت زمان صرف شده است.

هر ساختار دارای نسبتی متغیر که از **0.5** تا **1** طی **20** مرحله صعود می کند ، این روش می تواند وضعیت حساسیت دو روش را نسبت به هم طی تغییر تاثیر پذیری نشان دهد.

به عنوان مثال

		بازرس 1			بازرس 2			بازرس 3		
وضعیت	حجم	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3
قطعات	نمونه									
خراب	25	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>
درست	25	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>	<i>p</i>

این ساختار متشکل از **20** سیستم اندازه گیری مختلف است که از

		بازرس 1			بازرس 2			بازرس 3		
وضعیت	حجم	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3
قطعات	نمونه									
خراب	25	0.5	0.5	0.5	0.5	0.5	0.5	0.5	0.5	0.5
درست	25	0.5	0.5	0.5	0.5	0.5	0.5	0.5	0.5	0.5

شروع می شود و تا

		بازرس 1			بازرس 2			بازرس 3		
وضعیت	حجم	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3
قطعات	نمونه									
خراب	25	0.975	0.975	0.975	0.975	0.975	0.975	0.975	0.975	0.975
درست	25	0.975	0.975	0.975	0.975	0.975	0.975	0.975	0.975	0.975

صعود می کند.


¹ Seed

ساختار 1

		بازرس 1			بازرس 2			بازرس 3		
وضعیت	حجم نمونه	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3
خراب	25	p	p	p	p	p	p	p	p	p
درست	25	p	p	p	p	p	p	p	p	p

همانطور که مشاهده می شود این سیستم به ازای تمامی مقادیر p سیستم اندازه گیری R&R است و به ازای مقادیر $p < 0.8$ سیستم اندازه گیری با تاثیر پذیری کمتر از استاندارد است بنابراین باید این سیستم به ازای $p < 0.8$ رد و به ازای $p \geq 0.8$ پذیرفته گردد.

نمودار احتمال تجربی رد سیستم اندازه گیری (تعداد سیستم های رد شده توسط روش راهنمای MSA یا روش تعیینی تقسیم بر تعداد تکرار مونت کارلو) در برابر تغییر تاثیر پذیری سیستم اندازه گیری در زیر رسم شده است :



همانطور که مشاهده می شود روش تعیینی از $p = 0.7$


شروع به پذیرفتن سیستم ها می کند و در نقطه ی مرزی $p=0.8$ دارای احتمال نظری (و تجربی) خطای نوع اول برابر با 0.08 است. این در حالی است که روش راهنمای MSA سیستم های اندازه گیری بسیار کارا $p>0.95$ را با احتمال بزرگتر از 0.5 رد می کند. با زیاد شدن تاثیر پذیری سیستم اندازه گیری ، امتیاز بازرسان نیز به سمت 1 افزایش می یابد و همین موضوع باعث کوتاه شدن بازه ی اطمینان امتیاز بازرسان می شود و بنابراین بازه ی اطمینان امتیاز بازرسان شامل امتیاز همدیگر نمی شود و همین موضوع باعث رد شدن به اشتباه بسیاری از سیستم های اندازه گیری می شود.

ساختار 2

برای بررسی کردن حساسیت دو روش نسبت به عدم تعادل در نمونه های قطعات خراب و درست ساختار 2 کاملاً شبیه ساختار 1 است با این تفاوت که مجموع حجم نمونه های قطعات خراب و درست $(n_C + n_F = 50)$ به جای $n_C + n_F = 25$ بطور نامتعادل $n_C = 45$ و $n_F = 5$ انتخاب شده است.

وضعیت قطعات	حجم نمونه	بازرس 1			بازرس 2			بازرس 3		
		تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3
خراب	5	p	p	p	p	p	p	p	p	p
درست	45	p	p	p	p	p	p	p	p	p

نتیجه ی تصمیم گیری به دو روش در نمودار زیر پیاده سازی شده است:



همانطور که مشاهده می شود، روش راهنمای MSA در این ساختار دیرتر نزول می کند این در حالی است که روش تعیین حساسیت چندان به این عدم تعادل نشان نمی دهد.

علت حساسیت روش راهنمای MSA به این عدم تعادل استفاده از آماره ی کاپا است که همانطور که در فصل های قبل اشاره کردیم ، نسبت به عدم تعادل فراوانی های حاشیه ای حساس است و این عدم تعادل در فراوانی های حاشیه ای در 6 جدول توافقی دو طرفه ی آماره ی کاپا اتفاق خواهد افتاد.


ساختار 3

در دو ساختار قبل حساسیت دو روش را در برابر تاثیر پذیری سیستم اندازه گیری بررسی کردیم و در این ساختار حساسیت این دو روش را نسبت به R&R بودن سیستم اندازه گیری بررسی می کنیم

		بازرس 1			بازرس 2			بازرس 3		
وضعیت	حجم نمونه	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3
خراب	25	p	0.8	0.8	p	0.8	0.8	p	0.8	0.8
درست	25	p	0.8	0.8	p	0.8	0.8	p	0.8	0.8

طبق ساختار فوق سیستم اندازه گیری تنها به ازای $p=0.8$ هم R&R است و هم دارای حداقل تاثیر پذیری

است و بنابراین قابل قبول است ولی به ازای مقادیر $p < 0.8$ سیستم اندازه گیری R&R و تاثیر پذیر به میزان حداقل استاندارد نیست و به ازای $p > 0.8$ تاثیر پذیر به میزان حداقل استاندارد است ولی R&R نیست ، بنابراین قابل قبول نیست.



این نمودار نشان می دهد روش تعیین حساسیت بیشتری نسبت به روش راهنمای MSA به R&R بودن سیستم اندازه گیری نشان می دهد، این در حالی است که روش راهنمای MSA در نقطه ی قابل قبول سیستم اندازه گیری $p=0.8$ بیش از 80 درصد سیستم


هاي اندازه گيري را رد مي کند.

ساختار 4

		بازرس 1			بازرس 2			بازرس 3		
وضعيت	حجم نمونه	تكرار 1	تكرار 2	تكرار 3	تكرار 1	تكرار 2	تكرار 3	تكرار 1	تكرار 2	تكرار 3
خراب	5	p	0.8	0.8	p	0.8	0.8	p	0.8	0.8
درست	45	p	0.8	0.8	p	0.8	0.8	p	0.8	0.8

طي اين ساختار حساسيت دو روش نسبت به R&R بودن سيستم در شرايط نامتعادل بودن فراواني هاي حاشيه اي بررسي مي شود .

همانطور كه در نمودار زير مشاهده مي شود ، روش راهنماي MSA به هيچ وجه نمي تواند سيستمهاي R&R را تشخيص دهد ، اين در حالي است كه روش تعييني كماكن كارايي خود را حفظ مي کند.



ساختار 5


در چهار ساختار قبل حساسيت نسبت به دو خاصيت تأثير پذيري و R&R طي حجم هاي نمونه ي متعادل

و نامتعادل بررسی گردید. در فصل قبل خواص
مجانبی روش تعیینی بررسی شد ولی همانطور که
اشاره شد ، بررسی خواص مجانبی روش راهنما از
لحاظ نظری کمی مشکل است. بدین منظور این دو روش
طی ساختار شبیه سازی زیر در حجم های نمونه ی
نامتعادل در مجموع 1000 نمونه (به جای
50
نمونه) طی ساختار زیر بررسی شده اند:

		بازرس 1			بازرس 2			بازرس 3		
وضعیت	حجم	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3	تکرار 1	تکرار 2	تکرار 3
قطعات	نمونه									
خراب	100	p	0.85	0.85	p	0.85	0.85	p	0.85	0.85
درست	900	p	0.85	0.85	p	0.85	0.85	p	0.85	0.85

میزان تاثیر پذیری از 0.8 به 0.85 تغییر یافته
است تا با کاراتر کردن سیستم اندازه گیری روش
راهنما در وضعیت بهتری قرار بگیرد از طرفی با
20 برابر کردن حجم نمونه از هر دو روش انتظار
می رود بهبود قابل توجهی داشته باشند.
با توجه به اینکه به ازای $p \neq 0.85$ سیستم اندازه
گیری R&R نیست و به ازای $p = 0.85$ سیستم اندازه
گیری دارای خاصیت R&R و حداقل تاثیرپذیری
استاندارد است ، سیستم های اندازه گیری در
ساختار 5 به ازای $p \neq 0.85$ غیر قابل قبول و به
ازای $p = 0.85$ پذیرفته است.

ولی نمودار زیر نشان می دهد تنها روش تعیینی
بهبود قابل توجهی یافته است و روش راهنمای MSA
حتی در حجم های نمونه ی بالا نیز قادر به تشخیص
سیستم های R&R و کارا نیست و تمامی سیستمهای
اندازه گیری را رد می کند :



نمودار (2 7) احتمال تجربی رد سیستم اندازه گیری
در برابر تغییر تاثیر پذیری در ساختار 5

2- 3- 2 نتیجه گیری

شبیه سازی های بررسی شده در این فصل نشان می دهند روش راهنمای MSA دارای خطای نوع اول و نوع دوم بالایی است. هیچ کدام از این دو نوع خطا در این روش کنترل نشده است.

نسبت به عدم تعادل در حجم نمونه برای قطعات خراب و درست بسیار حساس است و کارایی این روش شدیداً به این عدم تعادل بستگی دارد. این در حالی است که در راهنمای MSA هیچگونه اشاره ای به این مطلب نشده است کسانی که هم اکنون از این روش در صنعت استفاده می کنند از این موضوع آگاه نیستند.

با زیاد شدن حجم نمونه کارایی آن لزوماً افزایش نمی یابد یا به بیان ریاضی تر روشی سازگار نیست.

با زیاد کردن تکرار ها برای هر بازرس ، این

روش سیستم اندازه گیری را بدتر از قبل ارزیابی می کند (علت آن نحوه ی تعریف امتیاز بازرسان است) به بیان دیگر یک سیستم اندازه گیری کارا با تکرار های به اندازه ی کافی بالا ، مقدار نزدیک به صفر را به عنوان امتیاز بازرس نتیجه می دهد که خلاف واقعیت است.

به ضرر کارخانه ها عمل می کند بدین معنا که ممکن است بسیاری از کارخانه ها سیستم اندازه گیری استاندارد در سطح معرفی شده در راهنمای MSA رسیده باشند ولی روش تصمیم گیری راهنمای MSA آنها را به اشتباه رد می کند ، این اشتباه نیز کنترل نشده است ، برخی از موارد احتمالی بیش از 0.9 دارد.

در مقابل روش تعیینی در هر مرحله خطای نوع اول را تحت کنترل قرار می دهد و به این وسیله خطای نوع اول کل آزمون تحت کنترل قرار گرفته است. نتیجه ی این کنترل در جمله ی زیر خلاصه می شود که ((اگر سیستم اندازه گیری درست باشد حداکثر با احتمال $\max(\alpha_1 + \alpha_2 + \alpha_3, \alpha_1 + \alpha_2 + \alpha_4 + \alpha_5)$ به اشتباه رد خواهد شد. این در حالی است که روش راهنمای MSA این احتمال را ممکن است حتی با حجم نمونه ی بسیار بالا به 1 (ساختار 5) برساند.

یک روش تصمیم گیری سازگار (با احتمال خطای نوع اول $\max(\alpha_1 + \alpha_2 + \alpha_3, \alpha_1 + \alpha_2 + \alpha_4 + \alpha_5)$ است و این سازگاری علاوه بر اثبات ریاضی در شبیه سازی نیز نشان داده شده است و به علاوه روش راهنمای MSA دارای این خاصیت مهم نیست.

نسبت به تعادل حجم نمونه در قطعات خراب و درست حساس نیست و این برتری دیگری در برابر روش راهنمای MSA است.

تصمیم گیری در مورد رد کردن یا پذیرفتن سیستم اندازه گیری با قاطعیت صورت می گیرد. برای سیستم های بیش از دو حالت و یا استفاده از بیش از 3 بازرس یا بیش از 3 تکرار برای هر بازرس نیز به راحتی قابل تعمیم است و به علاوه

تحت شرایط ذکر شده کماکان دارای خاصیت سازگاری است.

روش تعییني نیز مشکلاتي دارد که سعی می کنیم با ارائه کردن روش های مدلبندی ، آنها را از بین ببریم :

معرفي محک R&R معیاري مورد نظر در سیستم های اندازه گیری است و این محک در هیچکدام از روشهای تعییني و روش راهنمای MSA تعریف نشده اند و اصولاً تعریف آن چندان ساده نیست. سازگاري روش تعییني در حالي بررسی شده است که بازرسان در تکرارهای مختلف خود مستقل از هم تصمیم بگیرند حال آنکه تکرار های مختلف هر بازرس ممکن است به هم همبسته باشد و این موضوع نباید دور از نظر انگاشته شود . با استفاده از رابطه ي نزدیک برآوردهای درستنمایی ماکزیمم و برآوردهای معادلات برآورد تعمیم یافته ¹ (GEE) و استفاده از خاصیت سازگاري برآوردهای GEE حتي در شرایطی که ماتریس همبستگی نادرست فرض شده باشد (مراجعه کنید به لیانگ و زگر² 1986) می توان با فرض کردن ماتریس همبستگی که به صورت ماتریس هماني فرض شده است نیز سازگاري روش تعییني را در این حالت ثابت کرد ولي مشکل عمده اي که در این دیدگاه وجود دارد عدم وجود ماتریس همبستگی مناسب برای داده های دوتایی (به علت نحوه ي وابستگی ماتریس واریانس ، کوواریانس میانگین) است که در بسیاری از اوقات (بر خلاف داده های نرمال) نمی توان آنها را بطور حاشیه اي مدل کرد دیگل³ و همکاران 1994 و استفاده از مدل های آمیخته (مدلهای مؤلفه های واریانس) جهت توصیف نحوه ي وابستگی داده های دوتایی پیشنهاد می دهد.

¹ Generalized Estimating Equations

² Liang and Zeger

³ Diggle

2- 3- 3 پیاده سازی در مثال عملی

با توجه به اینکه داده های معتبر و قابل استنادی برای پیاده سازی این دو روش در مثال عملی امکان پذیر نبود از داده های گزارش شده در راهنمای MSA برای مقایسه ی دو روش در یک مثال عملی استفاده گردید.

روش راهنمای MSA

بررسی توافق بازرسان با همدیگر :

وضعیت واقعی	بازرس 1	بازرس 2	بازرس 1	بازرس 1
0.879	0.776	0.863	بازرس 1	بازرس 1
0.923	0.788	0.863	بازرس 2	بازرس 2
0.774	0.776	0.788	بازرس 3	بازرس 3
0.774	0.879	0.923	وضعیت واقعی	وضعیت واقعی

همانطور که مشاهده می شود تمامی آماره های کاپا بزرگتر از 0.75 است ، امتیاز بازرسان و بازه ی اطمینان آن به صورت زیر است:

بازرس 3	بازرس 2	بازرس 1	بازرس 1
0.91	0.98	0.94	حد بالای 95 درصد
0.8	0.9	0.84	امتیاز
0.69	0.82	0.74	حد پایین 95 درصد

همانطور که مشاهده می شود امتیاز بازرس 3 در بازه ی اطمینان 95 درصد بازرس 2 قرار نمی گیرد بنابراین راهنمای MSA پیشنهاد می کند سیستم اندازه گیری در اولین فرصت تعویض گردد.

روش تعیینی

آزمون توافق بازرسان و p -مقدار تقریبی به صورت زیر است :

p -مقدار تقریبی	آماره ی کی دو
0.273	18.9

آزمون اریبی :

p -مقدار تقریبی	آماره ی کی دو
0.203	1.61

بنابراین سیستم اندازه گیری مورد نظر ، نااریب تشخیص داده می شود و چون حد پایین 95 درصد تاثیرپذیری آمیخته عدد 0.91 است نه تنها سیستم

اندازه گيري قابل قبولي است بلکه تاثير پذيري
آن نسبت سيستم هاي اندادزه گيري خوب (تاثير
پذيري 0.9) تفاوت معني دار دارد و بنا بر اين در
سيستم هاي اندازه گيري خوب قرار مي گيرد و
نيازي به تعويض آن نيست

فصل 3

دیدگاه های مدل‌بندی

3-1- مقدمه

بررسی مدل‌های مزدوج دوتایی به دلایل زیر در این بخش ارائه شده است :

دیدگاه مدل‌بندی بر تحلیل سیستم های اندازه گیری را نشان می دهد.

برآوردگرها و استنباط ها از پیچیدگی کمتری نسبت به مدل‌های اثرات تصادفی برخوردارند.

رابطه ی نزدیکی با روش تعیینی دارد.

استفاده از محک BIC^1 را در انتخاب مدل‌های اثرات تصادفی ، توجیه می کند و درحقیقت نشان می دهد می توان مدل‌های اثرات تصادفی را مدل‌هایی نیمه بیزی انگاشت.

در این مدل‌ها علاقمند به مدل سازی تاثیر پذیری سیستم اندازه گیری هستیم و قاعده‌تاً متغیر پاسخ y_{ijk} تصمیم بازرس i ام در تکرار j ام بر روی k امین قطعه است و مقدار 1 میگیرد اگر این تصمیم با وضعیت واقعی قطعه سازگاری داشته باشد و در غیر این صورت مقدار 0 را اختیار می کند.

در این صورت تاثیر پذیری سیستم اندازه گیری مدل می شود نه اندازه گیری. این موضوع چند برتری به نسبت مدل سازی اندازه گیری دارد:

1. بسیار شبیه روش تعیینی ولی با دیدگاه بیزی است.
2. آزمون R&R بودن سیستم اندازه گیری به آسانی ممکن است.
3. بررسی تاثیر پذیری و R&R بودن سیستم اندازه گیری در یک مدل قابل انجام است

¹ Bayesian Information Criterion

بررسي وجود و يكتايي توزيع هاي پيشين مزدوج در خانواده هاي نمائي و فرمول كلي آن در موريس¹ 1983 ارائه شده است كه در حالت خاص تابع درستنمائي دو جمله اي ، پيشين بتا فرم مزدوج آن است.

3-2 مدل هاي مزدوج دوتايي و انتخاب توزيع پيشين

مي توان فرض كرد كه تاثير پذيري سيستم اندازه گيري در هر تكرار بازرس متغيري تصادفي است. با توجه به اينكه بازرسان بطور تصادفي انتخاب مي شوند و ترتيب انجام آزمايشات نيز تصادفي است، تصادفي بودن تاثير پذيري كاملاً منطقي است ، اين در حالي است كه دو روش تعييني تاثير پذيري ، پارامتر ثابت فرض شده بود. با توجه به دامنه ي تاثير پذيري (كه نسبت تصميم هاي درست بازرسان در تكرارهاي مختلف است) به نظر مي رسد پيشين بتا ، پيشين مناسب براي تاثير پذيري باشد. اگر تعداد بازرسها را با n_o ، تعداد تكرارها را با n_R و تعداد قطعات را با n_p نشان دهيم داريم :

$$y_{ijk} | p_{ij} \stackrel{iid}{\sim} \text{Bin}(1, p_{ij}) \quad i=1, \dots, n_o, \quad j=1, \dots, n_R, \quad k=1, \dots, n_p \quad (4 \quad 3)$$

$$p_{ij} \sim \text{Beta}(\alpha, \beta)$$

مشكل اساسي استفاده از اين مدل انتخاب تابع توزيع پيشين است. با اعتقاد به اينكه قبل از مشاهده ي داده ها احتمالاً نظري در مورد اينكه توزيع پيشين تاثير پذيري چه بايد باشد وجود ندارد. چند توزيع مختلف بدون اطلاع را در نظر مي گيريم ، هر چند بحث هاي زيادي در مورد عدم وجود توزيع پيشين بي اطلاع وجود دارد (مراجعه كنيد به برناردو² 1997).

¹ Morris

² Bernardo

3- 2- 2- پیشین لاپلاس

پیشین لاپلاس توزیع هم احتمال (یکنواخت) را به عنوان توزیع پیشین بی اطلاع پارامترها در نظر می گیرد و دلیل نام گذاری آن مقاله ی تاریخی لاپلاس در تحلیل جمعیت بوده است به دلیل اینکه خوشبختانه در فرم توزیع بتا قرار می گیرد برای مسئله ی تحلیل سیستم های اندازه گیری جالب توجه است به علاوه برآوردهای بیز درستنمایی ماکزیمم با پیشین یکنواخت با برآوردهای درستنمایی ماکزیمم بدست آمده با فلسفه ی فراوانی گرایی ، یکسان است. بیشترین مشکلی که می توان بر پیشین لاپلاس گرفت این است که اگر اطلاعی در مورد پارامتر وجود نداشته باشد ، در مورد تابعی از آن نیز وجود نخواهد داشت بنابراین بجاست که توزیعی برای پارامتر در نظر گرفته شود که لااقل برای کلاسی از تبدیلهای ، دارای خاصیت پایایی باشد. این دسته از پیشین ها با نام پیشین جفریز مطرح می شوند.

3- 2- 3- پیشین مرجع و جفریز


پیشین مرجع که به عنوان تعمیمی از پیشین جفریز توسط برناردو¹ در سال 1979 ارائه شد. تفاوت اساسی پیشین مرجع با پیشین جفریز (مراجعه کنید به جفریز² 1961) تمایز بین پارامتر مزاحم و پارامتر مورد نظر برای استنباط و نقش آن در تعیین توزیع پیشین است. بنابراین حالت تک پارامتری هر دو روش به یک پیشین منجر می شوند : $f(\theta) \propto \sqrt{I(\theta)}$ که $I(\theta)$ اطلاع فشرک نمونه ای θ بدست آمده از مشاهدات است. متأسفانه این روش همواره توزیع احتمال پیشین برای θ انتخاب نمی کند به بیان دیگر اگر فضای θ یک فضای غیر فشرده باشد ممکن است $f(\theta)$ تابعی باشد که $\int f(\theta)d\theta = \infty$ همین

¹ Bernardo

² Jeffreys

موضوع استفاده از این دسته توزیع های پیشین را در مسائل عملی محدود می کند. خوشبختانه در مسئله ی توزیع دو جمله ای ، پیشین جفریز (و مرجع) در فرم بتا می گنجد :

$$p(\theta) \propto \theta^{-\frac{1}{2}}(1-\theta)^{-\frac{1}{2}} = \text{Beta}\left(\frac{1}{2}, \frac{1}{2}\right) \quad (2 \ 3)$$



3- 2- 4 بیز تجربی

در این روش کلاس خاصی از توابع توزیع احتمال پیشین مانند $\text{Beta}(\alpha, \beta)$ فرض می شود و پارامترهای آن از توزیع حاشیه ای مشاهدات به روش درستنمایی ماکزیمم برآورد می شود. با توجه به اینکه y_{ijk} از $y_{ijk'}$ به ازای $k \neq k'$ مستقل است. می توان توزیع حاشیه ای را به صورت زیر نوشت

$$L(\alpha, \beta) = \int_0^1 \cdots \int_0^1 \prod_{k=1}^{n_p} f(y_{ijk} | p_{ij}) f(p_{ij}) dp_{ij} \quad (3 \ 3)$$

و چون روی پارامترها p_{ij} با توجه به توزیع احتمالی آنها یعنی $\text{Beta}(\alpha, \beta)$ انتگرال گرفته شده

است ، حاصل تنها تابعي از مشاهدات و پارامترهاي توزيع پيشين است كه خوشبختانه چون توزيع بتا با توزيع دو جمله اي تشكيل فرم مزدوج مي دهد ، اين انتگرالها به صورت تحليلي قابل محاسبه اند .

اگر $\sum_{k=1}^{n_p} y_{ijk} = y_{ij}$ نشان دهيم داريم :

$$\begin{aligned} L(\alpha, \beta) &= \int_0^1 \cdots \int_0^1 \prod_{k=1}^{n_p} f(y_{ijk} | p_{ij}) f(p_{ij}) dp_{ij} \\ &= \int_0^1 \cdots \int_0^1 \prod_{k=1}^{n_p} [p_{ij}^{y_{ijk}} (1-p_{ij})^{1-y_{ijk}}] \frac{1}{Beta(\alpha, \beta)} p_{ij}^{\alpha-1} (1-p_{ij})^{\beta-1} dp_{ij} \\ &= \int_0^1 \cdots \int_0^1 p_{ij}^{y_{ij.}} (1-p_{ij})^{n_p-y_{ij.}} \frac{1}{Beta(\alpha, \beta)} p_{ij}^{\alpha-1} (1-p_{ij})^{\beta-1} dp_{ij} \quad (4 \ 3) \\ &= \prod_{i=1}^{n_o} \prod_{j=1}^{n_p} \frac{1}{Beta(\alpha, \beta)} \int_0^1 p_{ij}^{y_{ij.}+\alpha-1} (1-p_{ij})^{n_p-y_{ij.}+\beta-1} dp_{ij} \\ &= \prod_{i=1}^{n_o} \prod_{j=1}^{n_p} \frac{1}{Beta(\alpha, \beta)} Beta(y_{ij.} + \alpha, n_p - y_{ij.} + \beta) \end{aligned}$$

با توجه به اينكه

$$Beta(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} \quad (5 \ 3)$$

مي توان نوشت :

$$L(\alpha, \beta) = \prod_{i=1}^{n_o} \prod_{j=1}^{n_p} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \times \frac{\Gamma(y_{ij.} + \alpha)\Gamma(n_p - y_{ij.} + \beta)}{\Gamma(n_p + \alpha + \beta)} \quad (6 \ 3)$$

$$\ell(\alpha, \beta) = \sum_{i=1}^{n_o} \sum_{j=1}^{n_p} \left\{ \begin{aligned} &\log(\Gamma(\alpha+\beta)) + \log(\Gamma(y_{ij.} + \alpha)) + \log(\Gamma(n_p - y_{ij.} + \beta)) \\ &- \log(\Gamma(\alpha)) - \log(\Gamma(\beta)) - \log(\Gamma(n_p + \alpha + \beta)) \end{aligned} \right\} \quad (7 \ 3)$$

با توجه به اينكه تابع گاما به ازاي تمام α و β ها فرم بسته ندارد از طرفي مشتق گيري $L(\alpha, \beta)$ يا $\ell(\alpha, \beta)$ نسبت به α و β جهت ماكزيمم سازي تابع درستنامي حاشيه اي منجر به فرم بسيار پيچيده اي مي شود دو راه براي غلبه بر اين مشكل پيشنهاده مي شود .

اولين راه ماكزيمم سازي تابع درستنامي حاشيه اي با روشهاي عددي كه نیاز به مشتق نداشته باشد مانند روش شبه نيوتن براي محاسبه ي ماتريس مشتقات درجه ي دو و استفاده از روش نلدر و ميد

برای محاسبه ی مشتقات درجه ی اول (مراجعه کنید به بازار¹ و همکاران 1993 و دومین راه استفاده از روش گشتاوری به جای روش درستنمایی ماکزیمم است.

استفاده از روش گشتاوری در زیر آمده است:

با تغییر پارامتر $\mu = \frac{\alpha}{\alpha + \beta}$ به عنوان پارامتر مرکزیت و $\sigma^{-1} = \alpha + \beta$ به عنوان پارامتر دقت توزیع پیشین p_{ij} خواهیم داشت (مراجعه کنید به کارلین و لوئیس² 2000):

$$V(p_{ij} | \mu, \sigma^{-1}) = \frac{\mu(1-\mu)}{\sigma^{-1} + 1} \quad \text{و} \quad E(p_{ij} | \mu, \sigma^{-1}) = \mu \quad (8 \quad 3)$$

و از طرفی $y_{ij.} = \sum_{k=1}^{n_p} y_{ijk}$ که $y_{ij.} | p_{ij} \sim \text{Bin}(n_p, p_{ij})$ خواهیم داشت:

$$f(y_{ij.} | \mu, \sigma^{-1}) = \binom{n_p}{y_{ij.}} \frac{\Gamma(y_{ij.} + \sigma^{-1}\mu) \Gamma(n - y_{ij.} + \sigma^{-1}(1-\mu))}{\Gamma(n + \sigma^{-1})} \quad (9 \quad 3)$$

که با آنچه که در تابع درستنمایی حاشیه ای قرار دارد، با ضریب ثابت $\binom{n_p}{y_{ij.}}$ اختلاف دارد.

داریم:

$$E\left(\frac{y_{ij.}}{n_p}\right) = E\left(E\left(\frac{y_{ij.}}{n_p} | p_{ij}\right)\right) = E(p_{ij}) = \mu \quad (10 \quad 3)$$

و

$$\begin{aligned} V\left(\frac{y_{ij.}}{n_p}\right) &= E\left(V\left(\frac{y_{ij.}}{n_p} | p_{ij}\right)\right) + V\left(E\left(\frac{y_{ij.}}{n_p} | p_{ij}\right)\right) \\ &= E\left(\frac{p_{ij}(1-p_{ij})}{n_p}\right) + V(p_{ij}) \\ &= \frac{\mu(1-\mu)}{n} \left(1 + \frac{n_p - 1}{\sigma^{-1} + 1}\right) \end{aligned} \quad (14 \quad 3)$$

برآورد معمول گشتاوری برای μ :

¹ Bazaraa

² Carlin and Louis

$$\hat{\mu} = \frac{y_{...}}{n_O \times n_R \times n_P} \quad (12 \ 3)$$

و برآورد گشتاوری برای σ^{-1} :

$$\hat{\sigma}^{-1} = \frac{\hat{\mu}(1-\hat{\mu}) - s^2}{s^2 - \frac{\hat{\mu}(1-\hat{\mu})}{n}} \quad (13 \ 3)$$

خواهد بود. که در آن:

$$s^2 = \frac{1}{n_O \times n_R} \sum_{i=1}^{n_O} \sum_{j=1}^{n_R} \left(\frac{y_{ij}}{n_P} - \hat{\mu} \right)^2 \quad (14 \ 3)$$

البته برآوردگرهای متفاوت دیگری برای حجم های نمونه ی غیر متعادل در لويس و درسيمونیان¹ 1982 ارائه شده است.

3- 2- 5- برآورد و استنباط

برآورد

برآورد پارامترها (p_{ij}) در مدل های دو تایی مزدوج و بطور کلی در مدل های بیزی معمولاً به دو روش حداقل امیدریاضی مربع خطا یا روش حداکثر پسین² (درستنمایی ماکزیمم بیز) انجام می شود. برآورد های پارامترها در مسئله ی تحلیل سیستم های اندازه گیری چندان مد نظر نیست، هر چند خوشبختانه در فرم فرض شده، توزیع پسین بطور تحلیلی قابل محاسبه است و در خانواده ی توزیع بتا است.

$$\begin{aligned} f(p_{ij} | \mathbf{y}) &\propto f(\mathbf{y} | p_{ij}) f(p_{ij}) \\ &= p_{ij}^{y_{ij}} (1-p_{ij})^{n_P - y_{ij}} p_{ij}^{\alpha-1} (1-p_{ij})^{\beta-1} \quad (15 \ 3) \\ &= p_{ij}^{y_{ij} + \alpha - 1} (1-p_{ij})^{n_P - y_{ij} + \beta - 1} \end{aligned}$$

که هسته ی توزیع $Beta(y_{ij} + \alpha - 1, n_P - y_{ij} + \beta - 1)$ است و بنابراین برآوردگرهای برآوردگرهای امیدریاضی حداقل مربعات خطا (میانگین توزیع پسین) و درستنمایی ماکزیمم بیز و آن فرم بسته دارد. برآوردگر درستنمایی ماکزیمم بیز:

¹ Louis and DerSimonian

² Maximum Posterior

$$L(p_{ij}) = p_{ij}^{y_{ij.} + \alpha - 1} (1 - p_{ij})^{n - y_{ij.} + \beta - 1}$$

$$\ell(p_{ij}) = (y_{ij.} + \alpha - 1) \log(p_{ij}) + (n - y_{ij.} + \beta - 1) \log(1 - p_{ij}) \quad (16 \ 3)$$

$$\frac{d\ell}{dp_{ij}} = 0 \rightarrow \frac{(y_{ij.} + \alpha - 1)}{p_{ij}} - \frac{(n - y_{ij.} + \beta - 1)}{(1 - p_{ij})} = 0$$

$$\rightarrow (1 - p_{ij})(y_{ij.} + \alpha - 1) - p_{ij}(n - y_{ij.} + \beta - 1) = 0$$

$$\rightarrow (y_{ij.} + \alpha - 1) - p_{ij}[(y_{ij.} + \alpha - 1) + (n - y_{ij.} + \beta - 1)] = 0 \quad (17 \ 3)$$

$$\rightarrow p_{ij} = \frac{(y_{ij.} + \alpha - 1)}{(y_{ij.} + \alpha - 1) + (n - y_{ij.} + \beta - 1)}$$

(17-3) توجه داریم که حاصل بدست آمده در همواره ماکزیمم کننده ی توزیع پسین نیست ، زمانی ماکزیمم کننده است که $\frac{d^2 \ell}{dp_{ij}^2} < 0$ باشد :

$$\frac{d^2 \ell}{dp_{ij}^2} = \frac{-(y_{ij.} + \alpha - 1)}{p_{ij}^2} + \frac{-(n - y_{ij.} + \beta - 1)}{(1 - p_{ij})^2} < 0$$

$$\rightarrow (y_{ij.} + \alpha - 1)(1 - p_{ij})^2 + (n - y_{ij.} + \beta - 1)p_{ij}^2 > 0 \quad (18 \ 3)$$

$$\rightarrow (y_{ij.} + \alpha - 1)(1 - 2p_{ij} + p_{ij}^2) + (n - y_{ij.} + \beta - 1)p_{ij}^2 > 0$$

$$\rightarrow (y_{ij.} + \alpha - 1) - 2(y_{ij.} + \alpha - 1)p_{ij} + (n - y_{ij.} + \beta - 1)p_{ij}^2 > 0$$

عبارت بدست آمده در (18-3) زمانی بزرگتر از صفر است که عبارت فرم درجه ی دو آن ریشه ی حقیقی نداشته باشد یعنی $\Delta' < 0$ باشد.

$$(y_{ij.} + \alpha - 1)^2 - (y_{ij.} + \alpha - 1)(n - y_{ij.} + \beta - 1) < 0 \quad (19 \ 3)$$

متأسفانه در حالت کلی نمی توان نشان داد ولی با توجه به اینکه $n_p \geq 2$ است، حداقل برای توزیع های پیشین لاپلاس و جفریز (مرجع) عبارت (17-3) ماکزیمم کننده است و البته برای توزیع ها پیشین با $(\alpha \geq 1 \text{ و } \alpha + \beta \geq 2)$ نیز چنین است.

استنباط

استنباط در مدل های بیزی توسط عامل بیز انجام می شود و در حقیقت فرضیه ای ترجیح داده می شود که تحت آن فرضیه (بطور متوسط) پسین بیشتری داشته باشد. استفاده از عامل بیز به عنوان معیار پشتیبانی

از داده ها در مدل‌های بیزی توسط جفریز¹ 1961 ارائه شده است و تعایبر و خواص جالبی دارد که در کاس و رفتري² 1995 به تفصیل مورد بررسی قرار گرفته است.

یکی از خواص مناسب عامل بیز، خاصیت سازگاری آن و انتخاب فرضیه‌ی درست بصورت مجانبی است که آزمونهای معنی داری فاقد آن است و یکی از دلایل مهم ما برای استفاده‌ی آن در انتخاب مدل و آزمون فرضیه‌ها به همین دلیل است. عامل بیز برای آزمون فرضیه به صورت زیر تعریف می‌شود:

$$\begin{cases} H_0: \theta \in \Omega_0 \\ H_1: \theta \in \Omega_1 \end{cases} \quad (20 \ 3)$$

تحت زیان برابر (برای هر دو نوع خطا) فرضیه‌ی انتخاب می‌شود که $\Pr(\theta | \mathbf{y})$ بیشتر باشد یا به بیان بهتر فرضیه‌ی 0 بر فرضیه‌ی 1 ارجح است اگر:

$$\int_{\theta \in \Omega_0} f(\theta | \mathbf{y}) d\theta > \int_{\theta \in \Omega_1} f(\theta | \mathbf{y}) d\theta$$

یعنی

$$B_{01} = \frac{\int_{\theta \in \Omega_0} f(\theta | \mathbf{y}) d\theta}{\int_{\theta \in \Omega_1} f(\theta | \mathbf{y}) d\theta} = \frac{\int_{\theta \in \Omega_0} f(\mathbf{y} | \theta) f(\theta) d\theta}{\int_{\theta \in \Omega_1} f(\mathbf{y} | \theta) f(\theta) d\theta} > 1 \quad (24 \ 3)$$

برای انتخاب مدل نیز تعریف عامل بیز تحت زیان برابر (برای هر دو نوع خطا) بطور مشابه انجام می‌شود:

مدل 1 بر مدل 2 ارجح است اگر پسین بیشتری داشته باشد:

$$B_{12} = \frac{f(M_1 | \mathbf{y})}{f(M_2 | \mathbf{y})} = \frac{f(\mathbf{y} | M_1)}{f(\mathbf{y} | M_2)} \times \frac{\Pr(M_2)}{\Pr(M_1)} > 1 \quad (22 \ 3)$$

همانطور که مشاهده می‌شود عامل بیز تابعی بر حسب توزیع پیشین است، در مسئله تحلیل سیستم‌های اندازه‌گیری انتخاب توزیع پیشین برای مدل‌ها برابر 0.5 و در آزمون فرضیه از توزیع‌های پیشین

¹ Jeffreys

² Kass and Raftery

ذکر شده در (3 - 2) استفاده خواهیم کرد.
شوارتز¹ 1978 با بسط مجانبی عامل بیز محک BIC معرفی شده است که تابعی از توزیع پیشین نیست و در (4 - 2 - 2) به تفصیل بررسی خواهد شد.

3- 2- 6 آزمون R&R

در آزمون R&R بودن سیستم اندازه گیری می خواهیم آزمون کنیم آیا تاثیر پذیری سیستم اندازه گیری برای افراد در تکرارهای مختلف متفاوت است یا خیر، در حقیقت می خواهیم یکی از دو مدل M_1 یا M_2 را انتخاب کنیم.

$$\begin{cases} H_0 : M_1 : y_{ijk} \stackrel{iid}{\sim} \text{Bin}((n_o \times n_R \times n_P), p) \\ H_1 : M_2 : y_{ijk} \stackrel{iid}{\sim} \text{Bin}(n_P, p_{ij}) \end{cases} \quad (23 \ 3)$$

برای محاسبه ی عامل بیز داریم :

$$f(M_1 | \mathbf{y}) = f(\mathbf{y} | M_1) \Pr(M_1) \quad (24 \ 3)$$

$$\begin{aligned} f(\mathbf{y} | M_1) &= \int_0^1 f(\mathbf{y} | M_1, p) f(p) dp \\ &= \int_0^1 p^{y_{..} + \alpha - 1} (1 - p)^{(n_o \times n_R \times n_P) - y_{..} + \beta - 1} dp \end{aligned} \quad (25 \ 3)$$

$$\begin{aligned} &= \text{Beta}((y_{..} + \alpha), ((n_o \times n_R \times n_P) - y_{..} + \beta)) \\ f(M_2 | \mathbf{y}) &= f(\mathbf{y} | M_2) \Pr(M_2) \end{aligned} \quad (26 \ 3)$$

$$\begin{aligned} f(\mathbf{y} | M_2) &= \int_0^1 \dots \int_0^1 f(\mathbf{y} | M_2, p_{ij}) f(p_{ij}) dp_{ij} \\ &= \int_0^1 \dots \int_0^1 p_{ij}^{y_{ij} + \alpha - 1} (1 - p_{ij})^{n_P - y_{ij} + \beta - 1} dp_{ij} \\ &= \prod_{i=1}^{n_o} \prod_{j=1}^{n_R} \text{Beta}((y_{ij} + \alpha), (n_P - y_{ij} + \beta)) \end{aligned} \quad (27 \ 3)$$

با فرض برابر بودن احتمالات پیشین برای دو مدل M_1 و M_2 :

$$\Pr(M_1) = \Pr(M_2) = 0.5 \quad (28 \ 3)$$

خواهیم داشت.

$$B_{12} = \frac{f(\mathbf{y} | M_1)}{f(\mathbf{y} | M_2)} = \frac{\text{Beta}((y_{..} + \alpha), ((n_o \times n_R \times n_P) - y_{..} + \beta))}{\prod_{i=1}^{n_o} \prod_{j=1}^{n_R} \text{Beta}((y_{ij} + \alpha), (n_P - y_{ij} + \beta))} \quad (29 \ 3)$$

اگر پس از مشاهده کردن داده ها مدل M_2 انتخاب

¹ Schwarz

شد ، بدین معنا است که سیستم اندازه گیری مورد نظر دارای خاصیت R&R نیست و اگر مدل M_1 انتخاب شد بیانگر این حقیقت است که داده ها R&R بودن سیستم اندازه گیری را تایید می کنند. B_{12} یا $\log(B_{12})$ معمولاً معیار مناسبی برای میزان R&R بودن سیستم اندازه گیری است. جفریز¹ 1961 میزان پشتیبانی داده ها از فرضیه ی صفر بر اساس عامل بیز را بصورت زیر بیان می کند :

تعبیر	$B_{10} = \frac{1}{B_{01}}$	$\log(B_{10}) = -\log(B_{01})$
نه چندان قابل توجه	1-3.2	0-0.5
قوی	10-100	1-2
قاطع	> 100	> 2

توجه به این نکته ضروری است که با حجم نمونه ی زیاد، توزیع پیشین در استنباط چندان مؤثر نیست ولی در حجم نمونه ی کم می تواند باعث تغییر نتیجه ی استنباط شود و این موضوع یکی از نقاط ضعف استفاده از عامل بیز برای استنباط در حجم نمونه های کم است.

3- 2- 7 آزمون تاثیر پذیری

با توجه به اینکه سیستم اندازه گیری مطلوب باید در ابتدا دارای خاصیت R&R باشد، آزمون تاثیر پذیری را تنها برای مدل M_1 بخش (3 - 2 - 6) بررسی می کنیم :

$$y_{ijk} | p \sim \overset{iid}{Bin}((n_o \times n_R \times n_P), p) \quad (30 \ 3)$$

$$p \sim Beta(\alpha, \beta)$$

$$\begin{cases} H_0 : p \geq 0.8 \\ H_1 : p < 0.8 \end{cases} \quad (34 \ 3)$$

¹ Jeffreys

$$B_{01} = \frac{\int_{0.8}^1 p^{y_{..} + \alpha - 1} (1 - p)^{(n_O \times n_R \times n_P) - y_{..} + \beta - 1}}{\int_0^{0.8} p^{y_{..} + \alpha - 1} (1 - p)^{(n_O \times n_R \times n_P) - y_{..} + \beta - 1}} \quad (32 \ 3)$$

$$= \frac{1 - \text{Beta}_{(0,0.8)}((y_{..} + \alpha), (n_O \times n_R \times n_P) - y_{..} + \beta)}{\text{Beta}_{(0,0.8)}((y_{..} + \alpha), (n_O \times n_R \times n_P) - y_{..} + \beta)}$$

که در آن $\text{Beta}_{(0,p)}(\alpha, \beta)$ انتگرال ناقص بتا با پارامترهای α و β است.

3-3 روشهای برآورد و استنباط در مدل‌های خطی تعمیم یافته آمیخته

مدل‌های خطی تعمیم یافته به جای مدل کردن میانگین توزیع نرمال به صورت شرطی، خواص دیگری (معمولاً میانگین) از توزیعی از دسته‌ی خانواده‌ی نمایی را مدل می‌کند و در این مسیر نیاز به تعریف مفاهیم دیگری مانند تابع وصل به وجود می‌آید که دانستن آنها قبل از ورود به مدل‌های خطی تعمیم یافته‌ی آمیخته، ضروری است. بنابراین ابتدا مروری کلی بر مدل‌های خطی تعمیم یافته و سپس مدل‌های خطی تعمیم یافته خواهیم داشت و از ترکیب این دو، مدل‌های خطی تعمیم یافته‌ی آمیخته را معرفی می‌کنیم.

3-3-1 مروری بر تاریخچه و پیشرفت‌ها در مدل‌های خطی تعمیم یافته

مدل‌های خطی تعمیم یافته به عنوان تعمیم مدل‌های خطی توسط نلدر و ودربرن¹ در سال 1972 معرفی شد که در زیر چکیده‌ی آن را می‌خوانید.
بررسی نظری بصورت دقیقتر در مک کولا و نلدر² 1989 آمده است و میر³ و همکاران 2002 منبع خوبی برای دیدگاه‌های شهودی است. مک کولا 2000 در بر

¹ Nelder and Wedderburn

² McCullagh and Nelder

³ Myers

گیرنده ی آخرین پیشرفته‌ها و کاربردهای این دسته از مدلها تا سال 2000 میلادی است. لازم به ذکر است که بیشترین استفاده از این دسته مدلها به عنوان رقیبی قوی در برابر مدلهای لگ خطی در تحلیل داده های گسسته گسترش یافته است. اطلاعات بیشتر در این مورد و ارتباط آن با مدلهای لگ خطی به آگرستی¹ 1996 مراجعه کنید. فرض می شود خاصیتی از این توزیع متغیر پاسخ (میانگین)، بطور شرطی توسط مدلی (نه لزوماً خطی) با متغیر توضیحی (نه لزوماً متغیری تصادفی) در ارتباط است. به علاوه نوع متغیر توضیحی در کل مسئله مشکلی ایجاد نمی کند (مراجعه کنید به مونتگمری² و همکاران 2001). علاقمند به بررسی میزان تاثیر متغیرهای توضیحی یا به بیان آماری تر برآورد و استنباط پارامترهای مدل هستیم. روش معمول برای برآورد استفاده از برآوردگرهای درستنمایی ماکزیمم است. روش حداقل مربعات بطور تکراری وزن داده شده نیز روش دیگری است که چارنس و یو³ 1976 نشان داده اند تحت شرایط معقولی با روش درستنمایی ماکزیمم معادل است. ودربرن⁴ 1974 نشان داد معادلات برآورد در مدلهای خطی تعمیم یافته تنها تابعی از میانگین و واریانس است به بیان دیگر برآوردگرهای درستنمایی ماکزیمم در مدلهای خطی تعمیم یافته تنها با مدل کردن میانگین و فرض ارتباط بین میانگین و واریانس قابل محاسبه است. این برآوردگرها تحت عنوان برآوردگرهای شبه درستنمایی بررسی شده اند. برآوردگرهای شبه درستنمایی تنومند با مدل کردن میانه به جای

¹ Agresti

² Montgomery

³ Charnes and Yu

⁴ Wedderburn

میانگین آن در جونگ¹ 1996 بدست آمده اند. گودمب و هید² 1987 نشان دادند برآوردگرهای شبه درستنمایی با تعریف گودمب و تامپسون³ 1984 معادلات برآورد بهینه است و گودمب⁴ 2002 برآوردگرهای شبه درستنمایی تنومند را در چاقوب معادلات برآورد بهینه تعمیم داد.

زگر و لیانگ⁵ 1986 برآوردگرهای شبه درستنمایی را برای حالت متغیرهای پاسخ وابسته تعمیم دادند و لیانگ و زگر⁶ 1986 نشان دادند این برآوردگرها حتی تحت ساختار همبستگی غلط نیز سازگارند.

کانتونی و رکچتی⁷ 2001 و کانتونی⁸ 2003 برآوردگرهای معادلات برآورد تعمیم یافته ی تنومند را در کلاس برآوردگرهای M بدست آوردند و چارچوبی برای تحلیل دویانس تنومند⁹ ارائه نمودند.

3- 2- 3 مدل‌های خطی تعمیم یافته

فرض کنید y_1, y_2, \dots, y_n مشاهداتی مستقل از توزیعی متعلق به دسته ی خانواده ی نمایی تعریف شده بصورت است

$$f(y_i) \sim \exp(a(\theta)b(y_i) + c(\theta) + d(y_i)) \quad (33 \ 3)$$

که به $a(\theta)$ پارامتر متعارف توزیع اطلاق می شود. این خانواده در برگیرنده ی کلاس به نسبت وسیعی از توزیع های احتمالی استفاده شده در تحلیل های آماری است: توزیع های دو جمله ای، پواسن، دو

¹ Jung

² Godambe and Heyde

³ Godambe and Thompson

⁴ Godambe

⁵ Zeger and Liang

⁶ Liang and Zeger

⁷ Cantoni and Rocchetti

⁸ Cantoni

⁹ Robust Analysis of Deviance

جمله ای منفی ، پارتو ، گاما، بتا، نرمال و ... در این کلاس قرار می گیرند .

اکنون فرض کنید میانگین ، یا پارامتر توزیع احتمالی فرض شده برای متغیر پاسخ توسط تابع وصل g با متغیر های توضیحی \mathbf{x} در ارتباط است :

$$\mu_i = E(y_i | \mathbf{x}_i) = g^{-1}(\mathbf{x}_i \boldsymbol{\beta}) = g^{-1}(\eta_i) \quad (34 \ 3)$$

که به η_i پیشگوی خطی اطلاق می شود .

با توجه به اینکه در خانواده ی نمایی معمولاً میانگین تابعی از واریانس است :

$$V_i(y_i) = h(\mu_i) = h(\boldsymbol{\beta}) \quad (35 \ 3)$$

و در ودربرن ¹ 1974 نیز اشاره شده است ، برآوردهای درستنمایی ماکزیمم پارامترها ($\boldsymbol{\beta}$) از حل معادلات :

$$\begin{bmatrix} \sum_{i=1}^n \frac{\partial \mu_i}{\partial \beta_1} V_i(\mu_i)(y_i - \mu_i) \\ \sum_{i=1}^n \frac{\partial \mu_i}{\partial \beta_2} V_i(\mu_i)(y_i - \mu_i) \\ \vdots \\ \sum_{i=1}^n \frac{\partial \mu_i}{\partial \beta_k} V_i(\mu_i)(y_i - \mu_i) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad (36 \ 3)$$

بدست خواهد آمد ، این معادلات از روش های عددی مانند نیوتن قابل حل است.

3- 3- 3 مشکل فرایاشی در مدل های خطی تعمیم یافته

با توجه به اینکه در مدل های خطی تعمیم یافته ، با تعیین توزیع متغیر پاسخ از خانواده نمایی، واریانس توزیع ، معمولاً تابعی مشخص از میانگین است و بنابر دلایل زیادی که مهمترین آن در نظر نگرفتن متغیر های توضیحی مهم یا در نظر نگرفتن نوعی وابستگی بین مشاهدات است، واریانس بدست آمده از مدل با واریانس بدست آمده از داده ها متفاوت است. معمولاً واریانس بدست آمده از داده

¹ Wedderburn

ها بیشتر از واریانس مدل است که فراپراشی¹ اطلاق می شود البته ممکن است عکس این مطلب نیز اتفاق بیافتد که فروپراشی² نامیده شده است. به هر حال عدم تطابق این دو، دلیلی بر نامناسب بودن مدل است که معمولاً به دو روش این مشکل رفع می شود استفاده از پارامتر مقیاس در مدل خطی تعمیم یافته و یا استفاده از مدل های خطی تعمیم یافته ی آمیخته. با توجه به اینکه استفاده از پارامتر مقیاس هر چند باعث زیاد شدن طول بازه های اطمینان برای پارامترهای ثابت مدل می شود (و تاثیری در برآورد نقطه ای آنها ندارد) ولی چندان مورد توجه قرار نگرفته است و بیشترین دلیل آن تفاسیری است که می توان از مدل های خطی تعمیم یافته ی آمیخته استخراج نمود.

استفاده از پارامتر مقیاس بصورت زیر است: با توزیع متغیر پاسخ از خانواده ی نمایی، تنها رابطه ی بین میانگین و واریانس با ایده گرفتن از توزیع مورد نظر به صورت

$$V_i(\beta) = \phi h(\beta) \quad (37 \quad 3)$$

فرض می شود. نتیجه ی مقاله ی ودربرن³ 1974 نشان می دهد اگر خانواده ی توزیع فرض شده برای متغیر پاسخ خانواده نمایی باشد، تنها در نظر گرفتن این رابطه و استفاده از برآوردگرهای شبه درستنمایی با برآوردگرهای درستنمایی ماکزیمم آن یکسان خواهد بود.

3- 3- 4 مدل های خطی آمیخته

میانگین متغیر پاسخ در این دسته مدل ها به صورت

$$E(y | \mathbf{X}, \mathbf{Z}, \mathbf{u}) = \mathbf{X}\beta + \mathbf{Z}\mathbf{u} \quad (38 \quad 3)$$

مدل می شود که $\mathbf{u} \sim N_p(\mathbf{0}, \Sigma)$ ، که معمولاً در طرح آزمایشها با اثرات آمیخته، داده های طولی و اندازه های تکرار شده کاربرد وسیعی دارد. به \mathbf{X}

¹ Overdispersion

² Underdispersion

³ Wedderburn

، ماتریس طرح¹ اثرات ثابت و به Z ماتریس طرح اثرات تصادفی اطلاق می شود.

بسته به نوع مدل (بر اساس اثرات تصادفی) مانند مدل‌های با اثرات متقابل و یا مدل‌های با اثرات آشیانه ای ماتریس طرح Z متفاوت خواهد بود.

برای آشنایی با نحوه ی تعیین Z در طرح های آزمایشی به پی اس آر اس رانو² 1997 و در داده های طولی به وربکو مولنبرگز³ 1997 مراجعه کنید.

برآوردگرهای اثرات ثابت (β) به روش درستنمایی ماکزیمم حاشیه ای⁴ (ML) و برآوردگرهای مؤلفه های واریانس (Σ) معمولاً به روش درستنمایی حاشیه ای باقیمانده⁵ (REML) انجام می شود. تمایز، مزایا و معایب برآوردگرهای ML و REML ی مؤلفه های واریانس به تفصیل در سرل و همکاران⁶ 1992 آمده است و در فرم بسته ی برآوردگرهای ML و REML مؤلفه های واریانس برای طرح های آزمایشی متعادل در پی اس آر اس رانو⁷ 1997 بصورت تحلیلی بدست آمده است، تکنیک دیگری نیز برای برآورد کردن پارامترهای ثابت و مؤلفه های واریانس با نام روش حداقل مربعات تکراری تعمیم یافته ($IGLS^8$) و حداقل مربعات تکراری تعمیم یافته ی محدود ($RIGLS^9$) نیز پیشنهاد شده است، گلدشتین¹⁰ 1986 و گلدشتین 1989 به ترتیب نشان داده اند این دو روش هر چند از تکنیک متفاوتی برای برازش استفاده می کند ولی معادل روش ML و REML اند.

¹ Design Matrix

² P.S.R.S. Rao

³ Verbeke and Molenberghs

⁴ Marginal Maximum Likelihood

⁵ Residual Maximum Likelihood

⁶ Searle

⁷ P.S.R.S. Rao

⁸ Iterative Generalized Least Squares

⁹ Restricted Iterative Generalized Least Squares

¹⁰ Goldstein

(u) پس از مشاهده ي داده ها معمولاً به روش،
بهترین پیشگوي خطي ($BLUP^1$) پیشگويي مي شود ، مي
توان نشان داد بهترین پیشگوي خطي به فرم $E(u|y)$
است ، (براي بحث هاي مفيد در اين زمینه به
رابینسون² 1991 مراجعه کنید).
الگوریتم EM ، پیشنهاد شده توسط دمپستر³ و
همکاران 1977 روش عملي و مناسبی برای بدست
آوردن برآوردگرهای درستنمایی ماکزیمم است، این
روش در لایرد و ور⁴ 1982 پیشنهاد شد و توسط
لانگفورد⁵ 1987 با در نظر گرفتن اثرات تصادفی به
عنوان داده هاي گمشده، توسعه یافت. با توجه به
اینکه توزیع حاشیه اي متغیر پاسخ در (توزیع
نرمال چند متغیره) در فرم خانواده نمایی است،
شرایط همگرایی الگوریتم EM نیز برقرار است.

3- 3- 5 مدلهاي خطي تعمیم یافته ي آمیخته

این مدلها ترکیبی از دو مدل ((خطي آمیخته)) و
((تعمیم یافته ي خطي)) است که به صورت زیر
تعمیم داده شده است.

$$\mu_i = g(E(y_i | \mathbf{X}, \mathbf{Z}, \mathbf{u})) = \mathbf{x}_i \boldsymbol{\beta} + \mathbf{z}_i \mathbf{u} \quad (39 \quad 3)$$

و معمولاً فرض مي شود $y_i | \mathbf{u} \sim F_{\beta, \mathbf{u}}^{iid}$, $\mathbf{u} \sim F_{\mathbf{u}}$ که $F_{\beta, \mathbf{u}}$ توزیع
خانواده ي نمایی است. به g تابع وصل، $F_{\beta, \mathbf{u}}$
توزیع پاسخ و به $F_{\mathbf{u}}$ توزیع آمیخته⁶ اطلاق مي شود.
بیشترین مشکلی که در راه برآزش این مدلها وجود
دارد ، فرم بسته نداشتن تابع درستنمایی است. در
حقیقت یکی از شرایطی که تحت آن تابع درستنمایی
فرم بسته دارد ، مزدوج بودن توزیع پاسخ و توزیع

¹ Best Linear Unbiased Predictor

² Robinson

³ Dempster

⁴ Laird and Ware

⁵ Longford

⁶ Mixing Distribution

آمیخته است. با توجه به اینکه در بیشتر مواقع این حالت وجود ندارد برای بدست آوردن تابع درستنمایی مجبور به استفاده از روشهای عددی و یا تقریب تیلور هستیم.

3- 3- 6- برآورد در مدل‌های غیر خطی آمیخته

تقریب تیلور

همانطور که اشاره شد مدل‌های خطی آمیخته مشکلات چندانی برای برآورد پارامترها (به خاطر الگوریتم EM) ندارند ولی در همین مدل‌ها اگر اثرات تصادفی به صورت غیر خطی وارد مدل شوند نمی‌توان فرم بسته برای مرحله ی E در الگوریتم EM پیدا کرد. استفاده از زنجیرهای مارکف مونت کارلویی¹ (MCMC) اشاره شده در هستینگس² 1970 یک راه غلبه بر این مشکل است و با توجه به اینکه در هر مرحله، مرحله ی E نیاز به حجم نمونه ی کافی برای تقریب مناسب میانگین دارد، این دسته از الگوریتم‌ها یا بسیار (از لحاظ زمانی) دیر همگرا می‌شوند و یا از لحاظ محاسباتی (لااقل با کامپیوترهای امروزی) تقریباً غیر عملی اند. یکی دیگر از روشهای معمول حل این مشکل استفاده از بسط تیلور تابع درستنمایی است. جهت روشن تر شدن موضوع مثال ساده ی زیر را در نظر بگیرید:

مثال 1.6: مدل خطی آمیخته ی

$$y_{ij} = \mathbf{x}_i' \boldsymbol{\beta} + b_i + \varepsilon_{ij}$$

$$\varepsilon_{ij} \stackrel{iid}{\sim} N(0, \sigma^2) \quad (40 \quad 3)$$

$$b_i \stackrel{iid}{\sim} N(0, \sigma_b^2)$$

را در نظر بگیرید، این مدل می‌تواند تعداد چند گروه در رگرسیون باشد که متغیرهای توضیحی آنها

¹ Markov Chain Monte Carlo

² Hastings

اندازه گيري نشده اند و براي خنثي سازي چنين تاثيرات آنها بر استنباط روي پارامترهاي در نظر گرفته شده باشد. بررسي مشكلات در نظر نگرفتن اثرات تصادفي در اينگونه مدلها در وربك و لزافر¹ 1997 بررسي شده است. در مدل (3-40) فرض كنيد متغير پاسخ در $i=1,\dots,n$ گروه بررسي و در هر گروه $j=1,\dots,n_i$ آزمودني مورد بررسي واقع شده اند.

در داده هاي چند سطحي، اين مدل به مدل اثرات تصادفي دو سطحي مشهور است، کاربردهاي زيادي براي اين مدل در داده هاي پزشكي و آموزشي وجود دارد (مراجعه كنيد به گلدشتين² 1995). در حقيقت مي توان مدل فوق را به صورت زير نيز نوشت :

$$\begin{aligned} y_{ij} | b_i &\sim N(\mathbf{x}'_i \boldsymbol{\beta} + b_i, \sigma^2) \\ b_i &\sim N(0, \sigma_b^2) \end{aligned} \quad (44 \ 3)$$

براي بدست آوردن توزيع حاشيه اي داريم :

$$L(\boldsymbol{\theta}) = \int \dots \int f(\mathbf{y} | b_i) f(b_i) db_i \quad (42 \ 3)$$

با توجه به اينكه $f(\mathbf{y} | b_i)$ و $f(b_i)$ هر دو توزيع نرمال هستند و در فرم مزدوج قرار دارند ، تابع درستنامايي به صورت تحليلي قابل محاسبه است و در فرم توزيع نرمال چند متغيره قرار دارد (مراجعه كنيد به گلدشتين 1995).

اكنون فرض كنيد ميانگين توزيع شرطي به صورت غير خطي با تابع g با پيشگوي خطي در ارتباط باشد.

اين دسته از مدلها بيشتر در شيمي فيزيك مورد استفاده قرار مي گيرد مانند مدل Michaelis-Menten (مراجعه كنيد به ميرس³ و همكاران 2002) برخي کاربردهاي ديگر از اين دسته مدلها نيز در سنيتيك دارويي وجود دارد (مراجعه كنيد به

¹ Verbeke and Lesaffre

² Goldstein

³ Myers

هارتفورد و دیویدیان¹ (2000)

مثال 1.6: مدل غیر خطی مشابه (3-41) را به صورت زیر فرض کنید:

$$\begin{aligned} y_{ij} &= g(\mathbf{x}'_i \boldsymbol{\beta} + b_i) + \varepsilon_{ij} \\ \varepsilon_{ij} &\sim N(0, \sigma^2) \\ b_i &\sim N(0, \sigma_b^2) \end{aligned} \quad (43 \quad 3)$$

واضح است در این مثال حتی در صورتی که تابع درست‌نمایی شرطی و تابع توزیع آمیخته در فرم مزدوج باشند، تابع درست‌نمایی فرم بسته ندارد:

$$L(\boldsymbol{\theta}) = \int \cdots \int f(\mathbf{y} | b_i) f(b_i) db_i$$

$$= \int \cdots \int \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left(-\frac{1}{2} \sum_{j=1}^n \left(\frac{y_{ij} - g(\mathbf{x}'_i \boldsymbol{\beta} + b_i)}{\sigma} \right)^2 \right) f(b_i) db_i \quad (44 \quad 3)$$

، اکنون با استفاده از بسط تیلور مرتبه ی اول، تابع درست‌نمایی را بطور تقریبی محاسبه می‌کنیم:

$$\begin{aligned} L(\boldsymbol{\beta}, \sigma^2, \sigma_b^2) &= \int \cdots \int \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^{n_i} \exp \left(-\frac{1}{2\sigma^2} \sum_{j=1}^{n_i} (y_{ij} - g(\boldsymbol{\beta}, b_i)) \right) \exp \left(-\frac{1}{2\sigma_b^2} b_i \right) db_i \\ &= \prod_{i=1}^{n_i} \int_{-\infty}^{+\infty} \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^{n_i} \exp \left(-\frac{1}{2\sigma^2} \sum_{j=1}^{n_i} (y_{ij} - g(\boldsymbol{\beta}, b_i)) \right) \exp \left(-\frac{1}{2\sigma_b^2} b_i \right) db_i \quad (45 \quad 3) \\ &= \prod_{i=1}^{n_i} L_i(\boldsymbol{\theta} | \mathbf{y}) \end{aligned}$$

این انتگرالها زمانی همگی از لحاظ تحلیل قابل حل هستند که g تابعی چند جمله ای از b_i ها باشد به همین دلیل از بسط تیلور (و برای سادگی مرتبه ی 1 آن) استفاده می‌کنیم. (ایده ی این روش مشابه روشهایی است که برسلو و کلایتون² 1993، گلدشتین³ 1991 و لیندستورم و بیتس¹

¹ Hartford and Davidian

² Breslow and Clayton

³ Goldstein

1991 ارائه داده اند.

$$(\theta | \mathbf{y}) \propto (\sigma_b^2)^{-\frac{1}{2}} (\sigma^2)^{-\frac{n_i}{2}} \int_{-\infty}^{+\infty} \exp \left(\sum_{j=1}^{n_i} \left(-\frac{1}{2\sigma^2} (y_{ij} - g(\beta, b_i))^2 - \frac{1}{2n_i\sigma_b^2} b_i^2 \right) \right) db_i \quad (46 \ 3)$$

با بسط تابع g حول مقدار ثابت b_{i0} داریم :

$$g(\beta, b_i) \cong g(\beta, b_{i0}) + \left. \frac{dg}{db_i} \right|_{b_i=b_{i0}} (b_i - b_{i0}) \quad (47 \ 3)$$

برای ساده نویسی $\left. \frac{dg}{db_i} \right|_{b_i=b_{i0}}$ را به صورت g' می نویسیم

:

با فرض

$$c_1 = (\sigma_b^2)^{\frac{1}{2}} (\sigma^2)^{-\frac{n_i}{2}}$$

خواهیم داشت :

$$L_i(\theta | \mathbf{y}) \propto c_1 \int_{-\infty}^{+\infty} \exp \left(\sum_{j=1}^{n_i} \left(-\frac{1}{2\sigma^2} (y_{ij} - g(\beta, b_{i0}) - g'(b_i - b_{i0}))^2 - \frac{1}{2n_i\sigma_b^2} b_i^2 \right) \right) db_i \quad (48 \ 3)$$

$$\propto c_1 \int_{-\infty}^{+\infty} \exp \left(\sum_{j=1}^{n_i} \left(-\frac{1}{2\sigma^2} \left[(y_{ij} - g(\beta, b_{i0}))^2 + (g'(b_i - b_{i0}))^2 \right] - \frac{1}{2n_i\sigma_b^2} b_i^2 \right) \right) db_i$$

$$L_i(\theta | \mathbf{y}) \propto c_1 \int_{-\infty}^{+\infty} \left[\exp \left(-\frac{1}{2\sigma^2} \sum_{j=1}^{n_i} (y_{ij} - g(\beta, b_{i0}))^2 \right) \exp \left(\sum_{j=1}^{n_i} \left(-\frac{1}{2\sigma^2} \left[g'^2(b_i - b_{i0})^2 + 2g'b_i(y_{ij} - g(\beta, b_{i0})) \right] - \frac{1}{2n_i\sigma_b^2} b_i^2 \right) \right) \right] db_i$$

$$= c_1 \exp \left\{ -\frac{1}{2\sigma^2} \sum_{j=1}^{n_i} [(y_{ij} - g(\beta, b_{i0}))^2 - 2g'b_{i0}(y_{ij} - g(\beta, b_{i0}))] \right\}$$

$$\times \int_{-\infty}^{+\infty} \exp \left(\sum_{j=1}^{n_i} \left(-\frac{1}{2\sigma^2} [g'^2(b_i^2 + b_{i0}^2 - 2b_i b_{i0}) + 2g'b_i(y_{ij} - g(\beta, b_{i0}))] - \frac{1}{2n_i\sigma_b^2} b_i^2 \right) \right) db_i$$

$$= c_1 \exp \left\{ -\frac{1}{2\sigma^2} \sum_{j=1}^{n_i} [(y_{ij} - g(\beta, b_{i0}))^2 - 2g'b_{i0}(y_{ij} - g(\beta, b_{i0})) + g'^2 b_{i0}^2] \right\}$$

$$\times \int_{-\infty}^{+\infty} \exp \left(\sum_{j=1}^{n_i} \left(-\frac{1}{2\sigma^2} [b_i \{g'^2 - 2b_{i0} + 2g'(y_{ij} - g(\beta, b_{i0}))\} + g'^2 b_i^2] - \frac{1}{2n_i\sigma_b^2} b_i^2 \right) \right) db_i$$

با فرض :

$$c_2 = \exp \left\{ -\frac{1}{2\sigma^2} \sum_{j=1}^{n_i} \left[(y_{ij} - g(\beta, b_{i0}))^2 - 2g'b_{i0}(y_{ij} - g(\beta, b_{i0})) \right] \right\}$$

د اريم :

$$L_i(\theta | y) \propto c_1 c_2 \int_{-\infty}^{+\infty} \exp \left(\sum_{j=1}^{n_i} \left[-\frac{1}{2\sigma^2 \sigma_b^2} \left[b_i [2g'(y_{ij} - g(\beta, b_{i0}))] - 2b_{i0}g'^2 \right] \sigma_b^2 \right] - \frac{1}{2n_i \sigma_b^2} b_i^2 \right] \right) db_i$$

$$= c_1 c_2 \int_{-\infty}^{+\infty} \exp \left(-\frac{1}{2\sigma^2 \sigma_b^2} \sum_{j=1}^{n_i} \left[\left[b_i \sigma_b^2 [2g'(y_{ij} - g(\beta, b_{i0}))] - 2b_{i0}g'^2 \right] \right. \right. \\ \left. \left. + b_i^2 \left[g'^2 \sigma_b^2 + \frac{\sigma^2}{n_i} \right] \right] - \frac{1}{2n_i \sigma_b^2} b_i^2 \right) db_i$$

$$\Rightarrow L_i(\theta | y) \propto c_1 c_2 \int_{-\infty}^{+\infty} \exp \left(-\frac{1}{2\sigma^2 \sigma_b^2} \sum_{j=1}^{n_i} \left[b_i^2 - 2b_i \frac{\sigma_b^2 [b_{i0}g'^2 - g'(y_{ij} - g(\beta, b_{i0}))]}{g'^2 \sigma_b^2 + \frac{\sigma^2}{n_i}} \right] \right) db_i$$

اکنون براي بدست آوردن مربع بر حسب b_i و حل انتگرال فوق بصورت تحليل با اضافه و کم کردن جمله ي لازم خواهيم داشت :

$$\Rightarrow L_i(\theta | y) \propto c_1 c_2 \exp \left(-\frac{1}{2\sigma^2 \sigma_b^2} \left\{ -\sum_{j=1}^{n_i} \left[\frac{\sigma_b^2 [b_{i0}g'^2 - g'(y_{ij} - g(\beta, b_{i0}))]}{g'^2 \sigma_b^2 + \frac{\sigma^2}{n_i}} \right] \right\} \right)$$

$$\times \int_{-\infty}^{+\infty} \exp \left(-\frac{1}{2\sigma^2 \sigma_b^2} \sum_{j=1}^{n_i} \left[b_i^2 - 2b_i \frac{\sigma_b^2 [b_{i0}g'^2 - g'(y_{ij} - g(\beta, b_{i0}))]}{g'^2 \sigma_b^2 + \frac{\sigma^2}{n_i}} \right] \right) db_i$$

با در نظر گرفتن

$$c_3 = \exp \left(-\frac{1}{2\sigma^2 \sigma_b^2} \left\{ -\sum_{j=1}^{n_i} \left[\frac{\sigma_b^2 [b_{i0}g'^2 - g'(y_{ij} - g(\beta, b_{i0}))]}{g'^2 \sigma_b^2 + \frac{\sigma^2}{n_i}} \right] \right\} \right)$$

خواهيم داشت:

$$L_i(\theta|y) \propto c_1 c_2 c_3 \sqrt{2\pi\sigma_b^2 \sigma^2} \propto c_2 c_3 (\sigma_b^2)^{-\frac{1}{2}} (\sigma_b^2)^{\frac{1}{2}} (\sigma^2)^{-\frac{n_i}{2}} (\sigma^2)^{\frac{1}{2}} \quad (49 \ 3)$$

$$\Rightarrow L_i(\theta|y) \propto c_2 c_3 (\sigma^2)^{\frac{1-n_i}{2}}$$

بنابراین ، با توجه به (45-3) تابع درستنمایی با ضرب کردن تک تک درستنمایی های حساب شده بصورت تحلیلی در فوق، بدست خواهد آمد. این روش بصورت کلی تحت نام تقریب لاپلاس محاسبه می شود توجه به چند نکته در این میان ضروری است:

چنانچه تابع وصل یک تابع خطی باشد ، برآوردگرهای حاصل از ماکزیمم سازی تابع درستنمایی فوق، جوابهای دقیقند. همانطور که مشاهده می شود بسط حول هر مقدار دلخواه مانند b_{i0} تابع درستنمایی تقریب زده شده را پیچیده می کند ، در حالیکه بسط حول مقدار امید ریاضی b_i ، عدد ثابت صفر (استفاده از بسط ماکلورن) بسیار فرم تابع تقریب زده شده را ساده تر می کند. گلدشتین¹ 1991 با بسط تیلور از درجه ی دو حول صفر، مسئله را حل کرده است و همچنین نشان داده است برآوردگرهای حاصل از درستنمایی تقریب زده شده به صورت مجانبی برآوردگرهای درستنمایی ماکزیمم اند. اگر بتوان تابع وصل را با بسط حول b_{i0} بصورت قابل قبولی ، تقریب زد ، برآوردگرهای درستنمایی ماکزیمم ، نیز جوابهای قابل قبولی است. ولفینگر و لین² 1997 بسط را حول $EBLUP^3$ تکرار قبل نوشته اند و شبیه سازی های آنها نشان می دهد با آنکه جوابها کارا تر شده اند ولی تفاوت محسوسی با بسط حول صفر ندارند ، این موضوع نشان می دهد نقطه ای که بسط حول آن نوشته می شود چندان تاثیری بر برآورد پارامترها نمی کند. چنانچه تابع درستنمایی شرطی، نرمال نباشد،

¹ Goldstein

² Wolfinger and Lin

³ Empirical Best Linear Unbiased Predictor

جوابهاي معقولي از ماكزيمم سازي تابع بدست آمده در فوق حاصل نمي شود. چنانچه حجم نمونه ي سطوح بالا (n در مثال فوق) زياد شود تقريبن به علت فرم حاصلضربي خطاهاي احتمالي، به جوابهاي مطلوبي منجر نخواهد شد.

3- 7- بحث ها :

ردرگز و گلدمن¹ 1995 نشان دادند استفاده از روش گلدشتين² 1991 براي مدلهاي آميخته ي دو تايي، (كه اتفاقياً هدف اين پايان نامه است) جوابهاي فوق العاده اريبي براي مؤلفه هاي واريانس مي دهد. طي اين بحث ها گلدشتين و رازباش³ 1996 برآوردگرهاي تصحيح شده ي خود را معرفي كردند، برسلو و لين⁴ 1995 برآوردگرهاي تصحيح شده ي ديگري را معرفي كردند و طي شبیه سازي هاي خود در لين و برسلو⁵ 1996 قابل اعتماد بودن برآوردگرهاي خود را نشان دادند. به هر حال استفاده از روش تربيع گاوس هرميتي از بسط تيلور قابل اعتماد تر است ولي مشكلات محاسباتي آن نيز بيشتري است. همين موضوع استفاده از آنها را در حجم نمونه ي بالا محدود مي كند. به هر حال اگر تابع درستنمايي هر توزيع دلخواه انتخاب شده باشد (معمولاً خانواده ي نمايي) و فرض توزيع آميخته ي نرمال صحيح باشد (با توجه به فرم مدلهاي تعميم يافته ي خطي آميخته و نحوه ي وارد كردن اثرات تصادفي، فرض نرمال بودن آن كاملاً منطقي است) آنگاه جوابهاي تربيع گاوس هرميتي به شرط انتخاب تعداد گره به اندازه ي كافي زياد، جوابهاي درستنمايي واقعي را نتيجه مي دهد.

¹ Rodriguez and Goldman

² Goldstein

³ Goldstein and Rasbash

⁴ Breslow and Lin

⁵ Lin and Breslow

با توجه به اینکه استفاده از تعداد نقاط بیشتر در تربیع گاوس هرمیتی تنها هزینه ی محاسباتی دارد ، مدلهاي مؤلفه ی واریانس دوتایی که در این پایان نامه بحث خواهد شد ، به این روش برآزش خواهند گردید.

3- 3- 8 درونیابی هرمیتی¹

درونیابی یکی از موارد مورد توجه در آنالیز عددی و ریاضیات محاسباتی است که شاید واژه ی مناسب آن در آمار رگرسیون (مخصوصاً رگرسیون ناپارامتری) باشد. مسئله این است : مقادیری از تابع مانند $(x_i, f(x_i))$ را مشاهده کرده ایم به دنبال پیدا کردن تابع مجهول f و یا تقریب آن در حد قابل قبولی هستیم. به بیان دیگر به دنبال روشی هستیم که بتواند تابع f را خوب تقریب بزند. یکی از روشهای معمول استفاده از روش حداقل مربعات است، به این معنا که اگر تعداد مشاهدات $i=1, \dots, n$ باشد ، یک معادله ی حداقلی از درجه ی $n-1$ (با احتساب عرض از مبدا) به آن قابل برآزش است ، توجه داشته باشید به علت اینکه در چنین شرایطی ، مدل اشباع شده خواهیم داشت ، مجموع مربعات خطای چنین رگرسیونی همواره صفر است. مدلهاي اشباع شده از دیدگاه مدلبندی آماری ، چندان مورد توجه نیستند زیرا به تعداد مشاهدات در مدل ، پارامتر وجود دارد.

مسلم است با مطالب گفته شده ، مدل برآزش شده به این روش از هر n نقطه ی مشاهدات می گذرد.

$$y_i = f(x_i) = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_{n-1} x_i^{n-1} \quad (50 \ 3)$$

البته ممکن است تابع چند جمله ای فوق، تابع واقعی f نباشد ، اما اگر فرض کنیم تابع f در شرایط قضیه ی تیلور صدق می کند، حتی اگر این تابع چند جمله ای نباشد، با زیاد کردن مشاهدات (زیاد کردن جملات چند جمله ای) می توانیم خطا را تا هر میزان مورد نظر ، کم کنیم.

¹ Hermit Interpolation

برای فرار از فرمولهای پیچیده جهت برازش مدل‌های چند جمله‌ای اشباع شده، از فرمولهای چند جمله‌ای خاص که مشابه آنها در طرح آزمایشها و رگرسیون با نام تحت نام چند جمله‌ای های متعامد دیده شده است استفاده می‌شود. اکنون به نحوه‌ی درونیابی به کمک این چند جمله‌ای ها می‌پردازیم که راهگشای کار در قسمتهای بعدی است.

تابع $\pi(x)$ را به صورت زیر در نظر بگیرید که m نقطه‌ی (x_i, y_i) مشاهده شده است.

$$\pi(x) = (x-x_1)(x-x_2)\cdots(x-x_m) \quad (51 \ 3)$$

و تابع $l_i(x)$ را به صورت

$$l_i(x) = \frac{\pi(x)}{(x-x_i)\pi'(x)} = \frac{(x-x_1)(x-x_2)\cdots(x-x_{i-1})(x-x_{i+1})\cdots(x-x_m)}{(x_i-x_1)(x_i-x_2)\cdots(x_i-x_{i-1})(x_i-x_{i+1})\cdots(x_i-x_m)} \quad (52 \ 3)$$

$$i=1,\dots,m$$

در نظر بگیرید.

تابع $\pi(x)$ دارای این خاصیت مهم است که

$$\forall i=1,\dots,m \quad \pi(x_i)=0 \quad (53 \ 3)$$

و $l_i(x_j)=\delta_{ij}$ که δ_{ij} ، دلتای کرونکر است به این معنا که

$$\begin{cases} \delta_{ij}=0 & i \neq j \\ \delta_{ij}=1 & i = j \end{cases} \quad (54 \ 3)$$

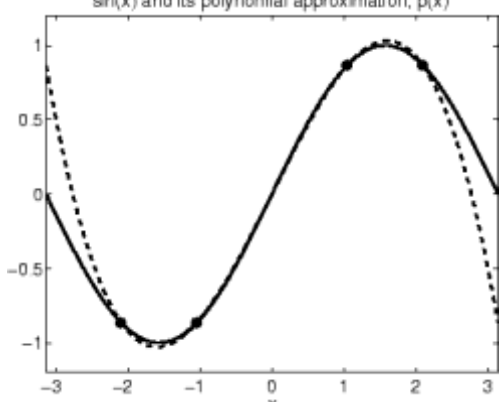
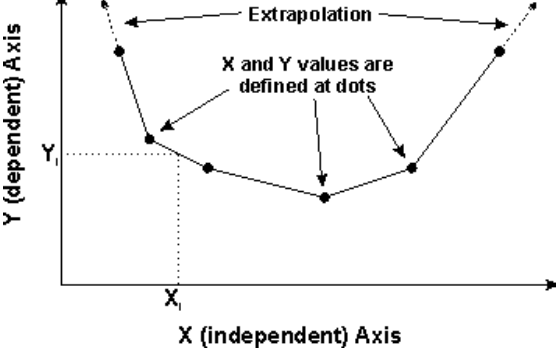
اکنون تابع f را که نقاط (x_i, y_i) را از آن مشاهده کرده ایم به صورت زیر درونیابی می‌کنیم :

$$f(x) = \sum_{i=1}^m l_i(x)y_i \quad (55 \ 3)$$

که تابع f تقریب زده شده در (55-3) دارای

این خاصیت مهم است که از تمامی نقاط

$$\forall i, f(x_i)=y_i \text{ می‌گذرد به عبارت دیگر } i=1,\dots,m.$$

	
<p>نمودار (3 3) : درون یابی تابع سینوس به کمک تابع چند جمله ای در چهار نقطه</p>	<p>نمودار (2 3) : مفهوم درون یابی و برون یابی توابع</p>

برای برآزش یک چندجمله ای از درجه ی $2m-1$ نیاز به داشتن $2m$ اطلاع (مشاهده) داریم این $2m$ اطلاع می تواند با $2m$ زوج (x_i, y_i) و یا m زوج (x_i, y_i) با داشتن m مشتق در آن نقاط یعنی سه تایی (x_i, y_i, y'_i) بدست آید.

در این شرایط فرض کنید m مشاهده از تابع f یعنی m تا از سه تایی های (x_i, y_i, y'_i) ، در اختیار داریم انتظار داریم بتوانیم یک چند جمله ای از درجه ی $2m-1$ بر داده ها برآزش دهیم. تابع f بصورت زیر در این شرایط تقریب زده می شود :

$$f(x) = \sum_{i=1}^m h_i(x)y_i + \sum_{i=1}^m \bar{h}_i(x)y'_i \quad (56 \ 3)$$

که $h_i(x)$ و $\bar{h}_i(x)$ چندجمله ای هایی حداکثر از درجه ی $2m-1$ اند.

برای اینکه تابع درونیابی شده به این روش، از هر m نقطه ی (x_i, y_i) بگذرد، لازم است :

$$h_i(x_j) = \delta_{ij} \quad (57 \ 3)$$

و به علاوه برای اینکه مشتق تابع درونیابی شده از (x_i, y'_i) بگذرد، لازم است

$$\begin{aligned} h'_i(x_j) &= 0 \\ \bar{h}_i(x_j) &= \delta_{ij} \end{aligned} \quad (58 \ 3)$$

تابع l_i ذکر شده در (52-3) به نظر شرایط لازم برای قرار گرفتن به جای تابع h (57-3) را دارد و تنها این مشکل وجود دارد که تابع l از درجه $m-1$ است و بنابراین تابع $[l_i(x)]^2$ از درجه $2m-2$ است و می تواند جایگزین مناسبی برای h_i باشد. با تمام این تفاسیر و برای اینکه درجه i چند جمله ای به $2m-1$ برسد تعریف می کنیم :

$$\begin{aligned} h_i(x) &= r_i(x)[l_i(x)]^2 \\ \bar{h}_i(x) &= s_i(x)[l_i(x)]^2 \end{aligned} \quad (59 \ 3)$$

که توابع r_i و s_i توابعی حداکثر خطی از x هستند و آنها را طوری تعیین می کنیم که شرایط (3-57) و (3-58) برقرار باشند. بنابراین خواهیم داشت :

$$\begin{aligned} r_i(x_i) &= 1 \\ s_i(x_i) &= 0 \end{aligned} \quad (60 \ 3)$$

و به علاوه

$$\begin{aligned} r'_i(x_i) + 2l'_i(x_i) &= 0 \\ s'_i(x_i) &= 1 \end{aligned} \quad (64 \ 3)$$

که دو تابع

$$s_i(x) = x - x_i \quad (62 \ 3)$$

و

$$r_i(x_i) = 1 - 2l'_i(x_i)(x - x_i) \quad (63 \ 3)$$

دارای دو خاصیت (60-3) و (61-3) هستند. با جایگذاری در (59-3)، خواهیم داشت :

$$h_i(x) = [1 - 2l'_i(x_i)(x - x_i)][l_i(x)]^2 \quad (64 \ 3)$$

$$\bar{h}_i(x) = (x - x_i)[l_i(x)]^2 \quad (65 \ 3)$$

که با جایگذاری آن در (3-56)، تابع درونیابی مشخص خواهد شد. به فرمول بدست آمده i ی اخیر، فرمول درونیابی هرمیتی گفته می شود. برای شرایط بیشتر و فرمول کلی با داشتن مشتق مراتب بالاتر به Fort(1948) مراجعه کنید.

3- 3- 9- تربيع هرميتي¹

$\int_a^b w(x)f(x)dx$ که محاسبه ي آن به کمک تابع اوليه يا مشکل است و يا دست نيافتني است را در نظر مي گيريم .

اين در حالي است که $\int_a^b w(x)P_n(x)dx$ ، که P_n یک تابع چند جمله اي از درجه ي n است داراي تابع اوليه ساده است و يا محاسبه ي آن کار ساده اي است. مي توان انتظار داشت که اگر بتوان تابع f را با چند جمله اي P_n خوب تقريب زد ، $\int_a^b w(x)P_n(x)dx$ تقريب خوبي براي $\int_a^b w(x)f(x)dx$ باشد .

با فرض اينکه در m نقطه ، مشتق تابع f در نقاط مورد نظر معلوم است ، f را به روش هرميت ، تقريب مي زنيم :

$$\int_a^b w(x)f(x)dx \cong \sum_{i=1}^m H_i y_i + \sum_{i=1}^m \bar{H}_i y'_i \quad (66 \ 3)$$

$$H_i = \int_a^b w(x)h_i(x)dx = \int_a^b w(x)[l - 2l'_i(x_i)(x - x_i)][l_i(x)]^2 dx \quad (67 \ 3)$$

$$\bar{H}_i = \int_a^b w(x)\bar{h}_i(x)dx = \int_a^b w(x)(x - x_i)[l_i(x)]^2 dx \quad (68 \ 3)$$

بديهي است که مي توان m نقطه را به صورت دلخواه انتخاب کرد. ضمناً خطاي اين تقريب را مي توان توسط تباعي از $f^{(2m)}$ (مشتق مرتبه ي $2m$ از تابع f) و $\int_a^b w(x)[\pi(x)]^2 dx$ محاسبه کرد و تعداد نقاط را طوري در نظر گرفت که تقريب مورد نظر قابل قبول باشد.

ولي مي توان نشان داد انتخاب نقاط با استفاده از یک فرآيند تصادفي در بازه ي (a,b) معمولاً جوابهاي قابل اعتماد تري را نتيجه مي دهد. اين روش معمولاً به تربيع تصادفي² معروف است (مراجعه کنيد به تامپسون³ 2001).

¹ Hermit Quadrature

² Random Quadrature

³ Thompson

3- 3- 10- تربيع گاوسي¹

روش تربيع گاوسي بسيار شبیه تربيع هرميتي است \bar{H}_i را به صورت ديگري نشان مي دهيم:

$$\bar{H}_i = \frac{1}{\pi(x_i)} \int_a^b w(x) \pi(x) l_i(x) dx \quad \text{که } \pi(x) l_i(x) \text{ از درجه ي } 2m-1$$

است. بنابر اين \bar{H}_i به ازاي $i=1, \dots, m$ مقدار صفر مي گيرد و اين در حالي است که دقت تقريب که برازش يک چند جمله اي از $2m-1$ است کماکان حفظ شده است. اگر تابع $\pi(x)$ بر تابع $i=1, \dots, m$ $l_i(x)$ بر بازه $[a, b]$ با تابع وزني $w(x)$ ، عمود باشد يعني:

$$\int_a^b \pi(x) l_i(x) w(x) dx = 0 \quad (69 \ 3)$$

آنگاه مي توان فرمول هرميت (3-66) را به

$$\int_a^b f(x) w(x) dx \cong \sum_{i=1}^m H_i y_i$$

ساده کرد، به علاوه اگر بتوان تابع π تحت شرط (3-69) را به انتگرالهاي نامتناهي نیز تعميم داد و کماکان تقريب مورد نظر با چند جمله اي از درجه ي $2m-1$ است.

فرم اين چند جمله اي ها به ازاي $w(x)$ هاي خاصي تعيين شده است، به عنوان مثال چند جمله اي هاي متعامد بر $l_i(x)$ ها با تابع وزني $w(x) = e^{-x^2}$ به چند جمله اي هاي هرميت مشهورند.

قضيه 1.6: با فرض $w(x) = e^{-\alpha^2 x^2}$ ، چند جمله اي هاي $H_r(x)$ ، با وزن $w(x)$ بر $l_i(x)$ ها عمودند:

$$H_r(x) = (-1)^r e^{x^2} \frac{d^r(e^{-x^2})}{dx^r} \quad (70 \ 3)$$

به بيان ديگر:

$$\int_{-\infty}^{+\infty} H_r(x) l_i(x) e^{-\alpha^2 x^2} dx = 0 \quad (74 \ 3)$$

3- 3- 11- تربيع گاوس هرميتي²

در اين بخش تنها انتگرالهاي به فرم $\int_{-\infty}^{+\infty} f(x) e^{-x^2} dx$

¹ Gaussian Quadrature

² Gauss-Hermit Quadrature

در نظر گرفته می شود ، این فرم انتگرالها در مدلهاي خطي تعمیم یافته ي آمیخته بسیار مورد توجه است و برای محاسبه ي درستنمایی حاشیه اي لازم است بتوان چنین فرم کلی را به ازاي f هاي دلخواه محاسبه کرد. مطالب این بخش بدون اثبات ذکر شده اند و برای مطالعه ي دقیقتر و بررسی اثباتها لازم است به کتب آنالیز عددي مراجعه کنید.

$\pi(x) = \frac{1}{A_m} H_m(x)$ که در آن $A_m = 2^m$ است ضریب A_m به این

علت انتخاب شده است که ضریب بالاترین درجه ي $H_m(x)$ را به یک ، تقلیل دهد.

از طرفي داریم :

$$\int_{-\infty}^{+\infty} e^{-\alpha^2 x^2} [H_r(\alpha x)]^2 dx = \frac{2^r r!}{\alpha} \sqrt{\pi} \quad (72 \ 3)$$

و برای حالت خاص :

$$\int_{-\infty}^{+\infty} e^{-x^2} [H_r(x)]^2 dx = 2^r r! \sqrt{\pi} \quad (73 \ 3)$$

که در آن :

$$H_r(x) = (-1)^r e^{x^2} \frac{d^r(e^{-x^2})}{dx^r} \quad (74 \ 3)$$

با فرمول اخیر ، چند جمله اي هاي اول هرمیت بصورت زیر بدست خواهند آمد :

$$\begin{aligned} H_0(x) &= 1 & H_1(x) &= 2x & H_2(x) &= 4x^2 - 2 \\ (x) &= 8x^3 - 12x & H_4(x) &= 16x^4 - 48x^2 + 12 & H_5(x) &= 32x^5 - 160x^3 + 120x \end{aligned} \quad (75 \ 3)$$

علاوه بر این با داشتن چند جمله ي اول به کمک اتحاد هرمیت ، می توان چند جمله اي هاي درجات بعد را به کمک درجات قبل توسط رابطه ي بازگشتي زیر ساخت :

$$H_r(x) = 2xH_{r-1}(x) - 2(r-1)H_{r-2}(x) \quad (76 \ 3)$$

با توجه به آنچه قبلاً ذکر گردید، اگر $H_m(x)$ را به جای $\pi(x)$ انتخاب کنیم، گره هاي تربیع گاوسي (x_1, \dots, x_m) دیگر دلخواه نخواهند بود، و این گره ها ریشه هاي $H_m(x)$ هستند. بنابراین خواهیم داشت :

$$\int_{-\infty}^{+\infty} f(x) e^{-x^2} dx = \sum_{i=1}^m H_i y_i = \sum_{i=1}^m H_i f(x_i) \quad (77 \ 3)$$

پس از انجام محاسبات خواهیم داشت :

$$H_i = \frac{2^{m+1} m! \sqrt{\pi}}{H_{m+1}(x_i)} \quad (78 \ 3)$$

که x_i ها ریشه های $H_m(x)$ هستند و H_{m+1} چند جمله ای مرتبه ی بعد است.

به عنوان مثال خواهیم داشت :

$$H_3(x) = 0 \Rightarrow \begin{cases} x_1 = -\frac{\sqrt{6}}{2} \\ x_2 = 0 \\ x_3 = \frac{\sqrt{6}}{2} \end{cases} \quad (79 \ 3)$$

$$\Rightarrow \begin{cases} H_1 = \frac{\sqrt{\pi}}{6} \\ H_2 = \frac{2\sqrt{\pi}}{3} \\ H_3 = \frac{\sqrt{\pi}}{6} \end{cases} \quad (80 \ 3)$$

بنابراین داریم :

$$\int_{-\infty}^{+\infty} f(x) e^{-x^2} dx \cong \frac{\sqrt{\pi}}{6} \left[f\left(-\frac{\sqrt{6}}{2}\right) + 4f(0) + f\left(+\frac{\sqrt{6}}{2}\right) \right] \quad (84 \ 3)$$

با ایده گرفتن از تقریب انتگرالهای فوق به روش گاوس هرمیت و محاسبه ی گره ها و وزنهای طوری که تابع درستنمایی حاشیه ای ماکزیمم شود ، می توان به برآوردگرهای $NPML^1$ دست یافت. لایرد ² 1978 نحوه ی برآورد درستنمایی ناپارامتری را به کمک الگوریتم EM ، برای توزیع آمیخته ، تشریح کرده است و ایتکین ³ 1999 آن را برای مدل دوتایی آمیخته به کار برده است.

استفاده از برآوردگرهای NPML از این جهت اهمیت دارد که هکمن و سینگر ⁴ 1984 طی شبیه سازی نشان

¹ Non-Parametric Maximum Likelihood

² Laird

³ Aitkin

⁴ Heckman and Singer

داده اند اگر فرض نرمال بودن اثرات تصادفی نادرست باشد، برآوردگرهای بدست آمده از تقریب های دیگر نامناسب است و در مقابل روش NPML¹، برآوردگرهای مناسبی ارائه می دهد. دیویس¹ 1987 نیز نشان داد برآورد مؤلفه های واریانس نسبت به انتخاب توزیع آمیخته، حساس است که نتایج هکمن و سینگر² 1984 را تایید می کرد. طی شبیه سازی های انجام شده در ردیگز و گلدمن³ 1995 برآوردهای مؤلفه ی واریانس در توزیع دو جمله ای به روش بسط تیلور، جوابهای نامناسبی گزارش می دهد زیرا برآوردگرهای درستنمایی ماکزیمم با بسط تیلور، زمانی بدست می آید که توزیع شرطی نرمال باشد، اگر توزیع دو جمله ای با توزیع نرمال خوب تقریب نخورد (مخصوصاً در حجم نمونه ی کم در داخلی ترین سطح داده ها و یا نسبت بسیار بالا و یا بسیار پایین در سطوح مختلف داده ها).

در چنین شرایطی می توان از تربیع گاوس هرمیتی با تعداد گره های کافی استفاده کرد. تنها مشکل استفاده از تربیع گاوس هرمیتی که در ورمونت⁴ 2003 نیز اشاره شده است این است که تعداد محاسبات برای بدست آوردن درستنمایی حاشیه ای با زیاد شدن گره ها و یا به زیاد شدن سطوح بالاتر از 1، به صورت نمایی افزایش می یابد و این موضوع ممکن است روش تربیع گاوس هرمیتی و یا روش NPML را برای برآزش داده ها دچار مشکل کند. تربیع گاوس هرمیتی با 5 و یا 10 نقطه معمولاً جوابهای قابل قبولی ارائه می دهند ولی با توجه به اینکه گره ها را نمیتوان انتخاب کرد و ریشه های چند جمله ای های هرمیت هستند، گاهی اوقات برای پوشاندن تمام دامنه ی تابع شرطی لازم است

¹ Davies

² Heckman and Singer

³ Rodriguez and Goldman

⁴ Vermunt

تعداد گره ها بسیار افزایش پیدا کند در چنین مواقعی پیشنهاد می شود تابع درستنمایی شرطی حول ماکزیمم خود مرکزیت داده شود. در این صورت می توان با تعداد گره های کم ، نتیجه ی قابل قبولی گرفت. لیو و پیرس¹ 1994 این روش را با نام تربیع گاوس هرمیتی وفقی² معرفی کردند. گاهی اوقات ماکزیمم سازی تابع درستنمایی شرطی جهت مرکزیت سازی تابع درستنمایی شرطی ، خود یک معضل است. رابه³ و همکاران 2000 تقریب تابع درستنمایی شرطی را توسط تقریب لاپلاس پیشنهاد می دهد ، لزافر و اسپینس⁴ 2000 نشان دادند استفاده از روش گاوس هرمیت معمولی با تعداد نقاط زیاد با روش گاوس هرمیت وفقی با تعداد نقاط کم در داده های دوتایی نتیجه ی تقریباً یکسانی نشان می دهد.

با توجه به اینکه در مسئله ی تحلیل سیستمهای اندازه گیری کیفی، داده ها دوتایی اند و از طرفی مشکلات استفاده از روش گاوس هرمیت وفقی ، از لحاظ زمانی (به علت ماکزیمم سازی عددی تابع درستنمایی شرطی) مقرون به صرفه نیست ترجیح می دهیم از روش گاوس هرمیت معمولی با تعداد نقاط زیاد استفاده کنیم .

از طرفی در آبرامویتز و استگون⁵ 1965، جدول حداکثر تعداد 20 گره و وزن برای تقریب گاوس هرمیتی گزارش شده است.

با توجه به آنچه توضیح داده شده است برنامه ی نوشته شده در این پایان نامه، این قابلیت را دارد که تا انتخاب هر تعداد گره دلخواه نتایج را گزارش دهد.

چند جمله ای های هرمیت به کمک معادله ی بازگشتی

¹ Liu and Pierce

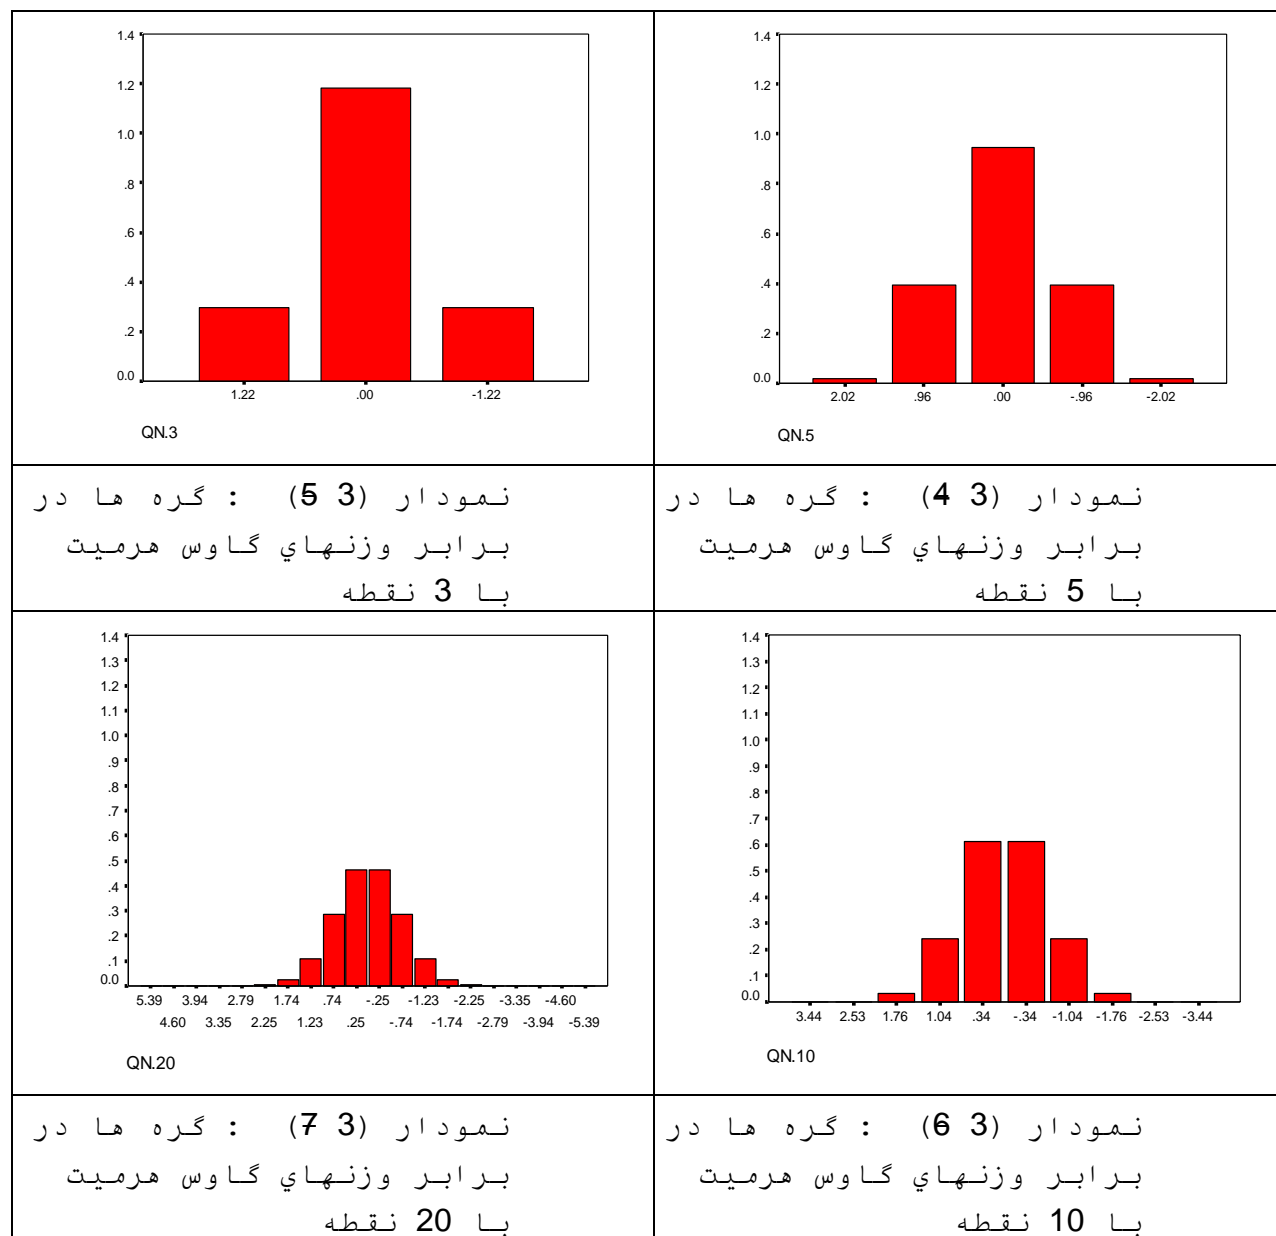
² Adaptive Gauss-Hermit Quadrature

³ Rabe

⁴ Lesaffre and Spiessens

⁵ Abramowitz and Stegun

(3-76) در نرم افزار Maple بدست آمده است و ریشه های آن به کمک تابع polyroot در Splus محاسبه شده اند. جوابهای بدست آمده تا 20 گره با جدول آبرامویتز و استگون 1965 مطابقت داشته است.



همانطور که مشاهده می شود دامنه ی گره ها به سرعت افزایش نمی یابد و با توجه به وزن بسیار کم گره های فرین ، تنها در صورتی جوابهای درستنمایی با گره های بالا جوابهای متفاوتی خواهند داشت که تابع درستنمایی شرطی در مقادیر

دور از صفر ، مقدار تابع بالایی داشته باشند.

3-4 مدل‌بندی با اثرات تصادفی و محاسبه ی تابع درست‌نمایی حاشیه ای

در فصل 2 ، 2 - 2 و فصل 3 سه دیدگاه مختلف بر تحلیل سیستم های اندازه گیری کیفی را مرور کردیم و تنها در فصل 3 دیدگاه مدل‌بندی آماری را بر مسئله ی تحلیل سیستم‌های اندازه گیری داشته ایم .

یکی از اشکالاتی که بر دیدگاه های قبل می توان گرفت ، این موضوع است که در فصول قبل ، فرض شده است که افراد در تکرار های خود روی قطعات ، مستقل از همدیگر تصمیم می گیرند حال آنکه اگر سیستم اندازه گیری دارای شرایط نامطلوبی باشد ، به افراد و یا به تکرارهای تک تک بازرسان وابسته است و در نظر گرفتن این وابستگی به قابل اعتماد تر شدن نتایج بیشتر کمک می کند. به علاوه در نظر نگرفتن چنین وابستگی هایی ممکن است به نتایج نادرستی منجر شود.

3-4-1 مدل‌بندی اندازه گیری (مدل با اثرات متقابل)

همانند مدل ارائه شده در بوردیک¹ و همکاران 2003 و مونتگمری² 1991 ، استقلال حاشیه ای را به استقلال شرطی تقلیل می دهیم :

در مدل خطی ارائه شده در مونتگمری 1993 :

$$y_{ijk} | O_i, P_j, OP_{ij} = \mu + O_i + P_j + OP_{ij} + \varepsilon_{ijk}$$

$$i = 1, \dots, n_O$$

$$j = 1, \dots, n_P$$

$$k = 1, \dots, n_R$$

(82 3)

که y_{ijk} تصمیم فرد i ام روی قطعه ی j ام در تکرار

¹ Burdick

² Montgomery

k ام روی آن قطعه است که μ اثر ثابت است و اثرات تصادفی O_i ، P_j و OP_{ij} مستقل از خطا و مستقل از همدیگر دارای توزیع نرمال هستند:

$$\begin{aligned} O_i &\sim N(0, \sigma_O^2) \quad P_j \sim N(0, \sigma_P^2) \quad OP_{ij} \sim N(0, \sigma_{OP}^2) \\ \varepsilon_{ijk} &\sim N(0, \sigma^2) \end{aligned} \quad (83 \quad 3)$$

تعمیم این مدل، به مدلی که بتواند در قالب مدل خطی تعمیم یافته قرار بگیرد به صورت زیر خواهد بود:

$$\begin{aligned} y_{ijk} | O_i, P_j, OP_{ij} &\sim N(\mu_{ij}, \sigma^2) \\ \mu_{ij} &= O_i + P_j + OP_{ij} \end{aligned} \quad (84 \quad 3)$$

جهت نوشتن تابع درستنمایی و با توجه به شرایط آزمایشی، فرض های زیر ضروری و منطقی است:

$$y_{ijk} | O_i, P_j, OP_{ij} \perp y_{ijk'} | O_i, P_j, OP_{ij} \quad (85 \quad 3)$$

$$y_{ij*} | O_i \perp y_{ij'*} | O_i \quad (86 \quad 3)$$

$$y_{i**} \perp y_{i'*} \quad (87 \quad 3)$$

که علامت \perp به معنای استقلال و $*$ به معنای دلخواه بودن اندیس است. با بازنویسی مناسب مدل برای توزیع شرطی دو جمله ای خواهیم داشت:

$$\begin{aligned} y_{ijk} | O_i, P_j, OP_{ij} &\sim \text{Bin}(1, \mu_{ij}) \\ \mu_{ij} &= g^{-1}(\mu + O_i + P_j + OP_{ij}) \end{aligned} \quad (88 \quad 3)$$

که g تابع وصل (ترجیحاً تابع وصل متعارف) است که در مسئله ی توزیع دوجمله ای:

$$g(x) = \log\left(\frac{x}{1-x}\right) \quad (89 \quad 3)$$

با توجه به فرضهای گفته شده در (85-3)، (86-3) و (87-3)، برای نوشتن تابع درستنمایی حاشیه ای داریم:

$$L(\theta) = \prod_{i=1}^{n_O} \prod_{j=1}^{n_P} \prod_{k=1}^{n_R} f(y_{ijk} | O_i, P_j, OP_{ij}) dF_{OP_{ij}} dF_{P_j} dF_{O_i} \quad (90 \quad 3)$$

که در آن $\theta = (\mu, \sigma_O, \sigma_P, \sigma_{OP})$ است.

با توجه به اینکه توزیع شرطی، توزیع برنولی است، داریم:

$$L(\theta) = \prod_{i=1}^{n_O} \prod_{j=1}^{n_P} \int \prod_{k=1}^{n_R} \mu_{ij}^{y_{jk}} (1 - \mu_{ij})^{1-y_{jk}} dF_{OP_{ij}} dF_{P_j} dF_{O_i} \quad (94 \ 3)$$

که در آن $F_{OP_{ij}}$ تابع توزیع $N(0, \sigma_{OP}^2)$ ، F_{P_j} تابع توزیع $N(0, \sigma_P^2)$ و F_{O_i} تابع توزیع $N(0, \sigma_O^2)$ است. با جایگذاری $\eta_{ij} = \mu + O_i + P_j + OP_{ij}$ که η_{ij} پیشگوی خطی است و

$$\mu_{ij} = \frac{\exp(\eta_{ij})}{1 + \exp(\eta_{ij})} \quad (92 \ 3)$$

و ساده کردن عبارات داریم :

$$L(\theta) = \prod_{i=1}^{n_O} \prod_{j=1}^{n_P} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \prod_{k=1}^{n_R} \frac{\exp\left(\eta_{ij} \sum_{k=1}^{n_R} y_{ijk}\right)}{\left(1 + \exp\left(\eta_{ij} \sum_{k=1}^{n_R} y_{ijk}\right)\right)^{n_R}} dF_{OP_{ij}} dF_{P_j} dF_{O_i} \quad (93 \ 3)$$

جهت سهولت و یکسان سازی توابع توزیعی که در انتگرال لبگ - اشتیلیس بالا حضور دارند ، پیشگوی خطی را با کمی تغییر در نظر می گیریم :

$$\eta_{ij} = \mu + \sigma_O^2 O_i + \sigma_P^2 P_j + \sigma_{OP}^2 OP_{ij} \quad (94 \ 3)$$

با این تغییر متغیر ، تابع درستنمایی (93-3) به فرم زیر قابل نوشتن است :

$$L(\theta) = \prod_{i=1}^{n_O} \prod_{j=1}^{n_P} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \prod_{k=1}^{n_R} \frac{\exp(\eta_{ij} y_{ij.})}{\left(1 + \exp\left(\eta_{ij} \sum_{k=1}^{n_R} y_{ijk}\right)\right)^{n_R}} d\Phi_{OP_{ij}} d\Phi_{P_j} d\Phi_{O_i} \quad (95 \ 3)$$

که در آن Φ تابع توزیع نرمال استاندارد و $y_{ij.} = \sum_{k=1}^{n_R} y_{ijk}$ است.

با توجه به آنچه در 3 - 3 - 6 بیان شد ، قابل حل نیست زیرا تابع وصل ، یک تابع غیر خطی از اثرات تصادفی O_i ، P_j و OP_{ij} است.

حتی اگر تابع وصل نیز خطی می بود ، به علت اینکه توزیع نرمال با توزیع دو جمله ای مزدوج نیست و با توجه به منحصر به فرد بودن توزیع های مزدوج در خانواده های نمایی ، نمی توان با بسط

تیلور اثرات تصادفی نیز مسئله را حل کرد مگر اینکه فرض کرد این توزیع با توزیع مزدوج (نرمال) خوب تقریب بخورد که در حجم نمونه n کم در داخلی ترین سطح (n_R کم) مقدور نیست.

باید توجه داشت که تابع $nlme$ در نرم افزار **SPlus** که جهت برآزش مدل‌های غیر خطی آمیخته به روش لینداستورم و بیتس¹ 1990 نوشته شده است از روش بسط تیلور بهره می برد که تنها زمانی جواب درست‌نمایی ماکزیمم است که توزیع شرطی نرمال باشد و یا با نرمال ، خوب تقریب بخورد.

این در حالی است که تعداد تکرارها $n_R=3$ است و تابع توزیع داخلی ترین انتگرال ، $Bin(3, \mu_{ij})$ است که تایید می کند جواب‌های نامناسبی برای پارامترها خواهد داشت.

جزئیات برآزش تابع $nlme$ و نحوه ی کاربرد آن در مدل‌های غیر خطی (مخصوصاً مدل‌های سنیتیک دارویی) در پینهیرو و بیتس² 2000 آمده است.

ناچاراً انتگرال $(3-95)$ را به روش تربیع گاوس هرمیتی تقریب عددی می زنیم.

از طرفی چون تابع وزن ، به صورت $e^{-\frac{x^2}{2}}$ است نه e^{-x^2} که جداول گاوس هرمیت بر اساس آن طرح شده اند نیاز داریم بتوانیم از طریق جدول گاوس هرمیت ، انتگرال‌های به فرم $\int_{-\infty}^{+\infty} g(x) e^{-\frac{x^2}{2}} dx$ را تقریب بزنیم در حالی که گره ها و وزن‌های گاوس هرمیت برای انتگرال‌های به فرم $\int_{-\infty}^{+\infty} g(x) e^{-x^2} dx$ است.

این مشکل با تغییر متغیر $z = \frac{x}{\sqrt{2}}$ ، به راحتی قابل حل است:

$$\int_{-\infty}^{+\infty} g(x) e^{-\frac{x^2}{2}} dx = \sqrt{2} \int_{-\infty}^{+\infty} g(\sqrt{2}z) e^{-z^2} dz \quad (96 \ 3)$$

با تمام این تفاسیر ، پس از تقریب داخلی ترین

¹ Lindstorm and Bates

² Pinheiro and Bates

انتگرال (95-3) ، داریم :

$$L(\theta) \approx \prod_{i=1}^{n_O} \int_{-\infty}^{+\infty} \prod_{j=1}^{n_P} \int_{-\infty}^{+\infty} \sum_{t=1}^{nqn_{OP}} w_{OP}^0(t) \left[\frac{\exp\left((\mu + \sqrt{2}\sigma_O O_i + \sqrt{2}\sigma_P P_j + \sqrt{2}\sigma_{OP} OP^0(t))y_{ij.}\right)}{\left(1 + \exp\left((\mu + \sqrt{2}\sigma_O O_i + \sqrt{2}\sigma_P P_j + \sqrt{2}\sigma_{OP} OP^0(t))y_{ij.}\right)\right)^{n_R}} \right] d\Phi_{P_j} d\Phi_{O_i} \quad (97 \ 3)$$

که در آن $OP^0(t)$ و $w_{OP}^0(t)$ به ترتیب گره ها (نقاط قطع) و وزنهای تقریب گاوس هرمیت هستند که با nqn_{OP} نقطه ی تربیع ، تقریب شده اند که از جداول آبراموویتز و استگون¹ 1965 قابل استخراج و یا توجه به توضیحات 3 - 3 - 11 قابل محاسبه اند. از طرفی باقی انتگرالها (97-3) نیز از لحاظ تحلیلی غیر قابل محاسبه اند و بطور مشابه به روش تربیع گاوس هرمیتی تقریب زده می شوند. لذا خواهیم داشت :

$$\ell(\theta) \approx \sum_{i=1}^{n_O} \log \left\{ \sum_{v=1}^{nqn_O} w_O^0(v) \prod_{j=1}^{n_P} \sum_{u=1}^{nqn_P} w_P^0(u) \sum_{t=1}^{nqn_{OP}} w_{OP}^0(t) \left[\frac{\exp\left((\mu + \sqrt{2}\sigma_O O^0(v) + \sqrt{2}\sigma_P P^0(u) + \sqrt{2}\sigma_{OP} OP^0(t))y_{ij.}\right)}{\left(1 + \exp\left((\mu + \sqrt{2}\sigma_O O^0(v) + \sqrt{2}\sigma_P P^0(u) + \sqrt{2}\sigma_{OP} OP^0(t))y_{ij.}\right)\right)^{n_R}} \right] \right\} \quad (98 \ 3)$$

با معلوم بودن nqn_{OP} ، nqn_P و nqn_O ، می توان تابع درستنمایی را بصورت تقریبی محاسبه کرد و دقت محاسبات با افزایش تعداد نقاط قطع ، افزایش می یابد.

تابع تقریب زده شده به کمک روش شبه نیوتن و با استفاده از تابع `nlminb` در نرم افزار `SPlus` با محدودیتهای $\sigma_O > 0$ ، $\sigma_P > 0$ و $\sigma_{OP} > 0$ ، ماکزیمم خواهد شد و برآوردهای درستنمایی حاشیه ای پارامترها یعنی $(\hat{\mu}, \hat{\sigma}_O, \hat{\sigma}_P, \hat{\sigma}_{OP})$ محاسبه خواهند گردید.

¹ Abromowitz and Stegun

3- 4- 2 مدل‌بندی تاثیر پذیری (مدل آشیانه ای)

در بخش 3 - 4 - 1 فرض شده است تصمیم فرد بر روی قطعه (به کمک سیستم اندازه گیری) به شرط افراد و قطعات از هم مستقلند. استقلال تکرارها به شرط افراد و قطعات همانطور که اشاره شد، یک مدل با اثرات متقابل پیشنهاد داد. اکنون معنای صفر و یک بودن را از (خراب و درست) تشخیص دادن قطعه به تشخیص صحیح تغییر می دهیم. منطقی است که فرض کنیم قدرت تشخیص صحیح قطعات برای سیستم اندازه گیری به شرط تکرار و افراد مستقل از هم روی قطعات مختلف، مستقل از هم تغییر می کند. با این توصیفات مدل زیر برای داده ها پیشنهاد می شود:

$y_{ijk}=1$ اگر تصمیم با واقعیت قطعه تطابق داشته باشد.

$y_{ijk}=0$ اگر تصمیم با واقعیت قطعه تطابق نداشته باشد.

که y_{ijk} تصمیم کاربر i ام در تکرار j ام روی قطعه k است.

مدل پیشنهادی به صورت:

$$y_{ijk} | \mu_{ij} \sim \text{Bin}(1, \mu_{ij})$$

$$\mu_{ij} | O_i, R_{ij} = g^{-1}(\mu + O_i + R_{ij}) \quad (99 \ 3)$$

این مدل شبیه مدل اندازه های تکرار شده اندرسون و ایتکین¹ 1985 است. فرضهای زیر برای نوشتن تابع درستنمایی حاشیه ای ضروری و منطقی است:

$$y_{ijk} | O_i, R_{ij} \perp y_{ijk'} | O_i, R_{ij} \quad (100 \ 3)$$

$$y_{ij*} | O_i \perp y_{ij'*} | O_i \quad (104 \ 3)$$

$$y_{i**} \perp y_{i'**} \quad (102 \ 3)$$

بنابراین تابع درستنمایی حاشیه ای به صورت زیر گزارش محاسبه می شود:

¹ Anderson and Aitkin

$$L(\theta) = \prod_{i=1}^{n_o} \prod_{j=1}^{n_R} \int \frac{\exp[(\mu + O_i + R_{ij})y_{ij.}]}{(1 + \exp[(\mu + O_i + R_{ij})y_{ij.}])^{n_p}} dF_{R_{ij}} dF_{O_i} \quad (103 \ 3)$$

با توجه به اینکه $F_{R_{ij}}$ تابع توزیع $N(0, \sigma_R^2)$ و F_{O_i} تابع توزیع $N(0, \sigma_O^2)$ است، انتگرالهای فوق از لحاظ تحلیلی غیر قابل محاسبه اند. با استفاده از تقریب گاوس هرمیتی برای انتگرالها، لگاریتم تابع درستنمایی حاشیه ای، به صورت زیر خواهد بود:

$$\ell(\theta) \approx \sum_{i=1}^{n_o} \log \left\{ \frac{\sum_{v=1}^{n_q n_o} w_o^0(v) \prod_{j=1}^{n_R} \sum_{u=1}^{n_q n_R} w_R^0(u) \exp[(\mu + \sqrt{2}\sigma_O O^0(v) + \sqrt{2}\sigma_R R^0(u))y_{ij.}]}{(1 + \exp[(\mu + \sqrt{2}\sigma_O O^0(v) + \sqrt{2}\sigma_R R^0(u))y_{ij.}])^{n_p}} \right\} \quad (104 \ 3)$$

که در آن $(R^0(u), O^0(v))$ و $(w_R^0(u), w_O^0(v))$ به ترتیب، نقاط قطع و وزنهای گاوس هرمیت هستند.

3-4-3 مدل آستانه ای دوتایی¹ و تعبیر آن در تحلیل سیستمهای اندازه گیری کیفی

مدلهای دوتایی از کیفی سازی یک متغیر کمی نیز بدست می آید که تعابیر مناسبی در تحلیل سیستمهای اندازه گیری کیفی و بالاحص سیستمهای اندازه گیری کمی کیفی شده (مانند گنج های برو - نرو) دارند.

فرض کنید $z_{ijk} | O_i, R_{ij} \sim F^{iid}$ متغیر پیوسته ای از توزیع هموار و پیوسته ای F با میانگین $\mu_{ij} = \mu + O_i + R_{ij}$ تولید شود یا به بیان بهتر:

$$z_{ijk} | O_i, R_{ij} = \mu + O_i + R_{ij} + \varepsilon_{ijk} \quad (105 \ 3)$$

که در آن ε_{ijk} دارای توزیعی هموار با میانگین صفر مانند F است.

در حالت خاص، فرض کنید F توزیع لجستیک با پارامتر مقیاس 1 است. داده ای پیوسته ای z_{ijk} در

¹Binary Threshold Model

نقطه ي نامعلومي مانند t_{ij} قطع مي شود و متغير جديد y_{ijk} را مي سازد . بدون از دست دادن كلت مسئله و جهت قابل تشخيص بودن¹ پارامترها فرض مي كنيم $t_{ij} = 0$.

$y_{ijk} = 1$ اگر $z_{ijk} > t_{ij}$ و $y_{ijk} = 0$ اگر $z_{ijk} \leq t_{ij}$ با توجه به فرض لجستيك بودن توزيع z_{ijk} ، داريم :

$$\begin{aligned} \Pr(y_{ijk} = 1 | O_i, R_{ij}) &= \Pr(z_{ijk} > 0 | O_i, R_{ij}) \\ &= \Pr(\mu + O_i + R_{ij} + \varepsilon_{ijk} > 0 | O_i, R_{ij}) \\ &= \Pr(\varepsilon_{ijk} > -(\mu + O_i + R_{ij}) | O_i, R_{ij}) = \Pr(-\varepsilon_{ijk} \leq (\mu + O_i + R_{ij}) | O_i, R_{ij}) \end{aligned}$$

از طرفي توزيع لجستيك استاندارد حول صفر متقارن است بنابراين $-\varepsilon_{ijk}$ نيز داراي توزيع لجستيك

استاندارد است بنابراين داريم :

$$\begin{aligned} \Pr(-\varepsilon_{ijk} \leq (\mu + O_i + R_{ij}) | O_i, R_{ij}) &= \Pr(\varepsilon_{ijk} \leq (\mu + O_i + R_{ij}) | O_i, R_{ij}) \\ &= \frac{\exp(\mu + O_i + R_{ij})}{1 + \exp(\mu + O_i + R_{ij})} \end{aligned}$$

که با مدل (3-99) با فرض $g(x) = \log\left(\frac{x}{1-x}\right)$ (وصل

لجيت) معادل است .

مدل دوتايي آستانه اي را مي توان به اين صورت تعبير کرد سيستم اندازه گيري قطعه را زماني درست تشخيص مي دهد که شباهت آن به قطعه ي صحيح ايده آل از آستانه ي نامعلومي تجاوز کند.

3-5 آزمون R&R در مدلهاي اثرات تصادفي

در مدلهاي مزدوج استفاده از عامل بيز کار را براي انتخاب مدل ساده نمود در اين فصل روشي شهودي براي آزمون R&R معرفي مي كنيم و نشان مي دهيم به کمک دیدگاه بيزي مي توان مسئله را به کمک عامل بيز حل کرد.

همانطور که از نحوه ي مدلبندي در 3 - 4 - 1 مي توان فهميد ، یک سيستم اندازه گيري R&R

¹ Identifiability

سیستمی است که $\sigma_o^2 = \sigma_{op}^2 = 0$ باشد ، آزمونهای معمول مؤلفه های واریانس در مدل های خطی توسط آنالیز واریانس قابل حل است که در مدل های خطی تعمیم یافته ، فرض های لازم برای آزمون آن به روش آنالیز واریانس وجود ندارد. یکی از راهکارهای ممکن استفاده از آزمون نسبت درستنمایی تعمیم یافته است. متأسفانه زمانی که پارامترها در مرز قرار داشته باشند قضیه ی ویلکس (مراجعه کنید به ویلکس¹ 1963) به علت استفاده از بسط تیلور برای تقریب $-2\log(lik)$ دیگر برقرار نیست زیرا در اثبات آن از بسط تیلور مرتبه ی 2 استفاده شده است و زمانی که پارامتر در مرز باشد ، تابع درستنمایی تنها از یک طرف مشتق دارد و بنابراین شرایط قضیه ی ویلکس برقرار نیست. مشکل آزمون درستنمایی تعمیم یافته ی مؤلفه های واریانس تنها محدود به مدل های گسسته نیست ، در مدل های مؤلفه ی واریانس نرمال با صفر نیز در $-2\log(lik)$ دارای مشکل مشابه است (مراجعه کنید به میلر² 1977) .

اگر مدل تحت بررسی تنها دارای یک مؤلفه ی واریانس (σ_b^2) باشد، آماره ی ویلکس برای آزمون مؤلفه ی واریانس

$$\begin{cases} H_0 : \sigma_b^2 = 0 \\ H_1 : \sigma_b^2 > 0 \end{cases} \quad (106 \ 3)$$

آمیژه ای از توزیع کی دو و تباهیده است (مراجعه کنید به سلف و لیانگ³ 1987) .

لین⁴ 1997 اخیراً آزمون های امتیاز کارا ی مؤلفه های واریانس را در حالت کلی بدست آورده است و نیز نشان داده است این دسته از آزمون ها، بطور مجانبی دقیقترین آزمون موضعی است. بهات و

¹ Wilks

² Miller

³ Self and Liang

⁴ Lin

ناگنور¹ 1965 نشان داده اند براي آزمون بيش از يك مؤلفه ي واريانس با صفر، بطور مجانبی و پرتوان ترين آزمون موضعی² وجود ندارد و بطور مجانبی و دقیقترین آزمون موضعی³ را معرفی کردند.

مشکل استفاده از روش لین 1997 خاصیت مجانبی آن است، زیرا براي اینکه آماره ي تحت بررسی دارای توزیع کي دو باشد، لازم است سطوح معادل مؤلفه ي واريانس به سمت بینهایت میل کند، این در حالی است که طبق طراحی راهنمای MSA تعداد سطوح معادل مؤلفه هاي واريانس برابر 3 است که نتایج قابل قبولی ارائه نخواهد داد. مدل مؤلفه ي واريانس دوتایی بررسی شده در لین 1997 که در شبیه سازی ها جوابهای قابل قبولی براي این چنین آزمونها ارائه داده اند دارای حداقل حجم نمونه ي 15 در سطوح مرتبط با مؤلفه ي واريانس بوده است.

راه مناسب دیگر، استفاده از روش خودگردان افرن⁴ 1979 براي تعیین توزیع آماره ي نسبت درستنمایی است. راه ساده ي دیگر بدون استفاده از آماره ي نسبت درستنمایی، استفاده از P -مقدار تجربی⁵ به کمک روش خود گردان است. استفاده از بازه هاي اطمینان مؤلفه هاي واريانس براي آزمون آنها نیز روش دیگری است.

3- 5- 2- روش P -مقدار تجربی

این روش اساساً به دو مرحله تقسیم می شود: مرحله ي برازش و مرحله ي شبیه سازی که P -مقدار بدست آمده از این روش حتی براي حجم هاي نمونه ي پایین در سطوح مؤلفه هاي واريانس نیز قابل

¹ Bhatt and Nagnur

² Asymptotically Locally Most Powerful Test

³ Asymptotically Locally Most Stringent Test

⁴ Efron

⁵ Empirical P-Value

اعتماد است.

مرحله ي برازش

اگر مؤلفه هاي واريانس موجود در فرضيه ي صفر را با θ_1 و باقي پارامترها را با θ_2 نشان دهيم

$$\theta = \begin{pmatrix} \theta_1 \\ \dots \\ \theta_2 \end{pmatrix} \quad (107 \ 3)$$

علاقمنند به آزمون :

$$\begin{cases} H_0 : \theta_1 = 0 \\ H_1 : \theta_1 > 0 \end{cases} \quad (108 \ 3)$$

هستيم. در ابتدا بايد مدل واريانس مناسب بر مجموعه داده ي مورد نظر (D) برازش شود برآوردهاي درستنمايي ماكزيمم تاممي پارامترها محاسبه شوند

$$\hat{\theta}_{ML} = \begin{pmatrix} \hat{\theta}_{1ML} \\ \dots \\ \hat{\theta}_{2ML} \end{pmatrix} \quad (109 \ 3)$$

مرحله ي شبیه سازی

مجموعه داده ي $D_m, m=1 \dots B$ که B تکرار بوت استرپ است، تحت فرضيه ي صفر توليد مي شود :

$$\theta = \begin{pmatrix} \theta_1 = 0 \\ \dots \\ \theta_2 = \hat{\theta}_{2ML} \end{pmatrix} \quad (110 \ 3)$$

برآوردهاي درستنمايي ماكزيمم براي مجموعه داده ي D_m

$$\hat{\theta}_{ML}^{(m)} = \begin{pmatrix} \hat{\theta}_{1ML}^{(m)} \\ \dots \\ \hat{\theta}_{2ML}^{(m)} \end{pmatrix} \quad (114 \ 3)$$

محاسبه مي شود.

P -مقدار تجربي به روش بوت استرپ، به صورت زیر بدست خواهد آمد:

$$P-Value = \frac{\#(\hat{\theta}_{1ML}^{(m)} > \hat{\theta}_{1ML})}{B} \quad (112 \ 3)$$

که $\hat{\theta}_{1ML}^{(m)} > \hat{\theta}_{1ML}$ است اگر حداقل يکي از اعضاي بردار $\hat{\theta}_{1ML}^{(m)}$ از $\hat{\theta}_{1ML}$ بزرگتر باشد.

مزیت استفاده از این روش ، عدم استفاده از
آزمونهای نسبت درستنمایی تعمیم یافته و بدست
آوردن P -مقدار آزمون بدون استفاده از کمیت
محوری است.

3- 5- 3 روش بازه های اطمینان بوت استرپ

با استفاده از این روش ، بازه های اطمینان برای
تک تک مؤلفه های واریانس بدست خواهد آمد ،
فرضیه H_0 رد می شود اگر مقدار صفر در حداقل
یکی از بازه های اطمینان مؤلفه های واریانس
بردار θ_1 وجود نداشته باشد.
برای بدست آوردن بازه ی اطمینان بوت استرپ برای
مؤلفه های واریانس، پس از برازش مدل مورد نظر
بر مجموعه ی داده ی اصلی D و محاسبه ی (3-
(109)

مجموعه ی داده ی D_m با پارامترهای (3-109)
تولید می کنیم

بعد از برازش همان مدل ، برآورد درستنمایی
ماکزیمم (3-111) را محاسبه می کنیم .
بازه ی اطمینان بوت استرپ $1-\alpha$ درصدی ، چندانک
مرتبه ی $\alpha/2$ و $1-\alpha/2$ مؤلفه های واریانس محاسبه
شده در (3-111) است.

فصل 4

محکهای R&R

4-1- مقدمه

در سه فصل اخیر سه مدل مختلف پیشنهاد شده است که هر کدام مزایا و معایبی دارند . مدل مزدوج ، تاثیر پذیری را مدل می کند و می تواند R&R بودن سیستم اندازه گیری را به کمک عامل بیز آزمون کند، به علاوه در همین مدل می توان تاثیر پذیری سیستم اندازه گیری را که یکی از مراجع تصمیم گیری در راهنمای MSA است را به کمک عامل بیز بررسی کرد. با توجه به اینکه اگر آماردان توزیع پیشین مشخصی مد نظر نداشته باشد، با چند دیدگاه متفاوت می توان توزیع های پیشین متفاوتی از فرم توزیع بتا برای آن در نظر گرفت که لزوماً منجر به تصمیم های یکسانی نخواهد شد و این یک ضعف محسوب می شود. تعریف محک R&R متناسب با تغییرات سیستم اندازه گیری در مدل اثرات متقابل از نقاط قوت آن است ولی این مدل قادر نیست تاثیر پذیری را نیز لحاظ کند و مانند مدل کمی بوردیک¹ و همکاران 2003 در این مدل قادر به تعریف محک قابلیت نیستیم. در مدل ذکر شده ی فوق می توان محک R&R را به صورت زیر تعریف کرد :

4-1-1- محک R&R برای مدل مزدوج

عامل بیز بدست آمده در (3-29) که انتخاب کننده ی یکی از دو مدل (3-23) است، محک R&R مناسبی است. $RR_1 = B_{12} \in (0, \infty)$ که مقادیر بزرگتر از 1 ، نشان دهنده ی R&R بودن سیستم است یا به طور معادل $RR_1 = \log(B_{12}) \in (-\infty, \infty)$ مقادیر بزرگتر از 0

¹ Burdick

نشان دهنده ی R&R بودن سیستم است.

4- 1- 2 محک R&R برای مدل اثرات متقابل

نسبت تغییرات متوسط پاسخ تحت فرض R&R بودن سیستم ($\sigma_{OP}^2 = \sigma_O^2 = 0$) بر تغییرات کل تحت عدم فرض R&R بودن سیستم است.

تحت فرض R&R بودن سیستم:

$$Var(g(E[y_{ijk}])) = Var(\mu + P_j) = \sigma_P^2 \quad (4 \ 4)$$

تحت عدم فرض R&R بودن سیستم:

$$Var(g(E[y_{ijk}])) = Var(\mu + O_i + P_j + OP_{ij}) = \sigma_O^2 + \sigma_P^2 + \sigma_{OP}^2 \quad (2 \ 4)$$

بنابراین:

$$RR_2 = \frac{\sigma_P^2}{\sigma_O^2 + \sigma_P^2 + \sigma_{OP}^2} \quad (3 \ 4)$$

$0 \leq RR_2 \leq 1$ یک محک مناسب برای R&R بودن سیستم اندازه گیری است، هر چه این محک به 1 نزدیکتر باشد خاصیت R&R بودن سیستم بیشتر است.

4- 1- 3 محک R&R برای مدل آشیانه ای

یکی از مزایای مدل آشیانه ای تعبیر مدل آستانه ای برای آن است و این تعبیر کمک می کند بتوان محک R&R با تعبیر متفاوت با آنچه گفته شد بیان کرد:

$$Var(z_{ijk}) = Var(\mu + O_i + R_{ij} + \varepsilon_{ijk}) = \sigma_O^2 + \sigma_R^2 + \frac{\pi^2}{3} \quad (4 \ 4)$$

تحت فرض R&R بودن سیستم اندازه گیری:

$$Var(z_{ijk}) = \frac{\pi^2}{3} \quad (5 \ 4)$$

بنابراین یک محک مناسب R&R، به فرم زیر قابل تعریف است.

$$RR_3 = \frac{\frac{\pi^2}{3}}{\sigma_O^2 + \sigma_R^2 + \frac{\pi^2}{3}} \quad (6 \ 4)$$

$0 \leq RR_3 \leq 1$ محک مناسبی برای تعیین R&R بودن سیستم

اندازه گيري است.

4-2 استفاده از محک BIC در مدل‌های اثرات تصادفی

استفاده از محک‌های انتخاب مدل یکی از روش‌های مناسب برای تصمیم‌گیری در نیاز به حضور یا عدم حضور اثر تصادفی در مدل است . آکائیک¹ 1973 با تعمیم اصل درست‌نمایی استفاده از محک آکائیک را برای انتخاب مدل، پیشنهاد می‌دهد که در حقیقت مدلی را انتخاب می‌کند که به طور جانبی نزدیکترین مدل را با فاصله ی کولبک لایبلر² باشد. از رابطه ی نزدیک بین آزمون‌های نسبت درست‌نمایی تعمیم یافته و محک آکائیک ، میتوان دریافت که حتی در حجم های نمونه ی بالا (بطور جانبی) همواره مدل صحیح با احتمالی مثبت ، انتخاب نخواهد شد این در حالی است که عامل بیز و BIC دارای این مشکل نیستند. خاصیت نامناسب ذکر شده برای محک AIC³ ، استفاده کنندگان از این محک را محدود کرده است بطوریکه همکنون در اکثر نرم افزارهای آماری ، محک AIC و BIC هر دو با هم گزارش می‌شوند. محک BIC از تقریب لاپلاس لگاریتم عامل بیز ، بطور جانبی بدست می‌آید و با توجه به اینکه عامل بیز در حجم نمونه ی بالا (و حتی با توزیع پیشین نادرست) مدل صحیح را با احتمال 1 مشخص می‌کند برای انتخاب مدل ، محک مناسبتری به نظر می‌رسد. استفاده از آزمون‌های نیمن پیرسني نیز مانند محک آکائیک دارای مشکل مشابه هستند زیرا زیاد کردن حجم نمونه تاثیری در کم شدن α (احتمال خطای نوع اول) ندارد . در حقیقت در فلسفه ی نیمن پیرسني ، احتمال خطای نوع اول قبل از مشاهده ی

¹ Akaike

² Kullback-Liebler

³ Akaike Information Criterion

داده ها و محاسبه ي آماره ي آزمون ، تعيين مي گردد و بنا بر اين ربطي به حجم نمونه ندارد و آزمونهاي سازگار در فلسفه ي نيمن پيرسني ، آزمونهايي اند که β (احتمال خطاي نوع دوم) با زياد شدن حجم نمونه به صفر ميل کند. اين درحالي است که در تصميم گيري با عامل بيز، با زياد شدن حجم نمونه ، هر دو نوع خطا به سمت صفر ميل مي کند. شايد به همين دليل است که آزمونهاي بهينه در کلاس آزمونهاي بيز تعريف مي شوند (آزموني بهينه است که بتوان توزيع پيشيني پيدا کرد که تحت آن توزيع پيشين ، آزمون مورد نظر يک آزمون بيز باشد). لازم به ذکر است که آزمونهاي نيمن پيرسني (فرضيه ي ساده در مقابل فرضيه ي ساده) در کلاس آزمونهاي بيز هستند (مراجعه کنيد به برگر¹ 1989).

4- 2- 1- مروري بر BIC

همانطور که قبلاً نيز اشاره شده است، بسط تيلور مجانبی لگاریتم عامل بيز BIC است (مراجعه کنيد به شوارز² 1978). اکنون تلاش مي کنيم تعبيري ساده و شهودي از آنچه در شوارز 1978 اشاره شده است نشان دهيم.

همانطور که در مورد عامل بيز گفته شد :

$$\log(B_{12}) = \log(f(M_1 | y)) - \log(f(M_2 | y)) \quad (7 \ 4)$$

اکنون بسط تيلور $\log(f(y | M_i, \theta_i))$ را حول مقدار $\hat{\theta}_i$ (که $\hat{\theta}_i$ ماکزيمم کننده ي نسبي و مطلق تابع $\log(f(y | M_i, \theta_i))$ يعني برآوردگر درستنمايي ماکزيمم است) مي نويسيم :

$$\begin{aligned} \log(f(y | M_i, \theta_i)) &= \log(f(y | M_i, \hat{\theta}_i)) + \frac{\partial \log(f(y | M_i, \theta_i))}{\partial \theta_i} \bigg|_{\theta_i = \hat{\theta}_i} (\theta_i - \hat{\theta}_i) \\ &+ \frac{1}{2} \times (\theta_i - \hat{\theta}_i)' \frac{\partial^2 \log(f(y | M_i, \theta_i))}{\partial \theta_i \partial \theta_i'} \bigg|_{\theta_i = \hat{\theta}_i} (\theta_i - \hat{\theta}_i) \end{aligned} \quad (8 \ 4)$$

¹ Berger

² Schwarz

بنابر فرض :

$$\left. \frac{\partial \log(f(\mathbf{y} | M_i, \boldsymbol{\theta}_i))}{\partial \boldsymbol{\theta}_i} \right|_{\boldsymbol{\theta}_i = \hat{\boldsymbol{\theta}}_i} = 0 \quad (9 \ 4)$$

پس عبارت (8-4) به با بکارگیری :

$$\mathbf{I}(\hat{\boldsymbol{\theta}}_i | \mathbf{y}) = - \left. \frac{\partial^2 \log(f(\mathbf{y} | M_i, \boldsymbol{\theta}_i))}{\partial \boldsymbol{\theta}_i \partial \boldsymbol{\theta}_i'} \right|_{\boldsymbol{\theta}_i = \hat{\boldsymbol{\theta}}_i} \quad (10 \ 4)$$

که \mathbf{I} ماتریس اطلاع فشر پارامترها است و بنابرین عبارت (8-4) به صورت زیر ساده می شود :

$$\log(f(\mathbf{y} | M_i, \boldsymbol{\theta}_i)) \cong \log(f(\mathbf{y} | M_i, \hat{\boldsymbol{\theta}}_i)) - \frac{1}{2} (\boldsymbol{\theta}_i - \hat{\boldsymbol{\theta}}_i)' \left. \frac{\partial^2 \log(f(\mathbf{y} | M_i, \boldsymbol{\theta}_i))}{\partial \boldsymbol{\theta}_i \partial \boldsymbol{\theta}_i'} \right|_{\boldsymbol{\theta}_i = \hat{\boldsymbol{\theta}}_i} (\boldsymbol{\theta}_i - \hat{\boldsymbol{\theta}}_i) \quad (14 \ 4)$$

بنابراین :

$$f(\mathbf{y} | M_i) \cong \int f(\mathbf{y} | \hat{\boldsymbol{\theta}}_i, M_i) f(\boldsymbol{\theta}_i | M_i) \exp \left(- \frac{1}{2} (\boldsymbol{\theta}_i - \hat{\boldsymbol{\theta}}_i)' \mathbf{I}(\hat{\boldsymbol{\theta}}_i | \mathbf{y}) (\boldsymbol{\theta}_i - \hat{\boldsymbol{\theta}}_i) \right) d\boldsymbol{\theta}_i \quad (12 \ 4)$$

اکنون در توزیع پیشین را نرمال p_i متغیره فرض می کنیم که p_i بعد $\boldsymbol{\theta}_i$ تحت مدل M_i است. بنابراین

$$f(\boldsymbol{\theta}_i | M_i) = N_{p_i}(\hat{\boldsymbol{\theta}}_i, \mathbf{I}^{-1}(\boldsymbol{\theta}_i | y_1)) \quad (13 \ 4)$$

که $\mathbf{I}(\boldsymbol{\theta}_i | y_1)$ اطلاع فشر با 1 نمونه است (نوعی توزیع پیشین کم اطلاع برای پارامترها در نظر گرفته شده است). اکنون به جای $\boldsymbol{\theta}_i$ برآوردگر درستنمایی آن را قرار می دهیم :

$$f(\hat{\boldsymbol{\theta}}_i | M_i) = (2\pi)^{-\frac{p_i}{2}} |\mathbf{I}(\boldsymbol{\theta}_i | y_1)|^{\frac{1}{2}} \quad (14 \ 4)$$

تا انتگرال (12-4) از لحاظ تحلیلی قابل محاسبه باشد، از طرفی زمانی که حجم نمونه بالا می رود ، نقش توزیع پیشین در استنباط کم رنگ تر می شود و بنابراین قرار دادن تابع ثابت به جای توزیع پیشین، استنباط یکسانی بطور مجانبی نتیجه خواهد داد :

$$f(\mathbf{y} | M_i) \cong f(\mathbf{y} | \hat{\boldsymbol{\theta}}_i, M_i) f(\hat{\boldsymbol{\theta}}_i | M_i) \int \exp \left(- \frac{1}{2} (\boldsymbol{\theta}_i - \hat{\boldsymbol{\theta}}_i)' \mathbf{I}(\hat{\boldsymbol{\theta}}_i | \mathbf{y}) (\boldsymbol{\theta}_i - \hat{\boldsymbol{\theta}}_i) \right) d\boldsymbol{\theta}_i \quad (15 \ 4)$$

انتگرال (4-15) یک انتگرال گاوسی است با فرض اینکه مشاهدات از هم مستقلند ، $\mathbf{I}(\hat{\theta}_i | \mathbf{y}) = n\mathbf{I}(\hat{\theta}_i | y_1)$ که n بعد بردار \mathbf{y} است و بنابراین :

$$\begin{aligned} f(\mathbf{y} | M_i) &\cong f(\mathbf{y} | \hat{\theta}_i, M_i) (2\pi)^{-\frac{p_i}{2}} |\mathbf{I}(\hat{\theta}_i | y_1)|^{\frac{1}{2}} (2\pi)^{\frac{p_i}{2}} |\mathbf{I}(\hat{\theta}_i | \mathbf{y})|^{-\frac{1}{2}} \\ &= f(\mathbf{y} | \hat{\theta}_i, M_i) (2\pi)^{-\frac{p_i}{2}} |\mathbf{I}(\hat{\theta}_i | y_1)|^{\frac{1}{2}} (2\pi)^{\frac{p_i}{2}} (n^{p_i} |\mathbf{I}(\hat{\theta}_i | y_1)|)^{-\frac{1}{2}} \quad (16 \ 4) \\ &= f(\mathbf{y} | \hat{\theta}_i, M_i) n^{-\frac{p_i}{2}} \end{aligned}$$

بنابراین خواهیم داشت :

$$-2\log(f(\mathbf{y} | M_i)) \cong -2\log(f(\mathbf{y} | \hat{\theta}_i, M_i)) + p_i \log(n) \quad (17 \ 4)$$

عبارت (4-17) به محک BIC_i (محک BIC برای مدل i ام) معروف است. مانند محک آکائیک ، مدلی بهتر است که BIC کمتری داشته باشد.

بنابراین :

$$2\log(B_{12}) = 2\log\left(\frac{f(y | \theta_1, M_1)}{f(y | \theta_2, M_2)}\right) - (p_1 - p_2)\log(n) \quad (18 \ 4)$$

4-2- AIC یا BIC ؟

با توجه به اینکه محک AIC از روش کاملاً متفاوتی به صورت

$$AIC_i = -2\log(lik) + 2p_i \quad (19 \ 4)$$

بدست آمده است ولی هر دو روش تابع درستنمایی را با تعداد پارامترها جریمه می کنند. در یک مدل ثابت، هر چه پارامترها بیشتر باشند ، تابع درستنمایی افزایش می یابد ولی AIC و BIC اینطور نیستند و به بیان ساده تر در دو مدل با درستنمایی های برابر ، مدلی ترجیح داده می شود که پارامترهای کمتری داشته باشد در محک BIC ، جریمه ی انتخاب مدل پیچیده تر با افزایش حجم نمونه ، افزایش می یابد که محکی منطقی تر به نظر می رسد.

شاید بتوان اینطور برداشت کرد که می توان به جای استفاده از این گونه محکها، به کمک آزمون درستنمایی یکی از دو مدل را انتخاب کرد مثلاً

آزمون کرد که آیا مدل M_1 با مدل M_2 تفاوت معنی داری دارد یا خیر، اگر دو مدل تفاوت معنی داری نداشتند، مدلی انتخاب شود که پارامترهای کمتری داشته باشد. محدودیت استفاده از آزمونهای درستنمایی (و مخصوصاً جانبی) همانطور که قبلاً نیز اشاره گردید شرایط استفاده از آماره ی ویلکس¹ است به علاوه آزمون درستنمایی تنها در شرایطی قابل انجام است که مدلهای تو در تو باشند به این معنا که $\theta|M_1 \subset \theta|M_2$ مانند حضور یا عدم حضور یک متغیر توضیحی در رگرسیون. یکی از مزایای مهم استفاده از AIC و BIC این است که حتی در مدلهای غیر تو در تو نیز قابل استفاده هستند مانند مدل پواسنی با مدل دو جمله ای منفی. شیباتا² 1976 و کاتز³ 1981 نشان دادند حتی بطور جانبی نیز محک AIC بعد مدل⁴ را بیش برآورد می کند (برابری AIC با آزمون نسبت درستنمایی نیز این موضوع را به صورت شهودی نشان می دهد). یک تصحیح مناسب AIC در آکائیک⁵ 1981 با دیدگاه بیزی انجام گرفته است که طی آن نشان داده شده است انتخاب مدل با AIC و عامل بیز بطور جانبی یکسان است و از طرفی چون داریم

$$\lim_{n \rightarrow \infty} \frac{2\log(B_{12}) - 2\log BIC}{\log(B_{12})} = 0 \quad (20 \ 4)$$

که در Kass and Raftery (1995) به آن اشاره شده است. انتظار می رود که BIC تحت شرایطی با AIC معادل باشد که البته این شرایط معمولاً وجود ندارد. در حقیقت برابری انتخاب مدل با استفاده از AIC با عامل بیز بطور جانبی تنها زمانی اتفاق می افتد که اطلاع موجود در توزیع پیشین همسطح با تابع درستنمایی باشد که معمولاً در عمل کم اتفاق می

¹ Wilks

² Shibata

³ Katz

⁴ Model Dimension

⁵ Akaike

افتد، به بیان دیگر معمولاً اطلاع توزیع پیشین کمتر از آن چیزی است که از تابع درستنمایی (داده ها) بدست می آید. آکائیک 1977 تصحیح دیگری از محک AIC ارائه می دهد که در مدلهای خطی نرمال به طور مجانبی مدل صحیح را انتخاب می کند، این محک بطور مجانبی با BIC معادل است. لینهارت و زوکچینی¹ 1986 تعمیم محک آکائیک 1973 را برای کلاسی از فاصله ها از جمله کولبک لایبلر² محاسبه کردند و نشان دادند با تعویض تعریف فاصله می توان ضریب 2 را در (4-19) به 4 نیز تغییر داد.

نتیجه گیری انتهایی این است که محک AIC تعمیم یافته به صورت زیر است :

$$AIC_i = -2\log(lik) + kp_i \quad k > 0 \quad (24 \quad 4)$$

این محک، لزوماً مدل مناسب را (حتی به طور مجانبی) انتخاب نمیکند ولی BIC از این لحاظ قابل اعتماد است. با این حال فیندلی³ 1991 شرایطی را پیدا کرده است که AIC بر خلاف BIC مدل را به طور مجانبی صحیح انتخاب می کند، بدیهی است که تحت شرایط فیندلی 1991، شرایط شوارز⁴ 1978 برای تقریب تیلور لگاریتم عامل بیز، برقرار نیست.

اشاره به این نکته ضروری است که در رگرسیون، استفاده از محک MSE برای انتخاب مدل معادل استفاده از محک آکائیک تعمیم یافته (4-21) با $k=1$ است. این نکته جالب توجه است که محک مالو یا C_p برای انتخاب مدل در رگرسیون نیز با همین استدلال، معادل محک آکائیک است. بسط تیلور مرتبه ی 1 اعتبار سنجی متقابل⁵ نیز معادل روش

¹ Linhart and Zucchini

² Kullback-Leibler

³ Findly

⁴ Schwarz

⁵ Cross Validation

محک مالو¹ C_p است مراجعه کنید به افرن و تیشیرانی² (1993).

4-3 استفاده از عامل بیز و BIC در مدل‌های آمیخته

همانطور که از ابتدای این فصل نیز مشخص است استفاده از عامل بیز و BIC با دیدگاه های بیزی بوجود آمده اند حال آنکه مدل‌های آمیخته به نظر می رسد در فلسفه ی درست‌نمایی بررسی می شوند آنالیز واریانس برای آزمون وجود و یا عدم وجود اثرات تصادفی در مدل نمونه ی بارز این تفکر است.

لازم است بتوان مشابَهت نزدیکی بین دیدگاه مدل‌بندی آمیخته و دیدگاه بیزی برقرار کرد. برای ایجاد کردن این مشابَهت لازم است دیدگاه مدل‌بندی بیزی تجربی مزدوج را مرور کنیم.

در مدل‌های بیز تجربی، ابتدا مدل به شرط پارامترها نوشته می شود و سپس از تابع توزیع حاشیه ای داده ها برای برآورد پارامترهای توزیع پیشین استفاده می شود.

عامل بیز نیز که نسبت پسین مدل‌ها پس از مشاهده ی داده ها است برای انتخاب مدل ، استفاده می شود.

در مدل مزدوج ابتدا مدل و تابع درست‌نمایی برای $f(y|\theta)$ نوشته شد، سپس توزیع مناسبی (مانند بتا) برای پارامترها (θ) فرض شد و پارامترهای توزیع پیشین فرض شده توسط تابع درست‌نمایی حاشیه ای زیر محاسبه می شود

$$L(\omega) = f(y|\omega) = \int f(y|\theta)f(\theta|\omega)d\theta \quad (22 \ 4)$$

در مدل‌های آمیخته تفاوت اساسی ، در نحوه ی وارد کردن توزیع پیشین است به علاوه برای بعضی از پارامترها (مانند پارامترهای ثابت) توزیع پیشین

¹ Mallows C_p

² Efron and Tibshirani

فرض نمی شود. به این دیدگاه گاهی از اوقات دیدگاه نیمه بیزی¹ اطلاق می شود. با فرض توزیع پیشین برای تمامی پارامترها (از جمله پارامترهای ثابت) می توان دیدگاه نیمه بیزی را بر دیدگاه تمام بیزی منطبق کرد. در مدل های آمیخته ابتدا مدل و تابع درستنمایی برای $f(y|\theta_1, \theta_2)$ نوشته می شود که θ_1 اثرات تصادفی و θ_2 اثرات ثابت هستند. سپس توزیع پیشین (معمولاً نرمال) برای اثرات تصادفی فرض می گردد و در انتها با توجه به ساختار وابستگی مشاهدات، تابع درستنمایی حاشیه ای داده ها بدست می آید:

$$L(\omega, \theta_1) = f(y|\omega, \theta_2) = \int f(y|\theta_1, \theta_2) f(\theta_1|\omega) d\theta_1 \quad (23-4)$$

برآورد اثرات ثابت و پارامترهای توزیع پیشین (ω) (در مسئله ی ما ، مؤلفه های واریانس) از ماکزیمم کردن تابع $(23-4)$ بدست می آید. بنابراین تک تک اثرات تصادفی در این دیدگاه خود یک پارامتر هستند و تعداد پارامترها در BIC با این دیدگاه ، تعداد سطوح عوامل تصادفی موجود در مدل است.

استفاده از BIC و مدل مزدوج از این دیدگاه نیز مناسب به نظر نمی رسد زیرا برای بدست آوردن تابع درستنمایی حاشیه ای ، مشاهدات از هم مستقل فرض شده اند که در مسئله ی تحلیل سیستم های اندازه گیری نامناسب ، لزوماً اینطور نیست. بنابراین عامل بیز (نیمه بیز) برای آزمون R&R در مدل اثرات تصادفی به صورت زیر محاسبه می شود. اگر فرض کنیم تحت مدل 1 سیستم اندازه گیری R&R است و تحت مدل 2 اینطور نیست ، در مدل 2 ، اثرات تصادفی وجود ندارند و بنابراین

$$B_{12} = \frac{Sup_{\theta_2}(f(y|\theta_2, M_1))}{Sup_{\theta_2, \omega}(f(y|\theta_2, \omega, M_2))} \quad (24-4)$$

البته این آزمون زمانی قابل انجام است که هیچکدام از مؤلفه های واریانس (ω) ، صفر برآورد

¹ Semi Bayesian Approach

نشده باشند.

فصل 5

پیاده سازی مدل‌های مختلف بر روی داده ها

5- 1- مقدمه

طی دو فصل اول روش راهنما و روش تعیینی مورد بحث قرار گرفت و در 2 - 3 - 3 بر روی داده های گزارش شده در راهنما ، پیاده شد . در این فصل با استفاده از همان داده ها و همچنین مطالب گفته شده ، مدل‌های مختلف را بر روی داده ها برازش می دهیم و نتایج را با هم مقایسه می کنیم .

5- 2- مدل مزدوج

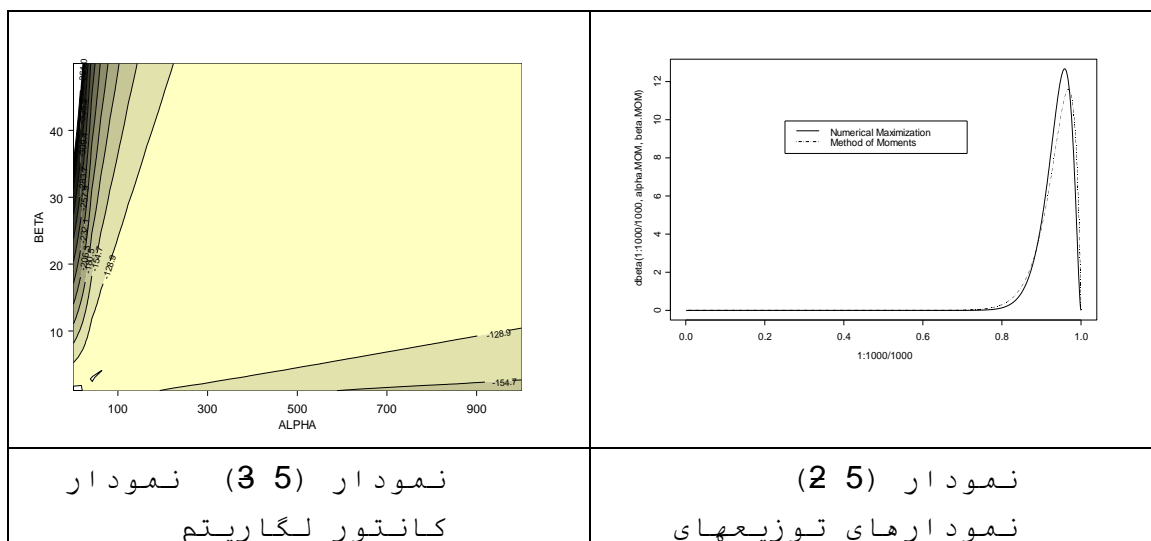
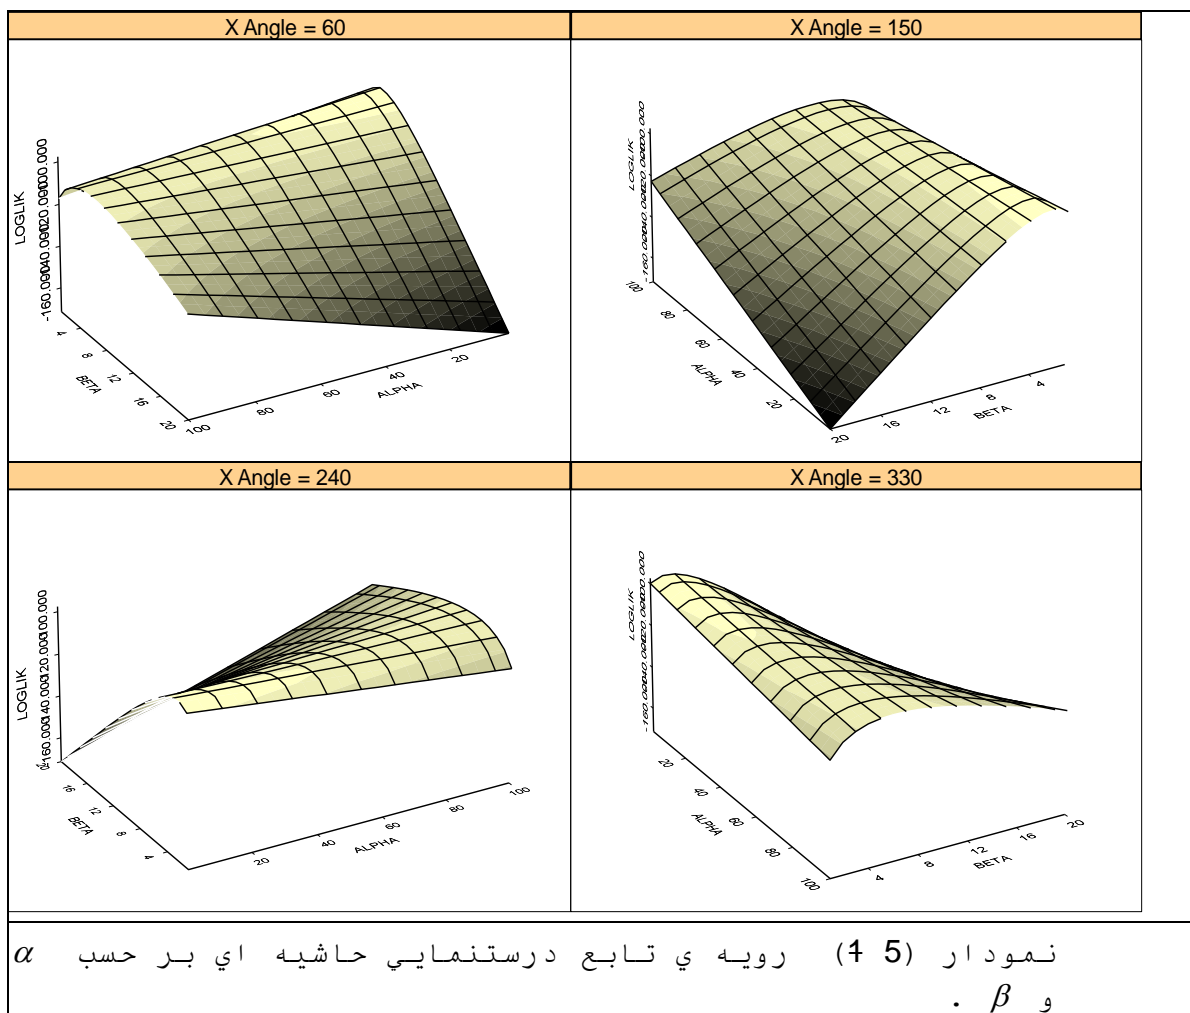
جدول داده ها برای برازش مدل مزدوج به صورت زیر است :

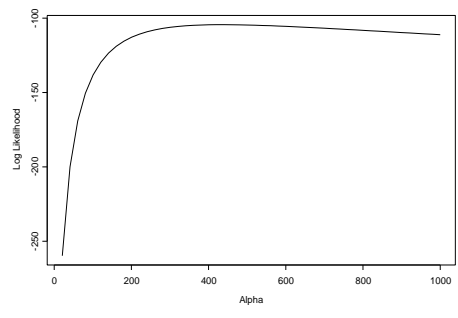
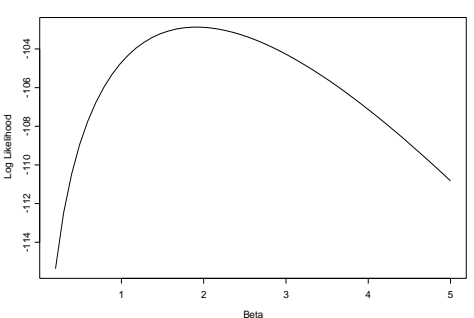
OPER * REP Crosstabulation					
Count					
		REP			Total
		1	2	3	
OPER	1	50	48	44	142
	2	50	48	47	145
	3	48	43	44	135
Total		148	139	135	422

جدول 1.11: جدول متقاطع تعداد تصمیم گیری های درست به تفکیک بازرس و تکرار

برازش مدل مزدوج ، به روش بیز تجربی (ماکزیم سازی عددی) برآوردهای پارامترهای توزیع پیشین $\alpha=28.90$ و $\beta=1.91$ بدست آمده است، این در حالی است که روش گشتاوری $\alpha=41.20$ و $\beta=2.73$ محاسبه شده

است:



پیشین بدست آمده از دو روش ماکزیمم سازی عددی و گشتاوری	درست‌نمایی حاشیه ای بر حسب پارامترهای توزیع پیشین
	
نمودار (5 4) تصویر لگاریتم درست‌نمایی در فضای یک بعدی	نمودار (5 5) تصویر لگاریتم درست‌نمایی در فضای یک بعدی

نمودار (3-5) نشان می دهد برآوردهای روش
گشتاوری ، از روش ماکزیمم سازی عددی چندان دور
نیست. در نمودار (4-5) و نمودار (5-5) یکی از
پارامترها (به ازای مقدار ماکزیمم شده ی عددی)
ثابت شده است و تنها یکی از پارامترها تغییر
یافته است.

نمودارهای اخیر جهت تاییدی بر استفاده از هر دو
روش ماکزیمم سازی عددی و روش گشتاوری ارائه شده
است.

اکنون عامل بیز بر اساس توزیعهای پیشین بدست
آمده از دو روش بیز تجربی و پیشین های بی اطلاع
جفریز و لاپلاس را محاسبه می کنیم:
عامل بیز برای R&R بودن سیستم اندازه گیری در
(29-3) اشاره شده است.

توزیع پیشین	(α, β)	$\log(B_{12})$
لاپلاس	(1,1)	9.76
جفریز	(0.5,0.5)	-3.38
بیز تجربی با ماکزیمم سازی عددی	(28.90,1.91)	48.54
بیز تجربی به روش گشتاوری	(41.20,2.73)	74.92

به جز توزیع پیشین جفریز باقی توزیعهای پیشین
تایید می کنند سیستم اندازه گیری R&R است و هر
دو روش بیز تجربی با ماکزیمم سازی عددی و روش
گشتاوری مدرک قوی علیه مدل M_2 ارائه می دهند.
محاسبه ی عامل بیز برای آزمون تاثیر پذیری در
جدول زیر گزارش شده است :

توزیع پیشین	(α, β)	$\log(B_{12})$
لایلاس	(1,1)	36.78
بیز تجربی با ماکزیمم سازی عددی	(28.90,1.91)	40.19
بیز تجربی به روش گشتاوری	(41.20,2.73)	41.20

که در هر سه مدرک قوی علیه فرضیه ی H_1 وجود
دارد.

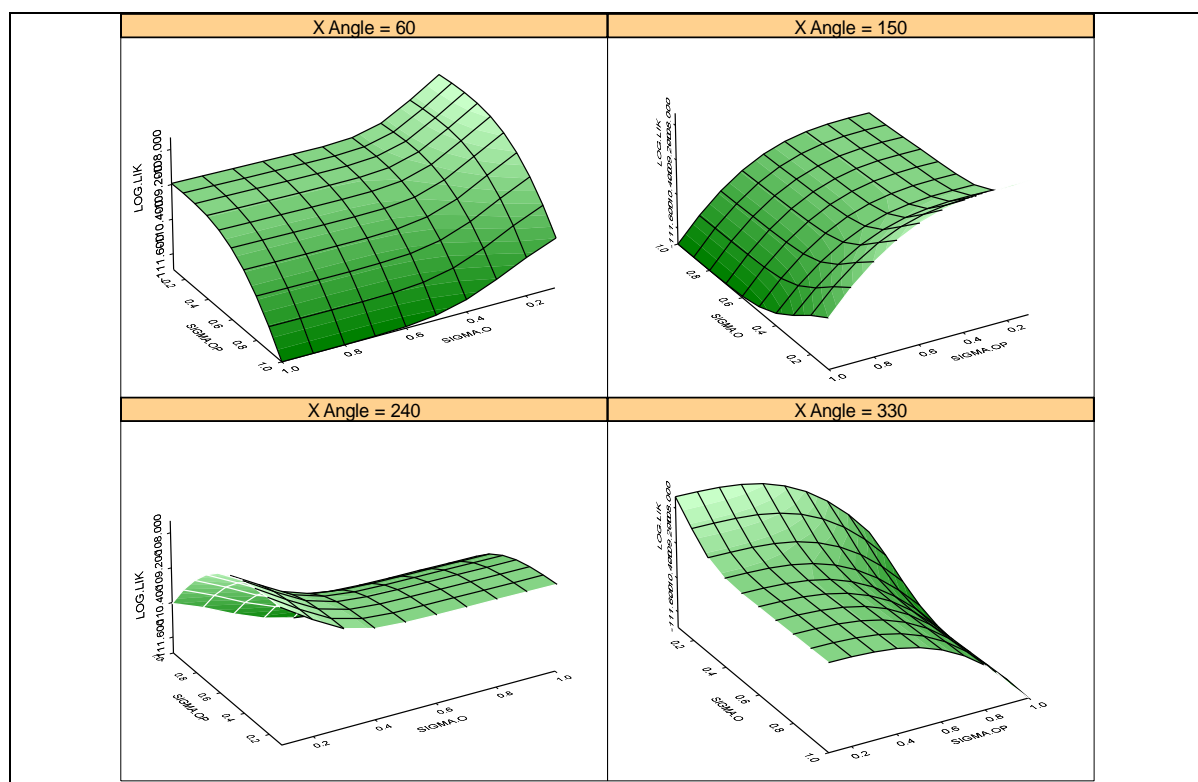
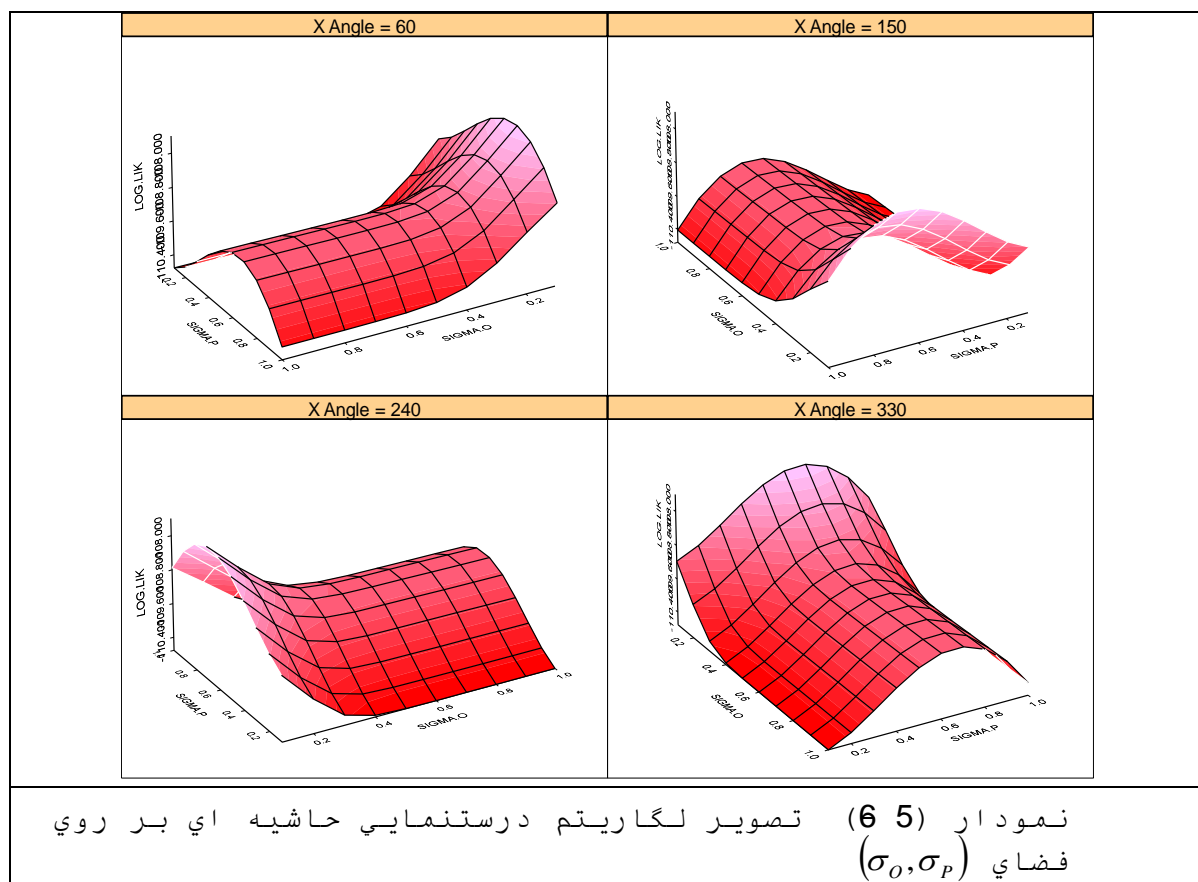
بنابراین سیستم اندازه گیری مناسب ارزیابی می
شود که نتایج بدست آمده در روش تعیینی را نیز
تایید می کند.

5- 3- مدل بندی با اثرات تصادفی

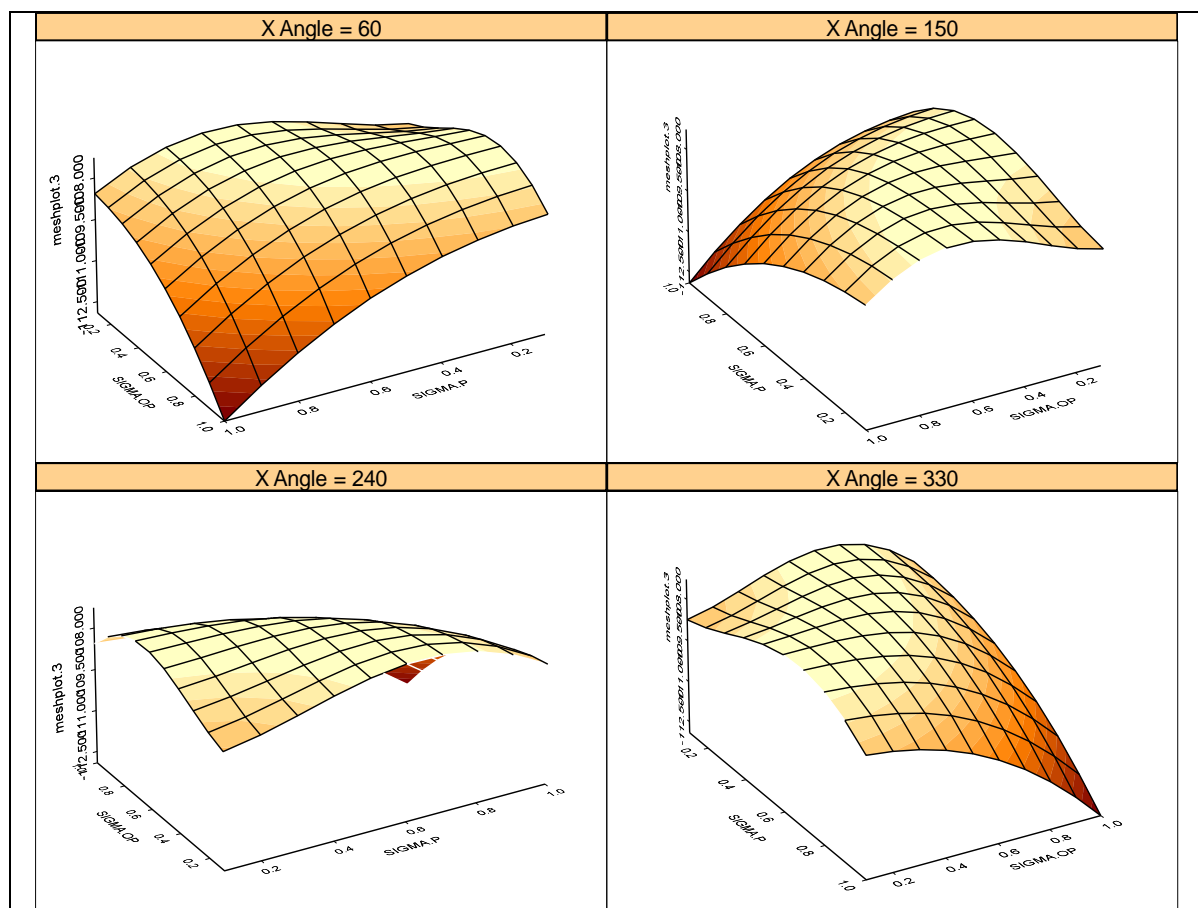
5- 3- 1- مدل بندی اندازه گیری

تابع درستنمایی حاشیه ای برای مدل بدست آمده در
3- 4- 1 برای داده های راهنمای MSA دارای 3
پارامتر σ_o ، σ_p ، σ_{op} و μ است که رسم آن در
حالت کلی ممکن نیست ، تنها تصویر آن را به ازای
مقادیر ثابت شده می توان در فضای 3 بعدی و 2
بعدی رسم کرد..

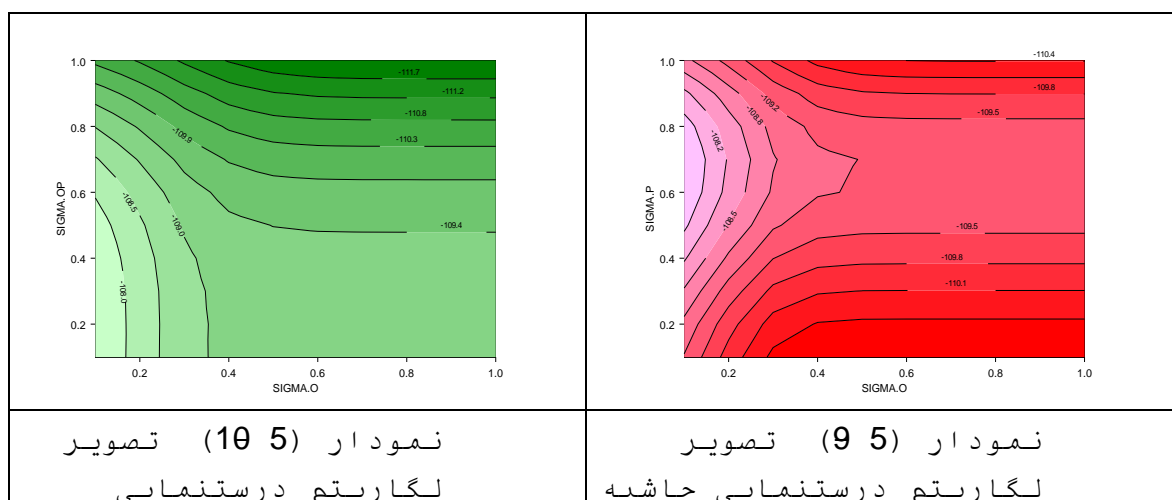
تعداد گره های گاوس هر میت برای تقریب هر انتگرال	$-\log(lik)$ - به ازای مقادیر ماکزیمم بدست آمده
2	107.08
3	107.28
4	107.27
5	107.27

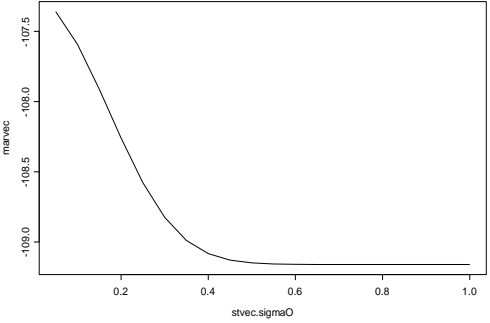
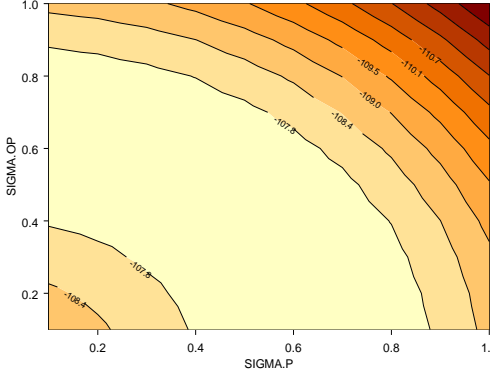
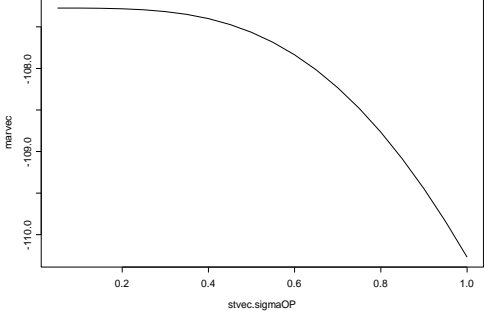
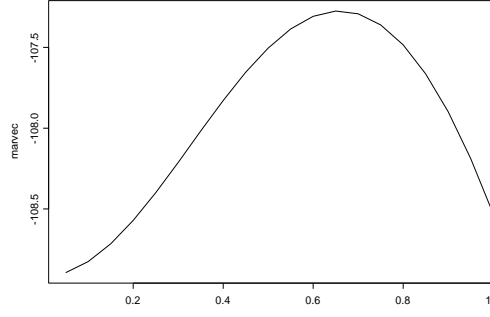
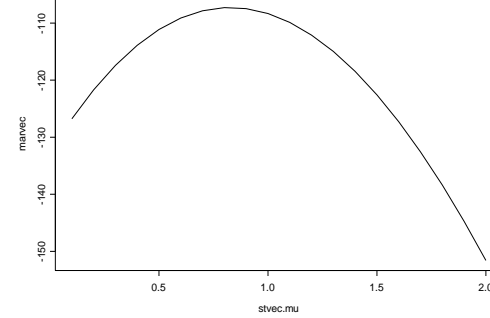


نمودار (5 7) تصویر لگاریتم درستنمایی حاشیه ای بر روی فضای (σ_O, σ_{OP})



نمودار (5 8) تصویر لگاریتم درستنمایی حاشیه ای بر روی فضای (σ_P, σ_{OP})



<p>حاشیه ای بر روی فضای (σ_O, σ_{OP})</p>	<p>ای بر روی فضای (σ_O, σ_P)</p>
 <p>A line plot showing the relationship between stvec.sigmaO (x-axis, 0.0 to 1.0) and marvec (y-axis, -107.5 to -109.0). The curve starts at approximately (-107.5, 0.0) and decreases monotonically, leveling off towards -109.0 as stvec.sigmaO approaches 1.0.</p>	 <p>A contour plot showing the relationship between SIGMA.P (x-axis, 0.0 to 1.0) and SIGMA.OP (y-axis, 0.2 to 1.0). The plot displays several contour lines representing different values of marvec, ranging from -107.2 to -110.7. The contours are roughly elliptical and centered around (0.6, 0.6).</p>
<p>نمودار (5 12) تصویر تابع درستنمایی حاشیه ای بر محور σ_O</p>	<p>نمودار (5 14) تصویر لگاریتم درستنمایی حاشیه ای بر روی فضای (σ_P, σ_{OP})</p>
 <p>A line plot showing the relationship between stvec.sigmaOP (x-axis, 0.0 to 1.0) and marvec (y-axis, -108.0 to -110.0). The curve starts at approximately (-108.0, 0.0) and decreases monotonically, reaching approximately -110.0 at stvec.sigmaOP = 1.0.</p>	 <p>A line plot showing the relationship between stvec.sigmaP (x-axis, 0.0 to 1.0) and marvec (y-axis, -107.5 to -108.5). The curve starts at approximately (-108.5, 0.0), reaches a peak of about -107.5 at stvec.sigmaP ≈ 0.6, and then decreases to approximately -108.5 at stvec.sigmaP = 1.0.</p>
<p>نمودار (5 14) تصویر تابع درستنمایی حاشیه ای بر محور σ_{OP}</p>	<p>نمودار (5 13) تصویر تابع درستنمایی حاشیه ای بر محور σ_P</p>
	 <p>A line plot showing the relationship between stvec.mu (x-axis, 0.0 to 2.0) and marvec (y-axis, -110 to -150). The curve starts at approximately (-130, 0.0), reaches a peak of about -110 at stvec.mu ≈ 0.8, and then decreases to approximately -150 at stvec.mu = 2.0.</p>
	<p>نمودار (5 15) تصویر</p>

تابع درست‌نمایی حاشیه ای
بر محور μ

برآوردهای بدست آمده حاصل از ماکزیمم سازی تابع درست‌نمایی حاشیه ای $\hat{\mu}=0.83$ ، $\sigma_o=0$ ، $\sigma_p=0.65$ و $\sigma_{op}=0$ گزارش شده است که تایید می کند سیستم اندازه گیری ، R&R است ، محک R&R بدست آمده از این مدل $RR_2=1$ بدست می آید.

5- 3- 2 مدل‌بندی تاثیر پذیری

تابع درست‌نمایی بدست آمده در 3 - 4 - 2 بر داده های راهنمای MSA محاسبه شده است و در زیر تاثیر انتخاب تعداد گره های گاوس هرمیت را مشاهده می کنید:

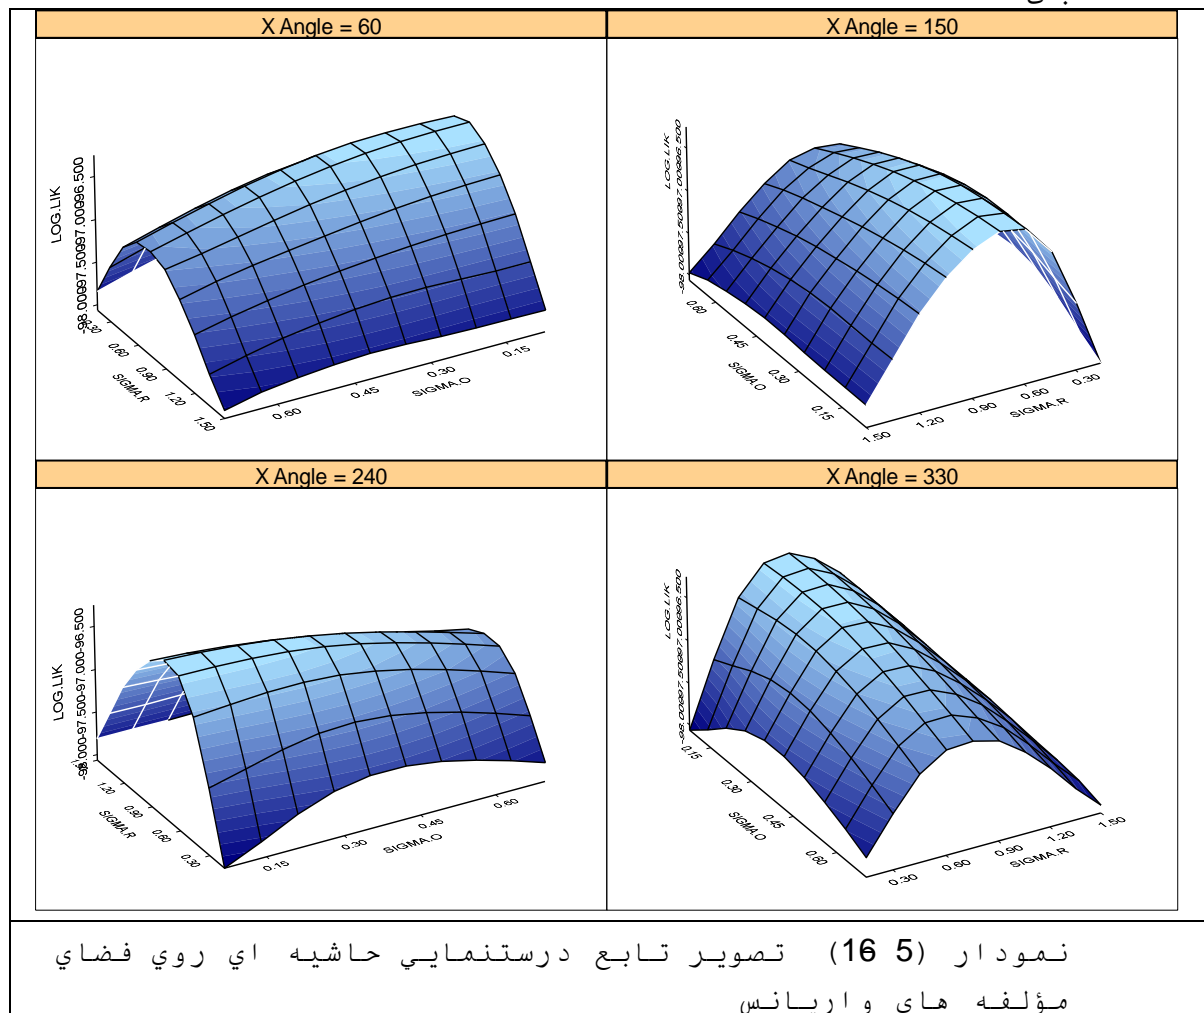
تعداد گره های گاوس هرمیت برای تقریب هر انتگرال	$-\log(lik)$ - به ازای مقادیر ماکزیمم بدست آمده
2	95.63
3	96.34
4	95.96
5	96.05
10	96.24
15	99.88
20	96.24

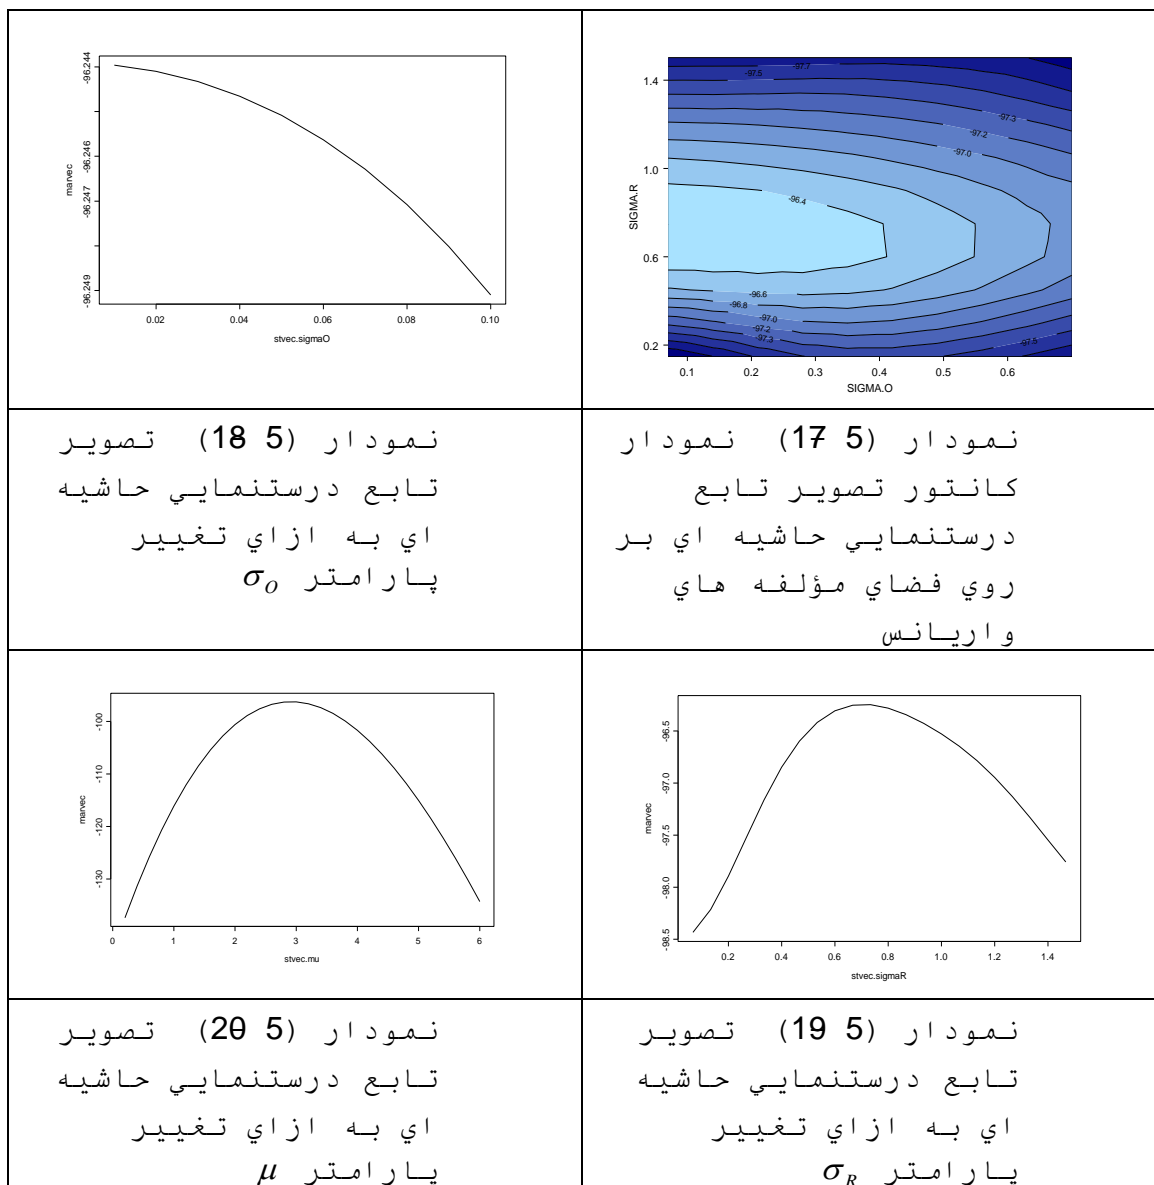
به نظر می رسد ، زیاد کردن تعداد گره ها تاثیر به سزایی در ماکزیمم سازی عددی لگاریتم تابع درست‌نمایی ندارد . یکی از دلیل مهم این موضوع می تواند به این دلیل باشد که با توجه به اینکه پارامتر ثابت تقریباً $\mu < 3$ است و نیز انتظار داریم مؤلفه های واریانس نزدیک به صفر باشند متغیرهایی که روی آنها انتگرال می گیریم حدوداً در دامنه ی حدوداً $(-3,3)$ ، قرار می گیرند که تربیع گاوس هرمیتی بیش از 3 نقطه برای آنها معمولاً تقریب مناسبی را نتیجه می دهد.

در هر حال در برآورد پارامترها و ادامه ی مطالب ، تابع درست‌نمایی هر انتگرال با 20 گره تقریب

زده شده است. پس از ماکزیمم سازی عددی لگاریتم تابع درستنمایی مقادیر $\mu=2.91$ ، $\sigma_o=1.43 \times 10^{-6}$ و $\sigma_R=0.71$ ماکزیمم کننده ی لگاریتم تابع درستنمایی اند .

تصویر تابع درستنمایی روی فضای مؤلفه های واریانس (σ_o, σ_R) نشان می دهد ، ماکزیمم سازی عددی قابل اعتماد است.





نمودارهای (11-16) تا (11-20) همگی تایید می کنند ، پارامتر ثابت و مؤلفه های واریانس بدست آمده از ماکزیمم سازی عددی ، قابل اعتمادند .

P - مقدار تجربی با 10.000 تکرار بوت استرپ و 10 گره گاوس هرمیت پس از 10 ساعت زمان ، عدد 0.1952 را گزارش می دهد که کماکان نشان می دهد آزمون فرضیه ی نیمن پیرسنی R&R بودن سیستم اندازه گیری رد نمی شود .

عامل نیمه بیز که در (4-24) به آن اشاره شده است به صورت زیر قابل محاسبه است :

$$B_{12} = \frac{Sup_{\theta_2}(f(\mathbf{y} | \theta_2, M_1))}{Sup_{\theta_2, \omega}(f(\mathbf{y} | \theta_2, \omega, M_2))} \quad (4 \ 5)$$


$$\begin{aligned} \log B_{12} &= Sup_{\mu} \log(f(\mathbf{y} | \theta_2, M_1)) - Sup_{\mu} \log(f(\mathbf{y} | \theta_2, \omega, M_2)) \\ &= Sup_p \log \left(\prod_{i=1}^{n_O} \prod_{j=1}^{n_R} \prod_{k=1}^{n_P} p^{y_{jk}} (1-p)^{1-y_{jk}} \right) \end{aligned} \quad (2 \ 5)$$


$$- Sup_{\mu} \log \left(\prod_{i=1}^{n_O} \int \prod_{j=1}^{n_R} \frac{\exp[(\mu + O_i + R_{ij})y_{ij.}]}{(1 + \exp[(\mu + O_i + R_{ij})y_{ij.}])^{n_P}} dF_{R_{ij}} dF_{O_i} \right)$$

$$\begin{aligned} &\cong Sup_p \sum_{i=1}^{n_O} \sum_{j=1}^{n_R} \sum_{k=1}^{n_P} \left[y_{ijk} \log \left(\frac{p}{1-p} \right) + \log(1-p) \right] \\ &- Sup_{\mu} \left\{ \sum_{i=1}^{n_O} \log \left\{ \frac{\sum_{v=1}^{nqn_O} w_O^0(v) \prod_{j=1}^{n_R} \sum_{u=1}^{nqn_R} w_R^0(u)}{\left(1 + \exp[(\mu + \sqrt{2}\sigma_O O^0(v) + \sqrt{2}\sigma_R R^0(u))y_{ij.}] \right)^{n_P}} \right\} \right\} \end{aligned} \quad (3 \ 5)$$

$$+ \frac{(n_O + n_R)}{2} \log(\pi)$$

پس از محاسبه ی مقدار فوق برای داده ها ، عدد $\log(B_{12}) = -5.18$ است. محک R&R بدست آمده از این مدل ، 0.82 بدست می آید. توزیع برآوردهای درستنمایی بدست آمده به کمک روش بوت استرپ در زیر آمده است:





بازه ی اطمینان 90 درصدی پارامترها از روش بوت استرپ پارامتری به صورت زیر بدست آمده است:

پارامتر	بازه ی اطمینان
μ	(2.47,3.37)
σ_O	(0,0.48)
σ_R	(0,1.1)

که نشان می دهد سیستم اندازه گیری R&R است و به علاوه از تاثیر پذیری لازم نیز برخوردار است.

5- نتیجه گیری

R&R بودن سیستم اندازه گیری در تمامی مدلها تایید می شود و تاثیر پذیری مناسب سیستم اندازه گیری در مدل مزدوج بالاتر از حد مورد انتظار راهنمای MSA است در نهایت همه ی مدلها تایید می کنند سیستم اندازه گیری مطلوب است که نتایج بدست آمده در روش تعیین را تایید می کند. لازم به ذکر است استفاده از عامل بیز برای تعیین R&R بودن سیستم اندازه گیری در مدل مزدوج و همچنین مدل اثرات تصادفی آشیانه ای دارای این

خاصیت مهم است که ((بدون در نظر گرفتن نوع توزیع پیشین فرض شده)) دارای خاصیت سازگاری برای هر دو نوع خطا است. از این لحاظ استفاده از دیدگاه مدل‌بندی، توصیه می‌گردد. استفاده از BIC برای تعیین R&R بودن سیستم اندازه‌گیری استفاده نشده است. زیرا استفاده از توزیع‌های پیشین متفاوت تاثیر به سزایی در مقدار بدست آمده در عامل بیز داشته‌اند و چون BIC تقریب مجانبی لگاریتم عامل بیز با فرض توزیع پیشین نرمال است. تغییر فرم توزیع پیشین از بتا به نرمال چندان منطقی به نظر نمی‌رسید مخصوصاً اینکه حجم نمونه آنقدر بالا نبود که بتوان فرض کرد نوع توزیع پیشین فرض شده تاثیر زیادی بر استنباط ندارد ولی بحث‌های لازم در 4 - 2 - 2 شده است که تایید می‌کند، استفاده از BIC کماکان خاصیت سازگاری را برای R&R بودن سیستم اندازه‌گیری، حفظ می‌کند.

5- 4- 1 خلاصه و پیشنهادات

در این پایان‌نامه دو دیدگاه نیم‌پیرسنی، بیزی و نیمه‌بیزی برای تعیین سیستم اندازه‌گیری قابل، بررسی شدند. تمامی برنامه‌ها به جز محاسبه‌ی چند جمله‌ای‌های هرمیت که در MAPLE نوشته شده بود بلا استثناء در نرم افزار SPLUS تهیه و اجرا شده‌اند. با توجه به اینکه نرم افزارهای موجود برای تحلیل سیستمهای اندازه‌گیری کیفی بسیار محدود است یکی از کارهای مهم می‌تواند تبدیل این برنامه‌ها به نرم افزاری کاربردی برای استفاده در صنعت باشد. مخصوصاً اینکه روش‌های ابداع شده در این پایان‌نامه هم در حجم نمونه‌ی پایین و هم در حجم نمونه‌ی بالا بر روش راهنمای MSA برتری دارد. طی شبیه‌سازی، دو روش تعیین‌ی و راهنمای MSA با هم مقایسه شدند ولی چنین مقایسه‌ای برای دیدگاه‌های مدل‌بندی انجام نشده است زیرا سزعت کامپیوترهای امروزی هنوز به آن حد نرسیده است که بتوان این

دیدگاه ها را با هم مقایسه کرد.

برنامه ی کامپیوتری مقایسه مانند آنچه در 2 - 3 ارائه شد برای دیدگاه های مدلبندی نیز نوشته شده است که طی محاسبات سرانگشتی با کامپیوتر Pentium III 700 MHz با 254MB RAM و سیستم عامل Windows XP قریب به 12 سال طول می کشد. استفاده از P-مقدار تجربی بطور مشابه مدل آشیانه ای برای مدل با اثرات متقابل 4 ماه به طول می انجامد و به این دلیل نتایج آن گزارش نشده است. فتوحی¹ 2003 نشان داده است استفاده از روش تقریب گاوس هرمیت اگر توزیع آمیخته نرمال نباشد منجر به جوابهای دور از واقعیت می گردد. استفاده از روش ماکزیمم درستنمایی ناپارامتری ایتکین² 1999 راهگشای این مشکل است و برای چک کردن اثرات تصادفی با توزیع نرمال لازم است بتوان $E(O_i|y)$ ، $E(P_j|y)$ ، $E(OP_{ij}|y)$ و $E(R_{ij}|y)$ را محاسبه کرد که از لحاظ تحلیلی غیر ممکن است و با استفاده از زنجیرهای مارکف مونت کارلویی (MCMC) به روش نمونه گیری متروپولیس هستینگس³ می توان این مقادیر را بطور تقریبی محاسبه کرد.

در تقریب درستنمایی حاشیه ای در مدل آشیانه ای 9 انتگرال به روش عددی تقریب خورده اند حال آنکه در روش اثرات متقابل 150 انتگرال به صورت عددی محاسبه شده اند و با توجه به تو در تو بودن انتگرالها ، خطای کل به همراه مشکلات محاسباتی به طور نمایی با تعداد سطوح داده زیاد می شود که با استفاده از روش MCEM⁴ و MCNR⁵ که در مک کولا⁶ 1997 ارائه شده اند قابل حل است و برآوردهای درستنمایی دقیق را با تکرارهای

¹ Fotouhi

² Aitkin

³ Metropolis-Hastings

⁴ Markov Chain Expectation Maximization

⁵ Markov Chain Newton Raphson

⁶ McCullagh

مناسب البته با پیچیدگی محاسباتی بیشتر نتیجه می دهد. در مدل آشیانه ای می توان با وارد کردن هم‌تغییر¹ اندازه ی واقعی قطعه در مدل، علاوه بر اریبی، خطیت و حتی روندهای بالاتر را در سیستم اندازه گیری کیفی نیز بررسی کرد. خلاصه اینکه: استفاده از مدلهای ذکر شده قادر است تمامی خواص بررسی شده برای سیستمهای اندازه گیری کمی را در سیستمهای اندازه گیری کیفی، بررسی کند.

¹ Covariate

راهنمای موضوعي

Subject Index

104 , 103 , 100	AIC
118 , 106 , 105 , 104 , 103 , 101 , 100 , 63 , 55	BIC
76	EBLUP
70	IGLS
100	Kullback-Liebler
69	ML
4 , 64 , 63 , 55 , 52 , 50 , 49 , 48 , 45 , 40 , 39 , 38 , 28 , 25 , 13	R&R
118 , 116 , 114 , 109 , 106 ,	
70	REML
70	RIGLS
77 , 54 , 44 , 40 , 39 , 38 , 36 , 32 , 29 , 13	اریبی
101 , 38	آزمون بیز
10	استاندارد QS
99 , 93	آستانه ای
118 , 102 , 72 , 66 , 65 , 64 , 62 , 61 , 57 , 55 , 22 ,	استنباط 21
105	اعتبار سنجی متقابل
95 , 54 , 51 , 46 , 28 , 27 , 26 , 25 , 23 , 15	امتیاز
105 , 101 , 94 , 90 , 85 , 77 , 76 , 73 , 72	بسط تیلور
95	بطور مجانبی و موضعی پرتوان ترین آزمون
95	بطور مجانبی و موضعی دقیقترین آزمون
70	بهترین پیشگوی خطی
89 , 72 , 70 , 68	پیشگوی خطی
90 , 89 , 76 , 71 , 68 , 65	تابع وصل
49 , 48 , 47 , 46 , 45 , 43 , 40 , 39 , 38 , 36 , 35 ,	پذیری 26
118 , 114 , 109 , 98 , 92	
56 , 54 , 50 , 35 , 34 , 15	تاثیرپذیری
114 , 91 , 90 , 85 , 83 , 82 , 81 , 77	تربیع
82	تربیع تصادفی
85 , 83	تربیع گاوس هرمیتی
85	تربیع گاوس هرمیتی وفقی
82	تربیع گاوسی
82 , 81	تربیع هرمیتی

تقریب لاپلاس.....	100 , 86 , 76	
توافق 15	28 , 27 , 26 , 25 , 24 , 23 , 22 , 21 , 20 , 19 , 18 , 17 , 16 ,	
توزیع آمیخته.....	119 , 85 , 84 , 77 , 73 , 71	
م پیشین 38	4 , 102 , 101 , 100 , 98 , 64 , 63 , 60 , 58 , 57 , 56 ,	
	118 , 110 , 109 ,	
تکثیر پذیری.....	13	
تکرار پذیری.....	25 , 12	
جدول توافقی.....	47 , 24 , 23 , 16	
جفریز.....	109 , 62 , 58 , 57	
حداکثر پسین.....	61	
خطای نوع اول.....	100 , 52 , 51 , 46 , 44 , 42 , 29 , 27	
خطیت.....	13	
خواص مجانبی.....	50 , 42 , 37 , 36 , 29	
درست‌نمایی حاشیه ای باقیمانده.....	70	
درست‌نمایی ماکزیمم حاشیه ای.....	69	
درونیابی.....	81 , 80 , 79 , 78 , 77	
درونیابی هرمیتی.....	81 , 77	
راهنمای MSA 11	35 , 32 , 27 , 26 , 25 , 24 , 23 , 20 , 18 , 15 , 13 , 11	
	114 , 110 , 98 , 95 , 54 , 53 , 52 , 51 , 50 , 49 , 47 , 46	
تعیینی 11	0 , 49 , 47 , 46 , 44 , 43 , 42 , 41 , 38 , 37 , 36 , 29 ,	
سازگاری.....	118 , 62 , 55 , 53 , 52 , 41 , 38 , 37	
ه گیری 12	28 , 27 , 26 , 25 , 24 , 23 , 17 , 15 , 14 , 13 ,	
	50 , 49 , 48 , 47 , 46 , 45 , 43 , 41 , 40 , 39 , 38 , 36 , 35	
	98 , 94 , 92 , 87 , 65 , 64 , 63 , 56 , 55 , 54 , 52 , 51	
	119 , 118 , 116 , 114 , 110 , 109 , 106 , 99	
سیستم اندازه گیری قابل.....	54 , 38 , 13	
ضریب توافق.....	17	
ضریب همبستگی اسمی کرامر.....	18	
امل بیز 62	09 , 106 , 105 , 104 , 101 , 100 , 98 , 94 , 65 , 64 , 63 ,	
مدل دوتایی آستانه ای.....	94	
نیمه بیزی.....	119 , 106	
همبستگی.....	67 , 53 , 17 , 16 , 15	
کاپا 15	43 , 28 , 27 , 26 , 25 , 24 , 23 , 22 , 21 , 20 , 19 , 18 , 16 ,	
کنترل فرآیند آماری.....	13	
کنترل کیفیت آماری.....	14	

راهنمای مؤلفین Author Index

86	Abramowitz
91	Abromowitz
119 , 84	Aitkin
104 , 100	Akaike
31	Andersen
92	Anderson
59	Bazaraa
101	Berger
57 , 56	Bernardo
95	Bhatt
77 , 73	Breslow
38	Brovkov
98 , 88	Burdick
67	Cantoni
60	Carlin
66	Charnes
31	Chung
18	Cohen
32	Cressie
85	Davies
70	Dempster
53	Diggle
105 , 95 , 21	Efron
21	Everitt
104	Findly
21	Fleiss
119	Fotouhi
67	Godambe
77 , 76 , 74 , 72 , 70	Goldstein
23	Gwett
73	Hartford

71	Hastings
85 , 84	Heckman
64 , 62 , 57	Jeffreys
67	Jung
104 , 62	Kass
103	Katz
17	Kendall
84 , 70	Laird
21 , 20	Landis
38	Lehman
86 , 72	Lesaffre
95 , 67 , 53 , 21	Liang
90 , 74	Lindstorm
104	Linhart
85	Liu
70	Longford
61	Louis
120 , 66	McCullagh
94	Miller
88 , 66	Montgomery
73 , 66	Myers
66	Nelder
90	Pinheiro
86	Rabe
70 , 69	Rao
70	Robinson
85 , 77	Rodriguez
38	Rohatgi
104 , 101 , 63	Schwarz
18	Scott
70	Searle
95	Self
103	Shibata
72 , 69	Verbeke
85	Vermunt
103 , 94 , 31	Wilks

76 Wolfinger
67 Zeger

ضمیمه

برنامه های کامپیوتری

مقایسه ی روش راهنمای MSA با روش تعیینی

```
options(object.size=3700000000(
manual.rejected.no<-c() ##### vector to create final plot of decision
deter.rejected.no<-c()
p.vec<-c ()
for (iter in 1:19(
)
p<-0.475+iter/40
n.c<-25          #number of correct parts
n.f<-25          #number of failed parts
prob.c<-matrix(c(p.p.p.p.p.p.p.p.p).ncol=3)#probs of correct decision rows=A1-B1-C1....
prob.f<-matrix(c(p.p.p.p.p.p.p.p.p).ncol=3(

#####Created for Parameter Summary
pca1<-prob.c[1(
pca2<-prob.c[2(
pca3<-prob.c[3(
pcb1<-prob.c[4(
pcb2<-prob.c[5(
pcb3<-prob.c[6(
pcc1<-prob.c[7(
pcc2<-prob.c[8(
pcc3<-prob.c[9(

pfa1<-prob.f[1(
pfa2<-prob.f[2(
pfa3<-prob.f[3(
pfb1<-prob.f[4(
pfb2<-prob.f[5(
pfb3<-prob.f[6(
pfc1<-prob.f[7(
pfc2<-prob.f[8(
pfc3<-prob.f[9(
#####Created for Parameter Summary

prop.ucl.c<-c()
prop.ucl.f<-c()
prop.ucl.g<-c()
r.agr.manual<-0 # Rejection of Operator's Agreement (Manual Approach(
r.agr.deter<-0 # Rejection of Operator's Agreement (Deterministic Approach(
alpha.agr<-0.01
alpha.equal.prop<-0.01
alpha.pc.cap<-0.01
alpha.pf.cap<-0.01
alpha.pg.cap<-0.01

k.m.agr<-0.4
k.m.cap<-0.4
pg.cap<-0.8
pc.cap<-0.8
pf.cap<-0.8

mc.iter<-1000
oper<-3
rep<-3

manual.kappa<-matrix(9.mc.iter,6(
```

```

decision.counter<-matrix(F.mc.iter.9) # True when a decision rejects null hypothesis

guiModify( "logical". Name = "decision.counter$1".NewName = "Kappa.Agr("
guiModify( "logical". Name = "decision.counter$2".NewName = "Kappa.Cap("
guiModify( "logical". Name = "decision.counter$3".NewName = "Prop.Eq("
guiModify( "logical". Name = "decision.counter$4".NewName = "Chisq.Agr("
guiModify( "logical". Name = "decision.counter$5".NewName = "PropC.Cap("
guiModify( "logical". Name = "decision.counter$6".NewName = "PropF.Cap("
guiModify( "logical". Name = "decision.counter$7".NewName = "PropG.Cap("
guiModify( "logical". Name = "decision.counter$8".NewName = "Manual.Decision("
guiModify( "logical". Name = "decision.counter$9".NewName = "Deter.Decision("

pearson.crstb<-matrix(0.3.9(
pearson.statistic<-c()
pearson.pval<-c()
pearson.df<-2*oper*rep

deter.crstb<-array(9.c(mc.iter.3.oper*rep(

guiModify( "double". Name = "manual.kappa$1".NewName = "A.B("
guiModify( "double". Name = "manual.kappa$2".NewName = "A.C("
guiModify( "double". Name = "manual.kappa$3".NewName = "B.C("
guiModify( "double". Name = "manual.kappa$4".NewName = "A.REF("
guiModify( "double". Name = "manual.kappa$5".NewName = "B.REF("
guiModify( "double". Name = "manual.kappa$6".NewName = "C.REF("

oper.decision<-array(9.c(mc.iter.oper.n.c+n.f.rep(

pop<-c() #making the
population
pop[1:n.c]<-0
pop[(n.c+1):(n.c+n.f)]<-1
pop.table<-rep(pop.3) # producing population for REF crosstabs
pc.ucl<-c()
pf.ucl<-c()

for(i in 1:mc.iter(
)
for(j in 1: oper(
)
for
(k in 1:n.c(
)
for (l in 1:rep(
)
oper.decision[i,j,k,l]<-rbinom(1.1.1-prob.c[l,j]{
{
for (j in 1:oper(
)
for
(k in
)n.c+1):(n.c+n.f((
)
for (l in 1:rep(
)
oper.decision[i,j,k,l]<-rbinom(1.1.prob.f[l,j]{
{
{
table.ab<-
t(table(matrix(oper.decision[i,1..].ncol=1).matrix(oper.decision[i,2..].ncol=1(((
table.ac<-

```

```

t(table(matrix(oper.decision[i.1..].ncol=1).matrix(oper.decision[i.3..].ncol=1(((
table.bc<-
t(table(matrix(oper.decision[i.2..].ncol=1).matrix(oper.decision[i.3..].ncol=1(((
table.aref<-
t(table(matrix(oper.decision[i.1..].ncol=1).matrix(pop.table(((
table.bref<-
t(table(matrix(oper.decision[i.2..].ncol=1).matrix(pop.table(((
table.cref<-
t(table(matrix(oper.decision[i.3..].ncol=1).matrix(pop.table(((

p0<-
(table.ab[1.1]+table.ab[2.2])/length(pop.table(
pe<-
((table.ab[1.1]+table.ab[2.1])*(table.ab[1.1]+table.ab[1.2])+(table.ab[1.2]+table.ab[2.2
])* (table.ab[2.1]+table.ab[2.2]))/length(pop.table)^2
manual.kappa[i 'A.B']<-(p0-pe)/(1-pe(

p0<-
(table.ac[1.1]+table.ac[2.2])/length(pop.table(
pe<-
((table.ac[1.1]+table.ac[2.1])*(table.ac[1.1]+table.ac[1.2])+(table.ac[1.2]+table.ac[2.2
])* (table.ac[2.1]+table.ac[2.2]))/length(pop.table)^2
manual.kappa[i 'A.C']<-(p0-pe)/(1-pe(

p0<-
(table.bc[1.1]+table.bc[2.2])/length(pop.table(
pe<-
((table.bc[1.1]+table.bc[2.1])*(table.bc[1.1]+table.bc[1.2])+(table.bc[1.2]+table.bc[2.2
])* (table.bc[2.1]+table.bc[2.2]))/length(pop.table)^2
manual.kappa[i 'B.C']<-(p0-pe)/(1-pe(

p0<-
(table.aref[1.1]+table.aref[2.2])/length(pop.table(
pe<-
((table.aref[1.1]+table.aref[2.1])*(table.aref[1.1]+table.aref[1.2])+(table.aref[1.2]+ta
ble.aref[2.2])* (table.aref[2.1]+table.aref[2.2]))/length(pop.table)^2
manual.kappa[i 'A.REF']<-(p0-pe)/(1-pe(

p0<-
(table.bref[1.1]+table.bref[2.2])/length(pop.table(
pe<-
((table.bref[1.1]+table.bref[2.1])*(table.bref[1.1]+table.bref[1.2])+(table.bref[1.2]+ta
ble.bref[2.2])* (table.bref[2.1]+table.bref[2.2]))/length(pop.table)^2
manual.kappa[i 'B.REF']<-(p0-pe)/(1-pe(

p0<-
(table.cref[1.1]+table.cref[2.2])/length(pop.table(
pe<-
((table.cref[1.1]+table.cref[2.1])*(table.cref[1.1]+table.cref[1.2])+(table.cref[1.2]+ta
ble.cref[2.2])* (table.cref[2.1]+table.cref[2.2]))/length(pop.table)^2
manual.kappa[i 'C.REF']<-(p0-pe)/(1-pe(
# this expression counts no. of rejection
if ((manual.kappa[i 'A.B']<k.m.agr) |
(manual.kappa[i 'A.C']<k.m.agr) | (manual.kappa[i 'B.C']<k.m.agr((
)
decision.counter[i,'Kappa.Agr']<-T
else
{
if
((manual.kappa[i 'A.REF']<k.m.cap) | (manual.kappa[i 'B.REF']<k.m.cap) |
(manual.kappa[i 'C.REF']<k.m.cap((
)
decision.counter[i,'Kappa.Cap']<-T
{
deter.crstb[i.1.1]<-
table(oper.decision[i.1..1].pop)[1.1] # A1 correct decision on correct parts
deter.crstb[i.1.2]<-
table(oper.decision[i.1..2].pop)[1.1] # A2 correct decision on correct parts

```

```

deter.crstb[i.1.3]<-
table(oper.decision[i.1..3].pop)[1.1] # A3 correct decision on correct parts

deter.crstb[i.1.4]<-
table(oper.decision[i.2..1].pop)[1.1] # B1 correct decision on correct parts
deter.crstb[i.1.5]<-
table(oper.decision[i.2..2].pop)[1.1] # B2 correct decision on correct parts
deter.crstb[i.1.6]<-
table(oper.decision[i.2..3].pop)[1.1] # B3 correct decision on correct parts

deter.crstb[i.1.7]<-
table(oper.decision[i.3..1].pop)[1.1] # C1 correct decision on correct parts
deter.crstb[i.1.8]<-
table(oper.decision[i.3..2].pop)[1.1] # C2 correct decision on correct parts
deter.crstb[i.1.9]<-
table(oper.decision[i.3..3].pop)[1.1] # C3 correct decision on correct parts

deter.crstb[i.2.1]<-
table(oper.decision[i.1..1].pop)[2.2] # A1 correct decision on failed parts
deter.crstb[i.2.2]<-
table(oper.decision[i.1..2].pop)[2.2] # A2 correct decision on failed parts
deter.crstb[i.2.3]<-
table(oper.decision[i.1..3].pop)[2.2] # A3 correct decision on failed parts

deter.crstb[i.2.4]<-
table(oper.decision[i.2..1].pop)[2.2] # B1 correct decision on failed parts
deter.crstb[i.2.5]<-
table(oper.decision[i.2..2].pop)[2.2] # B2 correct decision on failed parts
deter.crstb[i.2.6]<-
table(oper.decision[i.2..3].pop)[2.2] # B3 correct decision on failed parts

deter.crstb[i.2.7]<-
table(oper.decision[i.3..1].pop)[2.2] # C1 correct decision on failed parts
deter.crstb[i.2.8]<-
table(oper.decision[i.3..2].pop)[2.2] # C2 correct decision on failed parts
deter.crstb[i.2.9]<-
table(oper.decision[i.3..3].pop)[2.2] # C3 correct decision on failed parts

deter.crstb[i.3.1]<-n.c+n.f-
(deter.crstb[i.1.1]+deter.crstb[i.2.1]) # A1 failed decision = all parts - corrected
recognized

deter.crstb[i.3.2]<-n.c+n.f-
(deter.crstb[i.1.2]+deter.crstb[i.2.2]) # A2 failed decision = all parts - corrected
recognized

deter.crstb[i.3.3]<-n.c+n.f-
(deter.crstb[i.1.3]+deter.crstb[i.2.3]) # A3 failed decision = all parts - corrected
recognized

deter.crstb[i.3.4]<-n.c+n.f-
(deter.crstb[i.1.4]+deter.crstb[i.2.4]) # B1 failed decision = all parts - corrected
recognized

deter.crstb[i.3.5]<-n.c+n.f-
(deter.crstb[i.1.5]+deter.crstb[i.2.5]) # B2 failed decision = all parts - corrected
recognized

deter.crstb[i.3.6]<-n.c+n.f-
(deter.crstb[i.1.6]+deter.crstb[i.2.6]) # B3 failed decision = all parts - corrected
recognized

deter.crstb[i.3.7]<-n.c+n.f-
(deter.crstb[i.1.7]+deter.crstb[i.2.7]) # C1 failed decision = all parts - corrected
recognized

deter.crstb[i.3.8]<-n.c+n.f-
(deter.crstb[i.1.8]+deter.crstb[i.2.8]) # C2 failed decision = all parts - corrected
recognized

deter.crstb[i.3.9]<-n.c+n.f-
(deter.crstb[i.1.9]+deter.crstb[i.2.9]) # C3 failed decision = all parts - corrected
recognized

ec<-sum(deter.crstb[i.1.]) /9
ef<-sum(deter.crstb[i.2.]) /9
en<-n.c+n.f-(ef+ec)
for (j in
1:9(

```

```

pearson.crstb[1,j]<-(deter.crstb[i.1.j]-ec)^2/ec
pearson.crstb[2,j]<-(deter.crstb[i.2.j]-ef)^2/ef
pearson.crstb[3,j]<-(deter.crstb[i.3.j]-en)^2/en

pearson.statistic[i]<-
sum(pearson.crstb[1.])+sum(pearson.crstb[2.])+sum(pearson.crstb[3.])
pearson.pval[i]<-1-
pchisq(pearson.statistic[i],pearson.df(
    pc<-ec/n.c
    pf<-ef/n.f
    pg<-(n.c*pc+n.f*pf)/(n.c+n.f
    prop.ucl.c[i]<-pc+qnorm(1-
    prop.ucl.f[i]<-pf+qnorm(1-
    prop.ucl.g[i]<-pg+qnorm(1-
    alpha.pc.cap)*sqrt(pc*(1-pc)/(rep*oper*n.c((
    alpha.pf.cap)*sqrt(pf*(1-pf)/(rep*oper*n.f((
    alpha.pg.cap)*sqrt(pg*(1-pg)/(rep*oper*(n.c+n.f(((
# equality of pc and pf decision
(( z.statistic<-(pc-pf)/sqrt(pg*(1-
pg)*(1/(rep*oper*n.c)+1/(rep*oper*n.f
z.pval<-(1 - pnorm(abs(z.statistic)))*2
if (pearson.pval[i]<alpha.agr
    decision.counter[i,'Chisq.Agr']<-T
else
    if
(z.pval<alpha.equal.prop) #pc=pf decision
    decision.counter[i,'Prop.Eq']<-T
    pc.ucl<-pc+qnorm(1-
    pf.ucl<-pf+qnorm(1-
    if (pc.ucl<pc.cap(
    decision.counter[i,'PropC.Cap']<-T
    if (pf.ucl<pf.cap(
    decision.counter[i,'PropF.Cap']<-T
    else
    pg.ucl<-pg+qnorm(1-
    if (pg.ucl<pg.cap (
    decision.counter[i,'PropG.Cap']<-T

```



```

{
    {
        if
        (decision.counter[i.'Kappa.Agr']|decision.counter[i.'Kappa.Cap'])
        decision.counter[i.'Manual.Decision']<-T
        if (sum(decision.counter[i 4:7])!=0)
        decision.counter[i.'Deter.Decision']<-T
        print(' ')
        print(iter(
        print(i(
        {

#####Simulation Parameters Summary

        par.sum<-matrix(0.2,12(
        guiModify( "double" Name =
        "par.sum$1".NewName = "MC.Iter("
        guiModify( "double" Name =
        "par.sum$2".NewName = "Part("
        guiModify( "double" Name =
        "par.sum$3".NewName = "S.Size("
        guiModify( "double" Name =
        "par.sum$4".NewName = "A1("
        guiModify( "double" Name =
        "par.sum$5".NewName = "A2("
        guiModify( "double" Name =
        "par.sum$6".NewName = "A3("
        guiModify( "double" Name =
        "par.sum$7".NewName = "B1("
        guiModify( "double" Name =
        "par.sum$8".NewName = "B2("
        guiModify( "double" Name =
        "par.sum$9".NewName = "B3("
        guiModify( "double" Name =
        "par.sum$10".NewName = "C1("
        guiModify( "double". Name =
        "par.sum$11".NewName = "C2("
        guiModify( "double". Name =
        "par.sum$12".NewName = "C3("

        par.sum[1.'MC.Iter']<-mc.iter
        par.sum[1.'Part']<-0
        par.sum[1.'S.Size']<-n.c
        par.sum[1.'A1']<-pca1
        par.sum[1.'A2']<-pca2
        par.sum[1.'A3']<-pca3
        par.sum[1.'B1']<-pcb1
        par.sum[1.'B2']<-pcb2
        par.sum[1.'B3']<-pcb3
        par.sum[1.'C1']<-pcc1
        par.sum[1.'C2']<-pcc2
        par.sum[1.'C3']<-pcc3
        par.sum[2.'Part']<-1
        par.sum[2.'S.Size']<-n.f
        par.sum[2.'A1']<-pfa1
        par.sum[2.'A2']<-pfa2
        par.sum[2.'A3']<-pfa3

```

```

par.sum[2,'B1']<-pfb1
par.sum[2,'B2']<-pfb2
par.sum[2,'B3']<-pfb3
par.sum[2,'C1']<-pfc1
par.sum[2,'C2']<-pfc2
par.sum[2,'C3']<-pfc3

html.table(par.sum,"e:/Mehdi/msadecision.html".append=T(

                                decision.sum<-matrix(0.1.9(

                                guiModify(      "double"      Name      =
'  "decision.sum$1".NewName = "Kappa.Agr("      guiModify(      "double"      Name      =
'  "decision.sum$2".NewName = "Kappa.Cap("      guiModify(      "double"      Name      =
'  "decision.sum$3".NewName = "Prop.Eq("      guiModify(      "double"      Name      =
'  "decision.sum$4".NewName = "Chisq.Agr("      guiModify(      "double"      Name      =
'  "decision.sum$5".NewName = "PropC.Cap("      guiModify(      "double"      Name      =
'  "decision.sum$6".NewName = "PropF.Cap("      guiModify(      "double"      Name      =
'  "decision.sum$7".NewName = "PropG.Cap("      guiModify(      "double"      Name      =
'  "decision.sum$8".NewName = "Manual.Decision("      guiModify(      "double"      Name      =
'  "decision.sum$9".NewName = "Deter.Decision("      guiModify(      "double"      Name      =

                                for (k in      (1:9
                                )
                                {

                                decision.sum[k]<-sum(decision.counter[,k]{

html.table(decision.sum,"e:/Mehdi/msadecision.html".append=T(
p.vec[iter]<-p
manual.rejected.no[iter]<-decision.sum[1,'Manual.Decision('
deter.rejected.no[iter]<-decision.sum[1,'Deter.Decision('
{

برازش مدل مزدوج

#
set.seed(51(
lbeta<-function(theta){alpha<-theta[1];beta<-theta[2];
return(lgamma(alpha)+lgamma(beta)-lgamma(alpha+beta)((
nO<-3
nR<-3
nP<-50
prior.alpha<-2
prior.beta<-2
pij<-matrix(0.nO.nR(
yij<-matrix(c(50.50.48.48.43.44.47.44).nO.nR(
exam<-matrix(0.nO.nR(
prior.alpha<-3
prior.beta<-1
minus.log.marg.lik<-function(theta(
)
                                alpha<-theta[1(
                                beta<-theta[2(
return      (-sum(lgamma(alpha+beta)+lgamma(yij+alpha)+lgamma(nP-yij+beta)-lgamma(alpha)-

```

```

lgamma(beta)-lgamma(nP+alpha+beta)((
{

parameters.EB<-nlminb(start=c(1.1).minus.log.marg.lik.lower=c(-Inf,-Inf))$parameters
#plot(1:1000/1000.dbeta(1:1000/1000.parameters.EB[1].parameters.EB[2]).type='l('
print(parameters.EB[1]/(parameters.EB[1]+parameters.EB[2]))
mu.hat<-sum(yij)/(nP*nO*nR(
s2<-sum((yij/nP-mu.hat)^2)/(nO*nR(
sigma.inv.hat<-(mu.hat*(1-mu.hat)-s2)/(s2-mu.hat*(1-mu.hat)/nP(
alpha.MOM<-mu.hat*sigma.inv.hat
beta.MOM<-sigma.inv.hat-alpha.MOM
3 ###D PLOT

a.alpha<-1
b.alpha<-1000
n.alpha<-50

a.beta<-0.1
b.beta<-50
n.beta<-50

marvec<-c()

stvec.alpha<-c()

stvec.beta<-c()

meshplot<-matrix(1:n.alpha*n.beta,3(
for (i in 1:n.alpha(
}

for(j in 1:n.beta(
}

meshplot[(i-1)*n.alpha+j,1]<-i/n.alpha*(b.alpha-a.alpha)+a.alpha
meshplot[(i-1)*n.alpha+j,2]<-j/n.beta*(b.beta-a.beta)+a.beta
meshplot[(i-1)*n.alpha+j,3]<--minus.log.
marg.lik(c(meshplot[(i-1)*n.alpha+j,1],meshplot[(i-1)*n.alpha+j,2]))
{

meshplot<-as.data.frame(meshplot(

2 ###D Plot 1

a.alpha<-1
b.alpha<-1000
n.alpha<-50

marvec<-c()
stvec.alpha<-c()

for (i in 1:n.alpha(
}

stvec.alpha[i]<-i/n.alpha*(b.alpha-a.alpha)+a.alpha
marvec[i]<--minus.log.
marg.lik(c(stvec.alpha[i],parameters.EB[1]))
{

plot(stvec.alpha,marvec,xlab='Alpha',ylab='Log Likelihood',type='l('
a.beta<-0.1
b.beta<-50
n.beta<-50

marvec<-c()

```

```

stvec.beta<-c()

for (i in 1:n.alpha(
)
stvec.beta[i]<-j/n.beta*(b.beta-a.beta)+a.beta
marvec[i]<--minus.log.
marg.lik(c(parameters.EB[1].stvec.beta[i)(([
{

#plot(stvec.beta.marvec.xlab='Beta'.ylab='Log Likelihood'.type='l('

#####Bayes Factors

##Laplace

prior.
alpha<-parameters.EB[1[
prior.beta<-parameters.EB[2[

prior.
alpha<-1
prior.beta<-1

zij<-matrix(0.nO.nR(

for (i in 1:nO(
)
for(j in 1:nR(
)
zij[i j]<-lbeta(c(yij[i.j]+prior.alpha.nP-
yij[i.j]+prior.beta((
{
log.B1<-lbeta(c(sum(yij)+prior.alpha.nO*nP*nR-sum(yij)+prior.beta((
log.B2<-sum(zij(
log.B12<-log.B1-log.B2
beta.MOM parameters.EB

log(1-pbeta(0.8.(sum(yij)+prior.alpha).(nO*nP*nR-sum(yij)+prior.beta(((
-log(pbeta(0.8.(sum(yij)+prior.alpha).(nO*nP*nR-sum(yij)+prior.beta(((

```

تولید چند جمله ای های هرمیت

```

hermitfunction[1]:=2*x;hermitfunction[2]:=4*x^2-2;
>

hermitfunction[1] := 2 x

hermitfunction[2] := 4 x^2 - 2

> for r from 3 to 31 do;
> hermitfunction[r]:=expand(2*x*hermitfunction[r-1]-2*(r-1)*hermitfunction[r-2]);
> hermitnodes[r]:=evalf(solve(hermitfunction[r]=0,{x}));

```

```
> end do;
```

برازش مدل با اثرات متقابل

```
set.seed(250)
options(object.size=370000000)
logitinv<-function (x){exp(x)/(1+exp(x))}
matdiag<- function (xvec,dim)
{
  w<-matrix(0,length(xvec)*dim,dim)
  for (i in 0:(dim-1))
  {
    for (j in 1:length(xvec))
    {
      w[(i*length(xvec)+j),(i+1)]<-xvec[j]
    }
  }
  return(w)
}

indexfinder1<-function(r,n,O)
{
  if (r%%n.O==0)
  {
    {return(r%%n.O)}
    {return (r%%n.O+1)}
  }
}

indexfinder2<-function(r,n,O)
{
  if (r%%n.O==0)
  {
    {return(n.O)}
    {return(r%%n.O)}
  }
}

ghqn<-matrix(0,30,30)
ghqw<-matrix(0,30,30)

n.O<-3
n.P<-50
n.R<-3

sigma.O0<-0.1
sigma.P0<-0.1
sigma.OP0<-0.1
mu0<-1

nvec<-c(n.O,n.P,n.R)

nqn.O<-5
nqn.P<-5
nqn.OP<-5
qw.O<-c()
qw.P<-c()
qw.OP<-c()
qn.O<-c()
qn.P<-c()
qn.OP<-c()
yij<-matrix(-1,n.O,n.P)

#### GHQ 2 point
ghqn[2,1]<- -0.707107
ghqn[2,2]<- +0.707107
ghqw[2,1]<- 0.886227
ghqw[2,2]<- 0.886227

#### GHQ 3 point
ghqn[3,1]<- -1.224745
```

```

ghqn[3.2]<- 0
ghqn[3.3]<- +1.224745
ghqw[3.1]<- 0.295409
ghqw[3.2]<- 1.181636
ghqw[3.3]<- 0.295409

```

```

#### GHQ 4 point
ghqn[4.1]<- -1.650680
ghqn[4.2]<- -0.524648
ghqn[4.3]<- +0.524648
ghqn[4.4]<- +1.650680
ghqw[4.1]<- 0.0813128
ghqw[4.2]<- 0.804914
ghqw[4.3]<- 0.804914
ghqw[4.4]<- 0.0813128

```

```

#### GHQ 5 point
ghqn[5.1]<- -2.020183
ghqn[5.2]<- -0.958572
ghqn[5.3]<- 0
ghqn[5.4]<- +0.958572
ghqn[5.5]<- +2.020183
ghqw[5.1]<- 0.0199532
ghqw[5.2]<- 0.393619
ghqw[5.3]<- 0.945309
ghqw[5.4]<- 0.393619
ghqw[5.5]<- 0.0199532

```

```

#### Substituting from reference quadrature

```

```

for (i in 1:nqn.O) ## for Operator
{
qn.O[i]<-ghqn[nqn.O.i]
qw.O[i]<-ghqw[nqn.O.i]
}

```

```

for (i in 1:nqn.P) ## for Parts
{
qn.P[i]<-ghqn[nqn.P.i]
qw.P[i]<-ghqw[nqn.P.i]
}

```

```

for (i in 1:nqn.OP) ## for Operator*Parts
{
qn.OP[i]<-ghqn[nqn.OP.i]
qw.OP[i]<-ghqw[nqn.OP.i]
}

```

```

n.O<-nvec[1]
n.P<-nvec[2]
n.OP<-nvec[3]
eta<-array(-1.c(nqn.O,nqn.P,nqn.OP,4))

```

```

for (i in 1:nqn.O)
{
  for (j in 1:nqn.P)
  {
    for (k in 1:nqn.OP)
    {
      eta[i,j,k]<-c(1.qn.O[i],qn.P[j],qn.OP[k])
    }
  }
}

```

```

etavec<-c()
etamatrix<-matrix(-1*n.O*n.P,(4*nqn.O*nqn.P*nqn.OP))

for (i in 1:nqn.O)
  {
    for (j in 1:nqn.P)
      {
        for (k in 1:nqn.OP)
          {
            etavec<-
            cbind(etavec,t(eta[i,j,k]))
          }
      }
  }

for (i in 1:(n.O*n.P))
{
  etamatrix[i,<-etavec
}

##### DATA GENERATION SHOULD BE HERE #####

alldata<-array(0,c(n.O,n.R,n.P))

#### Data Generation #####

for (i in 1:n.O)
{
  for (j in 1:n.R)
    {
      for (k in 1:n.P)
        {
          alldata[i,j,k]<-manualdata.correct2$RESP[(i-
1)*n.O+(j-1)*n.R+k]
        }
    }
}

for (i in 1:n.O)
{
  for (j in 1:n.P)
    {
      yij[i,j]<-sum(alldata[i..j])
    }
}

##### DEFINING MARGINAL LIKELIHOOD #####

marginal.likelihood<-function (theta0)
{
  theta<-c()
  theta[1]<-theta0[1]
  theta[2:4]<-sqrt(2)*theta0[2:4]

  etacomp<-matrix(-1*n.O*n.P,n.O*n.P)

```

```

x<-matdiag(theta.(n.O*n.P))
etacomp<-etamatrix%%matdiag(theta.(nqn.O*nqn.P*nqn.OP))

yijmatrix<-matrix(-1.(n.O*n.P).(nqn.O*nqn.P*nqn.OP))

for (r in 1:(n.O*n.P))
{
    j<-indexfinder1(r.n.O)
    i<-indexfinder2(r.n.O)
    # print(c(r.i.j))
    # print(c(r.i.j.yij[i,j]))
    yijmatrix[r.]<-rep(yij[i,j].times=(nqn.O*nqn.P*nqn.OP))
}

etacompstar<-matrix(-1.(n.O*n.P).(nqn.O*nqn.P*nqn.OP))
etacompstar<-exp(etacomp*yijmatrix)/(1+exp(etacomp))^n.R
#print(etacompstar)

qw.P.vec<-c()
qw.OP.vec<-c()
qw.P.vec<-rep(qw.P.each=nqn.OP)
qw.OP.vec<-rep(qw.OP.times=nqn.P)

qw.P.OP.vec<-qw.P.vec*qw.OP.vec

etacompstar<-matrix(t(etacompstar).(n.O*n.P*nqn.O).(nqn.P*nqn.OP).byrow=T)

# etacomp 1.1.ut
# etacomp 1.2.ut
# ...
# etacomp 1.nqn.O.ut
# ...
# etacomp 2.1.ut
# etacomp 2.2.ut
# ...
# etacomp 2.nqn.O.ut
# ...
# etacomp n.O.nqn.O.ut

integ.lik.P.OP<-etacompstar%%qw.P.OP.vec

# integ.lik.P.OP i=1 j=1 v=1
# integ.lik.P.OP i=1 j=1 v=2
# ...
# integ.lik.P.OP i=1 j=1 v=nqn.O

# integ.lik.P.OP i=2 j=1 v=1
# integ.lik.P.OP i=2 j=1 v=2
# ...
# integ.lik.P.OP i=2 j=1 v=nqn.O

# ...

# integ.lik.P.OP i=n.O j=1 v=1
# integ.lik.P.OP i=n.O j=1 v=2
# ...
# integ.lik.P.OP i=2 j=1 v=nqn.O

# integ.lik.P.OP i=1 j=2 v=1
# integ.lik.P.OP i=1 j=2 v=2
# ...
# integ.lik.P.OP i=1 j=2 v=nqn.O

# ...

# integ.lik.P.OP i=1 j=n.P v=1
# integ.lik.P.OP i=1 j=n.P v=2
# ...
# integ.lik.P.OP i=1 j=n.P v=nqn.O

```



```

# ...

# integ.lik.P.OP i=n.O j=n.P v=1
# integ.lik.P.OP i=n.O j=n.P v=2
# ...
# integ.lik.P.OP i=n.O j=n.P v=nqn.O

marg.lik.O<-c()
prod1<-1

#for (i in 1:n.O)
#{
#summation<-0
#
#           for (v in 1:nqn.O)
#
#           {
#
#           prod2<-1
#           for (j in 1:n.P)
#           {
#
#
#           print(n.P*(j-1)+i)
#
#           print(n.P*nqn.O*(i-1)+(j-1)*nqn.O+v)
#
#           prod2<-
prod2*integ.lik.P.OP[n.P*nqn.O*(i-1)+(j-1)*nqn.O+v]
#
#           }
#
#           summation<-summation+prod2*qw.O[v]
#
#           }
#prod2<-prod2*summation
# Delet it for fast algorithm
#marg.lik.O[i]<-summation
#}

for (i in 1:n.O)
{
summation<-0
#
#           for (v in 1:nqn.O)
#
#           {
#
#           prod2<-1
#           for (j in 1:n.P)
#           {
#
#           prod2<-
prod2*integ.lik.P.OP[n.O*nqn.O*(j-1)+(i-1)*nqn.O+v]
#
#           }
#
#           summation<-summation+prod2*qw.O[v]
#
#           }
#
#           prod1<-prod1*summation
#
#           return(-log(prod1))
#
#           }

inter.max<-nlminb(start=c(2.0,0.0),objective=marginal.likelihood,lower=c(-Inf,0.0,0))
mu.bre<-inter.max$parameters[1]
sigmaO.bre<-inter.max$parameters[2]
sigmaP.bre<-inter.max$parameters[3]

sigmaOP.bre<-inter.max$parameters[4]

marginal.likelihood(c(mu.bre,sigmaO.bre,sigmaP.bre,sigmaOP.bre))

```

```

### 3d Plot for sigmaO sigmaP
a.sigmaO<-0
b.sigmaO<-1
n.sigmaO<-10

a.sigmaP<-0
b.sigmaP<-1
n.sigmaP<-10

marvec<-c()

stvec.sigmaO<-c()

stvec.sigmaP<-c()

meshplot<-matrix(1:n.sigmaO*n.sigmaP,3)

for (i in 1:n.sigmaO)
{

print(i)


                                for(j in 1:n.sigmaP)
                                {

meshplot[(i-1)*n.sigmaO+j,1]<-i/n.sigmaO*(b.sigmaO-a.sigmaO)+a.sigmaO
meshplot[(i-1)*n.sigmaO+j,2]<-j/n.sigmaP*(b.sigmaP-a.sigmaP)+a.sigmaP
                                meshplot[(i-1)*n.sigmaO+j,3]<-
-marginal.likelihood(c(mu.bre.meshplot[(i-1)*n.sigmaO+j,1].meshplot[(i-1)*n.sigmaO+j,2],
sigmaOP.bre))
                                }

}

meshplot<-as.data.frame(meshplot)


### 3d Plot for sigmaO sigmaOP
a.sigmaO<-0

```

```

b.sigmaO<-1
n.sigmaO<-10

a.sigmaOP<-0
b.sigmaOP<-1
n.sigmaOP<-10

marvec<-c()

stvec.sigmaO<-c()
stvec.sigmaOP<-c()

meshplot<-matrix(1:n.sigmaO*n.sigmaOP,3)

for (i in 1:n.sigmaO)
{

print(i)

for(j in 1:n.sigmaOP)
{

meshplot[(i-1)*n.sigmaO+j,1]<-i/n.sigmaO*(b.sigmaO-a.sigmaO)+a.sigmaO
meshplot[(i-1)*n.sigmaO+j,2]<-j/n.sigmaOP*(b.sigmaOP-a.sigmaOP)+a.sigmaOP
meshplot[(i-1)*n.sigmaO+j,3]<-
-marginal.likelihood(c(mu.bre.meshplot[(i-1)*n.sigmaO+j,1],
sigmaP.bre.meshplot[(i-1)*n.sigmaO+j,2]))
}

}

meshplot<-as.data.frame(meshplot)


## 3d Plot for sigmaP sigmaOP
a.sigmaP<-0
b.sigmaP<-1
n.sigmaP<-10

a.sigmaOP<-0
b.sigmaOP<-1
n.sigmaOP<-10

marvec<-c()

stvec.sigmaP<-c()
stvec.sigmaOP<-c()

meshplot<-matrix(1:n.sigmaP*n.sigmaOP,3)

for (i in 1:n.sigmaP)
{

print(i)

for(j in 1:n.sigmaOP)

```

```

        {
meshplot[(i-1)*n.sigmaP+j.1]<-i/n.sigmaP*(b.sigmaP-a.sigmaP)+a.sigmaP
meshplot[(i-1)*n.sigmaP+j.2]<-j/n.sigmaOP*(b.sigmaOP-a.sigmaOP)+a.sigmaOP
        meshplot[(i-1)*n.sigmaP+j.3]<-
-marginal.likelihood(c(mu.bre.
sigmaO.bre.meshplot[(i-1)*n.sigmaO+j.1].meshplot[(i-1)*n.sigmaO+j.2]))
        }
}

```

```

meshplot<-as.data.frame(meshplot)

```

```

### 2D Plot for sigmaO
a.sigmaO<-0
b.sigmaO<-1
n.sigmaO<-20

```

```

marvec<-c()

```

```

stvec.sigmaO<-c()

```

```

meshplot<-matrix(1,n.sigmaO*n.sigmaP,3)

```

```

for (i in 1:n.sigmaO)
{

```

```

  print(i)

```

```

  stvec.sigmaO[i]<-i/n.sigmaO*(b.sigmaO-a.sigmaO)+a.sigmaO
                    marvec[i]<-
-marginal.likelihood(c(mu.bre.stvec.sigmaO[i].sigmaP.bre.
sigmaOP.bre))

```

```

}

```

```

plot(stvec.sigmaO.marvec.type='l')

```

```

### 2D Plot for sigmaP
a.sigmaP<-0
b.sigmaP<-1
n.sigmaP<-20

```

```

marvec<-c()

```

```

stvec.sigmaP<-c()

```

```

for (i in 1:n.sigmaO)
{

```

```

  print(i)

```

```

  stvec.sigmaP[i]<-i/n.sigmaP*(b.sigmaP-a.sigmaP)+a.sigmaP
                    marvec[i]<-
-marginal.likelihood(c(mu.bre.sigmaO.bre.stvec.sigmaP[i].
sigmaOP.bre))
}

```

```

plot(stvec.sigmaP.marvec.type='l')

```

```

### 2D Plot for sigmaOP
a.sigmaOP<-0
b.sigmaOP<-1
n.sigmaOP<-20

marvec<-c()

stvec.sigmaOP<-c()

for (i in 1:n.sigmaOP)
{

print(i)

stvec.sigmaOP[i]<-i/n.sigmaOP*(b.sigmaOP-a.sigmaOP)+a.sigmaOP
marvec[i]<-
-marginal.likelihood(c(mu.bre.sigmaO.bre,
sigmaP.bre.stvec.sigmaOP[i]))
}

plot(stvec.sigmaOP.marvec.type='l')

```

```

### 2D Plot for sigmaOP
a.mu<-0
b.mu<-2
n.mu<-20

marvec<-c()

stvec.mu<-c()

for (i in 1:n.mu)
{

print(i)

stvec.mu[i]<-i/n.mu*(b.mu-a.mu)+a.mu
marvec[i]<-
-marginal.likelihood(c(stvec.mu[i],sigmaO.bre,
sigmaP.bre.sigmaOP.bre))
}

plot(stvec.mu.marvec.type='l')

```

برازش مدل آشیانه ای و محاسبه P -مقدار تجربی

```

set.seed(250)
options(object.size=370000000)
logitinv<-function (x){exp(x)/(1+exp(x))}
matdiag<- function (xvec,dim)
{
w<-matrix(0,length(xvec)*dim,dim)
for (i in 0:(dim-1))
{
for (j in 1:length(xvec))
{

```

```

        w[(i*length(xvec)+j).(i+1)]<-xvec[j]
    }

return(w)
}

indexfinder1<-function(r,n.O)
{
    if (r%%n.O==0)
        {return(r%%n.O)}
    {return (r%%n.O+1)}
}

indexfinder2<-function(r,n.O)
{
    if (r%%n.O==0)
        {return(n.O)}
    {return(r%%n.O)}
}

#####Gauss-Hermit Quadrature Calculations#####

c.f1<-c();
c.f2<-c();
c.f3<-c();
c.f4<-c();
c.f5<-c();
c.f6<-c();
c.f7<-c();
c.f8<-c();
c.f9<-c();

c.f10<-c();
c.f11<-c();
c.f12<-c();
c.f13<-c();
c.f14<-c();
c.f15<-c();
c.f16<-c();
c.f17<-c();
c.f18<-c();
c.f19<-c();

c.f20<-c();
c.f21<-c();
c.f22<-c();
c.f23<-c();
c.f24<-c();
c.f25<-c();
c.f26<-c();
c.f27<-c();
c.f28<-c();
c.f29<-c();

c.f30<-c();
c.f31<-c();

f0<-function(x){1}
f1<-function(x){2*x}
f2<-function(x){4*x^2-2}

c.f2[3]<- 4
c.f2[2]<- 0
c.f2[1]<- -2

```

```
f3<-function(x){8*x^3-12*x}  
c.f3[4]<- 8  
c.f3[3]<- 0  
c.f3[2]<- -12  
c.f3[1]<- 0
```

```
f4<-function(x){16*x^4-48*x^2+12}  
c.f4[5]<- 16  
c.f4[4]<- 0  
c.f4[3]<- -48  
c.f4[2]<- 0  
c.f4[1]<- +12
```

```
f5<-function(x){32*x^5-160*x^3+120*x}  
c.f5[6]<- 32  
c.f5[5]<- 0  
c.f5[4]<- -160  
c.f5[3]<- 0  
c.f5[2]<- +120  
c.f5[1]<- 0
```

```
f6<-function(x){64*x^6-480*x^4+720*x^2-120}  
c.f6[7]<- 64  
c.f6[6]<- 0  
c.f6[5]<- -480  
c.f6[4]<- 0  
c.f6[3]<- +720  
c.f6[2]<- 0  
c.f6[1]<- -120
```

```
f7<-function(x){128*x^7-1344*x^5+3360*x^3-1680*x}  
c.f7[8]<- 128  
c.f7[7]<- 0  
c.f7[6]<- -1344  
c.f7[5]<- 0  
c.f7[4]<- +3360  
c.f7[3]<- 0  
c.f7[2]<- -1680  
c.f7[1]<- 0
```

```
f8<-function(x){256*x^8-3584*x^6+13440*x^4-13440*x^2+1680}  
c.f8[9]<- 256  
c.f8[8]<- 0  
c.f8[7]<- -3584  
c.f8[6]<- 0  
c.f8[5]<- +13440  
c.f8[4]<- 0  
c.f8[3]<- -13440  
c.f8[2]<- 0  
c.f8[1]<- +1680
```

```
f9<-function(x){512*x^9-9216*x^7+48384*x^5-80640*x^3+30240*x}  
c.f9[10]<- 512  
c.f9[9] <- 0  
c.f9[8] <- -9216  
c.f9[7] <- 0  
c.f9[6] <- +48384  
c.f9[5] <- 0  
c.f9[4] <- -80640  
c.f9[3] <- 0  
c.f9[2] <- +30240  
c.f9[1] <- 0
```

```
f10<-function(x){1024*x^10-23040*x^8+161280*x^6-403200*x^4+302400*x^2-30240}  
c.f10[11]<- 1024  
c.f10[10]<- 0  
c.f10[9] <- -23040  
c.f10[8] <- 0
```

```

c.f10[7] <- +161280
c.f10[6] <- 0
c.f10[5] <- -403200
c.f10[4] <- 0
c.f10[3] <- +302400
c.f10[2] <- 0
c.f10[1] <- -30240

f11<-function(x){2048*x^11-56320*x^9+506880*x^7-1774080*x^5+2217600*x^3-665280*x}
c.f11[12]<- 2048
c.f11[11]<- 0
c.f11[10]<- -56320
c.f11[9] <- 0
c.f11[8] <- +506880
c.f11[7] <- 0
c.f11[6] <- -1774080
c.f11[5] <- 0
c.f11[4] <- +2217600
c.f11[3] <- 0
c.f11[2] <- -665280
c.f11[1] <- 0

f12<-function(x){4096*x^12-135168*x^10+1520640*x^8-7096320*x^6+13305600*x^4-
7983360*x^2+665280}
c.f12[13]<- 4096
c.f12[12]<- 0
c.f12[11]<- -135168
c.f12[10]<- 0
c.f12[9] <- +1520640
c.f12[8] <- 0
c.f12[7] <- -7096320
c.f12[6] <- 0
c.f12[5] <- 13305600
c.f12[4] <- 0
c.f12[3] <- -7983360
c.f12[2] <- 0
c.f12[1] <- +665280

f13<-function(x){8192*x^13-319488*x^11+4392960*x^9-26357760*x^7+69189120*x^5-
69189120*x^3+
17297280*x}
c.f13[14]<- 8192
c.f13[13]<- 0
c.f13[12]<- -319488
c.f13[11]<- 0
c.f13[10]<- +4392960
c.f13[9] <- 0
c.f13[8] <- -26357760
c.f13[7] <- 0
c.f13[6] <- +69189120
c.f13[5] <- 0
c.f13[4] <- -69189120
c.f13[3] <- 0
c.f13[2] <- 17297280
c.f13[1] <- 0

f14<-function(x){16384*x^14-745472*x^12+12300288*x^10-92252160*x^8+322882560*x^6-
484323840*x^4
+242161920*x^2-17297280}

c.f14[15]<- 16384
c.f14[14]<- 0
c.f14[13]<- -745472
c.f14[12]<- 0
c.f14[11]<- +12300288
c.f14[10]<- 0
c.f14[9] <- -92252160
c.f14[8] <- 0
c.f14[7] <- +322882560

```



```
c.f14[6] <- 0
c.f14[5] <- -484323840
c.f14[4] <- 0
c.f14[3] <- +242161920
c.f14[2] <- 0
c.f14[1] <- -17297280
```

```
f15<-function(x){32768*x^15-1720320*x^13+33546240*x^11-307507200*x^9+1383782400*x^7-
2905943040*x^5+2421619200*x^3-518918400*x}
```

```
c.f15[16]<- 32768
c.f15[15]<- 0
c.f15[14]<- -1720320
c.f15[13]<- 0
c.f15[12]<- +33546240
c.f15[11]<- 0
c.f15[10]<- -307507200
c.f15[9] <- 0
c.f15[8] <- +1383782400
c.f15[7] <- 0
c.f15[6] <- -2905943040
c.f15[5] <- 0
c.f15[4] <- +2421619200
c.f15[3] <- 0
c.f15[2] <- -518918400
c.f15[1] <- 0
```

```
f16<-function(x){65536*x^16-3932160*x^14+89456640*x^12-984023040*x^10+5535129600*x^8-
15498362880*x^6+19372953600*x^4-8302694400*x^2+518918400}
```

```
c.f16[17]<- 65536
c.f16[16]<- 0
c.f16[15]<- -3932160
c.f16[14]<- 0
c.f16[13]<- +89456640
c.f16[12]<- 0
c.f16[11]<- -984023040
c.f16[10]<- 0
c.f16[9] <- +5535129600
c.f16[8] <- 0
c.f16[7] <- -15498362880
c.f16[6] <- 0
c.f16[5] <- +19372953600
c.f16[4] <- 0
c.f16[3] <- -8302694400
c.f16[2] <- 0
c.f16[1] <- +518918400
```

```
f17<-function(x){131072*x^17-8912896*x^15+233963520*x^13-
3041525760*x^11+20910489600*x^9-
75277762560*x^7+131736084480*x^5-94097203200*x^3+17643225600*x}
```

```
c.f17[18]<- 131072
c.f17[17]<- 0
c.f17[16]<- -8912896
c.f17[15]<- 0
c.f17[14]<- +233963520
c.f17[13]<- 0
c.f17[12]<- -3041525760
c.f17[11]<- 0
c.f17[10]<- +20910489600
c.f17[9] <- 0
c.f17[8] <- -75277762560
c.f17[7] <- 0
c.f17[6] <- +131736084480
c.f17[5] <- 0
c.f17[4] <- -94097203200
c.f17[3] <- 0
c.f17[2] <- +17643225600
c.f17[1] <- 0
```

```
f18<-function(x){262144*x^18-20054016*x^16+601620480*x^14-
9124577280*x^12+75277762560*x^10
-338749931520*x^8+790416506880*x^6-846874828800*x^4+317578060800*x^2-17643225600}
```

```
c.f18[19]<- 262144
c.f18[18]<- 0
c.f18[17]<- -20054016
c.f18[16]<- 0
c.f18[15]<- +601620480
c.f18[14]<- 0
c.f18[13]<- -9124577280
c.f18[12]<- 0
c.f18[11]<- +75277762560
c.f18[10]<- 0
c.f18[9] <- -338749931520
c.f18[8] <- 0
c.f18[7] <- +790416506880
c.f18[6] <- 0
c.f18[5] <- -846874828800
c.f18[4] <- 0
c.f18[3] <- +317578060800
c.f18[2] <- 0
c.f18[1] <- -17643225600
```

```
f19<-function(x){524288*x^19-44826624*x^17+1524105216*x^15-
26671841280*x^13+260050452480*x^11
-1430277488640*x^9+4290832465920*x^7-6436248698880*x^5+4022655436800*x^3-
670442572800*x}
```

```
c.f19[20]<- 524288
c.f19[19]<- 0
c.f19[18]<- -44826624
c.f19[17]<- 0
c.f19[16]<- +1524105216
c.f19[15]<- 0
c.f19[14]<- -26671841280
c.f19[13]<- 0
c.f19[12]<- +260050452480
c.f19[11]<- 0
c.f19[10]<- -1430277488640
c.f19[9] <- 0
c.f19[8] <- +4290832465920
c.f19[7] <- 0
c.f19[6] <- -6436248698880
c.f19[5] <- 0
c.f19[4] <- +4022655436800
c.f19[3] <- 0
c.f19[2] <- -670442572800
c.f19[1] <- 0
```

```
f20<-function(x){1048576*x^20-99614720*x^18+3810263040*x^16-
76205260800*x^14+866834841600*x^12
-5721109954560*x^10+21454162329600*x^8-42908324659200*x^6+40226554368000*x^4-
13408851456000*x^2
+670442572800}
```

```
c.f20[21]<- 1048576
c.f20[20]<- 0
c.f20[19]<- -99614720
c.f20[18]<- 0
c.f20[17]<- +3810263040
c.f20[16]<- 0
c.f20[15]<- -76205260800
c.f20[14]<- 0
c.f20[13]<- +866834841600
```

```
c.f20[12]<- 0
c.f20[11]<- -5721109954560
c.f20[10]<- 0
c.f20[9] <- +21454162329600
c.f20[8] <- 0
c.f20[7] <- -42908324659200
c.f20[6] <- 0
c.f20[5] <- +40226554368000
c.f20[4] <- 0
c.f20[3] <- -13408851456000
c.f20[2] <- 0
c.f20[1] <- +670442572800
```

```
f21<-function(x){2097152*x^21-220200960*x^19+9413591040*x^17-
213374730240*x^15+2800543334400*x^13-21844238008320*x^11+100119424204800*x^9-
257449947955200*x^7+337903056691200*x^5-187723920384000*x^3+28158588057600*x}
f22<-function(x){4194304*x^22-484442112*x^20+23011000320*x^18-
586780508160*x^16+8801707622400*x^14-80095539363840*x^12+440525466501120*x^10-
1415974713753600*x^8+2477955749068800*x^6-2064963124224000*x^4+619488937267200*x^2-
28158588057600}
f23<-function(x){8388608*x^23-1061158912*x^21+55710842880*x^19-
1587759022080*x^17+26991903375360*x^15-283414985441280*x^13+1842197405368320*x^11-
7237204092518400*x^9+16283709208166400*x^7-18997660742860800*x^5+9498830371430400*x^3-
1295295050649600*x}
f24<-function(x){16777216*x^24-2315255808*x^22+133706022912*x^20-
4234024058880*x^18+80975710126080*x^16-971708521512960*x^14+7368789621473280*x^12-
34738579644088320*x^10+97702255248998400*x^8-
151981285942886400*x^6+113985964457164800*x^4-31087081215590400*x^2+1295295050649600}
f25<-function(x){64764752532480000*x-11142168576000*x^19+1139859644571648000*x^5-
518118020259840000*x^3+318347673600*x^21-157902634745856000*x^11-
3239028405043200*x^15+542790306938880000*x^9+28341498544128000*x^13-
1085580613877760000*x^7-5033164800*x^23+33554432*x^25+238163853312000*x^17}
f26<-function(x){-684244750565376000*x^12+688028909568000*x^18+752458137600*x^22-
28969638297600*x^20+1683883565844480000*x^2-7056273990205440000*x^8-
6735534263377920000*x^4+9878783586287616000*x^6+105268423163904000*x^14+28225095960821
76000*x^10-10526842316390400*x^16-64764752532480000+67108864*x^26-10905190400*x^24}
f27<-function(x){-3497296636753920000*x+1955450585088000*x^19-
72743770044481536000*x^5+30309904185200640000*x^3-
74493355622400*x^21+13855956198948864000*x^11+134217728*x^27+378966323390054400*x^15-
42337643941232640000*x^9-
2842247425425408000*x^13+76207759094218752000*x^7+1766640844800*x^23-23555211264*x^25-
33438205005004800*x^17}
```

```
f28<-function(x){64661128928428032000*x^12-104029971126681600*x^18-
189619450675200*x^22+5475261638246400*x^20-
97924305829109760000*x^2+533454313659531264000*x^8+424338658592808960000*x^4-
678941853748494336000*x^6-11368989701701632000*x^14-
237090806070902784000*x^10+1326382131865190400*x^16-
50734301184*x^26+268435456*x^28+3497296636753920000+4122161971200*x^24}
f29<-function(x){202843204931727360000*x-
317565175018291200*x^19+4922328439676583936000*x^5-
1893203246029455360000*x^3+15122151191347200*x^21-1250115159282941952000*x^11-
108984795136*x^27-
43960093513246310400*x^15+3437816688028090368000*x^9+288488113680678912000*x^13-
5625518216773238784000*x^7-
478170788659200*x^23+536870912*x^29+9563415773184*x^25+4525303744010649600*x^17}
```

```
f30<-function(x){-
6250575796414709760000*x^12+15084345813368832000*x^18+41242230521856000*x^22-
952695525054873600*x^20+6085296147951820800000*x^2-42191386625799290880000*x^8-
28398048690441830400000*x^4+49223284396765839360000*x^6+1236377630060052480000*x^14+20
626900128168542208000*x^10-164850350674673664000*x^16+22069421015040*x^26-
233538846720*x^28+1073741824*x^30-202843204931727360000-1195426971648000*x^24}
f31<-function(x){-12576278705767096320000*x+49222602127835136000*x^19-
352135803761478696960000*x^5+125762787057670963200000*x^3-
2812720121590579200*x^21+116260709813313601536000*x^11+50677929738240*x^27+51103608709
14883584000*x^15-290651774533284003840000*x^9-
29810438413670154240000*x^13+2147483648*x^31+435977661799926005760000*x^7+111174708363
264000*x^23-499289948160*x^29-2964658889687040*x^25-601218925989986304000*x^17}
```

```
#####Gauss-Hermit Quadrature Calculations#####
```

```
bootstrap.iter<-10000
```

```
mc.iter<-100
```

```
n.O<-3
```

```
n.R<-3
```

```
n.P<-50
```

```
sigma.O0<-0.4
```

```
sigma.R00<-
```

```
0.4
```

```
mu0<-2
```

```
# for final html.table
```

```
sigma.O0.out<-sigma.O0
```

```
sigma.R00.out<-sigma.R00
```

```
mu0.out<-mu0
```

```
nqn.O<-20
```

```
nqn.R<-20
```

```
qw.O<-c()
```

```
qw.R<-c()
```

```
qn.O<-c()
```

```
qn.R<-c()
```

```
yik<-matrix(-1,n.O,n.R)
```

```
ghqn<-matrix(0.30.30)
```

```
ghqw<-matrix(0.30.30)
```

```
##### GHQ 2 point
```

```
m<-2
```

```
ghqn[2.m:1]<- sort(Re(
```

```
polyroot(c.f2)))
```

```
ghqw[2.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f3(ghqn[2.m:1])^2
```

```
# GHQ 3 point
```

```
m<-3
```

```
ghqn[3.m:1]<- sort(Re(
```

```
polyroot(c.f3)))
```

```
ghqw[3.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f4(ghqn[3.m:1])^2
```

```
##### GHQ 4 point
```

```
m<-4
```

```
ghqn[4.m:1]<- sort(Re(
```

```
polyroot(c.f4)))
```

```
ghqw[4.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f5(ghqn[4.m:1])^2
```

```
##### GHQ 5 point
```

```
m<-5
```

```
ghqn[5.m:1]<- sort(Re(
```

```
polyroot(c.f5)))
```

```
ghqw[5.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f6(ghqn[5.m:1])^2
```

```
##### GHQ 6 point
```

```
m<-6
ghqn[6.m:1]<- sort(Re(
polyroot(c.f6)))
ghqw[6.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f7(ghqn[6.m:1])^2
```

```
##### GHQ 7 point
```

```
m<-7
ghqn[7.m:1]<- sort(Re(
polyroot(c.f7)))
ghqw[7.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f8(ghqn[7.m:1])^2
```

```
##### GHQ 8 point
```

```
m<-8
ghqn[8.m:1]<- sort(Re(
polyroot(c.f8)))
ghqw[8.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f9(ghqn[8.m:1])^2
```

```
##### GHQ 9 point
```

```
m<-9
ghqn[9.m:1]<- sort(Re(
polyroot(c.f9)))
ghqw[9.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f10(ghqn[9.m:1])^2
```

```
##### GHQ 10 point
```

```
m<-10
ghqn[10.m:1]<- sort(Re(
polyroot(c.f10)))
ghqw[10.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f11(ghqn[10.m:1])^2
```

```
##### GHQ 11 point
```

```
m<-11
ghqn[11.m:1]<- sort(Re(
polyroot(c.f11)))
ghqw[11.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f12(ghqn[11.m:1])^2
```

```
##### GHQ 12 point
```

```
m<-12
ghqn[12.m:1]<- sort(Re(
polyroot(c.f12)))
ghqw[12.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f13(ghqn[12.m:1])^2
```

```
##### GHQ 13 point
```

```
m<-13
ghqn[13.m:1]<- sort(Re(
polyroot(c.f13)))
ghqw[13.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f14(ghqn[13.m:1])^2
```

```
##### GHQ 14 point
```

```
m<-14
ghqn[14.m:1]<- sort(Re(
polyroot(c.f14)))
ghqw[14.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f15(ghqn[14.m:1])^2
```

```
##### GHQ 15 point
```

```
m<-15
ghqn[15.m:1]<- sort(Re(
polyroot(c.f15)))
ghqw[15.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f16(ghqn[15.m:1])^2
```

```
##### GHQ 16 point
```

```
m<-16
ghqn[16.m:1]<- sort(Re(
polyroot(c.f16)))
ghqw[16.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f17(ghqn[16.m:1])^2
```

```
##### GHQ 17 point
```

```
m<-17
ghqn[17.m:1]<- sort(Re(
polyroot(c.f17)))
ghqw[17.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f18(ghqn[17.m:1])^2
```

```
##### GHQ 18 point
```

```
m<-18
ghqn[18.m:1]<- sort(Re(
polyroot(c.f18)))
ghqw[18.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f19(ghqn[18.m:1])^2
```

```
##### GHQ 19 point
```

```
m<-19
ghqn[19.m:1]<- sort(Re(
polyroot(c.f19)))
ghqw[19.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f20(ghqn[19.m:1])^2
```

```
##### GHQ 20 point
```

```
m<-20
ghqn[20.m:1]<- sort(Re(
polyroot(c.f20)))
ghqw[20.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f21(ghqn[20.m:1])^2
```

```
##### Substituting from reference quadrature
```

```

for (i in 1:nqn.O) ## for Operator
{
qn.O[i]<-ghqn[nqn.O.i]
qw.O[i]<-ghqw[nqn.O.i]
}

```

```

for (i in 1:nqn.R) ## for Parts
{
qn.R[i]<-ghqn[nqn.R.i]
qw.R[i]<-ghqw[nqn.R.i]
}

```

DATA GENERATION SHOULD BE HERE

```

pvalue.vec<-c()
mu.bre.vec<-c()
mu.glm.vec<-c()
sigmaO.bre.vec<-c()
sigmaRO.bre.vec<-c()

```

```

html.table(date(),'d:/vahid/bootstrap.htm'.append=T)

```

```

#### Data Generation #####
yik<-matrix(c(50.50.48.48.48.43.44.47.44).n.O.n.R)

```

```

#theta<-c(mu0.sigma.O0.sigma.RO0)
marg.lik.rr<-function(theta){

```

```

mu<-theta[1]

```

```

sigma.O<-theta[2]

```

```

sigma.RO<-theta[3]

```

```

##### Creation eta i. k .
leftmat<-matrix(-1.nqn.O.3)

```

```

rightmat<-matrix(-1.3.nqn.R)

```

```

for (i in 1:nqn.O)

```

```

{
for (j in 1:3)

```

```

c(mu.sqrt(2)*sigma.O*qn.O[i].sqrt(2)*sigma.RO)
}

```

```

{
leftmat[i.]<-
}

```

```

for (i in 1:3)

```

```

{
for (j in 1:nqn.R)

```

```

                                {
                                rightmat[,j]<-c(1.1.qn.R[j])
                                }

etamat<-leftmat%*%rightmat

##### Defining Marginal Likelihood #####

unitmat<-matrix(1,n.O,n.R)

etacomp1<-
kronecker(yik.etamat,'*')
etacomp2<-kronecker(unitmat.etamat)

etacompstar<-exp(etacomp1)/(1+exp(etacomp2))^n.P

marg.R<-etacompstar%*%matdiag(qw.R,n.R)

product.k<-exp(log(marg.R)%*%rep(1,times=n.R))
product.k.mat<-t(matrix(product.k,nqn.O,n.O))

marg.O<-product.k.mat%*%qw.O
log.marg.lik<-rep(1,times=n.O)%*%

log(marg.O)
return(-1*log.marg.lik)
}

#bootstrap.pvalue<-function(yik)
#{

glm.data<-data.frame(rep(1:n.O,each=(n.R*n.P)),rep(rep(1:n.R,times=n.O),each=n.P),0)
names(glm.data)<-c('Oper','Rep','Resp')
for (i in 1:n.O)
{
    for (j in 1:n.R)
    {
        indx<-(i-1)*n.R*n.P+(j-1)*n.P+1
        glm.data$Resp[indx:(indx+yik[i,j]-1)]<-
rep(1,times=yik[i,j])
    }
}

glm.fit.minimal<-summary(glm(Resp~1,family=binomial,data=glm.data))

mu0.glm<-glm.fit.minimal$coefficients[1,1]

marg.lik.max<-nlminb(start=c(2.0,0),objective=marg.lik,rr.lower=c(-Inf,0.0))

mu0.bre<-marg.lik.max$parameters[1]
sigma00.bre<-marg.lik.max$parameters[2]

sigma.R00.bre<-marg.lik.max$parameters[3]

(
pi^2/3)/(pi^2/3+sigma00.bre+

```



```

sigma.R00.bre)

p<-sum(yik)/(n.O*n.R*n.P)
sum(yik)*log(p/(1-p))+(n.O*n.R*n.P)*log(1-p)

print(sum(yik)*log(p/(1-p))+(n.O*n.R*n.P)*log(1-p)+marg.lik.rr(c(
mu0.bre.sigma00.bre.sigma.R00.bre))-
0.5*6*log(4*pi^2*sigma.R00.bre*sigma00.bre))

####
3D Plots (Sigma0, SigmaR)

a.sigmaO<-0
b.sigmaO<-0.7
n.sigmaO<-10

a.sigmaR<-0
b.sigmaR<-1.5
n.sigmaR<-10

marvec<-c()

stvec.sigmaO<-c()

stvec.sigmaR<-c()

meshplot<-matrix(1,n.sigmaO*n.sigmaR,3)

for (i in 1:n.sigmaO)
{

print(i)

for(j in 1:n.sigmaR)
{

meshplot[(i-1)*n.sigmaO+j,1]<-i/n.sigmaO*(b.sigmaO-a.sigmaO)+a.sigmaO
meshplot[(i-1)*n.sigmaO+j,2]<-j/n.sigmaR*(b.sigmaR-a.sigmaR)+a.sigmaR
meshplot[(i-1)*n.sigmaO+j,3]<-
-marg.lik.rr(c(mu0.bre.meshplot[(i-1)*n.sigmaO+j,1],meshplot[(i-1)*n.sigmaO+j,2]))
}

}

meshplot<-as.data.frame(meshplot)

#### 2D Plots (Sigma0, SigmaR)

a.sigmaO<-0
b.sigmaO<-0.1
n.sigmaO<-10

marvec<-c()

stvec.sigmaO<-c()

meshplot<-matrix(1,n.sigmaO*n.sigmaR,3)

```

```

for (i in 1:n.sigma0)
{
  stvec.sigma0[i]<-i/n.sigma0*(b.sigma0-a.sigma0)+a.sigma0
  marvec[i]<-
-marg.lik.rr(c(mu0.bre.stvec.sigma0[i],
sigma.R00.bre))
}
#

```

```

plot(stvec.sigma0.marvec.type='l')

```

```

stvec.sigmaR<-c()

```

```

marvec<-c()

```

```

a.sigmaR<-0
b.sigmaR<-2
n.sigmaR<-30

```

```

for (i in 1:n.sigma0)
{
  stvec.sigmaR[i]<-i/n.sigmaR*(b.sigmaR-a.sigmaR)+a.sigmaR
  marvec[i]<-
-marg.lik.rr(c(mu0.bre.
sigma00.bre.stvec.sigmaR[i]))
}
#

```

```

plot(stvec.sigmaR.marvec.type='l')

```

```

## MU

```

```

stvec.mu<-c()

```

```

marvec<-c()

```

```

a.mu<-0
b.mu<-6
n.mu<-30

```

```

for (i in 1:n.mu)
{
  stvec.mu[i]<-i/n.mu*(b.mu-a.mu)+a.mu
  marvec[i]<-
-marg.lik.rr(c(stvec.mu[i],
sigma00.bre.
sigma.R00.bre))
}

```

```

#plot(stvec.mu.marvec.type='l')

-marg.lik.rr(c(mu0.bre.sigma00.bre.sigma.R00.bre))

#### BOOT STRAP TEST

h0.mu.bre<-c()
h0.sigma0.bre<-c()
h0.sigmaR0.bre<-c()
bootstrap.decision<-c()

for (b in 1:bootstrap.iter)
{
    for (i in 1:n.O)
    {
        for (k in 1:n.R)
        {
            yik[i,k]<-
            rbinom(1,n.P.logitinv(mu0.glm))
        }
    }

h0fit.bre<-nlminb(start=c(2.0,0).objective=marg.lik.rr.lower=c(-Inf,0.0))
h0.mu.bre[b]<-h0fit.bre$parameters[1]
h0.sigma0.bre[b]<-h0fit.bre$parameters[2]
h0.sigmaR0.bre[b]<-h0fit.bre$parameters[3]

if ((h0.sigma0.bre[b]>sigma00.bre) | (h0.sigmaR0.bre[b]>
sigma.R00.bre))
{bootstrap.decision[b]<-T}
else
{bootstrap.decision[b]<-F}

print(list(b,bootstrap.decision[b].(sum(bootstrap.decision)/b)))
}
# for i

```

برازش مدل آشیانه اي و بازه هاي اطمینان بوت استرپ

```
set.seed(250)
options(object.size=370000000)
logitinv<-function (x){exp(x)/(1+exp(x))}
matdiag<- function (xvec,dim)
{
  w<-matrix(0,length(xvec)*dim,dim)
  for (i in 0:(dim-1))
  {
    for (j in 1:length(xvec))
    {
      w[(i*length(xvec)+j),(i+1)]<-xvec[j]
    }
  }
  return(w)
}

indexfinder1<-function(r,n,O)
{
  if (r%%n.O==0)
  {
    {return(r%%n.O)}
    {return (r%%n.O+1)}
  }
}

indexfinder2<-function(r,n,O)
{
  if (r%%n.O==0)
  {
    {return(n.O)}
    {return(r%%n.O)}
  }
}

#####Gauss-Hermit Quadrature Calculations#####

c.f1<-c();
c.f2<-c();
c.f3<-c();
c.f4<-c();
c.f5<-c();
c.f6<-c();
c.f7<-c();
c.f8<-c();
c.f9<-c();

c.f10<-c();
c.f11<-c();
c.f12<-c();
c.f13<-c();
c.f14<-c();
c.f15<-c();
c.f16<-c();
c.f17<-c();
c.f18<-c();
c.f19<-c();

c.f20<-c();
c.f21<-c();
c.f22<-c();
c.f23<-c();
c.f24<-c();
c.f25<-c();
c.f26<-c();
c.f27<-c();
c.f28<-c();
```

```
c.f29<-c();
```

```
c.f30<-c();  
c.f31<-c();
```

```
f0<-function(x){1}  
f1<-function(x){2*x}  
f2<-function(x){4*x^2-2}
```

```
c.f2[3]<- 4  
c.f2[2]<- 0  
c.f2[1]<- -2
```

```
f3<-function(x){8*x^3-12*x}  
c.f3[4]<- 8  
c.f3[3]<- 0  
c.f3[2]<- -12  
c.f3[1]<- 0
```

```
f4<-function(x){16*x^4-48*x^2+12}  
c.f4[5]<- 16  
c.f4[4]<- 0  
c.f4[3]<- -48  
c.f4[2]<- 0  
c.f4[1]<- +12
```

```
f5<-function(x){32*x^5-160*x^3+120*x}  
c.f5[6]<- 32  
c.f5[5]<- 0  
c.f5[4]<- -160  
c.f5[3]<- 0  
c.f5[2]<- +120  
c.f5[1]<- 0
```

```
f6<-function(x){64*x^6-480*x^4+720*x^2-120}  
c.f6[7]<- 64  
c.f6[6]<- 0  
c.f6[5]<- -480  
c.f6[4]<- 0  
c.f6[3]<- +720  
c.f6[2]<- 0  
c.f6[1]<- -120
```

```
f7<-function(x){128*x^7-1344*x^5+3360*x^3-1680*x}  
c.f7[8]<- 128  
c.f7[7]<- 0  
c.f7[6]<- -1344  
c.f7[5]<- 0  
c.f7[4]<- +3360  
c.f7[3]<- 0  
c.f7[2]<- -1680  
c.f7[1]<- 0
```

```
f8<-function(x){256*x^8-3584*x^6+13440*x^4-13440*x^2+1680}  
c.f8[9]<- 256  
c.f8[8]<- 0  
c.f8[7]<- -3584  
c.f8[6]<- 0  
c.f8[5]<- +13440  
c.f8[4]<- 0  
c.f8[3]<- -13440  
c.f8[2]<- 0  
c.f8[1]<- +1680
```

```
f9<-function(x){512*x^9-9216*x^7+48384*x^5-80640*x^3+30240*x}  
c.f9[10]<- 512
```

```

c.f9[9] <- 0
c.f9[8] <- -9216
c.f9[7] <- 0
c.f9[6] <- +48384
c.f9[5] <- 0
c.f9[4] <- -80640
c.f9[3] <- 0
c.f9[2] <- +30240
c.f9[1] <- 0

f10<-function(x){1024*x^10-23040*x^8+161280*x^6-403200*x^4+302400*x^2-30240}
c.f10[11]<- 1024
c.f10[10]<- 0
c.f10[9] <- -23040
c.f10[8] <- 0
c.f10[7] <- +161280
c.f10[6] <- 0
c.f10[5] <- -403200
c.f10[4] <- 0
c.f10[3] <- +302400
c.f10[2] <- 0
c.f10[1] <- -30240

f11<-function(x){2048*x^11-56320*x^9+506880*x^7-1774080*x^5+2217600*x^3-665280*x}
c.f11[12]<- 2048
c.f11[11]<- 0
c.f11[10]<- -56320
c.f11[9] <- 0
c.f11[8] <- +506880
c.f11[7] <- 0
c.f11[6] <- -1774080
c.f11[5] <- 0
c.f11[4] <- +2217600
c.f11[3] <- 0
c.f11[2] <- -665280
c.f11[1] <- 0

f12<-function(x){4096*x^12-135168*x^10+1520640*x^8-7096320*x^6+13305600*x^4-
7983360*x^2+665280}
c.f12[13]<- 4096
c.f12[12]<- 0
c.f12[11]<- -135168
c.f12[10]<- 0
c.f12[9] <- +1520640
c.f12[8] <- 0
c.f12[7] <- -7096320
c.f12[6] <- 0
c.f12[5] <- 13305600
c.f12[4] <- 0
c.f12[3] <- -7983360
c.f12[2] <- 0
c.f12[1] <- +665280

f13<-function(x){8192*x^13-319488*x^11+4392960*x^9-26357760*x^7+69189120*x^5-
69189120*x^3+
17297280*x}
c.f13[14]<- 8192
c.f13[13]<- 0
c.f13[12]<- -319488
c.f13[11]<- 0
c.f13[10]<- +4392960
c.f13[9] <- 0
c.f13[8] <- -26357760
c.f13[7] <- 0
c.f13[6] <- +69189120
c.f13[5] <- 0
c.f13[4] <- -69189120
c.f13[3] <- 0
c.f13[2] <- 17297280
c.f13[1] <- 0

```

```
f14<-function(x){16384*x^14-745472*x^12+12300288*x^10-92252160*x^8+322882560*x^6-
484323840*x^4
+242161920*x^2-17297280}
```

```
c.f14[15]<- 16384
c.f14[14]<- 0
c.f14[13]<- -745472
c.f14[12]<- 0
c.f14[11]<- +12300288
c.f14[10]<- 0
c.f14[9] <- -92252160
c.f14[8] <- 0
c.f14[7] <- +322882560
c.f14[6] <- 0
c.f14[5] <- -484323840
c.f14[4] <- 0
c.f14[3] <- +242161920
c.f14[2] <- 0
c.f14[1] <- -17297280
```

```
f15<-function(x){32768*x^15-1720320*x^13+33546240*x^11-307507200*x^9+1383782400*x^7
-2905943040*x^5+2421619200*x^3-518918400*x}
```

```
c.f15[16]<- 32768
c.f15[15]<- 0
c.f15[14]<- -1720320
c.f15[13]<- 0
c.f15[12]<- +33546240
c.f15[11]<- 0
c.f15[10]<- -307507200
c.f15[9] <- 0
c.f15[8] <- +1383782400
c.f15[7] <- 0
c.f15[6] <- -2905943040
c.f15[5] <- 0
c.f15[4] <- +2421619200
c.f15[3] <- 0
c.f15[2] <- -518918400
c.f15[1] <- 0
```

```
f16<-function(x){65536*x^16-3932160*x^14+89456640*x^12-984023040*x^10+5535129600*x^8
-15498362880*x^6+19372953600*x^4-8302694400*x^2+518918400}
```

```
c.f16[17]<- 65536
c.f16[16]<- 0
c.f16[15]<- -3932160
c.f16[14]<- 0
c.f16[13]<- +89456640
c.f16[12]<- 0
c.f16[11]<- -984023040
c.f16[10]<- 0
c.f16[9] <- +5535129600
c.f16[8] <- 0
c.f16[7] <- -15498362880
c.f16[6] <- 0
c.f16[5] <- +19372953600
c.f16[4] <- 0
c.f16[3] <- -8302694400
c.f16[2] <- 0
c.f16[1] <- +518918400
```

```
f17<-function(x){131072*x^17-8912896*x^15+233963520*x^13-
3041525760*x^11+20910489600*x^9
-75277762560*x^7+131736084480*x^5-94097203200*x^3+17643225600*x}
```

```
c.f17[18]<- 131072
c.f17[17]<- 0
c.f17[16]<- -8912896
c.f17[15]<- 0
```

```
c.f17[14]<- +233963520
c.f17[13]<- 0
c.f17[12]<- -3041525760
c.f17[11]<- 0
c.f17[10]<- +20910489600
c.f17[9] <- 0
c.f17[8] <- -75277762560
c.f17[7] <- 0
c.f17[6] <- +131736084480
c.f17[5] <- 0
c.f17[4] <- -94097203200
c.f17[3] <- 0
c.f17[2] <- +17643225600
c.f17[1] <- 0
```

```
f18<-function(x){262144*x^18-20054016*x^16+601620480*x^14-
9124577280*x^12+75277762560*x^10
-338749931520*x^8+790416506880*x^6-846874828800*x^4+317578060800*x^2-17643225600}
```

```
c.f18[19]<- 262144
c.f18[18]<- 0
c.f18[17]<- -20054016
c.f18[16]<- 0
c.f18[15]<- +601620480
c.f18[14]<- 0
c.f18[13]<- -9124577280
c.f18[12]<- 0
c.f18[11]<- +75277762560
c.f18[10]<- 0
c.f18[9] <- -338749931520
c.f18[8] <- 0
c.f18[7] <- +790416506880
c.f18[6] <- 0
c.f18[5] <- -846874828800
c.f18[4] <- 0
c.f18[3] <- +317578060800
c.f18[2] <- 0
c.f18[1] <- -17643225600
```

```
f19<-function(x){524288*x^19-44826624*x^17+1524105216*x^15-
26671841280*x^13+260050452480*x^11
-1430277488640*x^9+4290832465920*x^7-6436248698880*x^5+4022655436800*x^3-
670442572800*x}
```

```
c.f19[20]<- 524288
c.f19[19]<- 0
c.f19[18]<- -44826624
c.f19[17]<- 0
c.f19[16]<- +1524105216
c.f19[15]<- 0
c.f19[14]<- -26671841280
c.f19[13]<- 0
c.f19[12]<- +260050452480
c.f19[11]<- 0
c.f19[10]<- -1430277488640
c.f19[9] <- 0
c.f19[8] <- +4290832465920
c.f19[7] <- 0
c.f19[6] <- -6436248698880
c.f19[5] <- 0
c.f19[4] <- +4022655436800
c.f19[3] <- 0
c.f19[2] <- -670442572800
c.f19[1] <- 0
```



```
f20<-function(x){1048576*x^20-99614720*x^18+3810263040*x^16-
76205260800*x^14+866834841600*x^12
-5721109954560*x^10+21454162329600*x^8-42908324659200*x^6+40226554368000*x^4-
13408851456000*x^2
+670442572800}
```

```
c.f20[21]<- 1048576
c.f20[20]<- 0
c.f20[19]<- -99614720
c.f20[18]<- 0
c.f20[17]<- +3810263040
c.f20[16]<- 0
c.f20[15]<- -76205260800
c.f20[14]<- 0
c.f20[13]<- +866834841600
c.f20[12]<- 0
c.f20[11]<- -5721109954560
c.f20[10]<- 0
c.f20[9] <- +21454162329600
c.f20[8] <- 0
c.f20[7] <- -42908324659200
c.f20[6] <- 0
c.f20[5] <- +40226554368000
c.f20[4] <- 0
c.f20[3] <- -13408851456000
c.f20[2] <- 0
c.f20[1] <- +670442572800
```

```
f21<-function(x){2097152*x^21-220200960*x^19+9413591040*x^17-
213374730240*x^15+2800543334400*x^13-21844238008320*x^11+100119424204800*x^9-
257449947955200*x^7+337903056691200*x^5-187723920384000*x^3+28158588057600*x}
f22<-function(x){4194304*x^22-484442112*x^20+23011000320*x^18-
586780508160*x^16+8801707622400*x^14-80095539363840*x^12+440525466501120*x^10-
1415974713753600*x^8+2477955749068800*x^6-2064963124224000*x^4+619488937267200*x^2-
28158588057600}
f23<-function(x){8388608*x^23-1061158912*x^21+55710842880*x^19-
1587759022080*x^17+26991903375360*x^15-283414985441280*x^13+1842197405368320*x^11-
7237204092518400*x^9+16283709208166400*x^7-18997660742860800*x^5+9498830371430400*x^3-
1295295050649600*x}
f24<-function(x){16777216*x^24-2315255808*x^22+133706022912*x^20-
4234024058880*x^18+80975710126080*x^16-971708521512960*x^14+7368789621473280*x^12-
34738579644088320*x^10+97702255248998400*x^8-
151981285942886400*x^6+113985964457164800*x^4-31087081215590400*x^2+1295295050649600}
f25<-function(x){64764752532480000*x-11142168576000*x^19+1139859644571648000*x^5-
518118020259840000*x^3+318347673600*x^21-157902634745856000*x^11-
3239028405043200*x^15+542790306938880000*x^9+28341498544128000*x^13-
1085580613877760000*x^7-5033164800*x^23+33554432*x^25+238163853312000*x^17}
f26<-function(x){-684244750565376000*x^12+688028909568000*x^18+752458137600*x^22-
28969638297600*x^20+1683883565844480000*x^2-7056273990205440000*x^8-
6735534263377920000*x^4+9878783586287616000*x^6+105268423163904000*x^14+28225095960821
76000*x^10-10526842316390400*x^16-64764752532480000+67108864*x^26-10905190400*x^24}
f27<-function(x){-3497296636753920000*x+1955450585088000*x^19-
72743770044481536000*x^5+30309904185200640000*x^3-
74493355622400*x^21+13855956198948864000*x^11+134217728*x^27+378966323390054400*x^15-
42337643941232640000*x^9-
2842247425425408000*x^13+76207759094218752000*x^7+1766640844800*x^23-23555211264*x^25-
33438205005004800*x^17}
```

```
f28<-function(x){64661128928428032000*x^12-104029971126681600*x^18-
189619450675200*x^22+5475261638246400*x^20-
97924305829109760000*x^2+533454313659531264000*x^8+424338658592808960000*x^4-
678941853748494336000*x^6-11368989701701632000*x^14-
237090806070902784000*x^10+1326382131865190400*x^16-
50734301184*x^26+268435456*x^28+3497296636753920000+4122161971200*x^24}
f29<-function(x){202843204931727360000*x-
317565175018291200*x^19+4922328439676583936000*x^5-
1893203246029455360000*x^3+15122151191347200*x^21-1250115159282941952000*x^11-
108984795136*x^27-
43960093513246310400*x^15+3437816688028090368000*x^9+288488113680678912000*x^13-
5625518216773238784000*x^7-}
```

```

478170788659200*x^23+536870912*x^29+9563415773184*x^25+4525303744010649600*x^17}

f30<-function(x){-
6250575796414709760000*x^12+15084345813368832000*x^18+41242230521856000*x^22-
952695525054873600*x^20+6085296147951820800000*x^2-42191386625799290880000*x^8-
28398048690441830400000*x^4+49223284396765839360000*x^6+1236377630060052480000*x^14+20
626900128168542208000*x^10-164850350674673664000*x^16+22069421015040*x^26-
233538846720*x^28+1073741824*x^30-202843204931727360000-1195426971648000*x^24}
f31<-function(x){-12576278705767096320000*x+49222602127835136000*x^19-
352135803761478696960000*x^5+125762787057670963200000*x^3-
2812720121590579200*x^21+116260709813313601536000*x^11+50677929738240*x^27+51103608709
14883584000*x^15-290651774533284003840000*x^9-
29810438413670154240000*x^13+2147483648*x^31+435977661799926005760000*x^7+111174708363
264000*x^23-499289948160*x^29-2964658889687040*x^25-601218925989986304000*x^17}

#####Gauss-Hermit Quadrature Calculations#####

bootstrap.iter<-10000
n.O<-3
n.R<-3

n.P<-50

sigma.O0<-0.5
sigma.R00<-0.5
mu0<-2

nqn.O<-10
nqn.R<-10

qw.O<-c()
qw.R<-c()
qn.O<-c()
qn.R<-c()

yik<-matrix(-1,n.O,n.R)

ghqn<-matrix(0.30,30)
ghqw<-matrix(0.30,30)

#### GHQ 2 point

m<-2
ghqn[2.m:1]<- sort(Re(
polyroot(c.f2)))
ghqw[2.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f3(ghqn[2.m:1])^2

# GHQ 3 point

m<-3
ghqn[3.m:1]<- sort(Re(
polyroot(c.f3)))
ghqw[3.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f4(ghqn[3.m:1])^2

#### GHQ 4 point

m<-4
ghqn[4.m:1]<- sort(Re(
polyroot(c.f4)))
ghqw[4.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f5(ghqn[4.m:1])^2

#### GHQ 5 point

m<-5

```

```
ghqn[5.m:1]<- sort (Re (
polyroot (c.f5)))
ghqw[5.m:1]<- 2^(m+1)*factorial (m)*sqrt (pi) /f6 (ghqn[5.m:1])^2
```

GHQ 6 point

```
m<-6
ghqn[6.m:1]<- sort (Re (
polyroot (c.f6)))
ghqw[6.m:1]<- 2^(m+1)*factorial (m)*sqrt (pi) /f7 (ghqn[6.m:1])^2
```

GHQ 7 point

```
m<-7
ghqn[7.m:1]<- sort (Re (
polyroot (c.f7)))
ghqw[7.m:1]<- 2^(m+1)*factorial (m)*sqrt (pi) /f8 (ghqn[7.m:1])^2
```

GHQ 8 point

```
m<-8
ghqn[8.m:1]<- sort (Re (
polyroot (c.f8)))
ghqw[8.m:1]<- 2^(m+1)*factorial (m)*sqrt (pi) /f9 (ghqn[8.m:1])^2
```

GHQ 9 point

```
m<-9
ghqn[9.m:1]<- sort (Re (
polyroot (c.f9)))
ghqw[9.m:1]<- 2^(m+1)*factorial (m)*sqrt (pi) /f10 (ghqn[9.m:1])^2
```

GHQ 10 point

```
m<-10
ghqn[10.m:1]<- sort (Re (
polyroot (c.f10)))
ghqw[10.m:1]<- 2^(m+1)*factorial (m)*sqrt (pi) /f11 (ghqn[10.m:1])^2
```

GHQ 11 point

```
m<-11
ghqn[11.m:1]<- sort (Re (
polyroot (c.f11)))
ghqw[11.m:1]<- 2^(m+1)*factorial (m)*sqrt (pi) /f12 (ghqn[11.m:1])^2
```

GHQ 12 point

```
m<-12
ghqn[12.m:1]<- sort (Re (
polyroot (c.f12)))
ghqw[12.m:1]<- 2^(m+1)*factorial (m)*sqrt (pi) /f13 (ghqn[12.m:1])^2
```

GHQ 13 point

```
m<-13
ghqn[13.m:1]<- sort(Re(
polyroot(c.f13)))
ghqw[13.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f14(ghqn[13.m:1])^2
```

GHQ 14 point

```
m<-14
ghqn[14.m:1]<- sort(Re(
polyroot(c.f14)))
ghqw[14.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f15(ghqn[14.m:1])^2
```

GHQ 15 point

```
m<-15
ghqn[15.m:1]<- sort(Re(
polyroot(c.f15)))
ghqw[15.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f16(ghqn[15.m:1])^2
```

GHQ 16 point

```
m<-16
ghqn[16.m:1]<- sort(Re(
polyroot(c.f16)))
ghqw[16.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f17(ghqn[16.m:1])^2
```

GHQ 17 point

```
m<-17
ghqn[17.m:1]<- sort(Re(
polyroot(c.f17)))
ghqw[17.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f18(ghqn[17.m:1])^2
```

GHQ 18 point

```
m<-18
ghqn[18.m:1]<- sort(Re(
polyroot(c.f18)))
ghqw[18.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f19(ghqn[18.m:1])^2
```

GHQ 19 point

```
m<-19
ghqn[19.m:1]<- sort(Re(
polyroot(c.f19)))
ghqw[19.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f20(ghqn[19.m:1])^2
```

GHQ 20 point

```
m<-20
ghqn[20.m:1]<- sort(Re(
polyroot(c.f20)))
ghqw[20.m:1]<- 2^(m+1)*factorial(m)*sqrt(pi)/f21(ghqn[20.m:1])^2
```

```
##### Substituting from reference quadrature
```

```
for (i in 1:nqn.O) ## for Operator
{
  qn.O[i]<-ghqn[nqn.O,i]
  qw.O[i]<-ghqw[nqn.O,i]
}
```

```
for (i in 1:nqn.R) ## for Parts
{
  qn.R[i]<-ghqn[nqn.R,i]
  qw.R[i]<-ghqw[nqn.R,i]
}
```

```
##### DATA GENERATION SHOULD BE HERE #####
```

```
#### Data Generation #####
```

```
yik<-matrix(c(50.50.48.48.48.43.44.47.44).n.O.n.R)
```

```
#theta<-c(mu0.sigma.O0.sigma.RO0)
marg.lik.rr<-function(theta){
```

```
mu<-theta[1]
```

```
sigma.O<-theta[2]
```

```
sigma.RO<-theta[3]
```

```
##### Creation eta i. k .
leftmat<-matrix(-1.nqn.O.3)
```

```
rightmat<-matrix(-1.3.nqn.R)
```

```
for (i in 1:nqn.O)
```

```
  {
    for (j in 1:3)
```

```
      {
        leftmat[i,j]<-
        c(mu.sqrt(2)*sigma.O*qn.O[i].sqrt(2)*sigma.RO)
      }
    }
```

```
for (i in 1:3)
```

```
  {
    for (j in 1:nqn.R)
      {
        rightmat[j]<-c(1.1.qn.R[j])
      }
    }
```

```
etamat<-leftmat%*%rightmat
```

```
##### Defining Marginal Likelihood #####

unitmat<-matrix(1,n.O,n.R)

etacomp1<-
kronecker(yik.etamat,'')
etacomp2<-kronecker(unitmat,etamat)

etacompstar<-exp(etacomp1)/(1+exp(etacomp2))^n.P

marg.R<-etacompstar%*%matdiag(qw.R,n.R)

product.k<-exp(log(marg.R)%*%rep(1,times=n.R))
product.k.mat<-t(matrix(product.k,nqn.O,n.O))

marg.O<-product.k.mat%*%qw.O
log.marg.lik<-rep(1,times=n.O)%*%
log(marg.O)
return(-1*log.marg.lik)
}

# Bootstrap Confidence Intervals

h0.mu.bre<-c()
h0.sigma0.bre<-c()
h0.sigmaR0.bre<-c()

marg.lik.max<-nlminb(start=c(2.0.0),objective=marg.lik,rr.lower=c(-Inf,0.0))

mu0.bre<-marg.lik.max$parameters[1]
sigma00.bre<-marg.lik.max$parameters[2]+1e-17

sigma.R00.bre<-marg.lik.max$parameters[3]+1e-17

for (b in 1:bootstrap.iter)
{

for (i in 1:n.O)
{

O<-rnorm(1.0,sigma00.bre)

for (k in 1:n.R)
{

sigma.R00.bre)
R<-rnorm(1.0,

muij<-logitinv(mu0.bre+O+R)
yik[i,k]<-rbinom(1,n.P,muij)
}

}

h0fit.bre<-nlminb(start=c(2.0.0),objective=marg.lik,rr.lower=c(-Inf,0.0))
h0.mu.bre[b]<-h0fit.bre$parameters[1]
```

```
h0.sigmaO.bre[b]<-h0fit.bre$parameters[2]  
h0.sigmaRO.bre[b]<-h0fit.bre$parameters[3]
```

```
print(c(b.h0.mu.bre[b],h0.sigmaO.bre[b],h0.sigmaRO.bre[b]))  
}  
print(c(sort(h0.mu.bre)[trunc(bootstrap.iter*10/100)].sort(h0.mu.bre)[trunc(bootstrap.iter*90/100)]))  
  
print(c(sort(h0.sigmaO.bre)[trunc(bootstrap.iter*10/100)].sort(h0.sigmaO.bre)[trunc(bootstrap.iter*90/100)]))  
  
print(c(sort(h0.sigmaRO.bre)[trunc(bootstrap.iter*10/100)].sort(h0.sigmaRO.bre)[trunc(bootstrap.iter*90/100)]))
```

داده هاي راهنماي MSA

RowNames	OPER	REP	RESP	REF
1	1.00	1.00	1.00	1.00
2	1.00	1.00	1.00	1.00
3	1.00	1.00	0.00	0.00
4	1.00	1.00	0.00	0.00
5	1.00	1.00	0.00	0.00
6	1.00	1.00	1.00	1.00
7	1.00	1.00	1.00	1.00
8	1.00	1.00	1.00	1.00
9	1.00	1.00	0.00	0.00
10	1.00	1.00	1.00	1.00
11	1.00	1.00	1.00	1.00
12	1.00	1.00	0.00	0.00
13	1.00	1.00	1.00	1.00
14	1.00	1.00	1.00	1.00
15	1.00	1.00	1.00	1.00
16	1.00	1.00	1.00	1.00
17	1.00	1.00	1.00	1.00
18	1.00	1.00	1.00	1.00
19	1.00	1.00	1.00	1.00
20	1.00	1.00	1.00	1.00
21	1.00	1.00	1.00	1.00
22	1.00	1.00	0.00	0.00
23	1.00	1.00	1.00	1.00
24	1.00	1.00	1.00	1.00
25	1.00	1.00	0.00	0.00
26	1.00	1.00	0.00	0.00
27	1.00	1.00	1.00	1.00
28	1.00	1.00	1.00	1.00
29	1.00	1.00	1.00	1.00
30	1.00	1.00	0.00	0.00
31	1.00	1.00	1.00	1.00
32	1.00	1.00	1.00	1.00
33	1.00	1.00	1.00	1.00
34	1.00	1.00	0.00	0.00
35	1.00	1.00	1.00	1.00
36	1.00	1.00	1.00	1.00
37	1.00	1.00	0.00	0.00
38	1.00	1.00	1.00	1.00
39	1.00	1.00	0.00	0.00
40	1.00	1.00	1.00	1.00
41	1.00	1.00	1.00	1.00

42	1.00	1.00	0.00	0.00
43	1.00	1.00	1.00	1.00
44	1.00	1.00	1.00	1.00
45	1.00	1.00	0.00	0.00
46	1.00	1.00	1.00	1.00
47	1.00	1.00	1.00	1.00
48	1.00	1.00	0.00	0.00
49	1.00	1.00	1.00	1.00
50	1.00	1.00	0.00	0.00
51	1.00	2.00	1.00	1.00
52	1.00	2.00	1.00	1.00
53	1.00	2.00	0.00	0.00
54	1.00	2.00	0.00	0.00
55	1.00	2.00	0.00	0.00
56	1.00	2.00	1.00	1.00
57	1.00	2.00	1.00	1.00
58	1.00	2.00	1.00	1.00
59	1.00	2.00	0.00	0.00
60	1.00	2.00	1.00	1.00
61	1.00	2.00	1.00	1.00
62	1.00	2.00	0.00	0.00
63	1.00	2.00	1.00	1.00
64	1.00	2.00	1.00	1.00
65	1.00	2.00	1.00	1.00
66	1.00	2.00	1.00	1.00
67	1.00	2.00	1.00	1.00
68	1.00	2.00	1.00	1.00
69	1.00	2.00	1.00	1.00
70	1.00	2.00	1.00	1.00
71	1.00	2.00	1.00	1.00
72	1.00	2.00	0.00	0.00
73	1.00	2.00	1.00	1.00
74	1.00	2.00	1.00	1.00
75	1.00	2.00	0.00	0.00
76	1.00	2.00	1.00	0.00
77	1.00	2.00	1.00	1.00
78	1.00	2.00	1.00	1.00
79	1.00	2.00	1.00	1.00
80	1.00	2.00	0.00	0.00
81	1.00	2.00	1.00	1.00
82	1.00	2.00	1.00	1.00
83	1.00	2.00	1.00	1.00
84	1.00	2.00	0.00	0.00
85	1.00	2.00	1.00	1.00
86	1.00	2.00	1.00	1.00
87	1.00	2.00	0.00	0.00
88	1.00	2.00	1.00	1.00
89	1.00	2.00	0.00	0.00

90	1.00	2.00	1.00	1.00
91	1.00	2.00	1.00	1.00
92	1.00	2.00	0.00	0.00
93	1.00	2.00	0.00	1.00
94	1.00	2.00	1.00	1.00
95	1.00	2.00	0.00	0.00
96	1.00	2.00	1.00	1.00
97	1.00	2.00	1.00	1.00
98	1.00	2.00	0.00	0.00
99	1.00	2.00	1.00	1.00
100	1.00	2.00	0.00	0.00
101	1.00	3.00	1.00	1.00
102	1.00	3.00	1.00	1.00
103	1.00	3.00	0.00	0.00
104	1.00	3.00	0.00	0.00
105	1.00	3.00	0.00	0.00
106	1.00	3.00	0.00	1.00
107	1.00	3.00	1.00	1.00
108	1.00	3.00	1.00	1.00
109	1.00	3.00	0.00	0.00
110	1.00	3.00	1.00	1.00
111	1.00	3.00	1.00	1.00
112	1.00	3.00	0.00	0.00
113	1.00	3.00	1.00	1.00
114	1.00	3.00	0.00	1.00
115	1.00	3.00	1.00	1.00
116	1.00	3.00	1.00	1.00
117	1.00	3.00	1.00	1.00
118	1.00	3.00	1.00	1.00
119	1.00	3.00	1.00	1.00
120	1.00	3.00	1.00	1.00
121	1.00	3.00	0.00	1.00
122	1.00	3.00	1.00	0.00
123	1.00	3.00	1.00	1.00
124	1.00	3.00	1.00	1.00
125	1.00	3.00	0.00	0.00
126	1.00	3.00	0.00	0.00
127	1.00	3.00	1.00	1.00
128	1.00	3.00	1.00	1.00
129	1.00	3.00	1.00	1.00
130	1.00	3.00	0.00	0.00
131	1.00	3.00	1.00	1.00
132	1.00	3.00	1.00	1.00
133	1.00	3.00	1.00	1.00
134	1.00	3.00	1.00	0.00
135	1.00	3.00	1.00	1.00
136	1.00	3.00	0.00	1.00
137	1.00	3.00	0.00	0.00

138	1.00	3.00	1.00	1.00
139	1.00	3.00	0.00	0.00
140	1.00	3.00	1.00	1.00
141	1.00	3.00	1.00	1.00
142	1.00	3.00	0.00	0.00
143	1.00	3.00	1.00	1.00
144	1.00	3.00	1.00	1.00
145	1.00	3.00	0.00	0.00
146	1.00	3.00	1.00	1.00
147	1.00	3.00	1.00	1.00
148	1.00	3.00	0.00	0.00
149	1.00	3.00	1.00	1.00
150	1.00	3.00	0.00	0.00
151	2.00	1.00	1.00	1.00
152	2.00	1.00	1.00	1.00
153	2.00	1.00	0.00	0.00
154	2.00	1.00	0.00	0.00
155	2.00	1.00	0.00	0.00
156	2.00	1.00	1.00	1.00
157	2.00	1.00	1.00	1.00
158	2.00	1.00	1.00	1.00
159	2.00	1.00	0.00	0.00
160	2.00	1.00	1.00	1.00
161	2.00	1.00	1.00	1.00
162	2.00	1.00	0.00	0.00
163	2.00	1.00	1.00	1.00
164	2.00	1.00	1.00	1.00
165	2.00	1.00	1.00	1.00
166	2.00	1.00	1.00	1.00
167	2.00	1.00	1.00	1.00
168	2.00	1.00	1.00	1.00
169	2.00	1.00	1.00	1.00
170	2.00	1.00	1.00	1.00
171	2.00	1.00	1.00	1.00
172	2.00	1.00	0.00	0.00
173	2.00	1.00	1.00	1.00
174	2.00	1.00	1.00	1.00
175	2.00	1.00	0.00	0.00
176	2.00	1.00	0.00	0.00
177	2.00	1.00	1.00	1.00
178	2.00	1.00	1.00	1.00
179	2.00	1.00	1.00	1.00
180	2.00	1.00	0.00	0.00
181	2.00	1.00	1.00	1.00
182	2.00	1.00	1.00	1.00
183	2.00	1.00	1.00	1.00
184	2.00	1.00	0.00	0.00
185	2.00	1.00	1.00	1.00

186	2.00	1.00	1.00	1.00
187	2.00	1.00	0.00	0.00
188	2.00	1.00	1.00	1.00
189	2.00	1.00	0.00	0.00
190	2.00	1.00	1.00	1.00
191	2.00	1.00	1.00	1.00
192	2.00	1.00	0.00	0.00
193	2.00	1.00	1.00	1.00
194	2.00	1.00	1.00	1.00
195	2.00	1.00	0.00	0.00
196	2.00	1.00	1.00	1.00
197	2.00	1.00	1.00	1.00
198	2.00	1.00	0.00	0.00
199	2.00	1.00	1.00	1.00
200	2.00	1.00	0.00	0.00
201	2.00	2.00	1.00	1.00
202	2.00	2.00	1.00	1.00
203	2.00	2.00	0.00	0.00
204	2.00	2.00	0.00	0.00
205	2.00	2.00	0.00	0.00
206	2.00	2.00	1.00	1.00
207	2.00	2.00	1.00	1.00
208	2.00	2.00	1.00	1.00
209	2.00	2.00	0.00	0.00
210	2.00	2.00	1.00	1.00
211	2.00	2.00	1.00	1.00
212	2.00	2.00	0.00	0.00
213	2.00	2.00	1.00	1.00
214	2.00	2.00	1.00	1.00
215	2.00	2.00	1.00	1.00
216	2.00	2.00	1.00	1.00
217	2.00	2.00	1.00	1.00
218	2.00	2.00	1.00	1.00
219	2.00	2.00	1.00	1.00
220	2.00	2.00	1.00	1.00
221	2.00	2.00	0.00	1.00
222	2.00	2.00	1.00	0.00
223	2.00	2.00	1.00	1.00
224	2.00	2.00	1.00	1.00
225	2.00	2.00	0.00	0.00
226	2.00	2.00	0.00	0.00
227	2.00	2.00	1.00	1.00
228	2.00	2.00	1.00	1.00
229	2.00	2.00	1.00	1.00
230	2.00	2.00	0.00	0.00
231	2.00	2.00	1.00	1.00
232	2.00	2.00	1.00	1.00
233	2.00	2.00	1.00	1.00

234	2.00	2.00	0.00	0.00
235	2.00	2.00	1.00	1.00
236	2.00	2.00	1.00	1.00
237	2.00	2.00	0.00	0.00
238	2.00	2.00	1.00	1.00
239	2.00	2.00	0.00	0.00
240	2.00	2.00	1.00	1.00
241	2.00	2.00	1.00	1.00
242	2.00	2.00	0.00	0.00
243	2.00	2.00	1.00	1.00
244	2.00	2.00	1.00	1.00
245	2.00	2.00	0.00	0.00
246	2.00	2.00	1.00	1.00
247	2.00	2.00	1.00	1.00
248	2.00	2.00	0.00	0.00
249	2.00	2.00	1.00	1.00
250	2.00	2.00	0.00	0.00
251	2.00	3.00	1.00	1.00
252	2.00	3.00	1.00	1.00
253	2.00	3.00	0.00	0.00
254	2.00	3.00	0.00	0.00
255	2.00	3.00	0.00	0.00
256	2.00	3.00	0.00	1.00
257	2.00	3.00	1.00	1.00
258	2.00	3.00	1.00	1.00
259	2.00	3.00	0.00	0.00
260	2.00	3.00	1.00	1.00
261	2.00	3.00	1.00	1.00
262	2.00	3.00	0.00	0.00
263	2.00	3.00	1.00	1.00
264	2.00	3.00	1.00	1.00
265	2.00	3.00	1.00	1.00
266	2.00	3.00	1.00	1.00
267	2.00	3.00	1.00	1.00
268	2.00	3.00	1.00	1.00
269	2.00	3.00	1.00	1.00
270	2.00	3.00	1.00	1.00
271	2.00	3.00	1.00	1.00
272	2.00	3.00	0.00	0.00
273	2.00	3.00	1.00	1.00
274	2.00	3.00	1.00	1.00
275	2.00	3.00	0.00	0.00
276	2.00	3.00	0.00	0.00
277	2.00	3.00	1.00	1.00
278	2.00	3.00	1.00	1.00
279	2.00	3.00	1.00	1.00
280	2.00	3.00	1.00	0.00
281	2.00	3.00	1.00	1.00

282	2.00	3.00	1.00	1.00
283	2.00	3.00	1.00	1.00
284	2.00	3.00	1.00	0.00
285	2.00	3.00	1.00	1.00
286	2.00	3.00	1.00	1.00
287	2.00	3.00	0.00	0.00
288	2.00	3.00	1.00	1.00
289	2.00	3.00	0.00	0.00
290	2.00	3.00	1.00	1.00
291	2.00	3.00	1.00	1.00
292	2.00	3.00	0.00	0.00
293	2.00	3.00	1.00	1.00
294	2.00	3.00	1.00	1.00
295	2.00	3.00	0.00	0.00
296	2.00	3.00	1.00	1.00
297	2.00	3.00	1.00	1.00
298	2.00	3.00	0.00	0.00
299	2.00	3.00	1.00	1.00
300	2.00	3.00	0.00	0.00
301	3.00	1.00	1.00	1.00
302	3.00	1.00	1.00	1.00
303	3.00	1.00	0.00	0.00
304	3.00	1.00	0.00	0.00
305	3.00	1.00	0.00	0.00
306	3.00	1.00	1.00	1.00
307	3.00	1.00	1.00	1.00
308	3.00	1.00	1.00	1.00
309	3.00	1.00	0.00	0.00
310	3.00	1.00	1.00	1.00
311	3.00	1.00	1.00	1.00
312	3.00	1.00	0.00	0.00
313	3.00	1.00	1.00	1.00
314	3.00	1.00	1.00	1.00
315	3.00	1.00	1.00	1.00
316	3.00	1.00	1.00	1.00
317	3.00	1.00	1.00	1.00
318	3.00	1.00	1.00	1.00
319	3.00	1.00	1.00	1.00
320	3.00	1.00	1.00	1.00
321	3.00	1.00	0.00	1.00
322	3.00	1.00	1.00	0.00
323	3.00	1.00	1.00	1.00
324	3.00	1.00	1.00	1.00
325	3.00	1.00	0.00	0.00
326	3.00	1.00	0.00	0.00
327	3.00	1.00	1.00	1.00
328	3.00	1.00	1.00	1.00
329	3.00	1.00	1.00	1.00

330	3.00	1.00	0.00	0.00
331	3.00	1.00	1.00	1.00
332	3.00	1.00	1.00	1.00
333	3.00	1.00	1.00	1.00
334	3.00	1.00	0.00	0.00
335	3.00	1.00	1.00	1.00
336	3.00	1.00	1.00	1.00
337	3.00	1.00	0.00	0.00
338	3.00	1.00	1.00	1.00
339	3.00	1.00	0.00	0.00
340	3.00	1.00	1.00	1.00
341	3.00	1.00	1.00	1.00
342	3.00	1.00	0.00	0.00
343	3.00	1.00	1.00	1.00
344	3.00	1.00	1.00	1.00
345	3.00	1.00	0.00	0.00
346	3.00	1.00	1.00	1.00
347	3.00	1.00	1.00	1.00
348	3.00	1.00	0.00	0.00
349	3.00	1.00	1.00	1.00
350	3.00	1.00	0.00	0.00
351	3.00	2.00	1.00	1.00
352	3.00	2.00	1.00	1.00
353	3.00	2.00	0.00	0.00
354	3.00	2.00	0.00	0.00
355	3.00	2.00	0.00	0.00
356	3.00	2.00	0.00	1.00
357	3.00	2.00	0.00	1.00
358	3.00	2.00	1.00	1.00
359	3.00	2.00	0.00	0.00
360	3.00	2.00	1.00	1.00
361	3.00	2.00	1.00	1.00
362	3.00	2.00	1.00	0.00
363	3.00	2.00	1.00	1.00
364	3.00	2.00	0.00	1.00
365	3.00	2.00	1.00	1.00
366	3.00	2.00	1.00	1.00
367	3.00	2.00	1.00	1.00
368	3.00	2.00	1.00	1.00
369	3.00	2.00	1.00	1.00
370	3.00	2.00	1.00	1.00
371	3.00	2.00	1.00	1.00
372	3.00	2.00	1.00	0.00
373	3.00	2.00	1.00	1.00
374	3.00	2.00	1.00	1.00
375	3.00	2.00	0.00	0.00
376	3.00	2.00	0.00	0.00
377	3.00	2.00	1.00	1.00

378	3.00	2.00	1.00	1.00
379	3.00	2.00	1.00	1.00
380	3.00	2.00	0.00	0.00
381	3.00	2.00	1.00	1.00
382	3.00	2.00	1.00	1.00
383	3.00	2.00	1.00	1.00
384	3.00	2.00	1.00	0.00
385	3.00	2.00	1.00	1.00
386	3.00	2.00	0.00	1.00
387	3.00	2.00	0.00	0.00
388	3.00	2.00	1.00	1.00
389	3.00	2.00	0.00	0.00
390	3.00	2.00	1.00	1.00
391	3.00	2.00	1.00	1.00
392	3.00	2.00	0.00	0.00
393	3.00	2.00	1.00	1.00
394	3.00	2.00	1.00	1.00
395	3.00	2.00	0.00	0.00
396	3.00	2.00	1.00	1.00
397	3.00	2.00	1.00	1.00
398	3.00	2.00	0.00	0.00
399	3.00	2.00	1.00	1.00
400	3.00	2.00	0.00	0.00
401	3.00	3.00	1.00	1.00
402	3.00	3.00	1.00	1.00
403	3.00	3.00	0.00	0.00
404	3.00	3.00	0.00	0.00
405	3.00	3.00	0.00	0.00
406	3.00	3.00	0.00	1.00
407	3.00	3.00	1.00	1.00
408	3.00	3.00	1.00	1.00
409	3.00	3.00	0.00	0.00
410	3.00	3.00	1.00	1.00
411	3.00	3.00	1.00	1.00
412	3.00	3.00	0.00	0.00
413	3.00	3.00	1.00	1.00
414	3.00	3.00	0.00	1.00
415	3.00	3.00	1.00	1.00
416	3.00	3.00	1.00	1.00
417	3.00	3.00	1.00	1.00
418	3.00	3.00	1.00	1.00
419	3.00	3.00	1.00	1.00
420	3.00	3.00	1.00	1.00
421	3.00	3.00	0.00	1.00
422	3.00	3.00	0.00	0.00
423	3.00	3.00	1.00	1.00
424	3.00	3.00	1.00	1.00
425	3.00	3.00	0.00	0.00

426	3.00	3.00	1.00	0.00
427	3.00	3.00	1.00	1.00
428	3.00	3.00	1.00	1.00
429	3.00	3.00	1.00	1.00
430	3.00	3.00	0.00	0.00
431	3.00	3.00	1.00	1.00
432	3.00	3.00	1.00	1.00
433	3.00	3.00	1.00	1.00
434	3.00	3.00	1.00	0.00
435	3.00	3.00	1.00	1.00
436	3.00	3.00	1.00	1.00
437	3.00	3.00	0.00	0.00
438	3.00	3.00	1.00	1.00
439	3.00	3.00	0.00	0.00
440	3.00	3.00	1.00	1.00
441	3.00	3.00	1.00	1.00
442	3.00	3.00	0.00	0.00
443	3.00	3.00	0.00	1.00
444	3.00	3.00	1.00	1.00
445	3.00	3.00	0.00	0.00
446	3.00	3.00	1.00	1.00
447	3.00	3.00	1.00	1.00
448	3.00	3.00	0.00	0.00
449	3.00	3.00	1.00	1.00
450	3.00	3.00	0.00	0.00

منابع

- 1) Abramowitz , M. and Stegun Eds. (1965) "Handbook of Mathematical Functions" Dover , New York.
- 2) Agresti , A. (1990) "Categorical Data Analysis" Wiley , New York.
- 3) Agresti , A. and Lang , J.B. "Quasi Symmetry Latent Class Models with Application to Rater Agreement" Biometrics , 49 , 131-139
- 4) Agresti , A. (1996) "An Introduction to Categorical Data Analysis" Wiley , New York.
- 5) Aitkin , M. (1999) "A General Maximum Likelihood Analysis of Variance Components in Generalized Linear Models" Biometrics , 55 , 117-128.
- 6) Akaike M. (1973) "Information Theory and Extension of the Maximum Likelihood Principle" in Second International Symposium on Information Theory , Eds. B.N.Petrox and F. Caski , Butapest , Akademia Kiado , 267.
- 7) Akaike , M. (1977) "On Entropy Maximization Principle" in Application of Statistics , Eds. P.R.Krishnaiah , Amesterdam , North-Holland , 27-41.
- 8) Akaike , M. (1983) "Information Measures and Model Selection" Bulltain of the International Statistical Institute , 50 , 277-290.
- 9) Andersen , E.B. (1991) "The Statistical Analysis of Categorical Data" Springer , Heidelberg , Germany.
- 10) Anderson , D.A. and Aitkin , M. (1985) "Variance

- Componen Models with Binary Response: Interviewer Variability" Journal of Royal Statistical Association , B , 47 , 2 , 203-210.
- 11) Automitive Industry Action Group (2002) "Measurement Systems Analysis Reference Manual" 3rd Ed. Detroit , MI.
 - 12) Bazarraa , M.S. , Hanif , D.S. and Shetty , C.M. (1993) "Nonlinear Programming : Theory and Algorithms" 2nd Ed. , Wiley , New York.
 - 13) Berger , J.O. (1985) "Decision Thoery and Bayesian Analysis" Springer , New York.
 - 14) Bernardo , J. (1979) "Reference Posterior Distributions for Bayesian Inference " , Journal of Royal Statistical Society , B , 41 , 113-147.
 - 15) Bernardo , J. (1997) "Noninformative Priors Do not Exist" Journal of Planning and Inference , 65 , 159-189.
 - 16) Bhatt , B.R. and Nagnur , B.N. (1965) "Locally Asymptotically Most Stringent Tests and Lagrangian Multiplier Tests for Linear Hypothesis" Biometrika 53 , 459-468.
 - 17) Boyles , R.A. (2001) "Gauge Capability for Pass-Fail Inspection" Technometrics , 29 , 223-229.
 - 18) Breslow , N. E. and Lin , X. (1995) "Bias Correction in Generalized Linear Mixed Models with a Singlge Comonent of Dispersion" Biometrika , 82 , 81-91.
 - 19) Breslow , N. E. and Clyton , D.G. (1993) "Approximate Inference in Generalized Linear Mixed Models" Journal of the American Statistical Association , 88 , 9-25.
 - 20) Brovkov , A.A. (1998) "Mathematical Statistics" Gordon and Breach , Australia.

- 21) Burdick, R.K., Borror, C.M. and Montgomery, D.C.
"A Review of Methods for Measurement Systems Capability Analysis" Journal of Quality Technology, 35, 4, 342-354.
- 22) Cantoni, E. and Rocchetti, E. (2001) "Robust Inference for Generalized Linear Models" Journal of the American Statistical Association, 96, 1022-1030.
- 23) Cantoni, E. (2003) "Robust Inference Based on Quasi Likelihoods for Generalized Linear Models and Longitudinal Data" in Developments in Robust Statistics, R.Dutter, P. Filzmoser, U. Gather and P.J. Rosseeuw Eds., Springer, Heidelberg, Germany.
- 24) Carlin, B.P. and Louis, T.A. (2000) "Bayes and Empirical Bayes Methods for Data Analysis" 2nd Ed. CRC Press, New York.
- 25) Charnes, E.L.F. and Yu, P.L. (1976) "Equivalence of Generalized Least Squares and Maximum Likelihood Estimates in the Exponential Family" Journal of the American Statistical Association, 71, 169-171.
- 26) Chung, K.L. (1974) "Probability Theory" Academic Press, New York.
- 27) Cohen, J. (1960) "A Coefficient of Agreement for Nominal Scales" Educational Psychology Measurement, 20, 37-46.
- 28) Cressie, N.A.C. and Read, T.R.C. "Goodness of Fit Statistics for Discrete Multivariate Data" Springer, New York.
- 29) Davies, R.B. (1987) "Masspoint Method for Dealing with Nuisance Parameters in Longitudinal Studies" in Longitudinal Data Analysis, R. Crouchley Ed., 88-109.
- 30) Dempster, A.P., Laird, N.M. and Rubin, D.B.
(1977) "Maximum Likelihood from Incomplete Data via EM

- Algorithm" Journal of the American Statistical Association ,
72 , 1-38.
- 31) Diggle , P.K. , Liang , K.Y. and Zeger , S.L. "Analysis of Longitudinal Data" Oxford , UK.
 - 32) Efron , B. and Tibshirani , R.J. (1993) "An Introduction to the Bootstrap" Chapman and Hall.
 - 33) Efron , B. (1979) "Bootstrap: Another Look at the Jackknife" Annals of Statistics , 7 , 1-26.
 - 34) Everitt (1968) "Moments of Statistics Kappa and Weighted Kappa" British Journal of Mathematical Statistics Psychology , 21 , 97-103.
 - 35) Findly , D.F. (1991) "Counterexamples to Parsimony and BIC" Annals of the Institute of Mathematical Statistics , 43 , 505-514.
 - 36) Fleiss (1981) "Statistical Methods for Rates and Proportions" Wiley , New York.
 - 37) Fort (1948) "Finite Differences and Difference Equations in the Real Domain" Oxford University Press, Fair Lawn, W.E.
 - 38) Fotouhi , A.R. (2003) "Comparison of Estimation Procedures for Nonlinear Multilevel Models" Journal of Statistical Software , 10 , 8.
 - 39) Godambe , V.P. and Heyde C.C. "Quasi Likelihood and Optimal Estimation" International Statistical Review , 55 , 231-244.
 - 40) Godambe , V.P. and Thompson , M.E. (1984) "Robust Estimation through Estimating Equations" Biometrika , 71 , 115-125.

- 41) Godambe, V.P. (2002) "Estimation of Median: Quasi Likelihood and Optimum Estimating Functions" To Appear.
- 42) Goldstein, H.(1986) "Multilevel Mixed Linear Models Analysis using Iterative Generalized Least Squares" *Biometrika*, 78, 43-56.
- 43) Goldstein, H. (1989) "Restricted Unbiased Iterative Generalized Least Squares" *Biometrika*, 76, 622-623.
- 44) Goldstein, H. (1995) "Multilevel Statistical Models"
- 45) Goldstein, H. (1991) "Nonlinear Multilevel Models with an Application to Discrete Response Data" *Biometrika*, 78, 45-51
- 46) Goldstein, H. and Rasbash, J. (1996) "Improved Approximations for Multilevel Models with Binary Responses" *Journal of Royal Statistical Society, A*, 3, 505-513.
- 47) Gwet, K.(2001) "Handbook of Interrater Agreement" Stataxis Consulting, Gaithersburg, MD.
- 48) Gwet, K. (2002) "Kappa Statistic is not Satisfactory for Assessing Extent of Agreement Between Raters" *Statistical Methods for Interrater Reliability Assessment*, No. 1, Stataxis Consulting, Gaithersburg, MD.
- 49) Hastings, W.K.(1970) "Monte Carlo Sampling Methods and Their Applications" *Biometrika*, 51, 1, 97-109.
- 50) Hartford, A. and Davidian, M. (2000)"Consequences of Misspecifying Assumptions in Nonlinear Mixed Effects Models" *Computational Statistics and Data Analysis*, 34, 139-164.
- 51) Heckman, J. and Singer, B. (1984) "A Method for Minimizing the Impact of Distributional Assumptions in Econometric Models for Duration Data" *Econometrica* 52, 2,

271-320.

- 52) Hildebrand, F.B. (1988) "Introduction to Numerical Analysis" McGraw Hill, India.
- 53) Jerffreys, H. (1961) "Theory of Probability" 3rd Ed., Oxford, UK.
- 54) Jung, S.H. (1996) "Quasi Likelihood for Median Regression Models" Journal of the American Statistical Association, 91, 251-257.
- 55) Kass, R.E. and Raftery, A.E. (1995) "Bayes Factors" Journal of the American Statistical Association, 90, 773-795.
- 56) Katz, R.W. (1981) "On Some Criteria for Estimating the Order of a Markov Chain" Technometrics, 23, 243-249.
- 57) Kendall, M. and Stuart, A. (1979) "Advanced Theory of Statistics" Vol. 2, Griffin, London.
- 58) Kendall, M. and Stuart, A. (1979) "Advanced Theory of Statistics" Vol. 1, Griffin, London.
- 59) Laird, N.M. and Ware, J.H. (1982) "Random Effects Models for Longitudinal Data" Biometrics, 38, 963-974.
- 60) Laird, N. (1978) "Nonparametric Maximum Likelihood Estimation of a Mixing Distribution" Journal of the American Statistical Association, 73, 805-811.
- 61) Landis, J.R. and Koch, G.G. (1977) "The Measurement of Observer Agreement for Categorical Data" Biometrics, 33, 159-174.
- 62) Lehman, E.L. (1986) "Testing Statistical Hypotheses" Wiley, New York.
- 63) Lehman, E.L. (1984) "Theory of Point Estimation"

Springer, New York.

- 64) Lesaffre, E. and Spiessens, B. (2000) "On the Effect of Number of Quadrature Points in a Logistic Random Effects Model: An Example" *Applied Statistics*, 50, 3, 325-335.
- 65) Lin, X. (1997) "Variance Component Testing in Generalized Linear Models with Random Effects" *Biometrika*, 84, 2, 309-326.
- 66) Lin, X. and Breslow, N. (1996) "Bias Correction in Generalized Linear Mixed Models with Multiple Components of Dispersion" *Journal of the American Statistical Association*, 91, 1007-1017.
- 67) Lindstorm, M.J. and Bates, D.M. (1990) "Nonlinear Mixed Effects Models for Repeated Measures Data" *Biometrics*, 46, 673-687.
- 68) Linhart, H. and Zuncchini (1986) "Model Selection" John Wiley, New York.
- 69) Liu, Q. and Pierce, D.A. (1994) "A Note on Gauss-Hermit Quadrature" *Biometrika*, 81, 3, 624-629.
- 70) Longford, N.T. (1987) "A Fast Scoring Algorithm for Maximum Likelihood Estimation in Unbalanced Mixed Models with Nested Random Effects" *Biometrika*, 74, 817-827.
- 71) Louis, T.A., DerSimonian, R. (1982) "Health Statistics Based on Discrete Population Groups" in *Regional Variations in Hospital Use*, D. Rothberg Ed. Heath and Co, Boston.
- 72) McCullagh, G. (1997) "Maximum Likelihood Algorithms for Generalized Linear Mixed Models" *Journal of the American Statistical Association*, 92, 162-170.
- 73) McCullagh, C.E. and Nelder, J.A. (1989) "Generalized Linear Models" Chapman and Hall.

- 74) McCullagh, C.E. (2000) "Generalized Linear Models" Journal of the American Statistical Association, 95, 1320-1324.
- 75) Miller (1977) "Asymptotic Properties of Maximum Likelihood Estimates in the Mixed Model of Analysis of Variance" Annals of Statistics 5, 746-762.
- 76) Montgomery, D.C. and Runger, G.C. "Gauge Capability and Designed Experiments Part I" Quality Engineering 6, 115-135.
- 77) Montgomery, D.C. and Runger, G.C. "Gauge Capability and Designed Experiments Part II" Quality Engineering 6, 289-305.
- 78) Montgomery, D.C., Peck, E. and Vining, G.G. (2001) "Introduction to Linear Regression Analysis" Wiley, New York.
- 79) Morris, C.N. (1983) "Parametric Empirical Bayes Inference : Theory and Applications" Journal of the American Statistical Association, 78, 47-65.
- 80) Myers, H. Montgomery, D.C. and Vining, G.G. (2002) "Generalized Linear Models with Applications in Engineering and Sciences" Wiley, New York.
- 81) Nelder, J.A. and Wedderburn, R.W.M. (1972) "Generalized Linear Models" Journal of Royal Statistical Society A, 135, 370-384.
- 82) Pinheiro, J.C. and Bates, D.M. (2000) "Mixed Effects Models in S and S-Plus" Springer, New York.
- 83) Rabe-Hesketh, S., Skrondal, A. and Pickles, A. (2002) "Reliable Estimation of Generalised Linear Mixed Models using Adaptive Quadrature" The Stata Journal, 2, 1-21.

- 84) Rao, P.S.R.S. (1997) "Variance Components: Mixed Models, Methodologies and Applications" Chapman and Hall, London.
- 85) Robinson, G.K. (1991) "That BLUP is a Good Thing" Statistical Science, 6, 15-51.
- 86) Rodriguez, G. and Goldman, N. (1995) "An Assessment of Estimation Procedures for Multilevel Models with Binary Response" Journal of Royal Statistical Society A, 1, 73-89.
- 87) Rohatgi, V.K. and Saleh, E. (2000) "An Introduction to Probability and Statistics" Wiley, New York.
- 88) Schwarz, G. (1978) "Estimating the Dimension of the Model" The Annals of Statistics, 6, 461-464.
- 89) Scott, W.A. (1955) "Reliability of Content Analysis: The Case of Nominal Scale Coding" Public Opinion Quart., 19, 321-325.
- 90) Searle, S.R., Casella, G. and McCullagh, C.E. "Variance Components" Wiley, New York.
- 91) Self, S.G. Liang K.Y. (1987) "Asymptotic Properties of Maximum Likelihood Estimators and Likelihood Ratio Tests under Nonstandard Conditions" Journal of the American Statistical Association 82, 605-610.
- 92) Shibata, R. (1976) "Selection of the Order of an Autoregressive Model by Akaike's Information Criterion" Biometrika, 63, 117-126.
- 93) Thompson, J. (2001) "Simulation: A Modeler's Approach" Wiley, New York.
- 94) Verbeke, G. and Lesaffre, E. (1997) "The Effect of Misspecifying the Random Effects Distribution in Linear

Mixed Models for Longitudinal Data” 23 , 541-556.

- 95) Verbeke , G. , and Molenberghs , G. “Linear Mixed Models in Practice” Lecture Notes in Statistics , No. 126 , Springer , New York.
- 96) Vermunt , J.K. (2003) “An Expectation-Maximization Algorithm for Generalised Linear Three Level Models” Multilevel Newsletter , 14 , 2 , 3-12.
- 97) Wedderburn , R.W.M. (1974) “Quasi Likelihood , Generalized Linear Models and Gauss-Newton Method” Biometrika , 61 , 3 , 439-447.
- 98) Wilks , S.S. (1963) “Mathematical Statistics” Wiley , New York.
- 99) Wolfinger , R.D. and Lin , X. “Two Taylor Series Approximation Methods for Nonlinear Mixed Models” Computational Statistics and Data Analysis , 25 , 465-490.